

Data & Apprentissage

—
Le 18 novembre 2019
—

EXAMEN - 45 MINUTES
—

Le sujet est imprimé sur 1 page
—

Les documents et notes de cours ainsi que les supports numériques (PCs, tablettes, téléphones portables) sont interdits.

Restitution du cours

Répondre aux questions suivantes en maximum 5-10 lignes par question.

1. Quelle est la différence entre l'apprentissage supervisé et non supervisé ?
Donnez deux exemples de problèmes de chaque type.
2. Quelle est la différence entre les données de type classification et celles de type régression ?
3. Quelles décisions peuvent être prises grâce au modèle de régression logistique ?
4. Décrire le modèle de régression logistique et expliquer comment l'utiliser pour un problème de classification ?
5. Quels sont les paramètres des algorithmes par arbres de décision ?
Donner un exemple graphique en 2D, où les classes sont séparables, et la classification par arbres n'est pas efficace.
6. Expliquer brièvement les deux principes clés de la classification de type SVM.
Est-ce qu'il est possible de les utiliser en régression ?
7. Comment valider le choix du nombre de clusters dans les méthodes de clustering ?
8. Qu'est-ce que l'erreur de généralisation et quelle est sa relation avec le phénomène d'overfitting. Ces concepts sont-ils pertinents pour le clustering ?
9. Vous avez $N = N_1 + N_2 = 1000$ observations de deux classes avec des étiquettes connues, où $N_1 = 700$ et $N_2 = 300$. Décrivez comment vous les utiliseriez exactement pour mesurer la performance de classification d'une méthode avec :
a) train-test split, b) k-fold cross validation.
10. Expliquer l'intérêt des méthodes d'apprentissage dans le domaine du calcul intensif.