

Data & Apprentissage

—
Le 16 novembre 2020 à 10h30
—

EXAMEN DISTANCIEL - DURÉE 1H30
—

Le sujet est sur 3 pages
—

A. Restitution du cours

Répondre aux questions suivantes en 5-10 lignes par question.

1. En quoi consiste le compromis "biais"- "variance" en apprentissage automatique ?
2. Décrire le modèle de régression logistique. Décrire ces deux utilisations possibles pour la prédiction ?
3. Rappeler le principe des arbres de décision (représentation, construction, décision en classification ou régression). Quels sont les hyperparamètres de ces algorithmes ? Comment les calibrer ?
4. Rappeler les principes des algorithmes de type Support Vector Machines (SVM).
5. Comment valider le choix du nombre de clusters dans les méthodes de clustering ?
6. Quelle est la différence fondamentale entre l'apprentissage profond et l'apprentissage peu profond ?

B. Problème : Etude de cas "smart city"

On considère le problème de la modélisation de la consommation d'énergie de différents sites dans une zone urbaine et celui de la prédiction des pics de consommation. Les données proviennent de 40 sites de consommation. On dispose de deux fichiers de données dont un extrait est fourni ci-dessous.

Fichier **sites** : Table descriptive des sites

Chaque ligne correspond à un site caractérisé par son code NAF ainsi que la période d'enregistrement :

ID	NAF	NAF code	Data collected from	To
string Text	string Text	string Text	string Text	string Date (unparsed)
ID01	20.59Z	Chemical industry	1/1/11	7/25/12
ID18	55.10Z	Hotels	1/1/11	11/28/12
ID31	55.10Z	Hotels	1/1/11	10/28/12

Fichier **data** : Table des mesures de consommation et des températures

Chaque ligne correspond à une mesure de la consommation moyenne sur une fenêtre temporelle de dix minutes ainsi qu'une indication de la température extérieure en degrés Celsius :

DATE_LOCAL	ID01	ID18	ID31	consomation	temperature
string Date (unparsed)	string Integer	string Integer	string Integer	string Integer	string Decimal (comma)
01/01/2011 00:00	1	0	0	4314	-2,5
01/01/2011 00:00	0	1	0	39	1,1
01/01/2011 00:00	0	0	1	93	5
01/01/2011 00:10	1	0	0	4295	-2,5
01/01/2011 00:10	0	1	0	45	1,1
01/01/2011 00:10	0	0	1	100	5
01/01/2011 00:20	1	0	0	4346	-2,5
01/01/2011 00:20	0	1	0	32	1,1
01/01/2011 00:20	0	0	1	84	5
01/01/2011 00:30	1	0	0	4379	-2,5
01/01/2011 00:30	0	1	0	47	1,1
01/01/2011 00:30	0	0	1	82	5

A titre d'illustration de ces données, on présente une visualisation sur un échantillon de trois sites parmi les quarante présents dans la base de données :



Question posée : proposer une méthodologie permettant de déployer un modèle prédictif des pics de consommation pour chaque site.

En particulier, il s'agira de :

1. décrire la pipeline de science des données à mettre en place
2. détailler la constitution d'une base d'apprentissage dans le cas supervisé et/ou non supervisé
3. préciser les éléments clés pour le développement d'un modèle d'apprentissage en donnant des exemples concrets d'algorithmes pouvant être utilisés dans le cas présent
4. proposer un protocole pour l'évaluation de la qualité du modèle prédictif développé
5. énumérer les points d'attention sur un tel modèle prédictif compte tenu de la dimension temporelle présente dans les données.

