CoderUJB: An Executable and Unified Java Benchmark for Practical Programming Scenarios

Présentation d'article – ISSTA 2024

Présenté par

Wei WEI Hao QIAN Jianye SHI

Xiang BIAN Zijie Fang Yupan Huang

Master CHPS – UVSQ
EDP

Article de Zhengran Zeng, Yidong Wang, Rui Xie, Wei Ye et Shikun Zhang

Sommaire

1. Contexte de la recherche

2. Contributions et méthode

3. Résultats : contexte et modèles

4. Résultats : effets de l'entraînement

5. Limites de l'étude

6. Critique et conclusion

1. Contexte de la recherche

Wei WEI

Comment évaluer une IA qui code ?

Un code qui semble correct
peut échouer à l'exécution.

CODE + TESTS

Benchmark : des tâches et des règles communes

Un exercice isolé a ses limites

HUMANEVAL

164 exercices Python

- Une fonction isolée
- Vérification par des tests

DANS UN VRAI PROJET

Du code déjà présent

- D'autres fichiers
- Des bibliothèques à utiliser

Développer, c'est faire plusieurs tâches

Écrire **Tester** **Détecter** **Corriger**

Une seule tâche donne une vision limitée.

CodeXGLUE : ressemblance entre les textes
XCodeEval : problèmes de concours

Le besoin : une évaluation plus réaliste

01	**Exécuter**	Vérifier le fonctionnement
02	**Vrais projets**	Code et environnement
03	**Plusieurs tâches**	Des capacités variées

CoderUJB : un benchmark Java pour des situations réelles

2. Contributions et méthode

Hao QIAN

Un benchmark commun pour cinq tâches

2 239	17	5
questions	projets Java	tâches

Source commune : Defects4J. Un benchmark et une étude comparative.

Les cinq tâches de CoderUJB

Tâche	**Action demandée**	**Questions**
FCG	Compléter une fonction	238
CTG	Créer un test à partir du code	140
ITG	Reproduire un bug signalé	451
APR	Corriger une fonction	470
DD	Détecter un bug : oui / non	940

Total : 2 239 questions. DD comprend 470 versions défectueuses et 470 versions corrigées.

Du projet à la réponse du modèle

Sélection

- Extraction, filtres et contrôle manuel

Prompt

- Consigne et contexte adaptés à la tâche

Évaluation

- Solutions replacées dans le projet

Projet complet disponible $\neq$ projet complet envoyé dans chaque prompt.

Des critères adaptés à chaque tâche

Génération

- 20 propositions par question ; pass-all@1 et pass-all@10

Tests de bugs

- Échec sur la version défectueuse, succès après correction

Détection

- Accuracy : proportion de classifications correctes

Syntaxe correcte, compilation et réussite des tests sont des étapes différentes.

3. Résultats : contexte et modèles

Jianye SHI

Le contexte aide la génération

Prompt	**FCG : pass-all@1**
Un exemple	12,84 %
Quatre exemples	14,50 %
Contexte du projet	21,91 %

CodeLlama-13B. Comparaison de prompts ; deux modèles étudiés dans RQ1.

Le classement dépend de la tâche

Modèle	**FCG**	**APR**
CodeLlama-34B	22,82 %	5,01 %
GPT-3.5-Turbo	23,37 %	9,31 %
GPT-4	30,52 %	18,76 %

Même indicateur : pass-all@1. Versions étudiées : GPT-3.5-Turbo-0301 et GPT-4-0314.

Des difficultés au-delà du code à compléter

GPT-4 : tâche	**pass-all@1**
FCG : compléter une fonction	30,52 %
CTG : test à partir du code	24,18 %
ITG : test reproduisant un bug	6,66 %
APR : réparer une fonction	18,76 %

Les quatre scores utilisent $k = 1$. Les exigences de réussite varient selon la tâche.

La détection reste particulièrement difficile

940	50 %	52,16 %
fonctions classées	référence constante	accuracy de GPT-4

470 fonctions défectueuses + 470 corrigées. Résultat descriptif, sans preuve de supériorité statistique.

4. Résultats : effets de l'entraînement

Xiang BIAN

Deux façons de poursuivre l'entraînement

RQ3 : spécialisation par langage

- Du code supplémentaire en Python ou en Java

RQ4 : ajustement sur instructions

- Des exemples de demandes et de réponses

Comparaison avec le modèle de départ, selon la tâche et la métrique.

Le langage d'entraînement change les résultats

StarCoder-15B

Version	CoderUJB FCG / Java	HumanEval / Python
Base	15,32 %	30,35 %
+ Python	14,39 %	33,57 %
+ Java	18,82 %	27,07 %

Génération de fonctions, k = 1. Deux benchmarks différents, comparés chacun entre versions.

Les instructions n'améliorent pas tout

CodeLlama-13B

Tâche et indicateur	Base	Instruct
FCG : pass-all@1	21,91 %	13,28 %
CTG : pass-all@1	12,61 %	6,14 %
APR : pass-all@1	4,50 %	4,09 %
APR : pass-all@10	8,39 %	15,72 %

Un gain à $k = 10$ ne garantit pas un gain à $k = 1$.

Une conclusion liée au protocole étudié

Constat

- Les effets varient selon la tâche et le nombre d'essais

Interprétation des auteurs

- La proximité avec le préentraînement pourrait compter

Cas particulier

- CodeLlama-Instruct-34B : réponses répétées en FCG et CTG

Les observations concernent les modèles et les réglages de l'article.

5. Limites de l'étude

Zijie Fang

Les limites reconnues par les auteurs

Validité interne

- Erreurs possibles dans l'implémentation

Validité externe

- Représentativité des modèles sélectionnés

Validité des mesures

- Indicateurs et couverture des tests

Limites explicitement discutées dans la section 6 de l'article.

Les scripts et les tests restent imparfaits

Réponse des auteurs

- Relecture des scripts et publication des résultats

Réserve sur les tests

- Un cas non testé peut encore contenir une erreur

Réserve sur la couverture

- Exécuter une ligne ne vérifie pas tous ses comportements

Réussir les tests disponibles ne prouve pas une correction complète.

Un périmètre précis de projets et de modèles

Modèles

- Versions précises sélectionnées pour l'étude

Données

- 17 projets Java provenant de Defects4J

Réparation

- Défauts concentrés dans une seule fonction

La cohérence de la source facilite l'étude, mais limite sa diversité.

Un protocole de réponse relativement simple

Protocole étudié

- Question-réponse ou complétion de code

Autre situation à tester

- Boucles avec outils, exécution et correction

Information reçue

- Contexte du prompt $\neq$ tout le dépôt

Ces réserves définissent le périmètre des conclusions ; elles ne suppriment pas l'intérêt du travail.

6. Critique et conclusion

Yupan Huang

Notre évaluation : un apport utile

Pertinence

- Plusieurs activités réelles de développement

Vérification

- Exécution et critères adaptés aux tâches

Transparence

- Code, scripts et résultats rendus publics

Notre appréciation : une contribution à la méthode d'évaluation, au-delà d'un classement.

Des comparaisons à mieux isoler

Constat du protocole

- Base : complétion ; Instruct : dialogue

Réserve

- Le format peut contribuer à l'écart observé

Amélioration proposée

- Tester plusieurs formats et quantifier l'incertitude

Un contenu équivalent ne garantit pas un effet identique du format.

Une lecture attentive des chiffres

GPT-4, tâche ITG

Indicateur	**Valeur du tableau 4**
pass-all@1	6,66 %
pass-all@10	15,76 %

RQ2 mentionne 15,76 parmi des scores annoncés à $k = 1$. Nos diapositives suivent le tableau 4.

Conclusion et pistes de prolongement

Élargir

- Autres projets, langages et méthodes avec outils

Contrôler

- Risque de contamination et sensibilité au protocole

Retenir

- Comparer par tâche, avec la même métrique

CoderUJB : une base utile pour une évaluation plus réaliste, dans un périmètre défini.