CoderUJB

Un benchmark Java pour évaluer les LLM

Zeng et al. – ISSTA 2024

Présenté par

Wei WEI Hao QIAN Jianye SHI

Xiang BIAN Zijie Fang Yupan Huang

Master CHPS – UVSQ

Évaluation de performances

Article de Zhengran Zeng, Yidong Wang, Rui Xie, Wei Ye et Shikun Zhang

Comment évaluer une IA qui code ?

Les LLM peuvent aider à programmer

Proposer du code · Corriger une erreur

À LA LECTURE

Un code peut **sembler correct**

Il faut donc le tester.

À L'EXÉCUTION

Pourtant, il peut **échouer**

Pour comparer les modèles : un benchmark

Des tâches et des règles communes

Un exercice isolé a ses limites

HUMANEVAL

164 exercices Python

Compléter une fonction

Des tests vérifient le résultat

Mais les exercices restent
assez isolés.

DANS UN VRAI PROJET

D'autres fichiers

Des bibliothèques

Du code qui existe déjà

Exercice de cours $\neq$ logiciel complet

Réussir le premier ne garantit pas qu'on réussira le second.

Développer, c'est faire plusieurs tâches

Écrire du code **Créer des tests** **Trouver des erreurs** **Les corriger**

Une seule tâche donne une **vision limitée.**

PLUSIEURS TÂCHES, MAIS D'AUTRES LIMITES

Selon les auteurs

CodeXGLUE	Ressemblance entre les textes
XCodeEval	Problèmes de concours

Ces approches ne réunissent pas toutes les conditions recherchées.

Le besoin : une évaluation plus réaliste

Réunir trois éléments

Exécuter les solutions

Vérifier leur fonctionnement

De vrais projets

Code et environnement

Plusieurs types de tâches

Des capacités variées

CoderUJB – un benchmark Java

Comment mieux évaluer les capacités des modèles dans des situations proches du travail réel ?