CoderUJB

Un benchmark Java pour évaluer les LLM

Zeng et al. – ISSTA 2024

Présenté par

Wei WEI Hao QIAN Jianye SHI

Xiang BIAN Zijie Fang Yupan Huang

Master CHPS – UVSQ

Évaluation de performances

Article de Zhengran Zeng, Yidong Wang, Rui Xie, Wei Ye et Shikun Zhang

Comment évaluer une IA qui code ?

Les LLM peuvent proposer du code et aider à corriger une erreur.

Lecture du code

Un code peut sembler correct

Exécution

Il peut pourtant échouer

Les tests vérifient son comportement.

Un benchmark fixe les tâches et les règles de comparaison.

HumanEval : des fonctions isolées

HumanEval

164 exercices Python

Compléter une fonction

Des tests vérifient le résultat

Ces fonctions restent isolées du reste d'un projet.

Dans un projet

D'autres fichiers

Des bibliothèques

Du code qui existe déjà

HumanEval ne teste pas l'utilisation des fichiers et bibliothèques d'un projet.

Développer, c'est faire plusieurs tâches

Écrire du code **Créer des tests** **Trouver des erreurs** **Les corriger**

Un modèle peut réussir une tâche et échouer sur une autre.

Les limites des autres benchmarks multitâches

Selon les auteurs

CodeXGLUE	Similarité du code, sans exécution
XCodeEval	Problèmes de concours

CoderUJB associe ces tâches à une exécution dans le projet.

Les choix de CoderUJB

Exécuter les réponses dans leur contexte de projet

Exécuter les solutions

Vérifier leur fonctionnement

De vrais projets

Code et environnement

Plusieurs types de tâches

Des capacités variées

CoderUJB : un benchmark Java

Les réponses sont évaluées dans le projet dont les questions sont issues.