Le contexte du projet aide la génération

Prompt	**FCG : pass-all@1**
Un exemple	12,84 %
Quatre exemples	14,50 %
Contexte du projet	21,91 %

CodeLlama-13B. Génération de fonctions (FCG), tableau 3.

Un écart plus marqué en réparation

Modèle	**FCG**	**APR**
CodeLlama-34B	22,82 %	5,01 %
GPT-3.5-Turbo	23,37 %	9,31 %
GPT-4	30,52 %	18,76 %

Scores : pass-all@1. Versions des modèles évaluées dans l'article de 2024.

GPT-4 : des scores différents selon la tâche

GPT-4 : tâche	**pass-all@1**
FCG : compléter une fonction	30,52 %
CTG : écrire un test à partir du code	24,18 %
ITG : écrire un test qui reproduit un bug	6,66 %
APR : réparer une fonction	18,76 %

Scores à $k = 1$. Chaque tâche a ses propres critères de réussite.

Détecter les bugs reste difficile

940	50 %	52,16 %
fonctions classées	toujours la même réponse	bonnes réponses de GPT-4

470 fonctions avec un bug et 470 versions corrigées.