Jianye SHI — Partie 3

Diapositive 14 — Le contexte du projet aide la génération

L'extrait montre les informations de contexte : les imports, les champs de la classe et les signatures des méthodes. Le tableau compare trois façons de présenter une question au modèle : un exemple, quatre exemples ou le contexte du projet.

Pour CodeLlama-13B, le score passe d'environ 13 % avec un exemple à 22 % avec le contexte du projet. Quatre exemples donnent environ 15 %.

Sur cette tâche, les informations sur le projet aident donc davantage que les exemples.

Jianye SHI — Partie 3

Diapositive 15 — Un écart plus marqué en réparation

Dans ce tableau, FCG signifie générer une fonction, et APR signifie réparer une fonction. Les scores utilisent tous pass-all à un.

Pour générer une fonction, CodeLlama-34B et GPT-3.5 sont très proches, autour de 23 %. GPT-4 atteint environ 31 %.

Pour réparer une fonction, CodeLlama obtient environ 5 %, GPT-3.5 environ 9 %, et GPT-4 environ 19 %. Les écarts sont donc plus grands en réparation.

Ce sont les versions évaluées dans l'article de 2024.

Diapositive 16 — GPT-4 : des scores différents selon la tâche

Pour GPT-4, le score est d'environ 31 % pour compléter une fonction, et de 24 % pour écrire un test à partir du code.

Pour écrire un test qui reproduit un bug décrit dans un rapport, il est de 6,66 %. Pour réparer une fonction, il atteint environ 19 %.

Les critères de réussite changent selon la tâche. Le score en génération de fonctions ne décrit donc pas les résultats en test ou en réparation.

Jianye SHI — Partie 3

Diapositive 17 — Détecter les bugs reste difficile

Pour la détection, le modèle doit dire si une fonction contient un bug. Il y a 470 fonctions avec un bug et 470 versions corrigées.

Répondre toujours la même chose donnerait donc 50 % de bonnes réponses. GPT-4 obtient 52,16 %, un résultat proche de cette référence.

Certains modèles donnent aussi des réponses que le script ne peut pas interpréter.

Après ces résultats, Xiang va présenter l'effet de l'entraînement sur les performances.