Les trois limites principales

Validité interne

- Erreurs possibles dans les scripts

Validité externe

- Choix des modèles et généralisation

Validité des mesures

- Indicateurs et qualité des tests

Les auteurs cherchent à limiter ces risques.

Réussir les tests ne suffit pas

Ce que font les auteurs

- Vérification des scripts et publication des résultats

Limite des tests

- Un programme peut encore contenir des bugs

Limite de la couverture

- Exécuter du code $\neq$ vérifier tous ses comportements

Passer les tests $\neq$ correction garantie.

Des résultats difficiles à généraliser

Modèles

- Des versions précises des LLM

Données

- 17 projets Java issus de Defects4J

Réparation (APR)

- Des bugs dans une seule fonction

Pas nécessairement les mêmes résultats ailleurs.

Une évaluation encore limitée

Protocole étudié

- Prompt → réponse → évaluation

Autre approche possible

- Tester → corriger → recommencer

Contexte fourni

- Le modèle ne reçoit pas forcément tout le projet

Ces limites précisent la portée des conclusions.