CoderUJB

Un benchmark Java
pour évaluer les LLM

Zeng et al. · ISSTA 2024

Évaluation de performances

Wei WEI Hao QIAN Jianye SHI
Xiang BIAN Zijie Fang Yupan Huang

PLAN

1. Contexte

2. Contributions et méthode

3. Résultats

4. Limites

5. Critique et conclusion

Comment évaluer une IA qui code ?

Les LLM peuvent aider à programmer

Proposer du code · Corriger une erreur

À LA LECTURE

Un code peut **sembler correct**

À L'EXÉCUTION

Pourtant, il peut **échouer**

Il faut donc le tester.

Pour comparer les modèles : un benchmark

Des tâches et des règles communes

Un exercice isolé a ses limites

HUMANEVAL

164 exercices Python

Compléter une fonction

Des tests vérifient le résultat

Mais les exercices restent
assez isolés.

DANS UN VRAI PROJET

D'autres fichiers

Des bibliothèques

Du code qui existe déjà

Exercice de cours $\neq$ logiciel complet

Réussir le premier ne garantit pas qu'on réussira le second.

Développer, c'est faire plusieurs tâches

Écrire du code **Créer des tests** **Trouver des erreurs** **Les corriger**

Une seule tâche donne une **vision limitée**.

PLUSIEURS TÂCHES, MAIS D'AUTRES LIMITES

Selon les auteurs

CodeXGLUE	Ressemblance entre les textes
XCodeEval	Problèmes de concours

Ces approches ne réunissent pas toutes les conditions recherchées.

Le besoin : une évaluation plus réaliste

Réunir trois éléments

Exécuter les solutions	**De vrais projets**	**Plusieurs types de tâches**
Vérifier leur fonctionnement	Code et environnement	Des capacités variées

---

CoderUJB — un benchmark Java

Comment mieux évaluer les capacités des modèles dans des situations proches du travail réel ?