ISM – INTRODUCTION À LA SIMULATION MICROSCOPIQUE

Responsable : Michel Masella
Directeur de Recherche CEA – Professeur Attaché UP-Saclay

CEA Saclay
Direction de la Recherche Fondamentale
Institut Joliot
Mail : michel.masella@cea.fr

https://http://biodev.cea.fr/polaris/

ISM1 – DESCRIPTION DE L'UE

Objectifs pédagogiques visés :

Ce module a pour objectif de présenter les approches permettant de modéliser la nature à l'échelle moléculaire et de montrer l'interdépendance entre un modèle physique et sa traduction sous forme d'un code sur des architectures de calcul parallèle modernes, dans le contexte particulier de la dynamique moléculaire. Le module s'organise en 9 cours principaux :

- Introduction « Qu'est-ce que la simulation microscopique » et rappels de thermodynamique statistique
- Notions de champs de force
- Résolution des équations du mouvement (algorithme de Verlet/ contraintes/algorithme à pas de temps multiples/effets chaotiques)
- Exploration de surface d'énergie potentielle (méthodes avec et sans biais)
- Calculs de grandeurs thermodynamiques à l'équilibre et grandeurs temporelles (viscosité/coefficient de diffusion)
- Systèmes à l'état condensé : conditions périodiques (sommes d'Ewald classique et sur grille)
- TP n° 1 : Analyse de données de simulations avec GNUPLOT
- Notion de complexité algorithmique en simulation microscopique
- Architecture d'un code de dynamique moléculaire : potentiel de Lennard-Jones (réduction de la complexité algorithmique/vectorisation/décomposition de domaine/parallélisation OPENMP et MPI)
- Analyse d'une simulation : grandeurs moyennes et estimation de l'erreur associée
- TP n° 2 : Simulations avec le code POLARIS(MD)
- TD : Corrigé de l'examen ISM 2020

Les notions abordées sont approfondies lors de séances de TD à la fin de chaque cours principal et de deux séances de TP (réalisées sur station de travail ou pc portable).

ISM1 – INTRODUCTION

1 – QU'EST CE QUE LA SIMULATION MICROSCOPIQUE

2 – APPLICATIONS DE LA SIMULATION MICROSCOPIQUE

3 – EN 2023, QU'EST-IL POSSIBLE DE FAIRE ?

4 - NOTIONS DE THERMODYNAMIQUE STATISTIQUE

5 – GÉNÉRER DES ENSEMBLES STATISTIQUES

ISM1 – SIMULATION MICROSCOPIQUE VS PHYSIQUE THÉORIQUE

En physique théorique, il suffit de résoudre un jeu d'équations pour prédire les propriétés d'un système, par exemple la longueur d'un polymère de caoutchouc

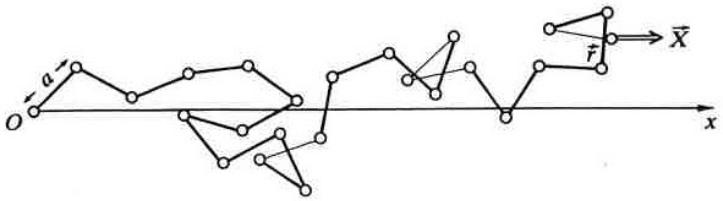

$$Z = \int \left(\prod_{i=1}^{N} d\omega_i\right) \exp\left(\vec{X} \cdot \vec{r}/k_B T\right)$$

Fonction de partition du système « polymères de caoutchouc » = *N* monomères de longueur *a*

$$\bar{x}_{PT} = Na\mathcal{L}\left(\frac{Xa}{kT}\right) \text{ avec } \mathcal{L}(t) = \coth(t) - \frac{1}{t}$$

Longueur moyenne $\bar{x}$ des polymères à la température *T*

La simulation microscopique est une expérience virtuelle : on échantillonne les structures possibles d'un système qui vont permettre de calculer des moyennes correspondant aux propriétés physiques d'intérêt = « expérience virtuelle »

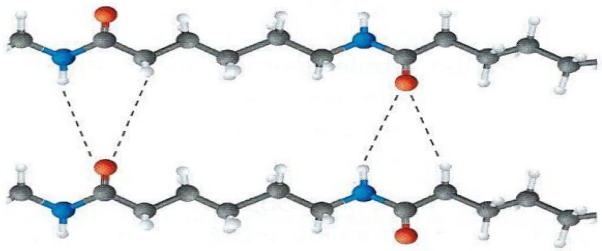

Simulation sur la base d'équations régissant les interactions Inter atomiques => génère *M* conformères chacun noté *C*

$$\bar{x}_{sim} = \frac{1}{M}\sum_{i=1}^{M} x_C \overset{?}{=} \bar{x}_{PT} = Na\mathcal{L}\left(\frac{Xa}{kT}\right)$$

ISM1 – LA SIMULATION MICROSCOPIQUE : UNE EXPÉRIENCE VIRTUELLE

La simulation microscopique permet d'observer directement une système microscopique directement à l'échelle atomique ou moléculaire (à l'échelle de l'Angström = 10^{-10} m)

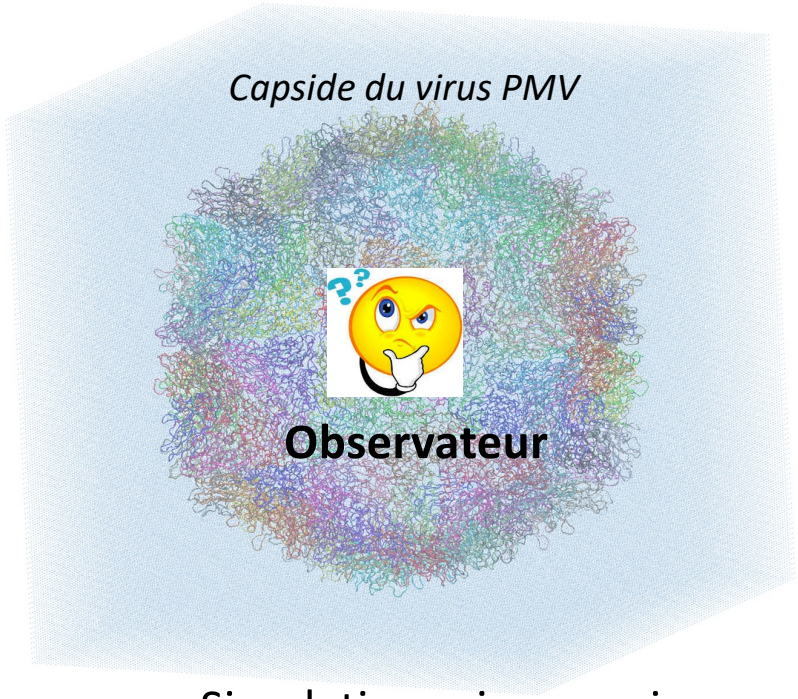

Simulation microscopique

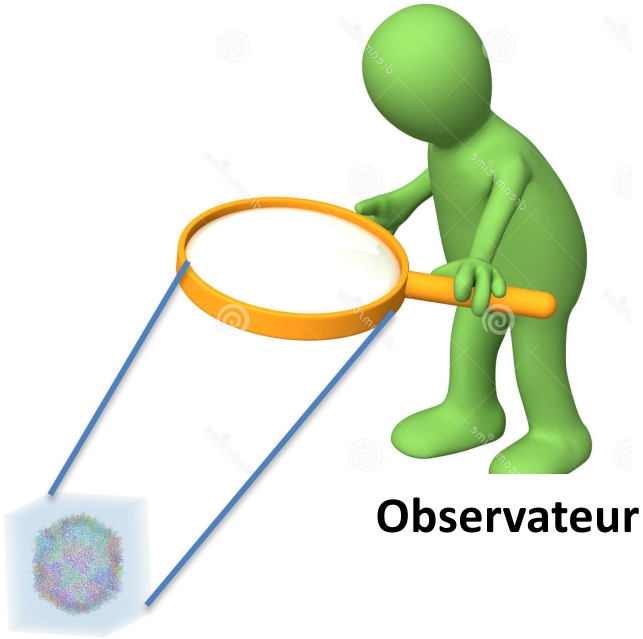

Expérience classique

Les données issues de simulations microscopiques (ou de véritables expériences) doivent obéir aux lois de la physique statistique (en particulier distributions de Boltzman) !

Probabilité d'observer une structure C d'énergie U_C : $p_B(C) = \exp\left(-\frac{U_C}{k_B T}\right)$

Deux facteurs clés qui conditionnent la qualité d'un simulation microscopique

1 – La qualité des potentiels inter atomique employé $\boldsymbol{U(\{\vec{r}_i\}_{1\leq i\leq N})}$

Plus les potentiels sont complexes plus ils coûtent chers en temps de calculs et sont-ils facilement implémentables efficacement sur une architecture de calcul (parallèle, GPU, processeurs dédiés) ?

Dans le meilleur des cas la précision des potentiels d'interaction employés est de l'ordre de k_BT, il y a donc une erreur δU sur l'énergie d'une structure (configuration) *C* ce qui affecte son poids statistique dans l'échantillonnage de structures générées

$$\bar{x} = \frac{1}{M}\sum_{i=1}^{M} Q(C)\times x_C \quad \text{si } U \text{ exacte en tout point alors } Q(C)=1 \quad \forall C$$

En effet, la probabilité $p_B(C)$ d'observer une configuration *C* qui correspond à une énergie *U(C),* c'est à dire le nombre de fois où *C* sera observée C le long d'une simulation, est d'après Boltzmann :

$$p_B(C) = \exp\left(-\frac{U(C)}{k_BT}\right)$$

Une « petite » erreur $\delta U(C)$ sur l'énergie *U(C)* se traduit par une erreur δp sur $p_B(C)$ de l'ordre de $\delta U/U(C)$

$$p_B(C) \pm \delta p = \exp\left(-\frac{U(C) \pm \delta U(C)}{k_BT}\right) = \exp\left(-\frac{U(C)}{k_BT}\right)\times\left(1 \mp \frac{\delta U(C)}{U(C)}\right) \Rightarrow \boxed{\frac{\delta p}{p_B(C)} = \frac{\delta U(C)}{U(C)}}$$

(U est définie à un constante additive près)

Deux facteurs clés qui conditionnent la qualité d'un simulation microscopique

2 – La qualité « statistique » de l'échantillon de structures générées

L'objectif est de calculer une moyenne statistique : il est impératif d'évaluer l'ordre de grandeur de l'incertitude lié à la taille finie de l'ensemble statistique correspondant à l'échantillon considéré

$$\bar{x} = \frac{1}{M}\sum_{i=1}^{M} x_C \text{ vrai à } \pm \delta x = \frac{1}{M}\sum_{i=1}^{+\infty} x_C - \frac{1}{M}\sum_{i=1}^{M} x_C$$

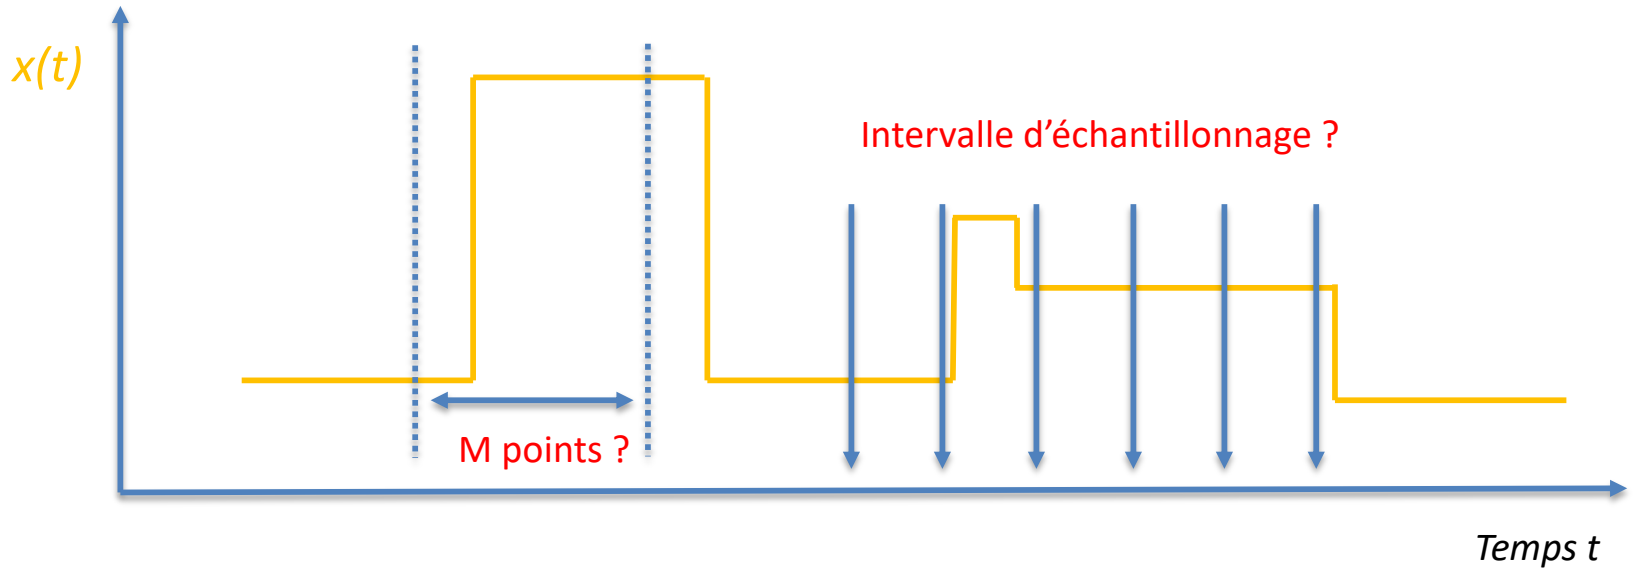

Interpréter des données expérimentales ambigües ou parcellaires

Comportement de molécules aux interfaces

➔ phénomènes de polution en haute atmosphère et impact sur le climat de polluants chimiques

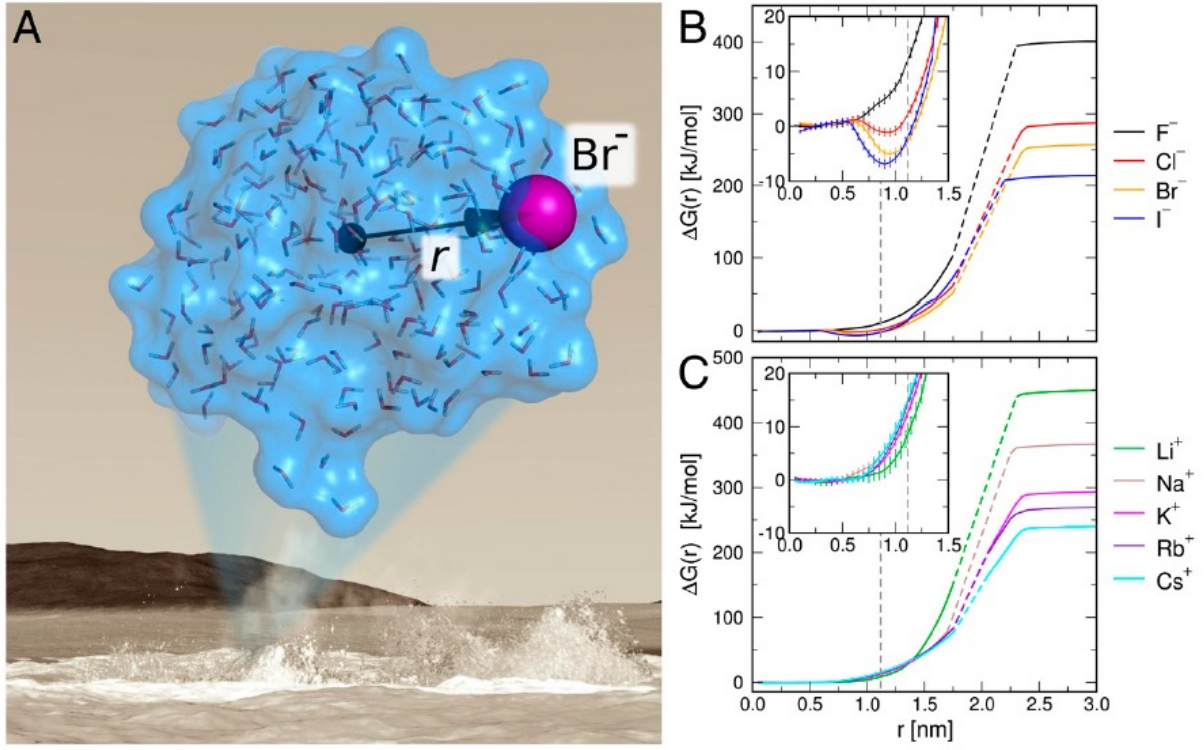

Il y a 9 ans, 1er centres de calcul pétaflopique, CPU INTEL Sandy Bridge 8 cœurs à 2.9 Ghz

Caleman et al, PNAS, 108 (2011) 6838

champs de force polarisable, 100 molécules d'eau + 1 ion, simulations à l'échelle de 300 ps

Why to simulate marine aerosols ?

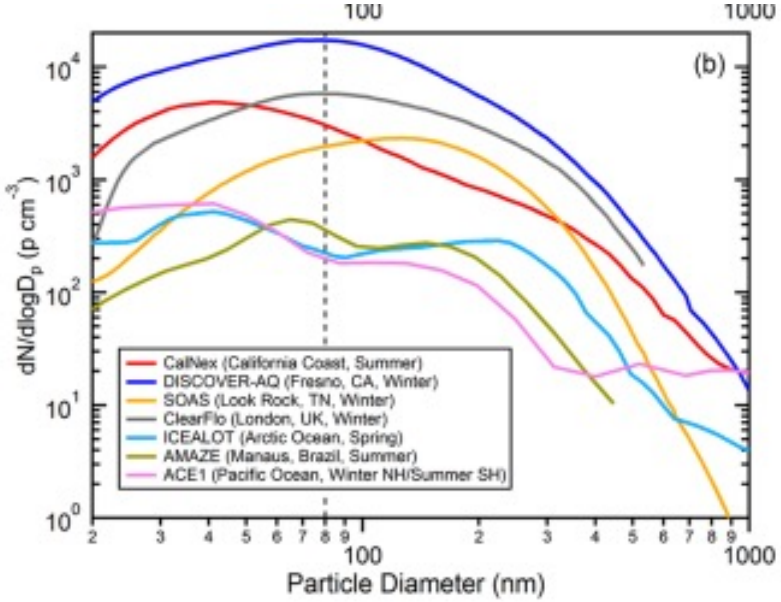

Size distribution of marine aerosols at ocean surfaces
Cf. Chem Rev 2015, 115, 4383–4399

1. A pivotal feature of marine aerosols to understand climate changing is their ability to evolve towards cloud based on their composition.

2. According to the Köhler equation (1936, based on the Kelvin term, 1871)

$$\frac{\mathrm{RH}}{100} = a_w \exp\left(\frac{4\sigma_s M_w}{RT\rho_w D_{p,wet}}\right)$$

the ability of an aerosol to evolve towards a cloud depends on a key property : the aerosol surface tension.

3. Surface tensions of aerosols (finite size systems) are unknown.

4. It is inferred that they can be approximated to their infinite surface values.

5. BUT because of the lacking of experimental evidence, there is still controversies about that assumption

cf. J Chem Phys 221101 (155) 2021

ISM1 – Simuler la matière à l'Echelle Microscopique pour

Compléter des données expérimentales parcellaires => demande du GIEC

« **Interfacial phenomena are considered as an important factor for climate change even if they are still insufficiently understood** » *Intergovernmental Panel on Climate Change, Climate Change 2013: The Physical basis*

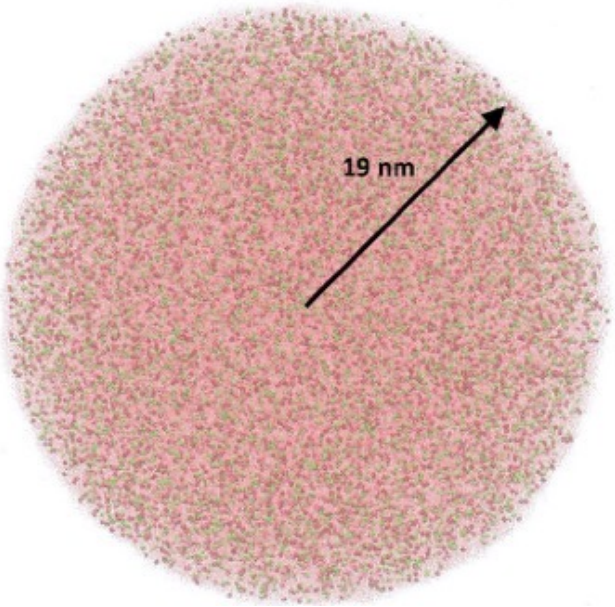

1M de molécules d'eau, 10 000 paires de NaCl, « starting structure »
Champ de force polarisable 0.5 ns/jour 4 096 cœurs AMD Epyc Rome

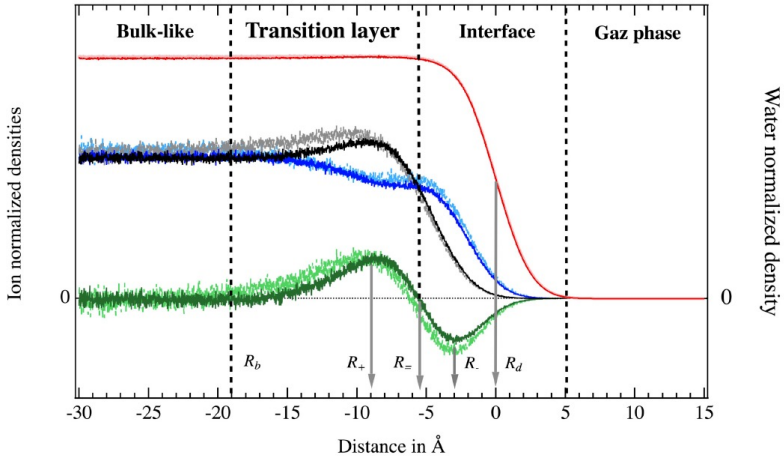

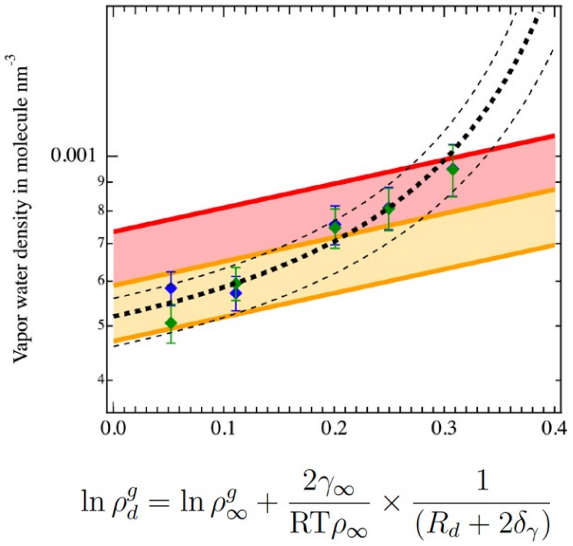

$$\ln \rho_d^g = \ln \rho_\infty^g + \frac{2\gamma_\infty}{\mathrm{RT}\rho_\infty} \times \frac{1}{(R_d + 2\delta_\gamma)}$$

Aujourd'hui, 1er centre de calcul à base de CPU AMD 64 cœurs à 2.5 Ghz (290 000 au total)

Masella et al, Grand Challenge TGCC@CEA
"NaCl salts in finite aqueous environments at the fine particle marine aerosol scale"
ACS Earth and Space Chemistry, 6 (2022) 1612

Molecular dynamics of Lithium Ion Transport in a Model Solid Electrolyte Interphase

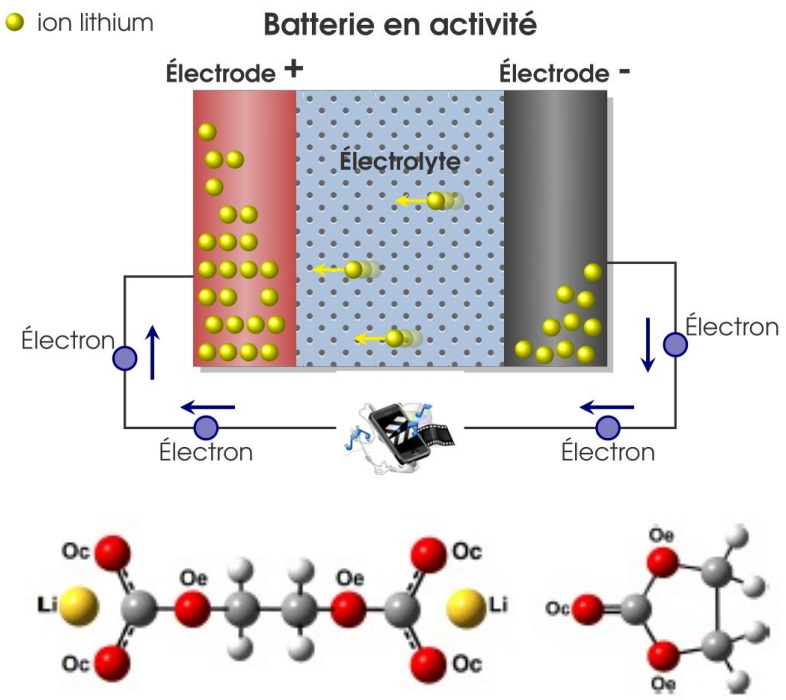

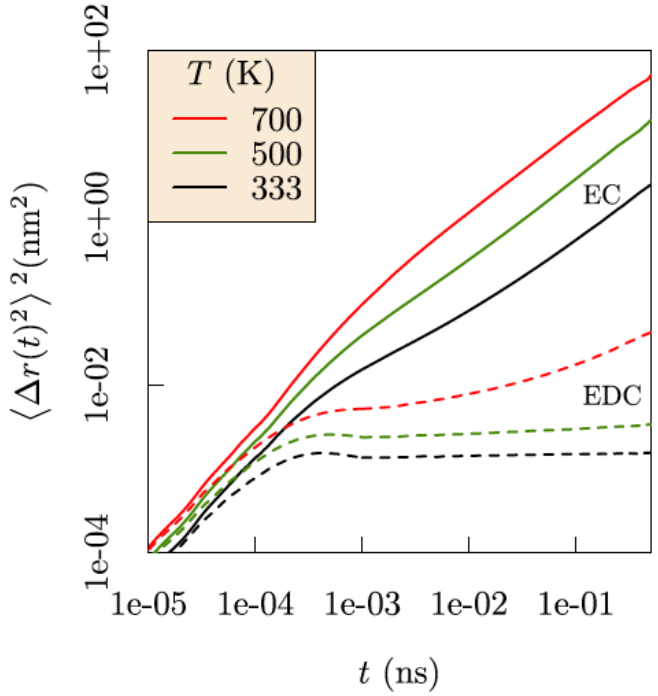

During charging and discharging cycles of lithium ion batteries, a solid electrolyte interphase (SEI) layer forms on the negative electrode due to decomposition of solvents like ethylene carbonate (EC). The SEI layer is a complex organic material and its composition is not operationally set[1]. Nevertheless, dilithium ethylene dicarbonate (Li_2EDC) has been identified experimentally as the primary component of the outer part of the SEI layer[2–5].

*Muralidharan et al, Sci. Rep., **8**, 10736; doi: 10.1038/s41598-018-Z8869-X (2018).*

ISM1 – MODÉLISATION MOLÉCULAIRE « AB INITIO »

Simulation de systèmes microscopiques expérimentalement peu ou pas étudiés à l'aide de champs de force évolués calés sur des calculs de chimie quantique de haut niveau.

Exemple en collaboration avec L'Oréal : Hybrid polarizable simulations of a conventional hydrophobic polyelectrolyte

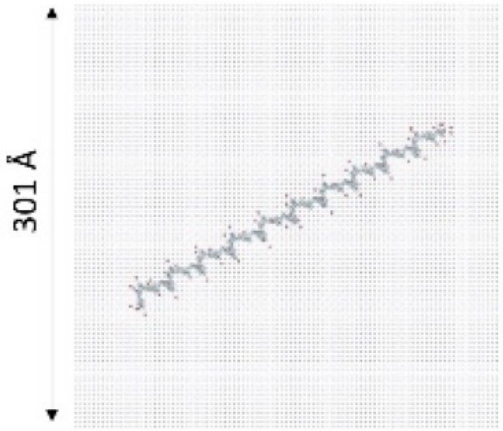

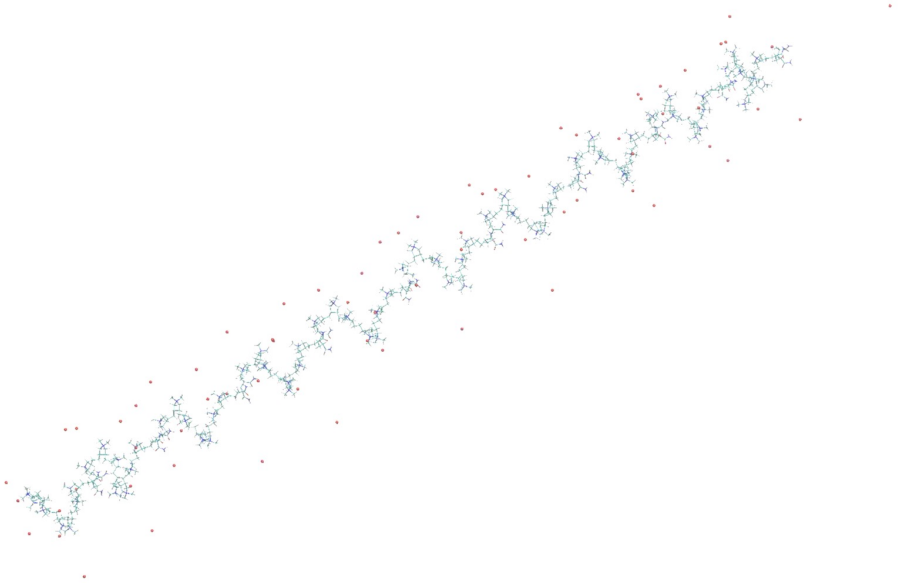

Polymère (25k atomes) + 1M pseudo particules modélisant l'eau (couplage champ de force *all atom* polarisable + multi-échelle)

2 ns/jours sur un CPU AMD 64 cœurs
10 Go de mémoire vive.
Code POLARIS(MD)

« ***Hybrid polarizable simulations of a conventional hydrophobic polyelectrolyte. Toward a theoretical tool for green science innovation*** », **J. Chem. Phys. 155, 114903 (2021); https://doi.org/10.1063/5.0056508**

ISM1 – CODE GÉNÉTIQUE ET PROTÉINES

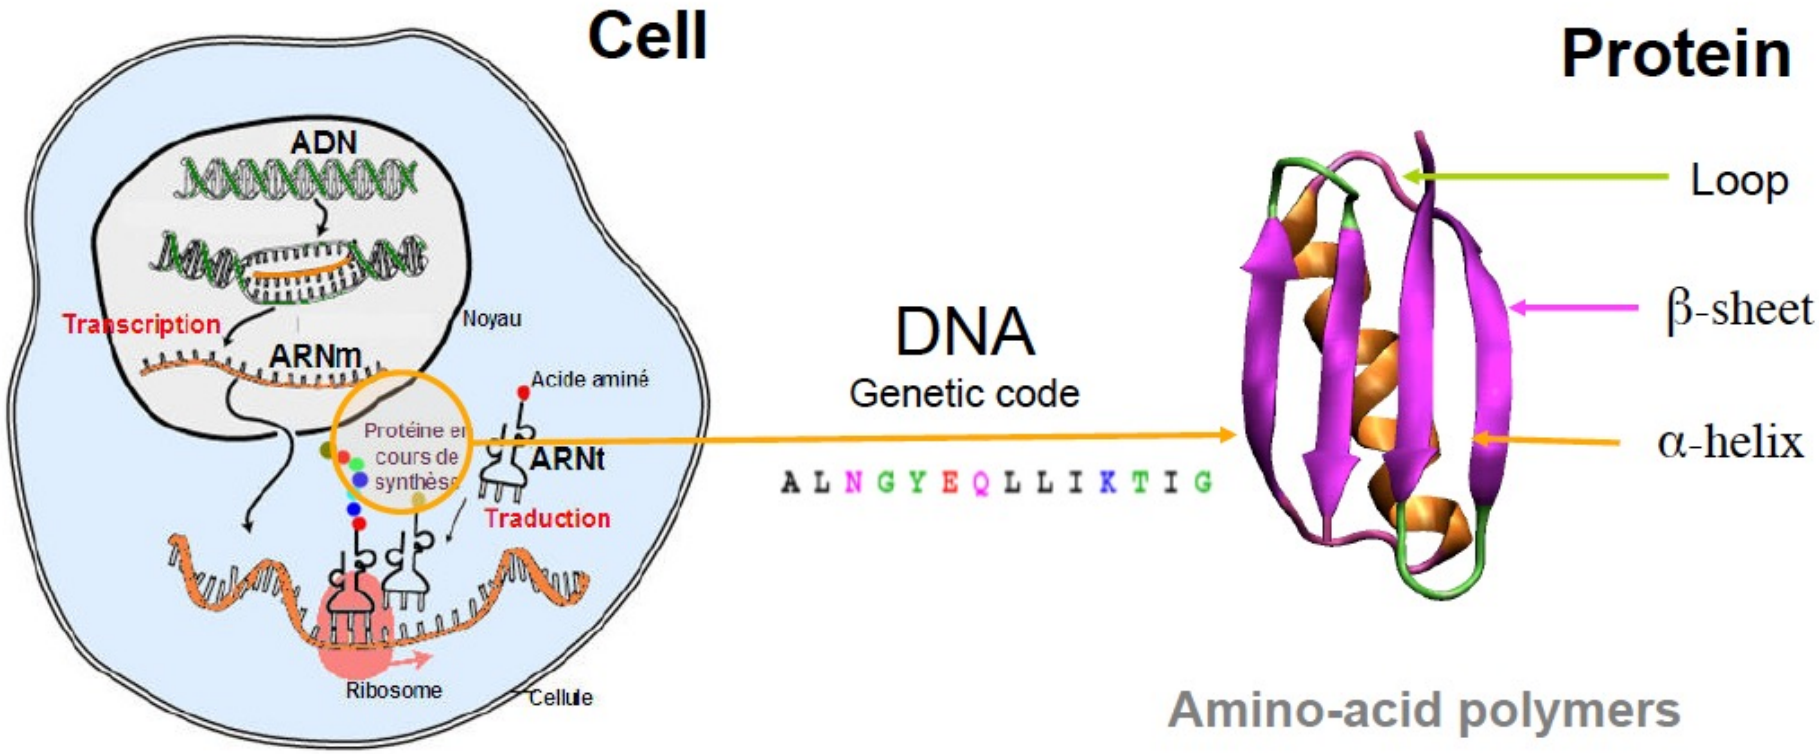

Human genetic code : about 30 000 genes
Human proteom ≈ 300 000 proteins

ISM1 – SIMULER LA MATIÈRE À L'ECHELLE MICROSCOPIQUE POUR

Interpréter des données expérimentales ambigües ou parcellaires

Phénomènes de réorganisation structurale de peptides dans des milieux hétérogènes
(ici un peptide en interaction avec une capside de virus)

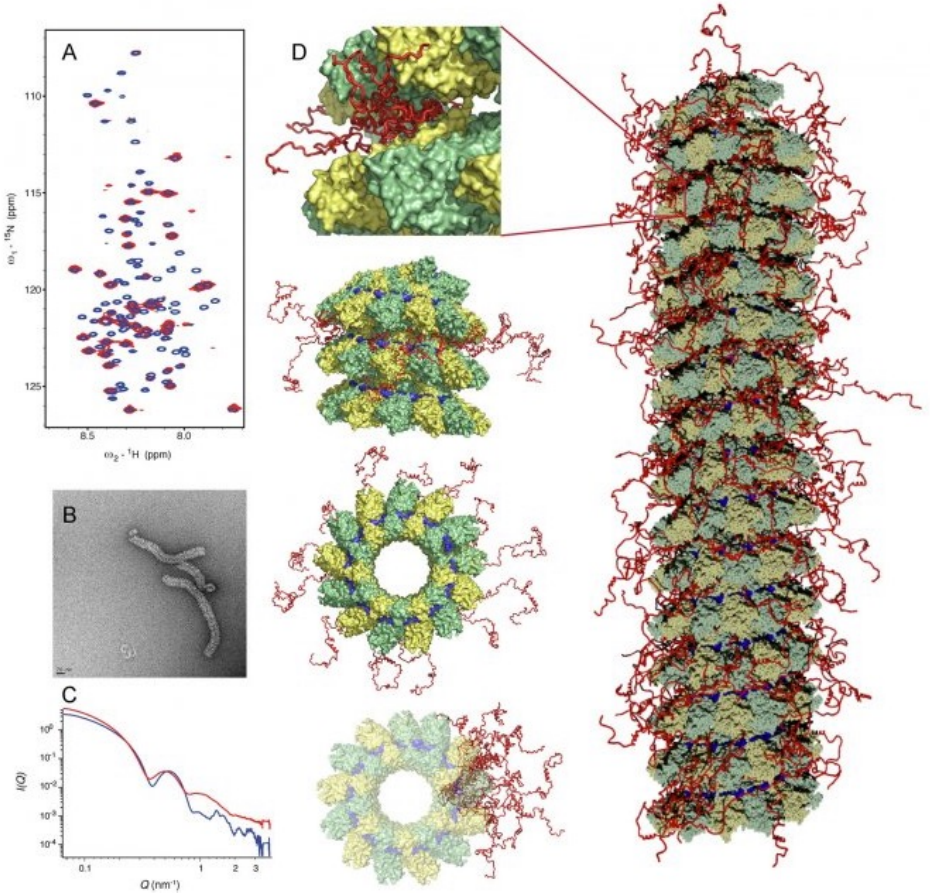

PLoS Pathog. 9, e1003631 (2013)

Focaliser des expériences sur les systèmes les plus pertinents
(docking moléculaire, drug design, etc ….)

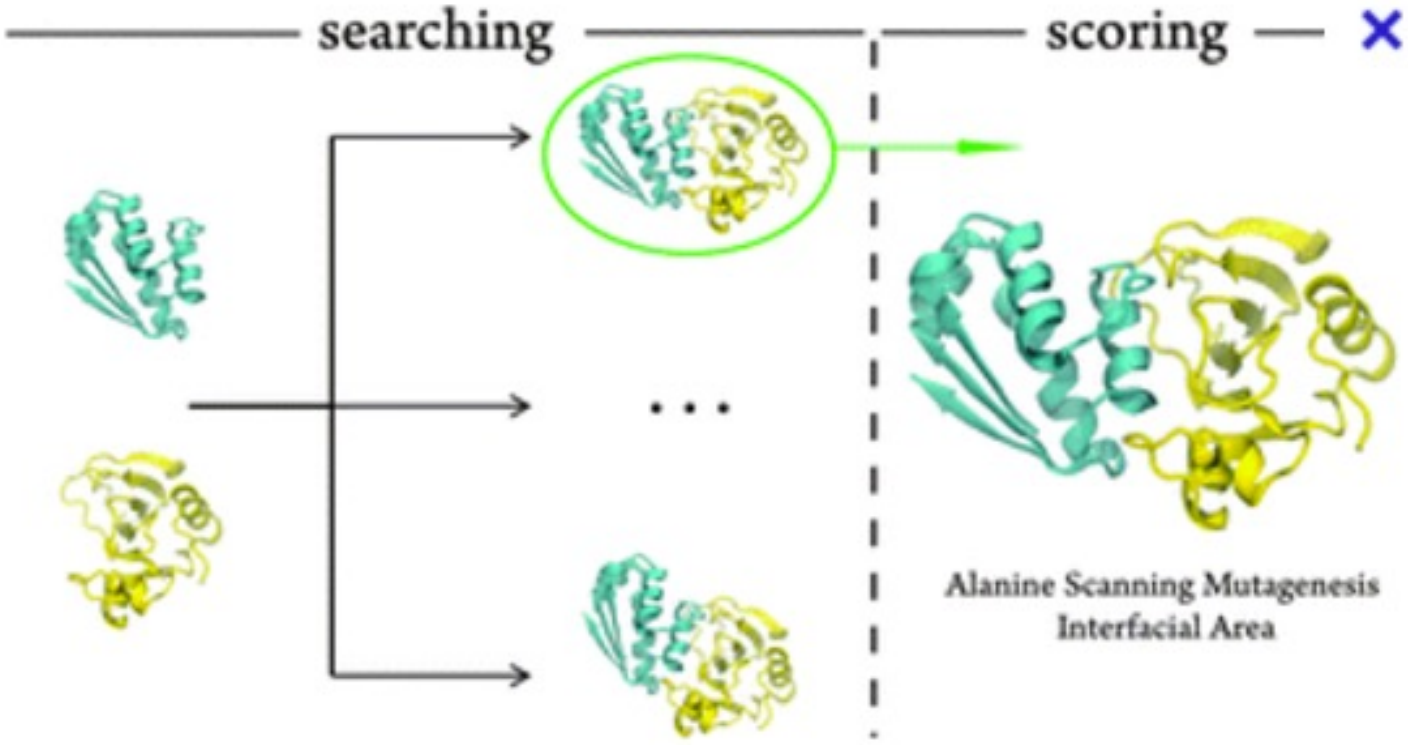

Moreira et al, PCCP, 17 (2015) 2378

ISM1 – SIMULER LE VIVANT ?

Etude de la dynamique du système de cleavage de l'ADN CRISPR-9

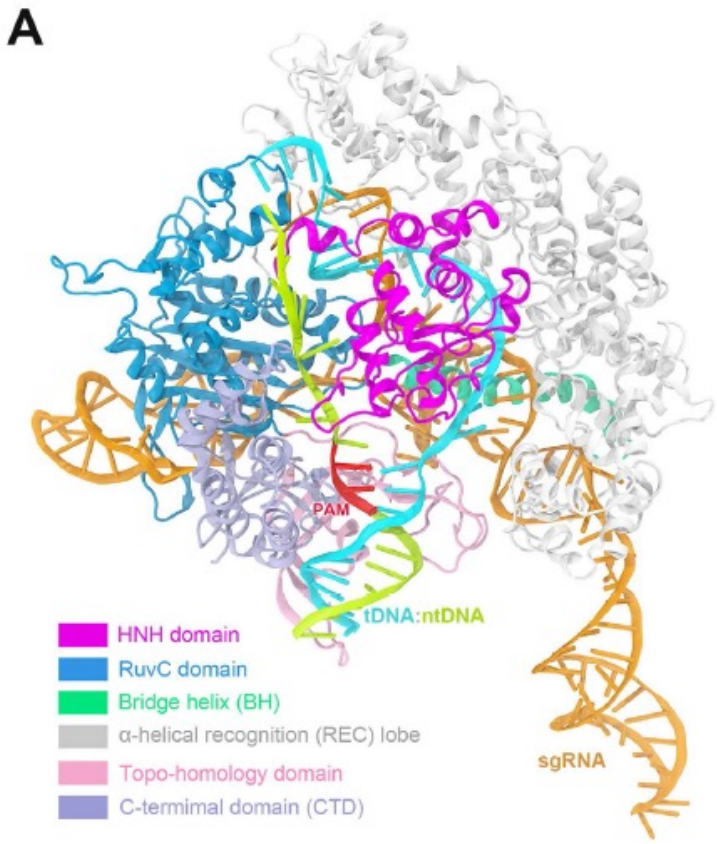

Simulations à l'échelle de 300 ns, réalisées à l'aide de processeurs GPU du supercalculateur Marverick du Texas Advanced Computing Center (USA)

*Zhuo and Liu, Sci. Rep., **6**, 37584; doi: 10.1038/srep37584 (2016).*

ISM1 – QUE SAIT-ON FAIRE EN 2023 ?

Capside de virus HIV mature

Capside : un assemblage de protéines qui encapsule le matériel génétique d'un virus

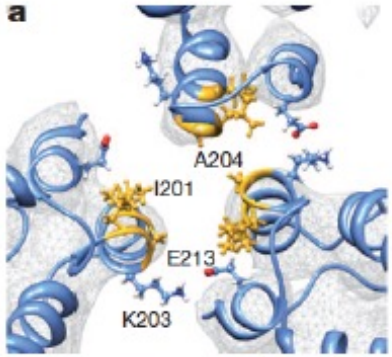

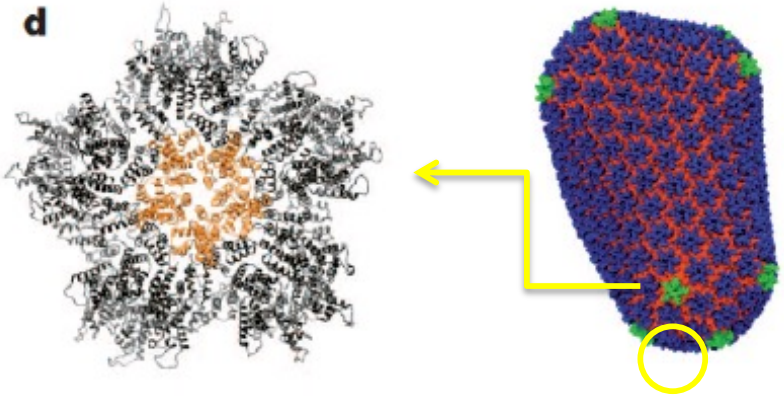

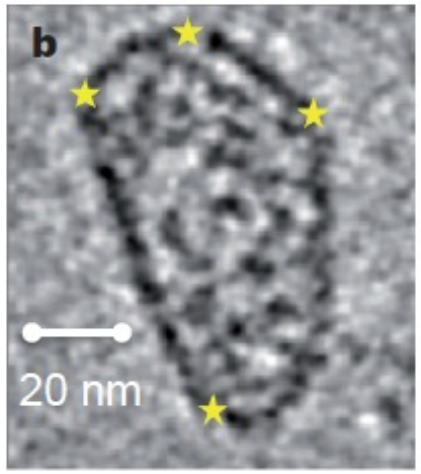

Microscopie cryo-électronique

Le capside du HIV seule, 5 M d'atomes à quoi s'ajoute le solvant (eau)
pour un total de 60 M d'atomes.

128 000 coeurs du calculateur Cray Bluewater (University of Illinois)
pour simuler 300 ns de la vie de cette capside (3.10^{-7} s)

*Zhao et al, Nature, **497** (2013) 643*

ISM1 – Que sait-on faire en 2021 ? Des Processeurs Dédiés

Le projet de système dédié ANTON du DE SHAW Laboratory (New-York, USA)

Code de simulation moléculaire codé en “dur”, temps de simulation à l’échelle de la µs -ms.

"Anton, A Special-Purpose Machine for Molecular Dynamics Simulation".
Communications of the ACM. ACM. 51 (7): 91–97.
Gordon Bell price winner 2014

ISM1 – Que sait-on faire en 2020 ? Des Processeurs Dédiés

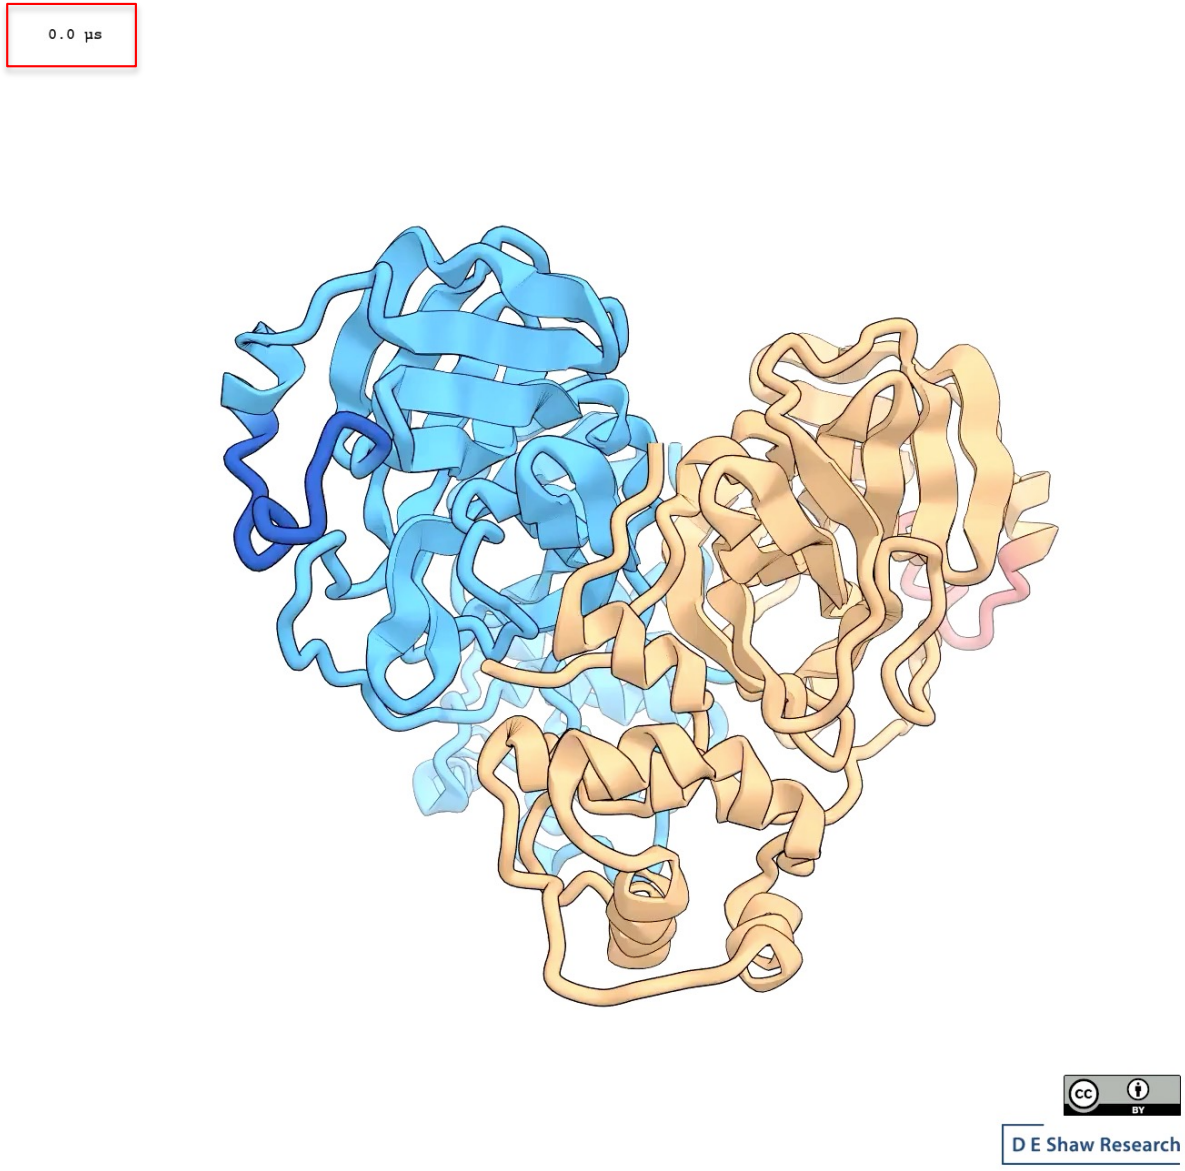

cf https://www.deshawresearch.com/

ISM1 –SYSTÈME MICROSOCOPIQUE

Un système microscopique $\mathcal{M}$ se caractérise par un ensemble de *N* particules (petites molécules et/ou groupements chimiques et/ou atomes) associées à un jeu de *N* coordonnées $\{\vec{r}_i\}_{1\le i\le N}$ qui correspond à une configuration du système microscopique :

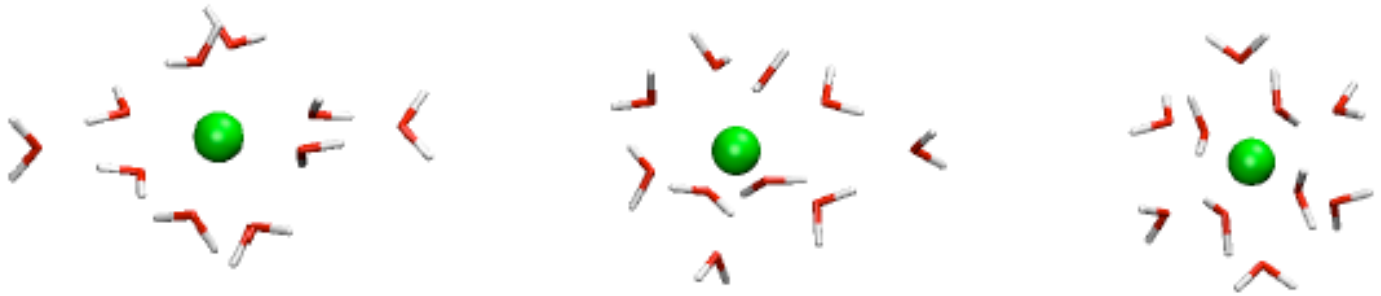

On appelle interactions microscopiques, les interactions physiques entre les *N* particules définissant le système $\mathcal{S}$. Par exemple, l'interaction coulombienne entre deux particules chargées

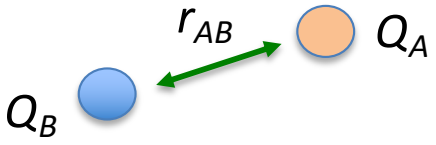

$$U(A,B)=\frac{1}{4\pi\varepsilon_0}\frac{Q_AQ_B}{r_{AB}}$$

La somme des interactions microscopiques définit l'énergie potentielle *U* du système microscopique $\mathcal{M}$. L'énergie potentielle *U* ne dépend que du jeu de coordonnées $\{\vec{r}_i\}_{1\le i\le N}$. Le système $\mathcal{M}$ se caractérise aussi par un jeu de vitesses de ses particules. Ces vitesses définissent son énergie cinétique *K* :

$$E(\{\vec{r}_i,\vec{v}_i\}_{1\le i\le N})=U(\{\vec{r}_i\}_{1\le i\le N})+K(\{\vec{v}_i\}_{1\le i\le N})=U(\{\vec{r}_i\}_{1\le i\le N})+\frac{1}{2}\sum_{i=1}^{N}m_iv_i^2=U(\{\vec{r}_i\}_{1\le i\le N})+\frac{1}{2}\sum_{i=1}^{N}\frac{p_i^2}{m_i}$$

ISM1 – OBJECTIF DE LA SIMULATION MOLÉCULAIRE

Générer des ensembles de structures représentatives d'un système microscopique permettant de calculer ses propriétés thermodynamiques.

Dans le cas d'un système $\mathcal{M}$ étudié dans des conditions définies (température *T*, pression *P*), l'objectif est de calculer la fonction de partition *Z* du système $\mathcal{M}$

$$Z = \frac{1}{N!h^{3N}} \iiint_V \exp(-\frac{U+K}{k_B T}) \Pi_{i=1}^{N} d^3 x_i d^3 p_i$$

1 - **A la différence de l'astrophysique**, la simulation moléculaire n'a pas pour objectif de calculer une trajectoire 'exacte' mais des distributions réalistes des variables internes d'un système moléculaire.

2 - Ces distributions réalistes des variables internes d'un système moléculaire permettent de calculer toutes les propriétés de ce système qui peuvent être comparées à des données expérimentales. **Autrement dit, les propriétés 'utiles' d'un système microscopique sont des valeurs moyennes.**

Cas d'un système $\mathcal{M}$ composé de *N* particules (atomes ou molécules) étudié à une température définie *T*, sa fonction de partition *Z* est

$$Z = Z_p \times \iiint_V \exp\left(-\frac{U(\{\vec{r}_i\}_{1\le i\le N})}{k_B T}\right)\Pi_{i=1}^{N} d\vec{r}_i$$

$\{\vec{r}_i\}_{1\le i\le N}$ Système de coordonnées des particules composant le système $\mathcal{M}$ et définissant sa configuration géométrique

$U(\{\vec{r}_i\}_{1\le i\le N})$ Énergie potentielle microscopique du système $\mathcal{M}$ quand ces particules sont dans la configuration géométrique précédente

Remarque : les vitesses des particules (ou leurs moments cinétiques $\boldsymbol{p}_i$) sont des variables indépendantes des coordonnées $\boldsymbol{r}_i$, le préfacteur de *Z* est le résultat de l'intégration de

$$Z_p = \frac{1}{N!h^{3N}}\Pi_{i=1}^{N}\iiint_V \exp\left(-\frac{p_i^2}{2m_i k_B T}\right)d\vec{p}_i$$

Energie libre *F* du système microscopique $\mathcal{M}$

$$F(T) = -k_B T \ln(Z)$$

un système $\mathcal{M}$ évolue afin de minimiser *F(T)*

Energie microscopique moyenne $\bar{U}$ du système $\mathcal{M}$

$$\bar{U} \propto \iiint_v U(\{\vec{r}_i\}_{1\le i\le N}) \times \exp(-\frac{U(\{\vec{r}_i\}_{1\le i\le N})}{k_B T}) \Pi_{i=1}^{N} d\vec{r}_i \propto -\frac{\partial \ln(Z)}{\partial \beta}$$

$$\beta = 1/k_B T$$

Remarque, la fonction enthalpie H de $\mathcal{S}$ est égale à $\bar{U} + PV = \bar{U} + RT$ (gaz parfait)

Entropie *S(T)* du système $\mathcal{M}$

$$S(T) = \frac{\bar{U} - F(T)}{T}$$

un système $\mathcal{M}$ évolue afin de maximiser *S(T)*

ISM1 – ENTROPIE

Soit un système microscopique $\mathcal{M}$ *(*volume *V*, *N* particules et énergie potentielle *U) :*

$$Z = Z_p \times \iiint_V \exp(-\frac{U(\{\vec{r}_i\}_{1\le i\le N})}{k_B T}) \Pi_{i=1}^{N} d\vec{r}_i \qquad F(T) = -k_B T \ln(Z) \qquad S(T) = \frac{\bar{U} - F(T)}{T}$$

Si *U* est constante quelque soit le configuration microscopique de $\mathcal{M}$ et en ignorant les vitesses

$$F(T) = U - k_B T \ln(\Omega) = \bar{U} - k_B T \ln(\Omega) \rightarrow S(T) = k_B \ln(\Omega)$$

$$\Omega = \iiint_V \prod_{i=1}^{N} d\vec{r}_i \sim V^N \rightarrow S(T) = N k_B \ln(V)$$

Remarques :

Le système $\mathcal{M}$ évolue pour maximiser son entropie, donc ici son volume *V*. Plus *V* est grand plus la probabilité de trouver une de ses particules en un point $\vec{r}_i$ particulier est faible, donc moins on dispose d'« information » sur les particules du système $\mathcal{M}$.

Plus la surface d'énergie potentielle associée à $\mathcal{M}$ est « plate », plus le comportement de M sera gouverné par son entropie…

Enthalpie vs. Entropie : *F = U- TS*

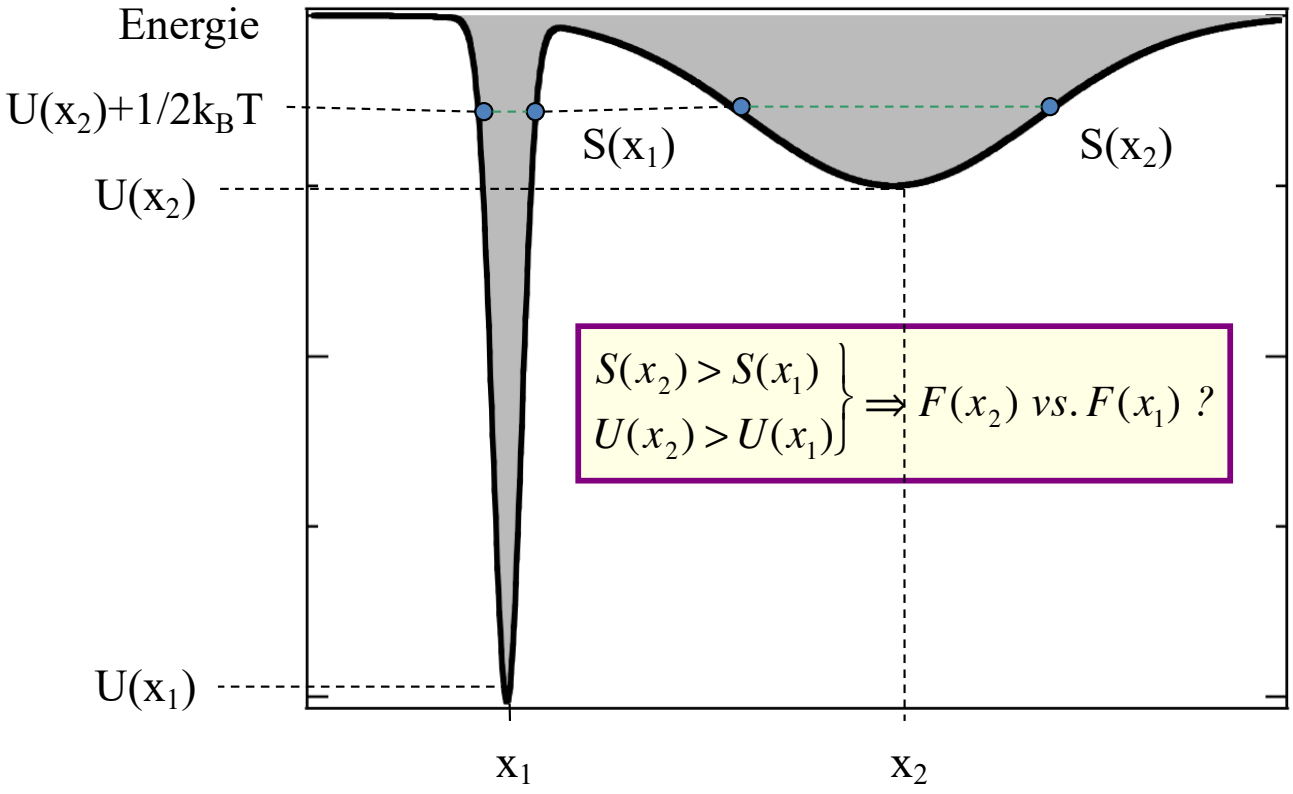

Il faut bien échantillonner les deux minima, sinon on commettra ici une erreur significative soit sur *U* soit sur *S* et donc sur la moyenne de *x*…

M. Christen and W.F. van Gunsteren, J. Comput. Chem., 29 (2008) 157

ISM1 – GÉNÉRER UN ENSEMBLE DE CONFIGURATIONS REPRÉSENTATIVES

1 - Si une méthode théorique (un algorithme) est capable de générer une distribution réaliste des jeux de coordonnées $\{\vec{r}_i\}_{1\leq i\leq N}$ possibles pour les particules d'un système microscopique $\mathscr{M}$ à des conditions données (par exemple *T* et *P*, mais également champ électrique extérieur imposé, etc…), alors on peut calculer l'ensemble des grandeurs macroscopiques et thermodynamiques de ce système.

2 - Si la méthode théorique (algorithme) génère une distribution "exacte" de ces configurations, les écarts observés avec l'expérience pour les différentes grandeurs macroscopiques et/ou thermodynamiques n'ont pour origine que la fonction *U*, i.e. une représentation théorique des interactions microscopiques erronées.

Deux aspects à bien maîtriser :

1 - Génération des ensembles des structures à l'échelle microscopique d'un système $\mathscr{M}$
2 - Représentation les interactions entre les particules de ce système

ISM1 – GÉNÉRER DES CONFIGURATIONS PAR DYNAMIQUE MOLÉCULAIRE

Supposons l'énergie microscopique *U* continue et dérivable, il est alors possible de calculer les forces inter-particulaires au sein du système $\mathcal{M}$

$$\vec{F}_i = -\vec{\nabla}_i U$$

Dès lors il est possible de résoudre les équations de mouvements de Newton (formalisme classique) pour l'ensemble des particules du système $\mathcal{M}$

$$m_i \frac{\partial^2 \vec{r}_i}{\partial t^2} = -\vec{F}_i = \vec{\nabla}_i U$$

Avantage : toutes formes de mouvements au sein du système $\mathcal{M}$ sont facilement étudiables, accès aux moyennes temporelles du système $\mathcal{M}$ (coefficient de diffusion …)

Inconvénient : le pas d'intégration des équations de Newton sont de l'ordre au plus de la femto-seconde (10^{-15} s), alors que nombre de phénomènes physico-chimiques ont des temps caractéristiques > 1 ms.

ISM1 – GÉNÉRER DES CONFIGURATIONS PAR MONTE CARLO

La méthode Monte-Carlo repose se décompose en deux étapes :

1 – tirage aléatoire des coordonnées d'un système microscopique $\mathcal{M}$ à partir d'une configuration donnée, ce qui génère une nouvelle configuration

2 – la nouvelle configuration est retenue pour calculer les grandeurs moyennes du système $\mathcal{M}$ si la différence des énergies internes avec la configuration précédemment retenue vérifie le critère de Metropolis :

$$\mathrm{P} = \exp\left(-\frac{U_n - U_{n-1}}{k_B T} \right) < \xi_{random} \quad \text{avec} \;\; 0 \le \xi_{random} \le 1$$

Avantage : il est inutile de calculer les forces microscopiques du système $\mathcal{M}$, par construction, la méthode Monte-Carlo génère une distribution canonique

Inconvénient : il faut éviter de générer des configurations inutiles (dont le poids statistique est négligeable). Il n'est pas toujours évidents de générer des configurations de manière aléatoire, surtout lorsque des contraintes fortes affectent le particules du système $\mathcal{M}$.

http://www.insp.jussieu.fr/jsnum/Old/MC_Metropolis.pdf

ISM1 –THERMODYNAMIQUE STATISTIQUE VS SIMULATION

Des notions élémentaires de thermodynamique statistique permettent de vérifier la validité d'un échantillonnage, voire d'un code.

Cas d'un potentiel d'interaction à symétrie sphérique *G(r)*, par exemple potentiel effectif d'un ion qui interagit avec une goutte d'eau modélisée par son seul centre de masse CM.

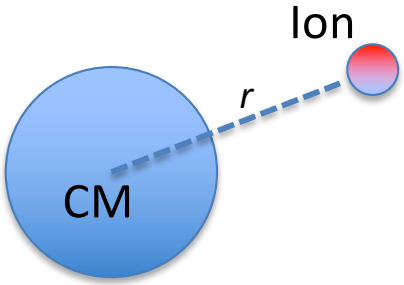

$$Z = \iiint \exp\left(-\frac{G(r)}{k_B T}\right) d\vec{r} = \int_0^{+\infty} \exp\left(-\frac{G(r)}{k_B T}\right) \times 4\pi r^2 dr$$

La probabilité de trouver l'ion à un distance *r* de CM :

$$\boldsymbol{p(r) = \exp\left(-\frac{G(r)}{k_B T}\right) \times 4\pi r^2 dr}$$

Zone d'exclusion $p(r \to 0) \approx 0$

G(r) a un comportement « physique »
i.e. G(r) est bornée en tout point de l'espace

Les ions, qui ont une grande affinité pour l'eau, ne peuvent pas être observés au centre d'une goutte d'eau…

La probabilité de trouver l'ion à un distance *r* de CM :

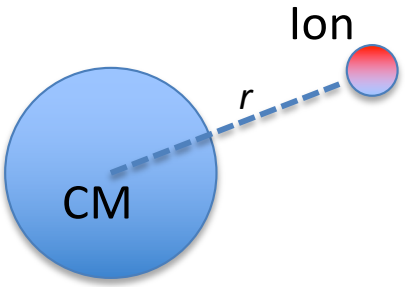

$$p(r:r+dr) = \exp\left(-\frac{G(r)}{k_B T}\right) \times 4\pi r^2 dr \sim \exp\left(-\frac{G(r)-2k_B T ln(r)}{k_B T}\right) \times dr$$

On peut interpréter le nouveau potentiel d'interaction ion/goutte d'eau $G(r) - 2k_B T\ln(r)$ comme la somme de deux termes :

- le premier de nature 'enthalpique' $G(r)$
- le second purement entropique $-2k_B T\ln(r)$

Il y a donc une compétition entre le potentiel $G(r)$ qui a tendance a attiré l'ion vers (dans) la goutte d'eau et le terme $-2k_B T\ln(r)$qui favorise la dissociation de l'ion de la goutte d'eau…

ISM1 – ANNALE EXAMEN 2019

I.1 Rappeler la définition de la grandeur thermodynamique énergie libre *F* en fonction des grandeurs énergie interne *U*, entropie *S* et température T.
Réponse : une ligne maximum

I.2 Comment varie la grandeur énergie libre *F* lors de l'évolution spontanée d'un système microscopique isolé ?
Réponse : une ligne maximum

I.3 Supposons qu'un système microscopique isolé présentent deux états d'équilibre A et B pour lesquels la courbure de la surface d'énergie potentielle au voisinage de ceux états est identique. Quelle grandeur thermodynamique va permettre d'évaluer la stabilité relative de ces deux états ?
Réponse : l'énergie interne, l'enthalpie, l'entropie ?

I.4 Cette grandeur sera-t-elle la plus grande ou la plus faible pour l'état le plus stable entre A et B ?
Réponse : une ligne maximum

I.5 Un système microscopique isolé peut-il évoluer vers un état correspondant à la fois à un maximum de son énergie interne et de son entropie ?
Réponse : oui, non

1 – APPROCHE QUANTIQUE VS EMPIRIQUE

2 – CHAMP DE FORCE ADDITIF CLASSIQUE

3 – CHAMP DE FORCE POLARISABLE

ISM2 –SYSTÈME MICROSOCOPIQUE

Un système microscopique $\mathcal{M}$ se caractérise par un ensemble de *N* particules (petites molécules et/ou groupements chimiques et/ou atomes) associées à un jeu de *N* coordonnées $\{\vec{r}_i\}_{1\le i\le N}$ qui correspond à une configuration du système microscopique :

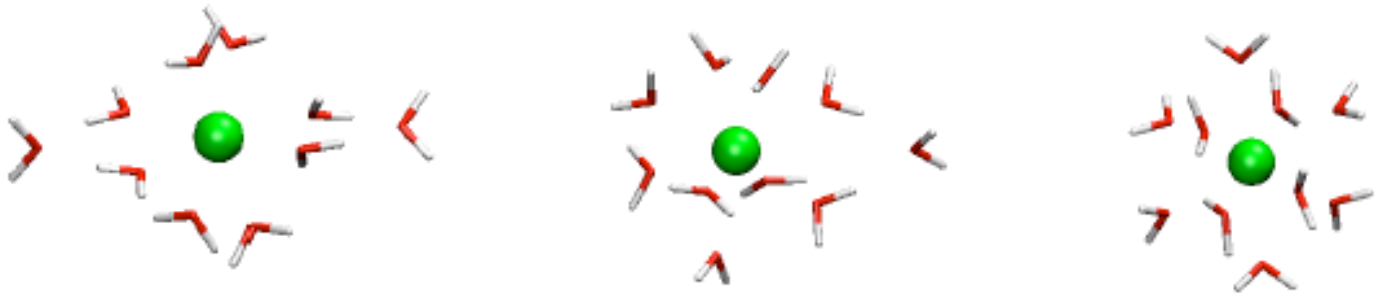

On appelle interactions microscopiques, les interactions physiques entre les *N* particules définissant le système $\mathcal{S}$. Par exemple, l'interaction coulombienne entre deux particules chargées

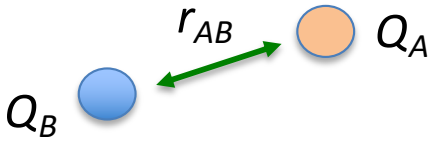

$$U(A,B)=\frac{1}{4\pi\varepsilon_0}\frac{Q_AQ_B}{r_{AB}}$$

La somme des interactions microscopiques définit l'énergie potentielle *U* du système microscopique $\mathcal{M}$. L'énergie potentielle *U* ne dépend que du jeu de coordonnées $\{\vec{r}_i\}_{1\le i\le N}$. Le système $\mathcal{M}$ se caractérise aussi par un jeu de vitesses de ses particules. Ces vitesses définissent son énergie cinétique *K* :

$$E(\{\vec{r}_i,\vec{v}_i\}_{1\le i\le N})=U(\{\vec{r}_i\}_{1\le i\le N})+K(\{\vec{v}_i\}_{1\le i\le N})=U(\{\vec{r}_i\}_{1\le i\le N})+\frac{1}{2}\sum_{i=1}^{N}m_iv_i^2=U(\{\vec{r}_i\}_{1\le i\le N})+\frac{1}{2}\sum_{i=1}^{N}\frac{p_i^2}{m_i}$$

ISM2 – ENERGIE MICROSCOPIQUE

Fonction de partition *Z* d'un système $\mathcal{M}$ composé de *N* particules et étudié à une température définie *T*

$$Z = \frac{1}{A}\iiint_V \exp\left(-\frac{U(\{\vec{r}_i\}_{1\le i\le N})}{k_B T}\right)\Pi_{i=1}^{N} d\vec{r}_i$$

Energie microscopique *U* du système $\mathcal{M}$ qui ne dépend que des coordonnées $\{\vec{r}_i\}_{1\le i\le N}$

Deux approches pour calculer *U :*

1 – Méthodes quantiques (*ab initio* ou DFT)

2- Potentiels empiriques appelés champs de force (ou fonctions de coût)

Soit un système microscopique $\mathscr{M}$ de *M* atomes et de *N* électrons, l'approche physique la plus pertinente pour calculer ses propriétés est de résoudre l'équation de Schrödinger :

$$\tilde{\mathrm{H}}\Psi = E\Psi$$

$\tilde{\mathrm{H}}$ est l'Hamiltonien du système $\mathscr{M}$ qui décrit les interactions entre les orbitales du système

Ψ est la fonction d'onde du système $\mathscr{M}$ qui décrit sa structure électronique dans l'espace. C'est un vecteur complexe qui se décompose sur des bases d'orbitales atomiques. Sa norme est interprétée comme la densité de probabilité de présence d'un électron en un point de l'espace :

$$\rho_e(\vec{r}) = \left|\Psi(\vec{r})\right|^2$$

Cette approche, en particulier les méthodes *ab initio*, donne des résultats particulièrement précis par comparaison avec l'expérience. Mais c'est une approche lourde en temps de calcul. Pour chaque atome il faut considérer une jeu d'une centaine de bases atomiques, les matrices à diagonaliser sont donc de très grande taille et chacun de leurs éléments est le résultat d'un calcul d'intégral volumique.

ISM2 – CHAMP DE FORCE

Un champ de force est un potentiel d'interaction empirique *U* traitant de manière implicite les électrons d'un système microscopique. **Ce potentiel ne dépend que des coordonnées des centres atomiques** (ou du centre de masse d'un groupe d'atome dans le cas d'approches dites gros grains.)

***U* est toujours définie comme une fonction continue et dérivable** et dont sa dérivée est également continue (pour garantir la conservation de l'énergie totale d'un système lors d'un simulation de dynamique moléculaire).

Il n'y a pas de règle générale pour définir la forme analytique de *U*, elle doit permettre de reproduire au mieux (avec une jeu de paramètres adaptés) les propriétés microscopiques d'un système donné.

Les progrès des ces dernières deux décennies laissent envisager à terme de disposer de potentiels *U* (associés à des jeux de paramètres pertinents) capables de décrire avec précision des systèmes moléculaires dans des conditions physiques (T,P) variées mais également au sein de milieux hétérogènes. C'est la vocation de **la nouvelle génération de champs de force dits "*ab initio*"**.

ISM2 – ENERGIE D'INTERACTION ET COOPÉRATIVITÉ

L'énergie microscopique totale d'un système $\mathcal{M}$ peut se décomposer sous la forme

$$U = \underbrace{\sum_i u_i(\vec{r}_i) + \sum_i \sum_{j>i} u_{ij}(\vec{r}_i,\vec{r}_j)}_{\text{potentiel additifs}} + \underbrace{\sum_i \sum_{j>i} \sum_{k>j} u_{ijk}(\vec{r}_i,\vec{r}_j,\vec{r}_k) + \ldots}_{\text{Effets à N-corps}}$$

$u_i(\vec{r}_i)$ Énergie interne d'une des particules décrivant le système (particle = atome, $u_i = 0$)

$u_{ij}(\vec{r}_i,\vec{r}_j)$ Énergie de paires (i,j), par exemple le terme Coulombien $\frac{q_i q_j}{\left|\vec{r}_i - \vec{r}_j\right|}$

$u_{ijk}(\vec{r}_i,\vec{r}_j,\vec{r}_k)$ Effets à 3-corps (cf. champ de force polarisable), peuvent représenter jusqu'à 20% de *U,* les effets d'ordre supérieur sont en général bien plus faibles.

La grande majorité des champs de force employés aujourd'hui sont de nature additive pour les interactions entre atomes "non liés".

Exemple du polysiloxane (le silicone…)

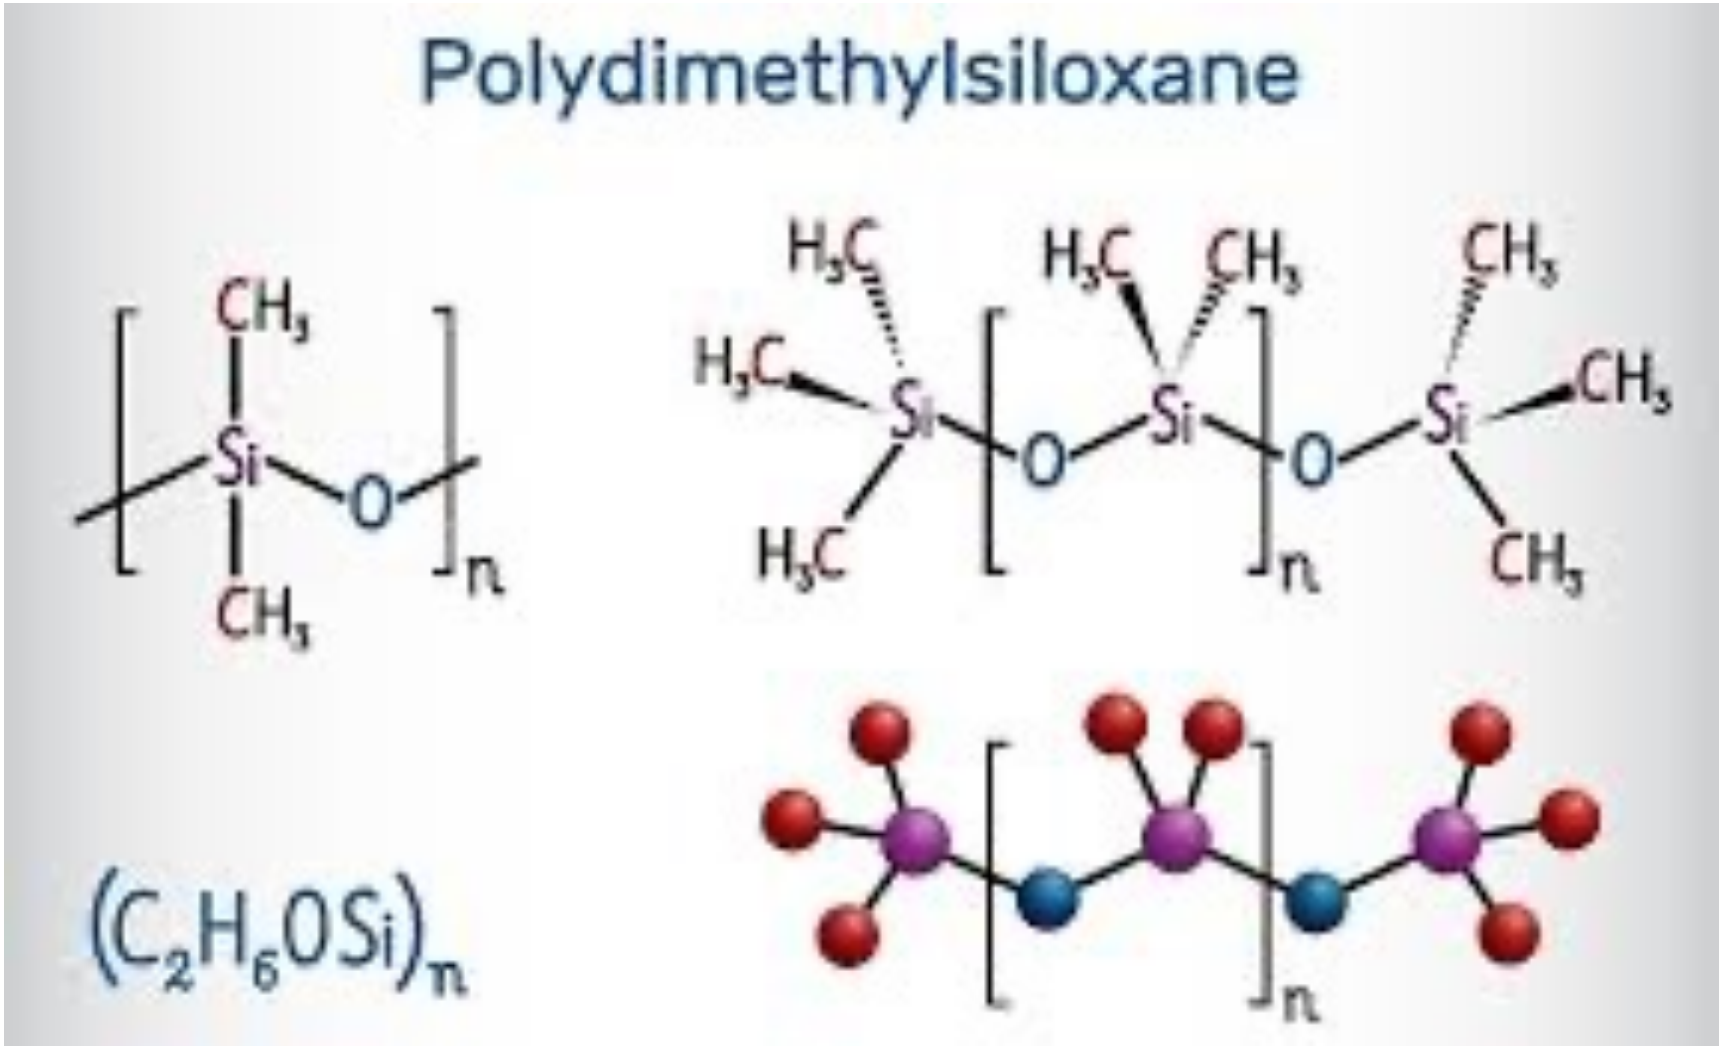

ISM2 – CHAMPS DE FORCE : HIÉRARCHISATION DES INTERACTIONS MICROSCOPIQUES

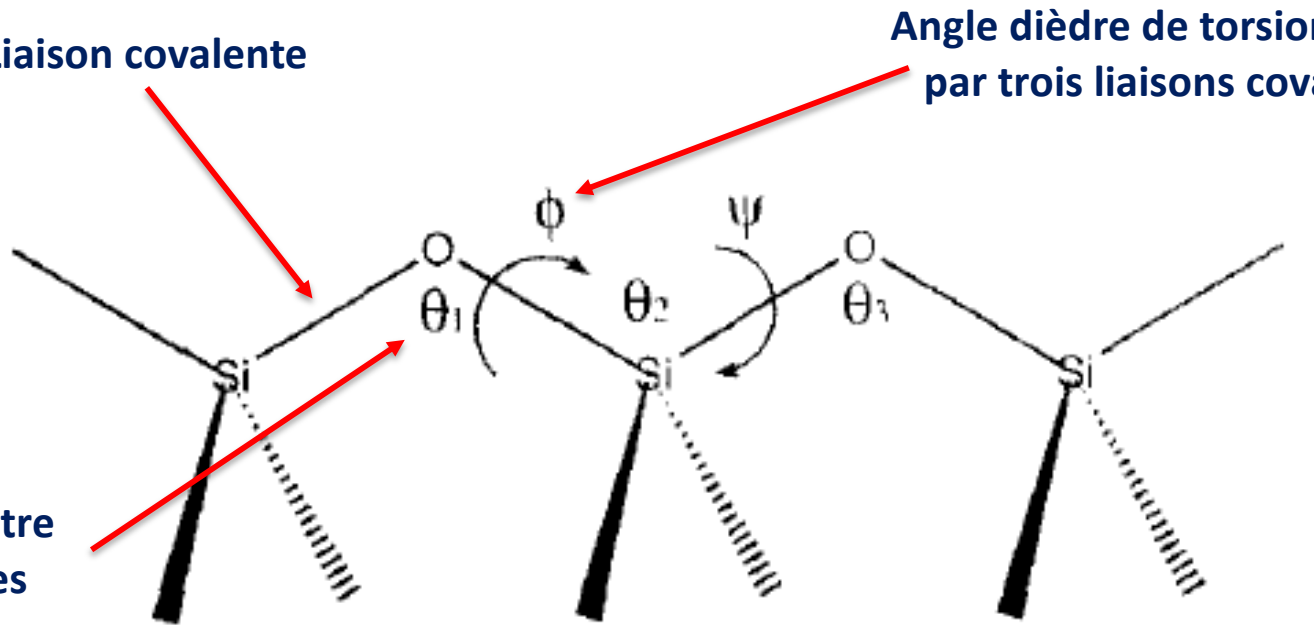

Interactions entre atomes liés (chimiquement)

Interaction entre atomes d'un même liaison covalente ou définissant un angle covalent

Interactions entre atomes non liés

Interaction entre atomes distants de plus de trois liaisons chimiques

Cas particulier pour les atomes 1-4 d'un angle dièdre de torsion

ISM2 – CAS DE DEUX ATOMES LIÉS PAR UNE LIAISON CHIMIQUE COVALENTE

Soient A et B deux atomes liés par une liaison covalente, on peut alors approximer leur potentiel d'interaction à un terme harmonique dépendant de la distance entre ces deux atomes

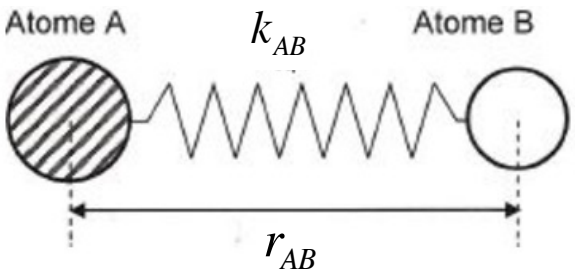

$$U_{AB}^{stretch} = k_{AB}(r_{AB} - r_{AB}^{0})^2$$

Terme à deux corps (additif), d'ordre O(*N*)
car un atome est impliqué dans un nombre limité de liaisons chimiques (en général ≤ 4)

Les paramètres k_{AB} et r_{AB}^{0} sont définis afin de reproduire des données expérimentales (structures cristallographiques, spectres de vibration …) ou des données issues de calculs quantiques.

Il existe de nombreux champs de force qui considèrent un développement plus important, mais ils sont de moins en moins employés

$$U_{AB}^{stretch} = k_{AB}\left(r_{AB} - r_{AB}^{0}\right)^2 + \delta_{AB}\left(r_{AB} - r_{AB}^{0}\right)^3 + \ \ldots$$

ISM2 – GRADIENT ANALYTIQUE EN COORDONNÉES CARTÉSIENNES

Soient A et B deux atomes définis par leurs coordonnées $\vec{r}_A = (x_A, y_A, z_A)$ et $\vec{r}_B = (x_B, y_B, z_B)$

$$U_{AB}^{stretch} = k_{AB}\left(r_{AB} - r_{AB}^0\right)^2 = k_{AB}\left(\sqrt{(x_A - x_B)^2 + (y_A - y_B)^2 + (z_A - z_B)^2} - r_{AB}^0\right)^2$$

Gradient analytique de $U_{AB}^{stretch}$ en fonction des coordonnées des deux atomes A et B

$$\frac{\partial U_{AB}^{stretch}}{\partial x_A} = 2k_{AB}(r_{AB} - r_{AB}^0)\frac{\partial r_{AB}}{\partial x_A} = 2k_{AB}(r_{AB} - r_{AB}^0)\frac{x_A - x_B}{r_{AB}} = -\frac{\partial U_{AB}^{stretch}}{\partial x_B}$$

Remarque :

Dérivée de la fonction $g(\mathrm{x}) = \sqrt{f(x)}$ => $\frac{f\prime(x)}{\sqrt{f(x)}}$ avec $f'(x)$ dérivée de la fonction $f(x)$

ISM2 – CAS DE TROIS ATOMES LIÉS PAR DES LIAISONS CHIMIQUES COVALENTES

Soient A, B et C trois atomes liés deux à deux par une liaison covalente, on peut alors approximer leur potentiel d'interaction à une somme de deux termes harmoniques dépendant chacun des distances entre A et B et entre B et C, et d'un terme hamornique angulaire

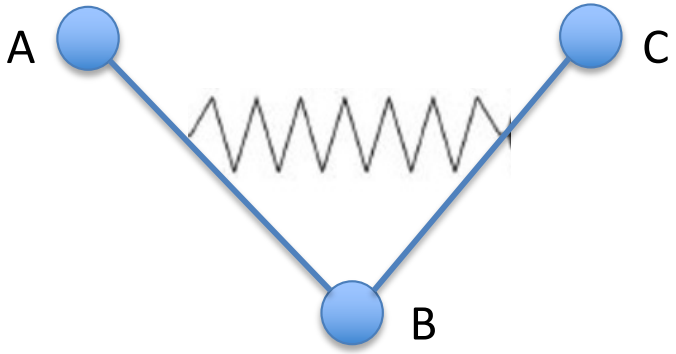

$$U^{bending} = k_{ABC}(\theta_{ABC} - \theta^0_{ABC})^2$$

Terme à trois corps, d'ordre O(*N*)
car un atome est impliqué dans un nombre limité de liaisons chimiques (en général ≤ 4)

Remarques :

- Les deux liaisons covalentes sont décrites par $U^{stretch} = k_{AB}(r_{AB} - r^0_{AB})^2 + k_{BC}(r_{BC} - r^0_{BC})^2$

- A, B et C sont définis par leur vecteurs positions $\vec{r}_A, \vec{r}_B$ et $\vec{r}_C$. L'angle θ_{ABC} se calcule suivant

$$\cos(\theta_{ABC}) = \frac{(\vec{r}_A - \vec{r}_B)\cdot(\vec{r}_C - \vec{r}_B)}{|\vec{r}_A - \vec{r}_B| \cdot |\vec{r}_C - \vec{r}_B|} = f(\vec{r}_A, \vec{r}_B, \vec{r}_C)$$

ISM2 – GRADIENT ANALYTIQUE EN COORDONNÉES CARTÉSIENNES

Coordonnées des atomes *A*, *B* et *C* : $\vec{r}_A = (x_A, y_A, z_A)$ $\vec{r}_B = (x_B, y_B, z_B)$ et $\vec{r}_C = (x_C, y_C, z_C)$

$$U^{bending} = k_{ABC}(\theta_{ABC} - \theta^0_{ABC})^2 \quad \text{et} \quad \cos(\theta_{ABC}) = \frac{(\vec{r}_A - \vec{r}_B)\cdot(\vec{r}_C - \vec{r}_B)}{|\vec{r}_A - \vec{r}_B|\cdot|\vec{r}_C - \vec{r}_B|} = f(\vec{r}_A, \vec{r}_B, \vec{r}_C)$$

Gradient analytique de $U^{bending}$:

$$\frac{\partial U^{bending}_{ABC}}{\partial x_A} = 2k_{ABC}(\theta_{ABC} - \theta^0_{ABC})\frac{\partial \theta_{ABC}}{\partial x_A}$$

Pour calculer la dérivée de l'angle θ_{ABC}, il faut repasser par l'expression de son cosinus

$$\frac{\partial \cos(\theta_{ABC})}{\partial x_A} = -\sin(\theta_{ABC})\frac{\partial \theta_{ABC}}{\partial x_A} = \frac{\partial f(\vec{r}_A, \vec{r}_B, \vec{r}_C)}{\partial x_A} \Rightarrow \boxed{\frac{\partial \theta_{ABC}}{\partial x_A} = -\frac{1}{\sin(\theta_{ABC})} \times \frac{\partial f(\vec{r}_A, \vec{r}_B, \vec{r}_C)}{\partial x_A}}$$

Attention pour des valeurs d'angles proches de 0° ou 180°…

ISM2 – CAS DE LA MOLÉCULE D'EAU

Une molécule d'eau est une molécule triatomique qui peut donc être traitée par le potentiel d'interaction total :

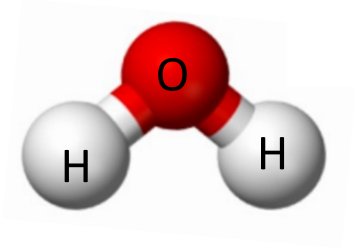

$$U^{stretch} = k_{OH}(r_{OH1} - r_{OH}^0)^2 + k_{OH}(r_{OH2} - r_{OH}^0)^2$$

$$U^{bending} = k_{HOH}(\theta_{HOH} - \theta_{HOH}^0)^2$$

Mais un tel potentiel ne permet pas de reproduire avec précision le spectre de vibration d'une molécule d'eau isolée. Il faut lui ajouter un terme dit croisé

$$U^{cross} = k_{OH}^*(r_{OH1} - r_{OH}^0)(r_{OH2} - r_{OH}^0)$$

L'emploi d'un champ de force est toujours un choix entre précision et efficacité.

Remarque :

Pour des raisons d'efficacité, on contraint les liaisons de type XH dans des simulations microscopiques (dans ce cas les propriétés vibrationnelles de l'eau ne sont pas l'objet de l'étude)

ISM2 – CAS DE QUATRE ATOMES LIÉS PAR DES LIAISONS CHIMIQUES COVALENTES

Soient A, B, C et D quatre atomes liés deux à deux par une liaison covalente, on peut alors approximer leur potentiel d'interaction à une somme de trois termes harmoniques dépendant chacun des distances entre A et B, entre B et C, et entre C et D, de deux termes harmoniques angulaires ABC et BCD et d'un terme de torsion

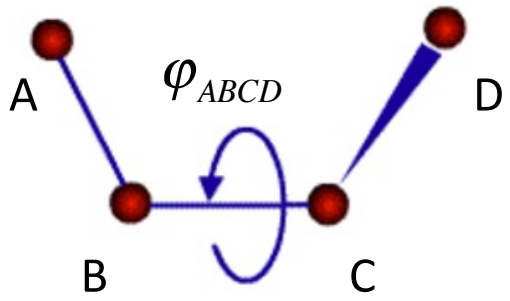

$$U^{stretch} = k_{AB}(r_{AB} - r_{AB}^0)^2 + k_{BC}(r_{BC} - r_{BC}^0)^2 + k_{CD}(r_{CD} - r_{CD}^0)^2$$

$$U^{bending} = k_{ABC}(\theta_{ABC} - \theta_{ABC}^0)^2 + k_{BCD}(\theta_{BCD} - \theta_{BCD}^0)^2$$

$$U^{torsion} = \sum_{n=1}^{3} v_n \cos\left(n(\varphi_{ABCD} - \varphi_{ABCD}^0)\right)$$

$$\vec{\omega}_1 = \frac{(\vec{r}_A - \vec{r}_B) \wedge (\vec{r}_C - \vec{r}_B)}{|\vec{r}_A - \vec{r}_B| \cdot |\vec{r}_C - \vec{r}_B|} \quad \text{et} \quad \vec{\omega}_2 = \frac{(\vec{r}_B - \vec{r}_C) \wedge (\vec{r}_D - \vec{r}_C)}{|\vec{r}_B - \vec{r}_C| \cdot |\vec{r}_D - \vec{r}_C|} \rightarrow \cos(\varphi_{ABCD}) = \vec{\omega}_1 \cdot \vec{\omega}_2 = f(\vec{r}_A, \vec{r}_B, \vec{r}_C, \vec{r}_D)$$

Formellement, il s'agit d'un terme à quatre corps, d'ordre O(*N*).

https://fr.khanacademy.org/science/organic-chemistry/bond-line-structures-alkanes-cycloalkanes/conformations-alkanes-cycloalkanes/v/conformational-analysis-of-ethane

ISM2 – INTERACTION ENTRE ATOMES NON LIÉS, TERME DE LENNARD JONES

Soient A et B deux atomes non liés chimiquement, le terme de Lennard Jones est introduit pour modéliser la forte répulsion due aux interactions électron/électron lorsque A et B se rapproche, ainsi que les phénomènes dits de dispersion (force de *van der Waals*) :

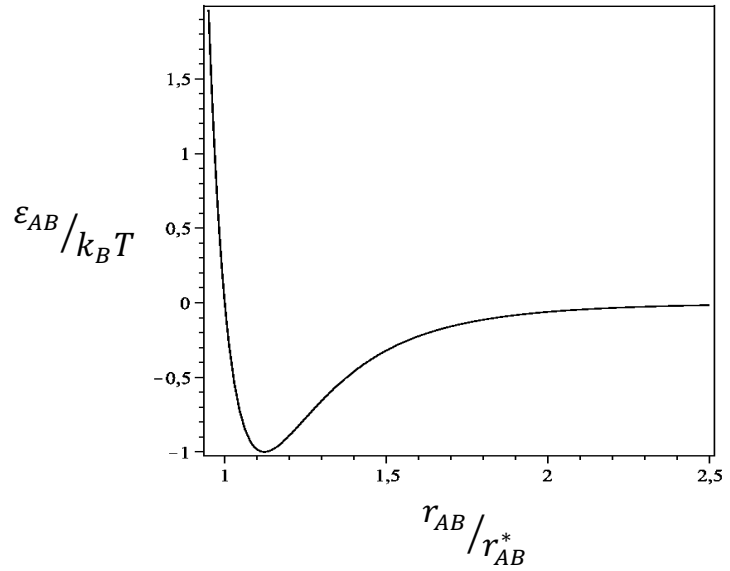

$$U^{LJ} = 4\varepsilon_{AB}\left[\underbrace{\left(\frac{r^*_{AB}}{r_{AB}}\right)^{12}}_{répulsion} - \underbrace{\left(\frac{r^*_{AB}}{r_{AB}}\right)^{6}}_{dispersion}\right]$$

Terme à deux corps (additifs) mais d'ordre O(N^2).

ε_{AB} et r^*_{AB} sont deux paramètres

L'origine des forces de dispersion peut s'expliquer dans le cadre d'un formalisme quantique. Elles sont à distinguer des interactions de type électrostatique, en r_{AB}^{-1}…

Ce terme est très courant dans les champs de force mais :

- il décrit mal les phénomènes de répulsion inter atomique à courte portée
- seul, il ne peut s'employer que pour décrire des molécules non chargées/non polaires.

ISM2 – TERME DE LENNARD JONES ET EFFICACITÉ NUMÉRIQUE

La convergence rapide vers zéro d'un terme de Lennard Jones permet d'employer un rayon de coupure

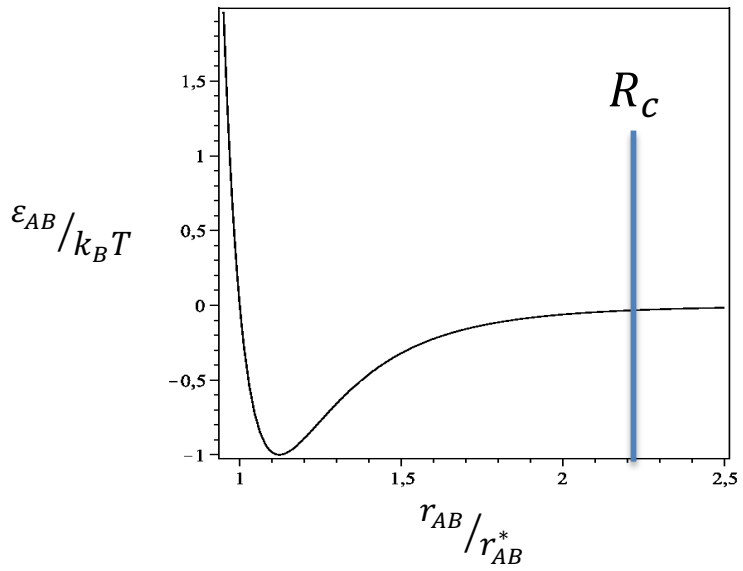

$$U^{LJ} = 4\sum_{i=1}^{N}\sum_{j>i}^{N}\varepsilon_{ij}^{*}\left[\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{12} - 2\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{6}\right] \quad O(N^2)$$

$$U^{LJ} \approx 4\sum_{i=1}^{N}\sum_{j/r_{ij}<R_c}\varepsilon_{ij}^{*}\left[\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{12} - 2\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{6}\right] \quad O(N)$$

La densité de la matière étant bornée, le nombre d'atomes voisins d'un atome *i* est borné, d'où une complexité ***a priori*** en *O(N)* lors de l'emploi d'un rayon de coupure.

ISM2 – TERME DE LENNARD JONES ET GRADIENT ANALYTIQUE

Terme de Lennard Jones

$$U^{LJ} = 4\sum_{i=1}^{N}\sum_{j>i}^{N}\varepsilon_{ij}^{*}\left[\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{12} - 2\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{6}\right] = \sum_{i=1}^{N}\sum_{j>i}^{N}u_{ij}(r_{ij})$$

Gradient analytique associé aux fonctions élémentaires u_{ij} :

$$\frac{\partial u_{ij}}{\partial x_i} = -4\varepsilon_{ij}^{*}\left[12\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{13} - 2\times 6\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{7}\right]\times\frac{\partial r_{ij}}{\partial x_i} = -48\varepsilon_{ij}^{*}\left[\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{14} - \left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{8}\right]\times(x_i - x_j)$$

Lors du calcul du terme de Lennard Jones et de son gradient analytique, nul besoin de calculer les distances r_{ij}, seulement leur carré :

=> on épargne ainsi un grand nombre de calculs de racine carrée…

ISM2 – INTERACTION ENTRE ATOMES NON LIÉS, TERME COULOMBIEN - 1

Soient A et E deux atomes non liés chimiquement, les propriétés de leurs nuages électroniques peuvent être décrites comme résultant de la présence de deux charges partielles sur ces atomes

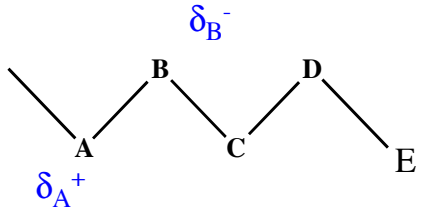

➔ $U^{Coulomb} = \frac{\delta_A \delta_E}{r_{AE}}$ ➔ Les charges électrostatiques sont des paramètres statiques lors d'une simulation !

Remarques :

1 – dans tous les champs de force disponibles, les interactions entre atomes non liés correspondent à des interactions entre atomes distants de plus de deux liaisons chimiques (i.e. A et C sont liés, pas A et D)

2 – toutefois, les paramètres du terme de Lennard Jones et du terme de Coulomb pour les atomes séparés par 3 liaisons chimiques (A et D) sont redondant avec le terme de torsion ABCD. Généralement, le terme de Lennard Jones et de Coulomb sont 'atténués' pour des atomes de type A/D.

3 – les approches de rayons de coupure ne sont as adaptées au terme Coulombien…

ISM2 – INTERACTION ENTRE ATOMES NON LIÉS, TERME COULOMBIEN - 2

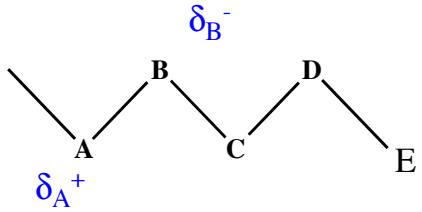

$$U^{Coulomb} = \frac{\delta_A \delta_E}{r_{AE}}$$

Les charges localisées sur les atomes d'un système $\mathcal{M}$ sont définies en général afin de reproduire le moment dipolaire des molécules constituant $\mathcal{M}$ (si ces molécules sont neutres).

$$\vec{M} = \sum_{i=1}^{n} q_i \vec{r}_i$$

L'inconvénient majeur est que le moment dipolaire d'une molécule neutre varie en fonction de son environnement, par exemple

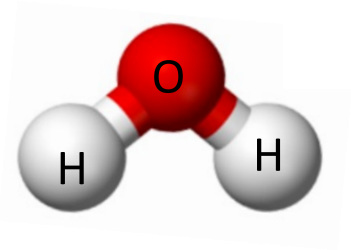

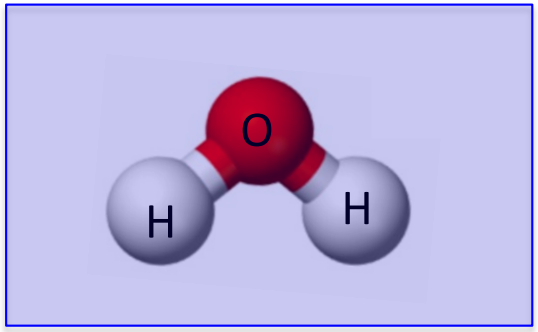

Phase	gaz	aqueuse
Dipole	1.85 Debye	estimé entre 2.5 et 3.0 Debye
Charge O	-0.66 e	< -0.80 e

ISM2 – INTERACTION ENTRE ATOMES NON LIÉS, TERME COULOMBIEN - 3

Un terme Coulombien basé sur des charges fixes (statiques) lors d'une simulation ne peut modéliser correctement des molécules polarisables (i.e. dont le moment dipolaire varie) dans des milieux hétérogènes. C'est en particulier le cas de molécules proches d'une interface de type liquide/vapeur :

Cas de l'eau à l'interface liquide/vapeur

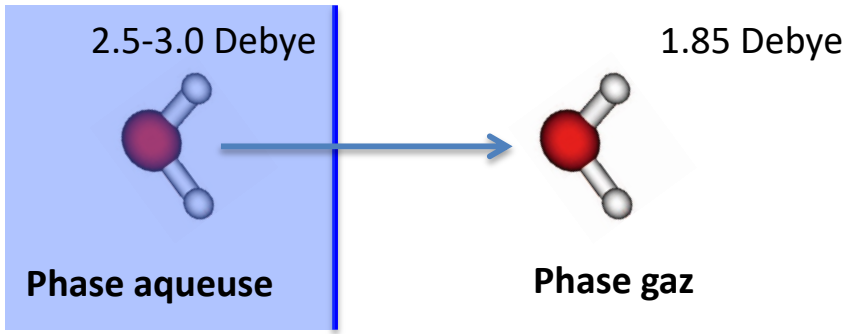

Moment dipolaire d'une molécule d'eau

$$\vec{M} = \sum_{i=O,H,H} q_i \cdot \vec{r}_i$$

La géométrie d'une molécule d'eau varie faiblement au passage de l'interface et les charges q_i sont constantes…

Quel jeu de charges faut-il considérer pour les molécules d'eau pour reproduire la variation du moment dipolaire moléculaire l'eau lors du passage de l'interface liquide/vapeur ?

ISM2 – INTERACTIONS ENTRE ATOMES NON LIÉS, TERME DE POLARISATION

A l'interface eau condensée/vapeur, quel jeu de charges considérer pour les molécules d'eau ?

Une solution : considerer un champ de force polarisable

Trois grandes familles de champs de force polarisable :

1 – Méthode de la charge fluctuante. Les charges q_i peuvent varier sous l'effet du milieu extérieur. **Les bases physiques de cette approche ne sont pas fondées.**

2 – Oscillateurs de Drude. Un atome est représenté par une charge fixe q_i et par un jeu de charges $q_{i,j}^D$ liés à cet atome par des ressorts dont la position s'adapte au potentiel électrostatique généré par le milieu extérieur. **Modèle physique fondé, peu de choses à reprendre dans les codes classiques de modélisation moléculaire, mais pas de temps réduits…**

3 – Moments dipolaires induits. Un atome est représenté par une charge q_i et par un moment dipolaire $\vec{\mu}_i$ qui dépend du champ électrique extérieur. **Modèle physique fondé, pas de temps bien plus grand que pour les oscillateurs de Drude, mais codes de dynamique moléculaire à reprendre…**

ISM2 - MOMENTS DIPOLAIRES INDUITS

Les moments dipolaires dépendent du champ électrique généré par les charges statiques q_j environnantes et par les autres moments dipolaires $\vec{\mu}_j$:

$$\vec{\mu}_i = \alpha_i \left(\vec{E}_i + \sum_{i=1, i\neq j}^{n} \boldsymbol{T}\left|\vec{r}_i - \vec{r}_j\right| \otimes \vec{\mu}_j \right) \Rightarrow$$

ces équations se résolvent de manière itérative, et sont d'ordre O(N^2)

Le champ électrique est le gradient du potentiel électrostatique généré par les charges q_i

$$\vec{E}_i = -\vec{\nabla}_i \Phi = -\vec{\nabla}_i \left(\sum_{i\neq j} \frac{q_j}{\left|\vec{r}_i - \vec{r}_j\right|} \right) = -\sum_{i\neq j} \vec{\nabla}_i \left(\frac{q_j}{\left|\vec{r}_i - \vec{r}_j\right|} \right) = \sum_{i\neq j} \frac{q_j (\vec{r}_i - \vec{r}_j)}{\left|\vec{r}_i - \vec{r}_j\right|^3}$$

T est le tenseur de polarisabilité qui s'écrit

$$\boldsymbol{T}\left|\vec{r}_i - \vec{r}_j\right| = \vec{\nabla}_i \left(\vec{\nabla}_j \left(\frac{1}{\left|\vec{r}_i - \vec{r}_j\right|} \right) \right) = \frac{3\vec{r}_i \otimes \vec{r}_j}{\left|\vec{r}_i - \vec{r}_j\right|^5} - \frac{1}{\left|\vec{r}_i - \vec{r}_j\right|^3}$$

Remarque : l'opérateur $\vec{\nabla}_i \times \vec{\nabla}_j$ n'est pas l'opérateur $\vec{\nabla}_i^2 = \frac{\partial^2}{\partial x_i^2} + \frac{\partial^2}{\partial y_i^2} + \frac{\partial^2}{\partial z_i^2}$

ISM2 - MOMENTS DIPOLAIRES INDUITS – ENERGIE ÉLECTROSTATIQUE TOTALE

Soit un système $\mathcal{M}$ constitué de M charges q_i et de M moments dipolaires $\vec{\mu}_i$, son énergie électrostatique totale est la somme de l'énergie Coulombienne et de l'énergie de polarisation :

$$U^{elec} = \sum_{i=1}^{M}\sum_{j>i}^{M}\frac{q_i q_j}{\left|\vec{r}_i-\vec{r}_j\right|} - \sum_{i=1}^{M}\sum_{j\neq i}^{M}\frac{q_j\vec{\mu}_i(\vec{r}_i-\vec{r}_j)}{\left|\vec{r}_i-\vec{r}_j\right|^3} - \sum_{i=1}^{M}\sum_{j>i}^{M}\vec{\mu}_i\otimes T\left|\vec{r}_i-\vec{r}_j\right|\otimes\vec{\mu}_j$$

$$= \underbrace{\sum_{i=1}^{M}\sum_{j>i}^{M}\frac{q_i q_j}{\left|\vec{r}_i-\vec{r}_j\right|}}_{Coulomb} - \underbrace{\sum_{i=1}^{M}\sum_{j\neq i}^{M}\frac{q_j\vec{\mu}_i(\vec{r}_i-\vec{r}_j)}{\left|\vec{r}_i-\vec{r}_j\right|^3} - \sum_{i=1}^{M}\sum_{j>i}^{M}\frac{3\left(\vec{\mu}_i.\vec{r}_i\right)\times\left(\vec{\mu}_j.\vec{r}_j\right)}{\left|\vec{r}_i-\vec{r}_j\right|^5} - \frac{\vec{\mu}_i.\vec{\mu}_j}{\left|\vec{r}_i-\vec{r}_j\right|^3}}_{Polarisation}$$

On peut réécrire cette relation de manière plus compacte avec l'opérateur $q_i+\vec{\mu}_i.\vec{\nabla}_i$

$$U^{elec} = \frac{1}{2}\sum_{i=1}^{M}\sum_{j=1,j\neq i}^{M}(q_i+\vec{\mu}_i.\vec{\nabla}_i)\times(q_j+\vec{\mu}_j.\vec{\nabla}_j)\left(\frac{1}{\left|\vec{r}_i-\vec{r}_j\right|}\right)$$

ISM2 – POLARISATION ET COOPÉRATIVITÉ

Considérons le champ électrique généré par les charges Q_1 *et* Q_2 de deux ions sur une molécule d'eau intercalée entre eux

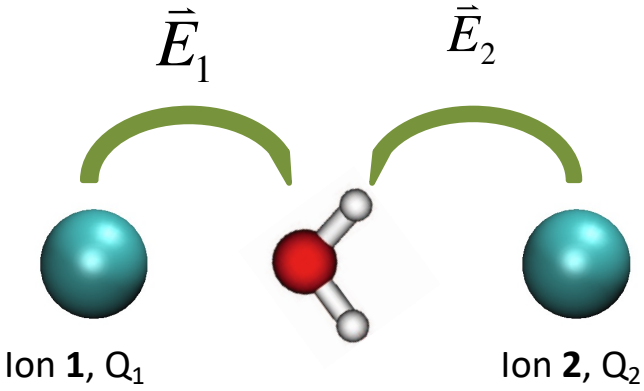

Si les ions ne sont pas polarisables, l'énergie de polarisation s'écrit

$$U^{pol} = -\vec{\mu}_{eau} \cdot (\vec{E}_1 + \vec{E}_2) = -\alpha_{eau} \left(\vec{E}_1 + \vec{E}_2\right).\left(\vec{E}_1 + \vec{E}_2\right) = -\alpha_{eau} \left(\underbrace{E_1^2 + E_2^2}_{\text{Terme additif}} + \underbrace{2\vec{E}_1 \cdot \vec{E}_2}_{\text{Terme à N-corps}} \right)$$

ISM2 – POLARISATION - CONCLUSION

Les champs de force polarisables sont une avancée majeure dans le domaine de la simulation moléculaire. Ils améliorent très nettement la “transférabilité” des champs de force pour traiter une même molécule à l’interface de milieux distincts, cas des interactions ligand/protéine :

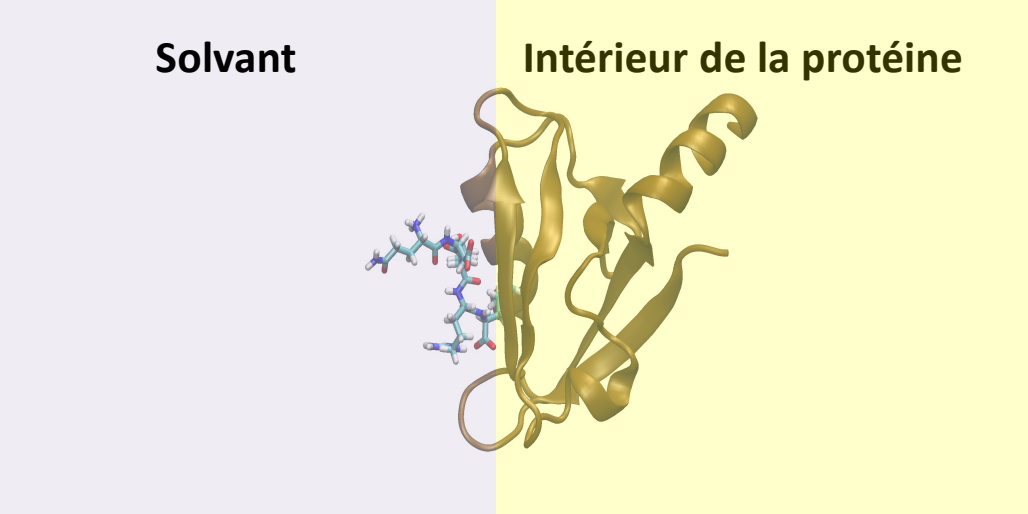

Par exemple, tous les champs de force polarisable, reproduisent bien l’augmentation du moment dipolaire d’une molécule d’eau lorsqu’elle franchit l’interface eau liquide/vapeur.

Ces champs de force polarisable sont le futur de la simulation moléculaire à l’horizon de 10 ans (certainement moins), mais ils nécessitent dès aujourd’hui d’être pris en compte dans le développement de codes de simulation moléculaire.

ISM2 – EXERCICES

1 – Soient trois atomes A, B et C liés par une liaison chimique deux à deux. Donner l'expression du terme de bending et de son gradient analytique. Le produit scalaire permettant de calculer l'angle ABC sera noté $f(\vec{r}_A, \vec{r}_B, \vec{r}_C)$ et sa dérivée $\partial f(\vec{r}_A, \vec{r}_B, \vec{r}_C)$.

2 – Dans le cas où ABC est une molécule linéaire (comme CO_2), quel problème d'ordre numérique pose le gradient analytique précédent ?

3 – Comment y remédier ?

4 - Dans le cas de molécule plane suivante (par exemple NO_3^-), peut on définir à l'aide d'un angle de torsion bien choisi une terme d'énergie qui force la molécule à rester plane en moyenne lors d'une simulation de type dynamique moléculaire ?

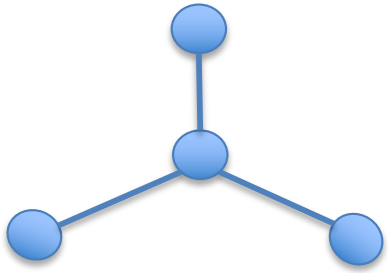

ISM2 – CORRECTION EXERCICES

1 – **Soient trois atomes A, B et C liés par une liaison chimique deux à deux. Donner l'expression du terme de bending et de son gradient analytique. Le produit scalaire permettant de calculer l'angle ABC sera noté** $f(\vec{r}_A,\vec{r}_B,\vec{r}_C)$ **et sa dérivée** $\partial f(\vec{r}_A,\vec{r}_B,\vec{r}_C)$ **.**

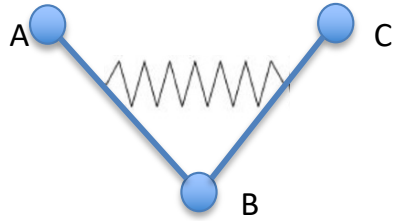

Par définition le terme de bending $U^{bending}$ est donné $U^{bending} = k_{ABC}(\theta_{ABC} - \theta^0_{ABC})^2$

L'angle θ_{ABC} entre trois atomes se calcule à partir de $\cos(\theta_{ABC}) = \dfrac{(\vec{r}_A - \vec{r}_B)\cdot(\vec{r}_C - \vec{r}_B)}{|\vec{r}_A - \vec{r}_B|\cdot|\vec{r}_C - \vec{r}_B|} = f(\vec{r}_A,\vec{r}_B,\vec{r}_C)$

Le gradient de $U^{bending}$ suivant une des coordonnées (x_A, y_A, z_A) de l'atome A vérifie

$$\frac{\partial U^{bending}_{ABC}}{\partial x_A} = 2k_{ABC}(\theta_{ABC} - \theta^0_{ABC})\frac{\partial \theta_{ABC}}{\partial x_A} \quad \text{avec} \quad \frac{\partial \cos(\theta_{ABC})}{\partial x_A} = -\sin(\theta_{ABC})\frac{\partial \theta_{ABC}}{\partial x_A} = \frac{\partial f(\vec{r}_A,\vec{r}_B,\vec{r}_C)}{\partial x_A}$$

Conclusion :

$$\frac{\partial U^{bending}_{ABC}}{\partial x_A} = 2k_{ABC}\left(\theta_{ABC} - \theta^0_{ABC}\right)\frac{\partial \theta_{ABC}}{\partial x_A} = -\frac{2k_{ABC}\left(\theta_{ABC} - \theta^0_{ABC}\right)}{\sin(\theta_{ABC})} \times \frac{\partial f(\vec{r}_A,\vec{r}_B,\vec{r}_C)}{\partial x_A}$$

2 – **Dans le cas où ABC est une molécule linéaire (comme CO_2), quel problème d'ordre numérique pose le gradient analytique précédent ?**

La molécule de CO2 est linéaire 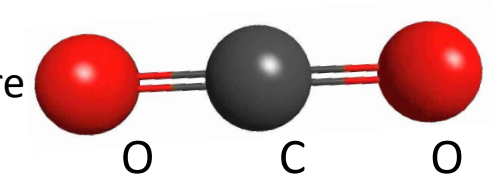

, son angle OCO fluctue autour de 180°

D'après la formule du gradient analytique précédente, celui-ci n'est pas défini en 180° :

$$\frac{\partial U_{ABC}^{bending}}{\partial x_A} = 2k_{ABC}(\theta_{ABC} - 180°)\frac{\partial \theta_{ABC}}{\partial x_A} = -\frac{2k_{ABC}(\theta_{ABC} - 180°)}{\sin(\theta_{ABC})} \times \frac{\partial f(\vec{r}_A, \vec{r}_B, \vec{r}_C)}{\partial x_A}$$

3 – **Comment y remédier ?**

En remarquant que $\sin\theta_{ABC} = -\sin(\theta_{ABC} - 180°)$, alors au voisinage de 180° :

$$\sin\theta_{ABC} = -\sin(\theta_{ABC} - 180°) \approx -(\theta_{ABC} - 180°)$$

$$\frac{\partial U_{ABC}^{bending}}{\partial x_A} = -\frac{2k_{ABC}(\theta_{ABC}-180°)}{\sin(\theta_{ABC})} \times \frac{\partial f(\vec{r}_A,\vec{r}_B,\vec{r}_C)}{\partial x_A} \approx 2k_{ABC} \times \frac{\partial f(\vec{r}_A,\vec{r}_B,\vec{r}_C)}{\partial x_A}$$

3 – **Comment y remédier (suite) ?**

Mais, pour garantir la continuité du gradient analytique, il faut pousser le développement limité de $\sin(\theta_{ABC} - 180°)$ jusqu'à à atteindre la précision souhaitée. Avec X = $\theta_{ABC} - 180°$

$$\sin(\mathrm{X}) = \mathrm{X} - \frac{\mathrm{X}^3}{3!} + \frac{\mathrm{X}^5}{5!} - \frac{\mathrm{X}^7}{7!} + \cdots + \frac{(-1)^n \mathrm{X}^{(2n+1)}}{(2n+1)!} + \mathrm{O}(\mathrm{X}^{2n+1})$$

D'où :

$$-\frac{2k_{ABC}(\theta_{ABC} - 180°)}{\sin(\theta_{ABC})} = \frac{2k_{ABC}}{1 - \frac{(\theta_{ABC} - 180°)^2}{3!} + \frac{(\theta_{ABC} - 180°)^4}{5!} - \frac{(\theta_{ABC} - 180°)^6}{7!} + \cdots}$$

Dès lors on peut par exemple définir l'angle θ_{ABC}^{DL} à partir du quel le gradient analytique du terme de *bending* sera calculée à l'aide d'e la formule avec développement limité comme

$$\left| \sin(\theta_{ABC}) + \left((\theta_{ABC} - 180°) - \frac{(\theta_{ABC} - 180°)^3}{3!} + \cdots + \frac{(-1)^n (\theta_{ABC} - 180°)^{2n+1}}{(2n+1)!} \right) \right| < \varepsilon_{precision}$$

Le développement n dépend donc de θ_{ABC}^{DL} et de $\varepsilon_{precision}$

ISM2 – CHAMPS DE FORCE – TERMES ENTRE ATOMES LIÉS

4 - **Dans le cas de molécule plane suivante (par exemple NO_3^-), peut on définir à l'aide d'un angle de torsion bien choisi une terme d'énergie qui force la molécule à rester plane en moyenne lors d'une simulation de type dynamique moléculaire ?**

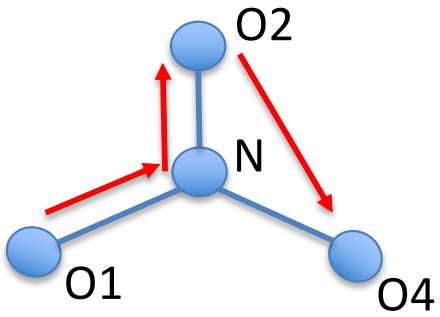

Soit l'angle dièdre ζ défini entre les atomes O1-N-O2-03 (défini comme étant un angle de torsion dièdre « impropre »).

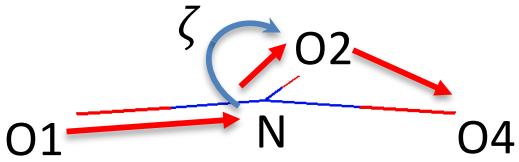

$\zeta = 180°$

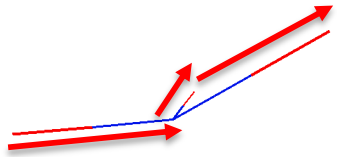

$\zeta = 145°$

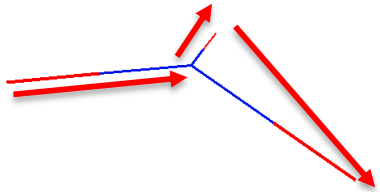

$\zeta = -145°$

Cet angle dièdre est dit impropre car il n'est pas défini par trois liaisons covalentes adjacentes mais par deux liaisons covalentes et par un vecteur défini entre les deux atomes O2 et O4 non liés chimiquement.

ISM2 – CHAMPS DE FORCE – TERMES ENTRE ATOMES LIÉS

Différence entre torsion classique et torsion impropre (pour décrire un mouvement hors du plan) :

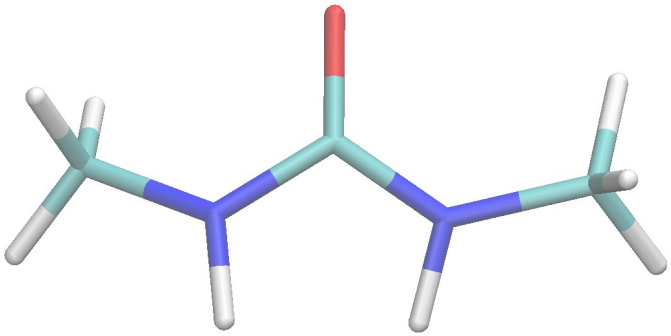

Cas de l'urée (cf. TP)

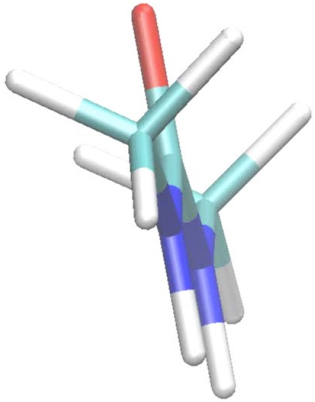

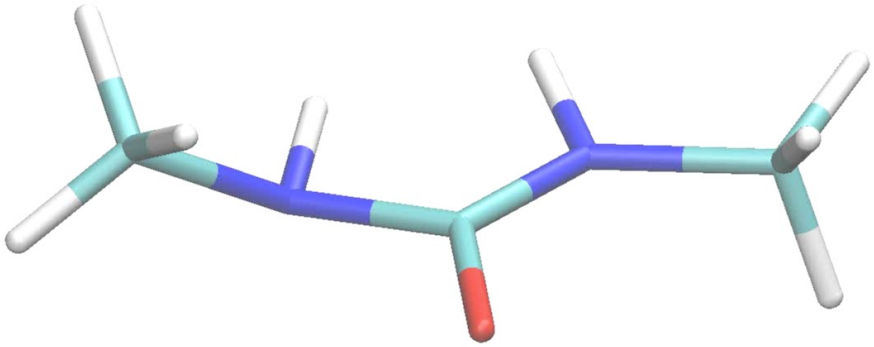

Torsion classique : toutes les valeurs d'angle dièdre sont possibles

$$U^{torsion} = \sum_{n=1}^{3} v_n \cos\left(n(\varphi_{ABCD} - \varphi^0_{ABCD})\right)$$

Torsion impropre : modéliser la sortie hors du plan ne nécessite pas de bien modéliser toutes les valeurs d'angle ζ

Si la molécule fluctue faiblement autour de sa structure plane alors on peut considérer un terme d'énergie potentielle *ad hoc* de la forme développement limité de l'angle dièdre $\chi = \zeta - 180°$ au voisinage de 0° :

$$U^{improper} = k_{improper}\chi^2 = k_{improper}(\zeta - 180°)^2$$

Ce terme d'énergie potentielle exerce un force de « rappel » lorsque la molécule se déforme (ici se « pyramidalise ») afin de la « ramener » vers sa structure plane.

Même si l'angle dièdre ζ est qualifié d'impropre, toutes les considérations concernant les angles dièdres restent valables pour lui :

1 - il est calculé à partir de son cosinus défini par un produit scalaire,
2 - il existe donc un problème lors de l'évaluation numérique du gradient analytique associé à $U^{improper}$
3 – ce problème est crucial car cet angle ζ fluctue autours de la valeur 180°…

$$\frac{\partial U^{improper}}{\partial x_A} = 2k_{improper}(\zeta - 180°)\frac{\partial \zeta}{\partial x_A} = -\frac{2k_{improper}(\zeta - 180°)}{\sin(\zeta)} \times \frac{\partial f(\vec{r}_{O1}, \vec{r}_N, \vec{r}_{O3}, \vec{r}_{O4})}{\partial x_A}$$

Mais a solution précédente proposé pour le terme dit de *bending* reste valable, i.e. il suffit de considérer un développement limité de $\sin(\zeta - 180°)$ à la précision souhaité :

$$\left|\sin(\zeta) + \left((\zeta - 180°) - \frac{(\zeta - 180°)^3}{3!} + \cdots + \frac{(-1)^n(\zeta - 180°)^{2n+1}}{(2n+1)!}\right)\right| < \varepsilon_{precision}$$

ISM2 – ANNALES EXAMEN 2019

I.7 Soit une fonction f d'énergie potentielle dépendante d'un angle θ défini entre trois atomes. f est continue et bornée. Le gradient analytique en coordonnées cartésiennes de ces trois atomes d'une telle fonction est-il défini pour toute valeur de θ ?
Réponse : oui, non

I.8 Quelle propriété doit vérifier la fonction $f(\theta)$ précédente pour que son gradient analytique soit défini pour toute valeur de θ ?
Réponse : une ligne maximum

I.9 Quel est le principe de l'approximation dite du rayon de coupure pour les termes de Lennard-Jones et de Coulomb ?
Réponse à développer (deux lignes maximum)

I.13 Quels sont les deux termes d'énergie potentielle les moins coûteux en temps de calcul d'un champ de force classique ?
Réponse : le terme de torsion, le terme de *stretching*, le terme de Coulomb, le terme de *bending* ?

ISM2 – CODE DE SIMULATION MICROSCOPIQUE

Objectif : développer un code de simulation microscopique basé sur un potentiel de Lennard-Jones pour étudier un fluide de particule homogène (i.e. toutes les particules sont identiques). Langage => au choix, processeur visé => au choix.

1 – Le fichier particule.xyz contient les coordonnées cartésiennes (x,y,z) d'un système de 1 000 particules identiques, avec le format :

> 0 1
> 2 x y z
> 2 x y z

La première ligne est un commentaire, dans les suivantes ' 2 ' est le type de particule, pour notre sujet sans importance. Ecrire un code qui permet de lire ce fichier et de stocker les coordonnées x,y,z dans un (ou des) vecteurs ou tableaux. On introduira les paramètre *N_particules_total* = 1000 et *N_particules_local*, le dernier permettant de réaliser des calculs sur un sous ensemble des *N_particules_local* premières particules (*N_particules_local < N_particules_total).*

2 – Sur la base des coordonnées (x,y,z) des 1000 particules, calculées l'énergie microscopique de ce système et les forces agissant sur chacune des particules dans le cas d'un potentiel de Lennard Jones :

$$U^{LJ} = 4 \sum_{i=1}^{N} \sum_{j>i}^{N} \varepsilon^* \left[\left(\frac{r^*}{r_{ij}} \right)^{12} - 2 \left(\frac{r^*}{r_{ij}} \right)^{6} \right]$$

On prendra r^* = 3.0 et ε^* = 0.2.

ISM2 – CODE DE SIMULATION MICROSCOPIQUE

Rappel pour un terme de Lennard Jones

$$U^{LJ} = 4\sum_{i=1}^{N}\sum_{j>i}^{N}\varepsilon_{ij}^{*}\left[\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{12} - 2\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{6}\right] = \sum_{i=1}^{N}\sum_{j>i}^{N}u_{ij}(r_{ij})$$

Les forces des particules se calculent à partir du gradient analytique associé aux fonctions élémentaires u_{ij}

$$\frac{\partial u_{ij}}{\partial x_i} = -4\varepsilon_{ij}^{*}\left[12\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{13} - 2\times 6\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{7}\right]\times\frac{\partial r_{ij}}{\partial x_i} = -48\varepsilon_{ij}^{*}\left[\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{14} - \left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{8}\right]\times(x_i - x_j)$$

Comme pour les coordonnées (x,y,z), les forces (fx,fy,fz) seront stockées dans un (des) vecteur(s) ou tableau(x).

3 – Vérifier que la sommes des forces agissant sur les particules est nulles.

4 – Vérifier que la complexité algorithmique de ce potentiel est bien en *O(N²)*

ISM2 – EXERCICES À RENDRE POUR LE 08/02/2021 : MOMENTS DIPOLAIRES

1 – Soit un système S électriquement neutre de N atomes portant chacun une charge électrostatique q_i et dont les coordonnées sont notées $\vec{r}_i$. Donner l'expression du moment dipolaire totale du système S.

2 – Les charges atomiques de la molécules linéaires CO_2 sont notées q_C et q_O. La molécule étant neutre, quelle est la valeur de son moment dipolaire ?

3 – Donner la formule reliant le moment dipolaire et les charges q_O et q_H d'une molécule d'eau H_2O (les longueurs de liaisons OH sont de 0,96 Å et l'angle HOH est de 104,5°). Quelle est la valeur de la charge q_O (en unité de charge électronique e) permettant de reproduire le moment dipolaire de la molécule d'eau en phase gaz, i.e. 0,385 e $Å^{-1}$? Et en phase aqueuse, i.e. 0,573 e $Å^{-1}$? Que peut-on en conclure ?

Pas cette année…

1 – CONDITIONS PÉRIODIQUES

2 – SOMMES D'EWALD

3 – INTERPOLATION SUR GRILLE – MÉTHODE SPME

4 – CONDITIONS PÉRIODIQUES POUR SIMULER UN SYSTÈME SANS CONDITIONS PÉRIODIQUES...

ISM3 – PHASE CONDENSÉE AU NIVEAU MICROSCOPIQUE

Une fonction de distribution radiale g(*r*) normalisée mesure le nombre moyen de particules contenues dans le volume d'une calotte sphérique d'épaisseur *dr* et centré sur une particule quelconque normalisée par la densité moyenne ρ des particules (= atomes ou molécules)

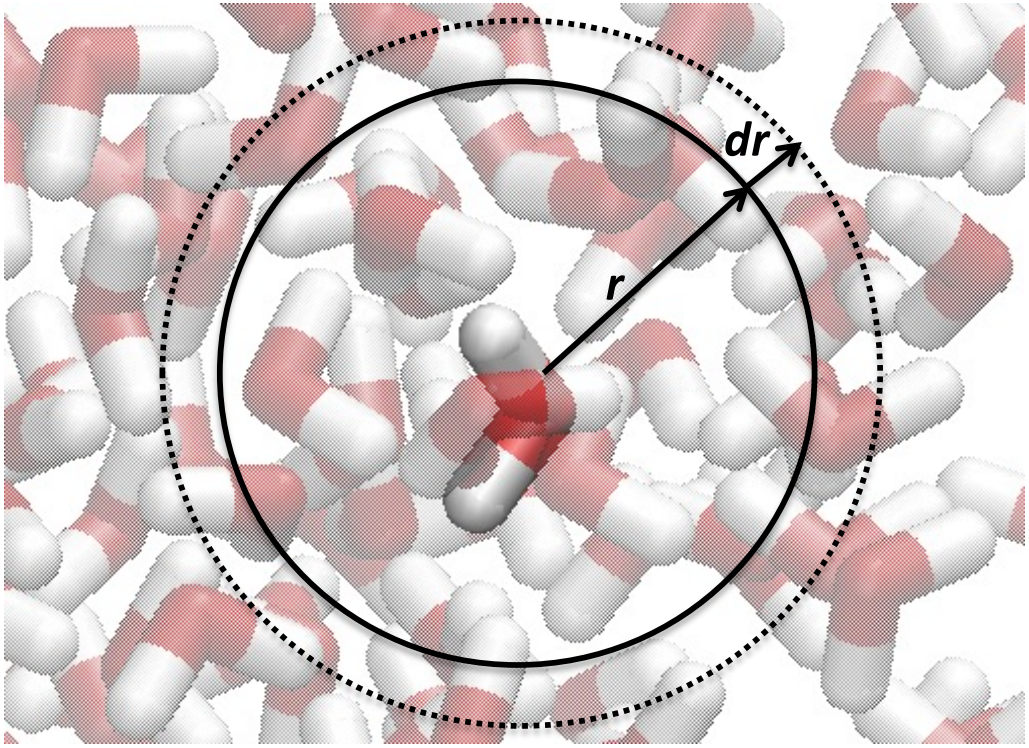

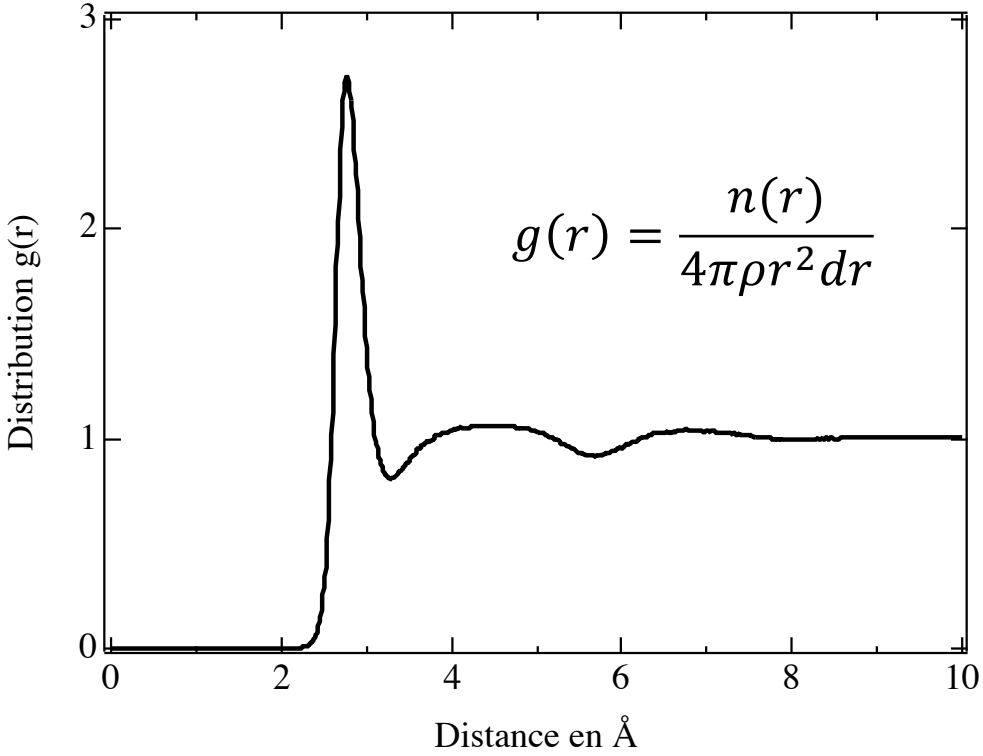

A priori, on peut donc « moyenner » le traitement des interactions pour des distances *r*/g*(r)*=1
=> dans le cas de l'eau dès *r* = 8 Å (avec 1 Å = 10^{-10} m)

ISM3 – PHASE CONDENSÉE AU NIVEAU MICROSCOPIQUE

Une fonction de distribution s'interprète comme une probabilité de trouver des voisins d'une particule quelconque à un distance donnée de celle-ci.

On peut donc lui faire correspondre une « énergie libre » au sens thermodynamique :

$$g(r) = \frac{n(r)}{4\pi r^2 dr} = \exp\left(-\frac{A(r)}{k_B T}\right)$$

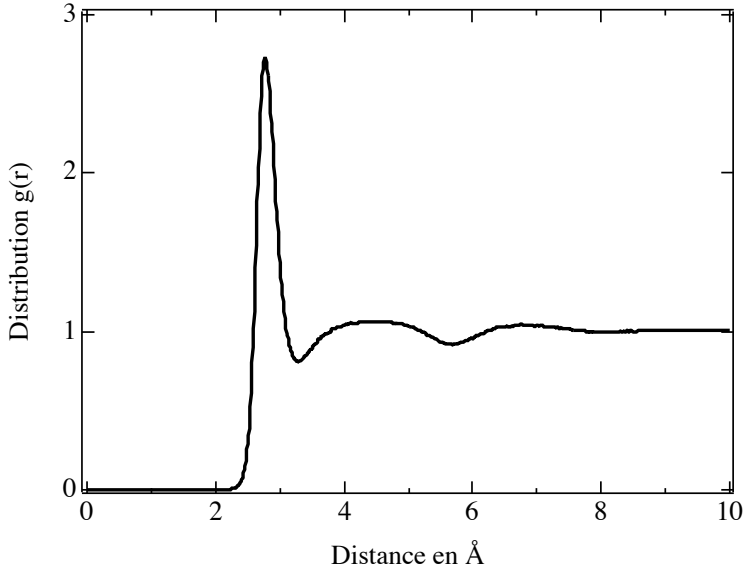

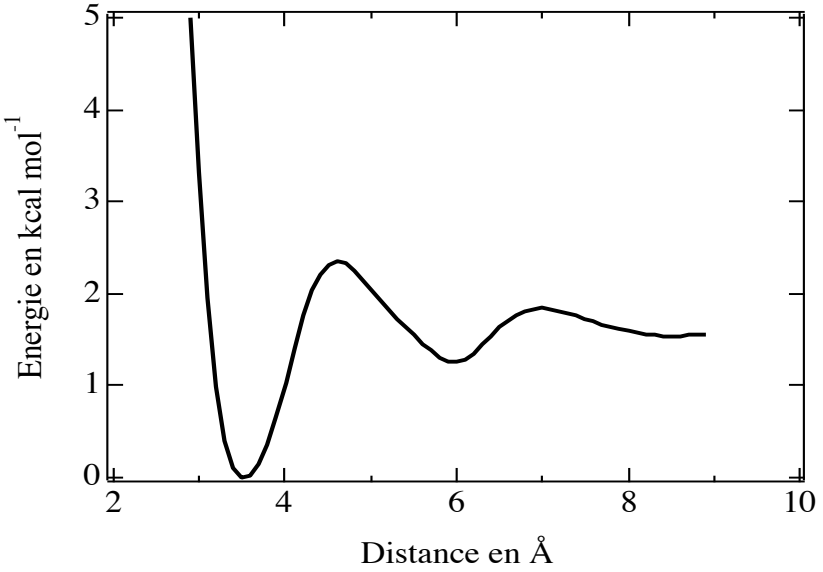

La fonction *g(r)* peut être obtenue expérimentalement ou par simulation. En général, on observe une grande incertitude concernant la hauteur de ses deux premiers pics et leur position exacte, mais toutes ces fonctions pour un système donné ont des propriétés très proches.

ISM3 CONDITIONS PÉRIODIQUES

Pour traiter un système en phase condensée, on considère un volume de ce système, qui est alors répliqué symétriquement. Les interactions au sein de ce volume et entre ce volume et les images périodiques de celui-ci sont une approximation des interactions ayant lieu au sein du système condensée de taille infini.

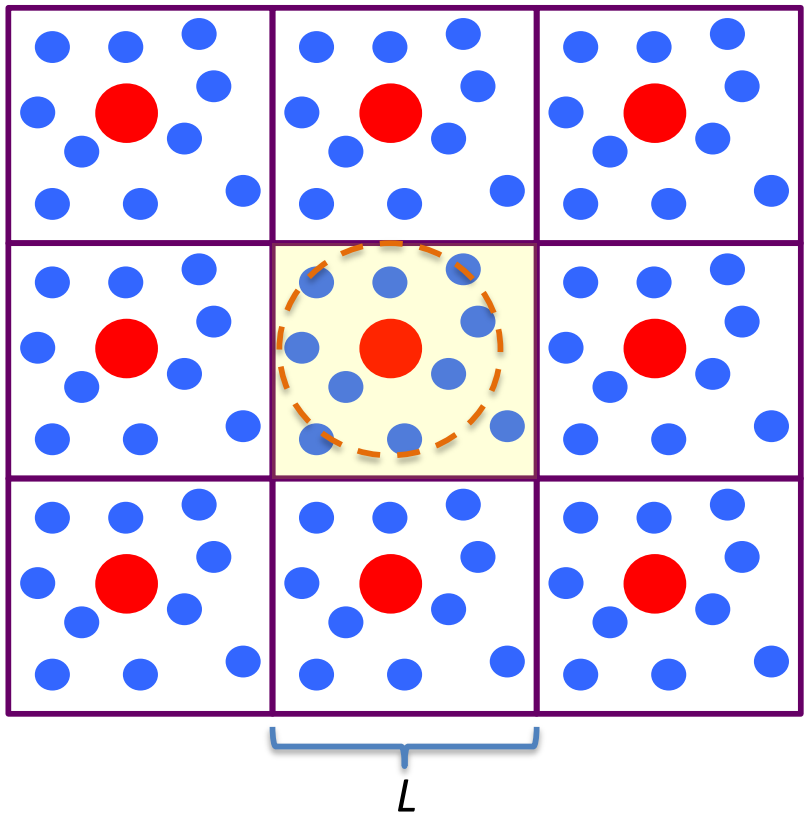

L'ordre de grandeur de la taille d'une boite cubique permettant de « bien » décrire l'eau liquide est au minimum de L = 2x8 Å.

La densité de l'eau liquide aux conditions ambiantes est ρ_{eau} = 0,0331 molécules par Å^{-3}.

Cette boite « minimale » contient donc :

$$\rho_{eau} \times L^3 = 0.0331 * 16^3 \approx 135 \text{ molécules d'eau}$$

ISM3 CONDITIONS PÉRIODIQUES

Soit un système microscopique de *N* particules de coordonnées $\{\vec{r}_i\}_{1\le i\le N}$ et contenues dans une boite cubique de dimension *L*. Les coordonnées de ses 1$^{\text{ères}}$ images périodiques des *N* particules s'écrivent en 3 dimensions :

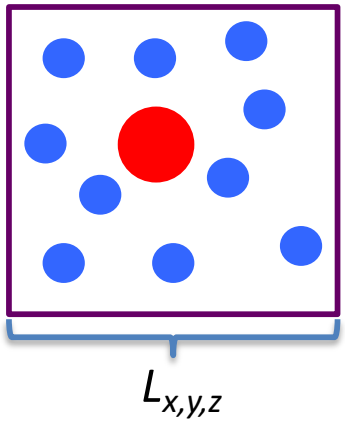

$$\vec{r}_i^{\,\eta} = \vec{r}_i + \vec{\eta} = \vec{r}_i + \left(k\vec{a}_x L_x + l\vec{a}_y L_y + m\vec{a}_z L_z\right)$$

$$\forall j \in \{k,l,m\} \quad -1 \le j \le 1 \quad \Rightarrow \quad \text{il y a donc 27 images possibles}$$

D'autres types de systèmes périodiques sont également considérés en fonction des symétries du système microscopique

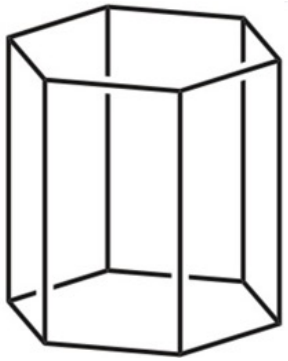

Symétrie hexagonale

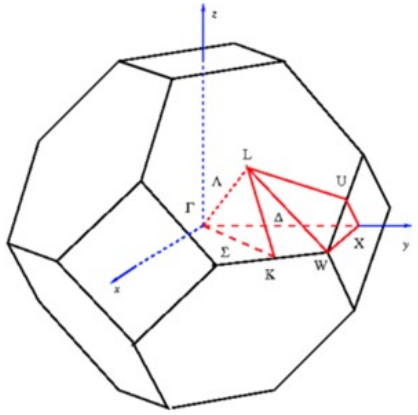

Symétrie rhomboédrique

ISM3 CONDITIONS PÉRIODIQUES CUBIQUES…

Les conditions périodiques cubiques induisent la prise en compte d'un grand nombre de molécules de solvant dans le cas de l'étude d'une longue molécule en phase condensée (par exemple dans l'eau liquide).

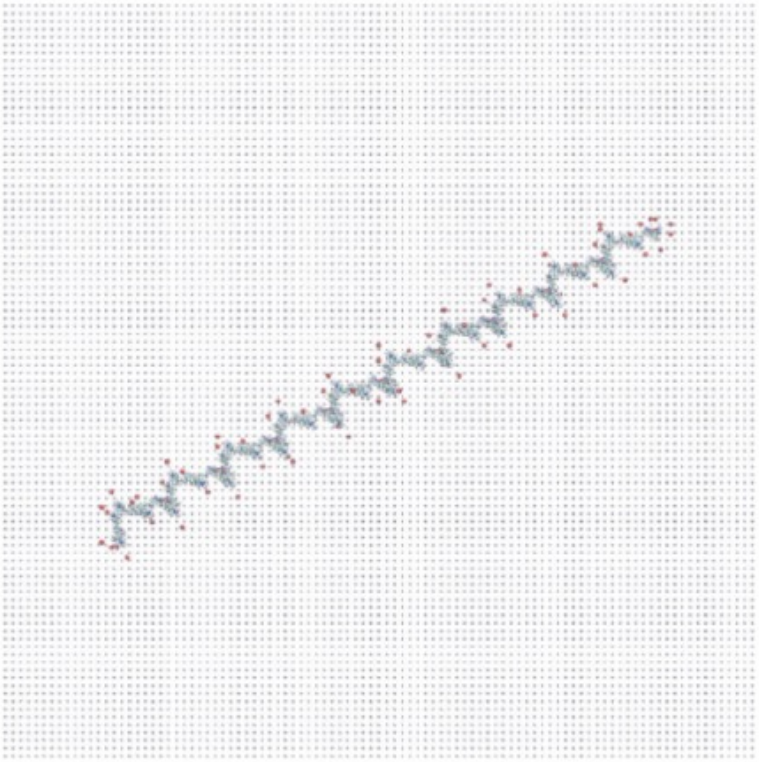

Ici, cas d'un polymère PQ7 de type «hydrophobic polyelectrolyte» composé de 2 500 atomes.

Une boîte cubique est bien adaptée (suffisamment grande) si elle lui permet d'évoluer librement sans contrainte artificielle induite par les limites géométriques de la boite

=> Une telle boite doit contenir 1 000 000 molécules d'eau…

ISM3 CONDITIONS PÉRIODIQUES – CALCULS DES INTERACTIONS

Soit un système microscopique de *N* particules de coordonnées $\{\vec{r}_i\}_{1\le i\le N}$, contenues dans une boite cubique de dimensions (L_x, L_y, L_z) et interagissant par un potentiel additif $f(|\vec{r}_i - \vec{r}_j|^{-n})$

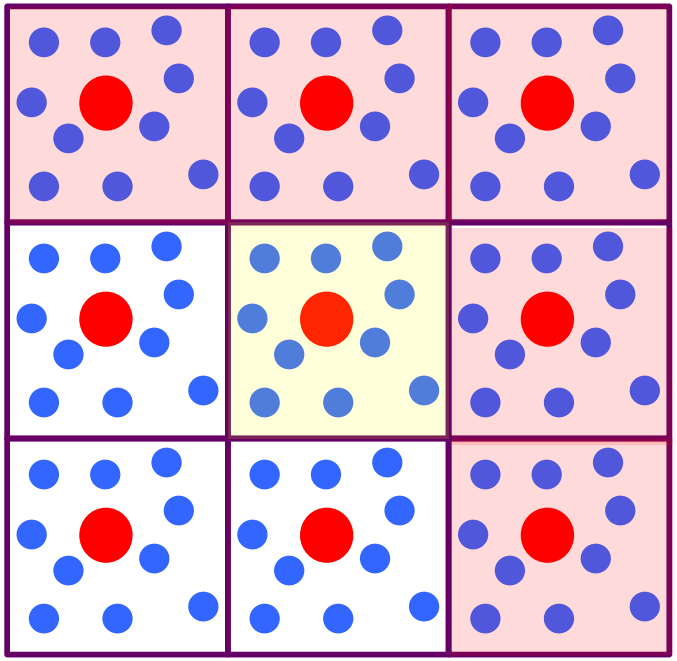

L'énergie potentielle totale U au sein de boite cubique est

$$U = \sum_{i=1}^{N} \sum_{j>i}^{N} f(|\vec{r}_i - \vec{r}_j|^{-n})$$

L'énergie potentiel totale U résultant des périodiques est

$$U^{périodique} = \sum_{i=1}^{N} \sum_{j=1}^{N} \sum_{\{\vec{\eta}\}} f(|\vec{r}_i - \vec{r}_j - \vec{\eta}|^{-n}) \times \frac{1}{2}$$

Jeu de $\{\vec{\eta}\}$ à considérer

ISM3 CONDITIONS PÉRIODIQUES

Dans une simulation avec conditions périodiques, les particules peuvent quitter la boite principale qui est répliquée…

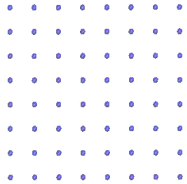

512 particules (eau) simulées à 300 K (26,5° C) en conditions périodiques, le volume de la boite de simulation est constant le long de la trajectoire

ISM3 CONDITIONS PÉRIODIQUES

Mais chaque fois qu'une particule quitte la boite répliquée, une de ses images entre dans celle-ci

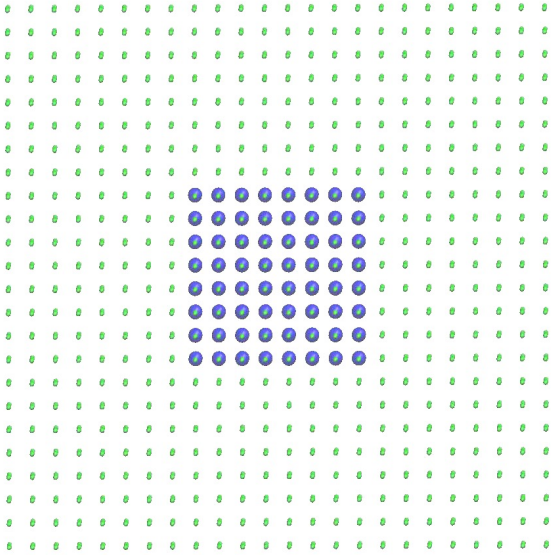

512 particules (eau) simulées à 300 K (26,5° C) en conditions périodiques, le volume
De la boite de simulation est constant le long de la trajectoire

ISM3 CONDITIONS PÉRIODIQUES

Pour éviter que les particules ne » quitte la boite principale, il faut corriger périodiquement leurs coordonnées :

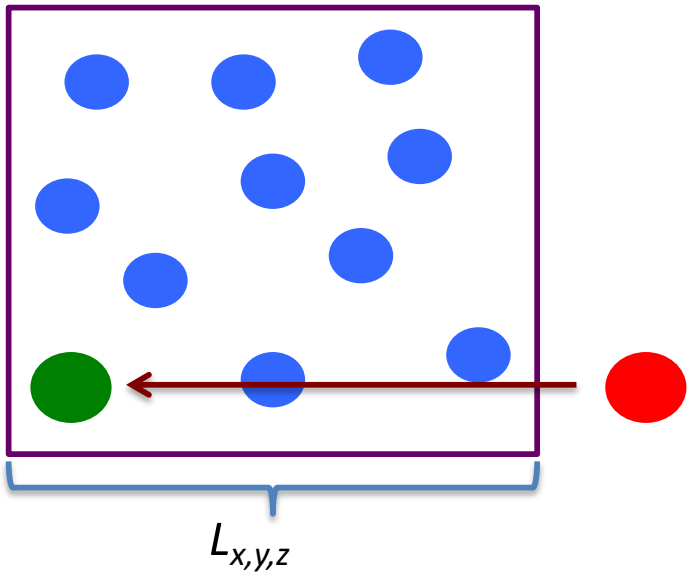

$$\vec{r}_i = \begin{cases} x_i - \text{aint}(\frac{x_i}{L_x})L_x \rightarrow x_i \\ y_i - \text{aint}(\frac{y_i}{L_y})L_y \rightarrow y_i \\ z_i - \text{aint}(\frac{z_i}{L_z})L_z \rightarrow z_i \end{cases}$$

Ce type de transformation n'a aucun impact sur le calcul de l'énergie si sur la continuité des forces :

$$U = \sum_{i=1}^{N} \sum_{j>i}^{N} f(\left|\vec{r}_i - \vec{r}_j\right|^{-n}) \longrightarrow U^{périodique} = \sum_{i=1}^{N} \sum_{j=1}^{N} \sum_{\{\vec{\eta}\}} f(\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right|^{-n}) \times \frac{1}{2}$$

Remarque : cette somme est a priori infinie

ISM3 CONDITIONS PÉRIODIQUES

Résultat sur la trajectoire de 512 particules à 300 K :

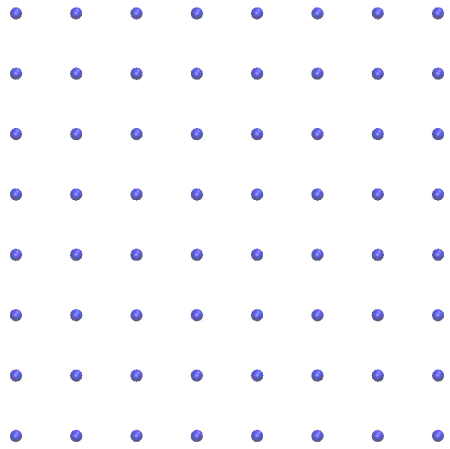

ISM3 CONDITIONS PÉRIODIQUES

Cas d'un polymère dont les dimensions sont >> à la taille d'une molécule d'eau (le solvant)

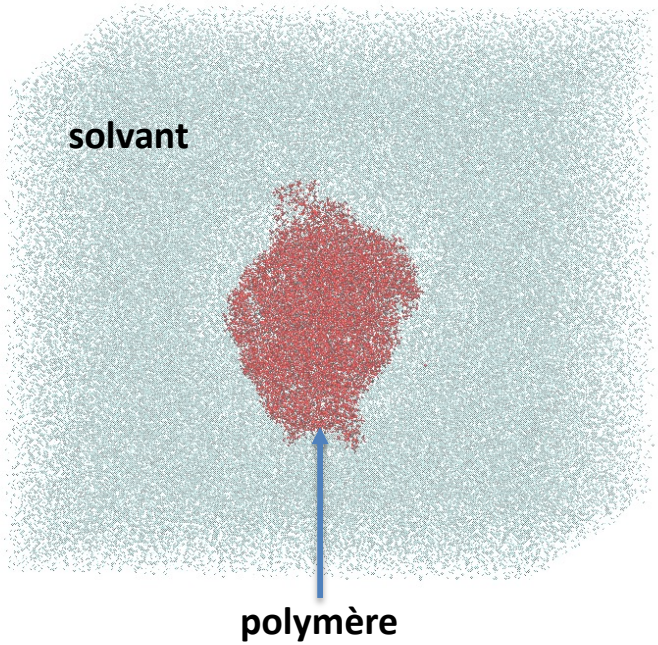

$$\vec{r}_i = \begin{cases} x_i - \text{aint}(\frac{x_i}{L_x})L_x \rightarrow x_i \\ y_i - \text{aint}(\frac{y_i}{L_y})L_y \rightarrow y_i \\ z_i - \text{aint}(\frac{z_i}{L_z})L_z \rightarrow z_i \end{cases}$$

=> ne s'applique qu'aux molécules de solvant !

Pour que le polymère 'reste' dans la boite de simulation, il suffit de forcer périodiquement son centre de masse (dont les coordonnées correspondent au vecteur $\vec{R}_G$) à se confondre avec le centre de la boite, en général centrée en (0,0,0). Autrement dit, il faut appliquer le vecteur translation $-\vec{R}_G$ au polymère mais aussi à toutes les molécules de solvant, puis appliquer la transformation précédentes au molécule de solvant.

ISM3 CONDITIONS PÉRIODIQUES

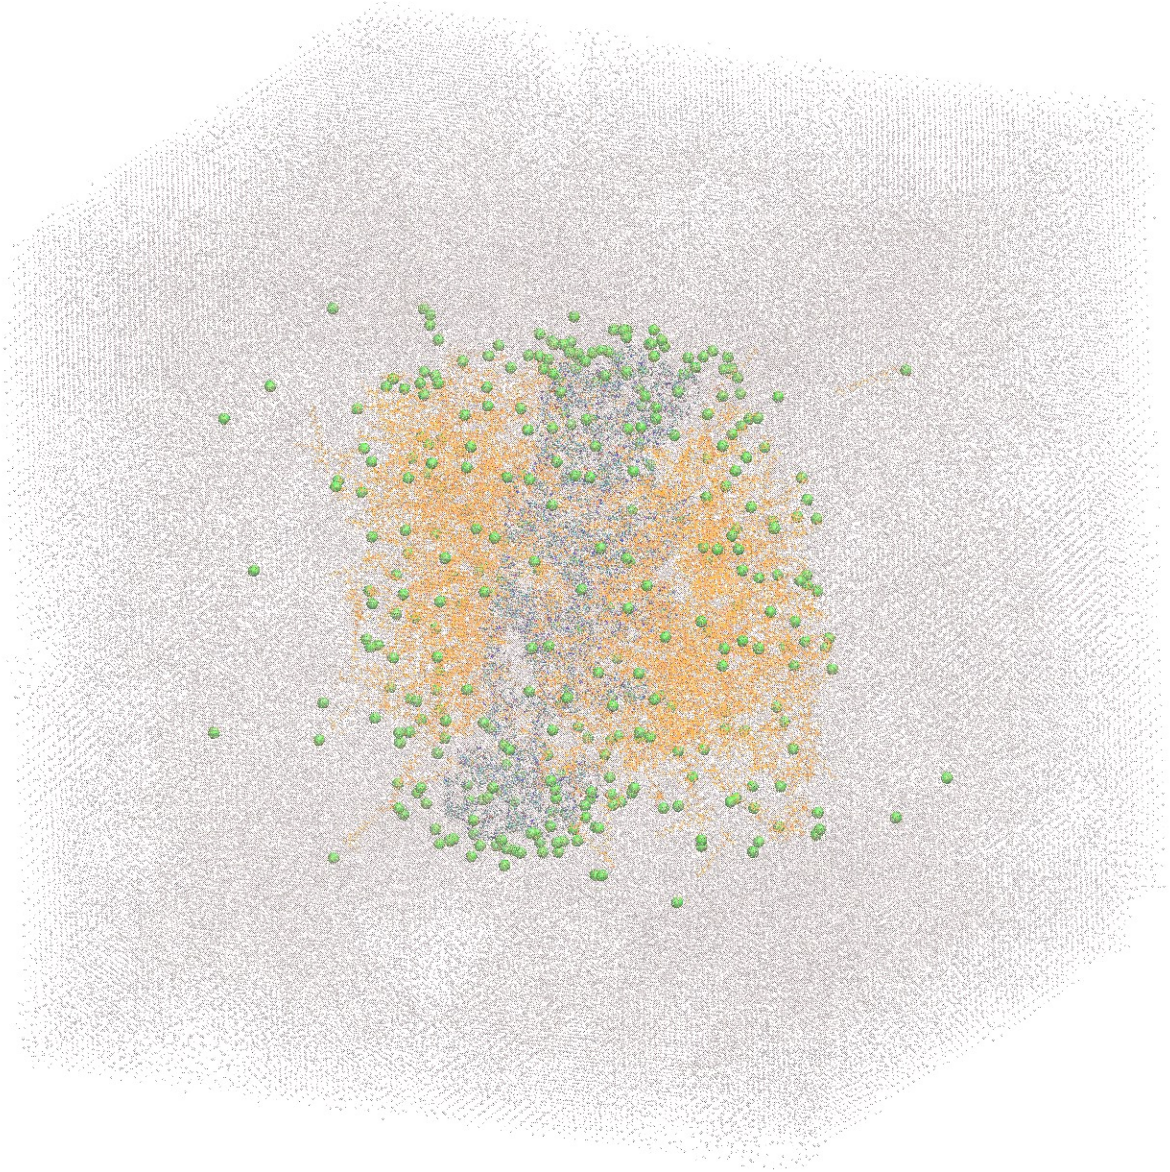

ISM3 NOMBRE D'IMAGES PÉRIODIQUES À PRENDRE EN COMPTE

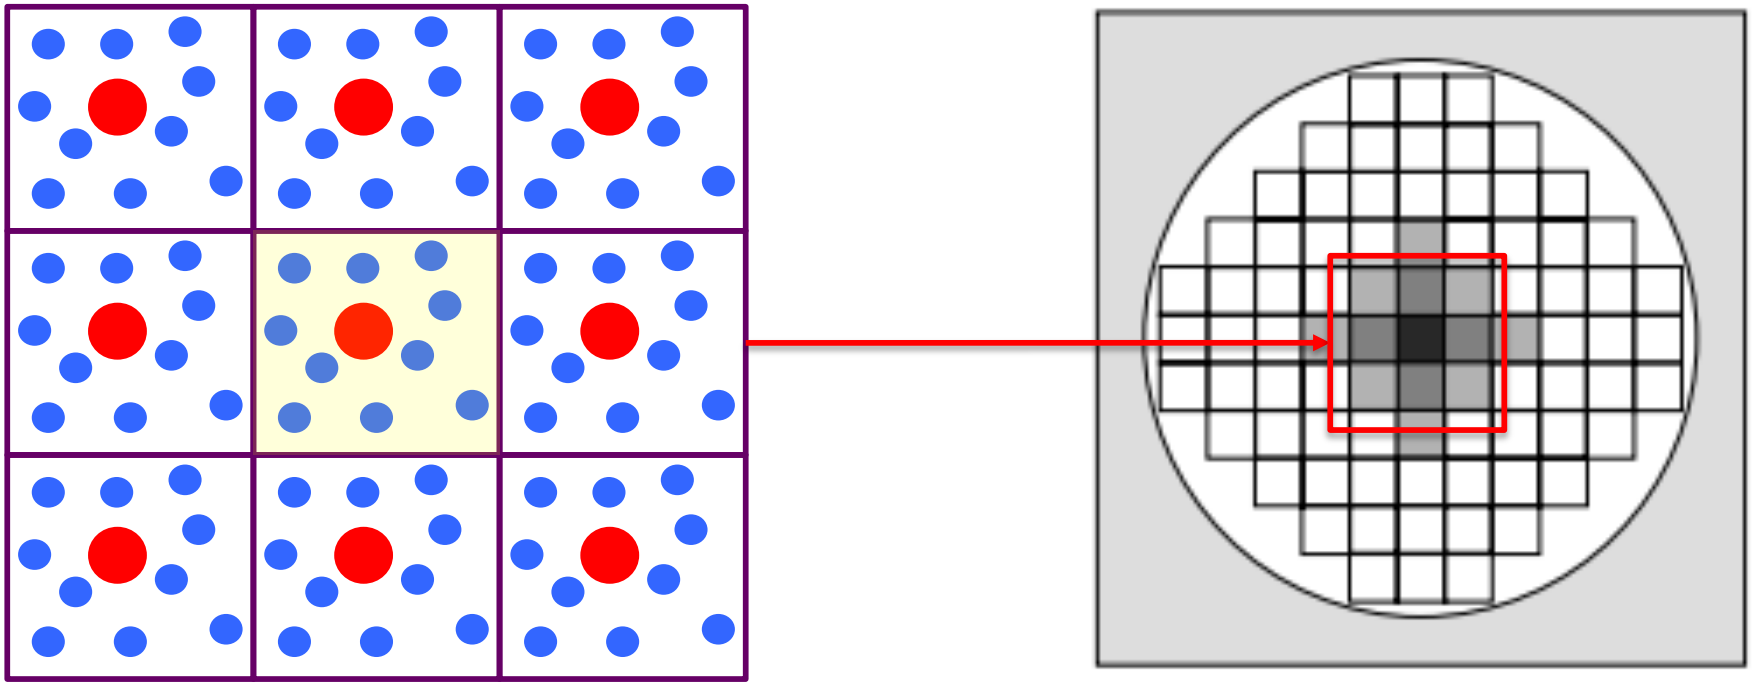

Simuler un système infini à l'aide d'images répliquées périodiquement nécessite de prendre en compte un nombre infini d'images.

Question : peut-on limiter ce nombre d'images à prendre en compte en considérant que :

1 – la densité locale de la matière devient rapidement uniforme (interaction moyenne ?)

2 – et/ou les termes d'interaction entre atomes → 0 (i.e. deviennent négligeable au sens mathématique) pour des atomes à l'infini (rayon de coupure)

ISM3 – CAS DU TERME DE LENNARD JONES

La convergence rapide vers zéro d'un terme de Lennard Jones permet d'employer un rayon de coupure

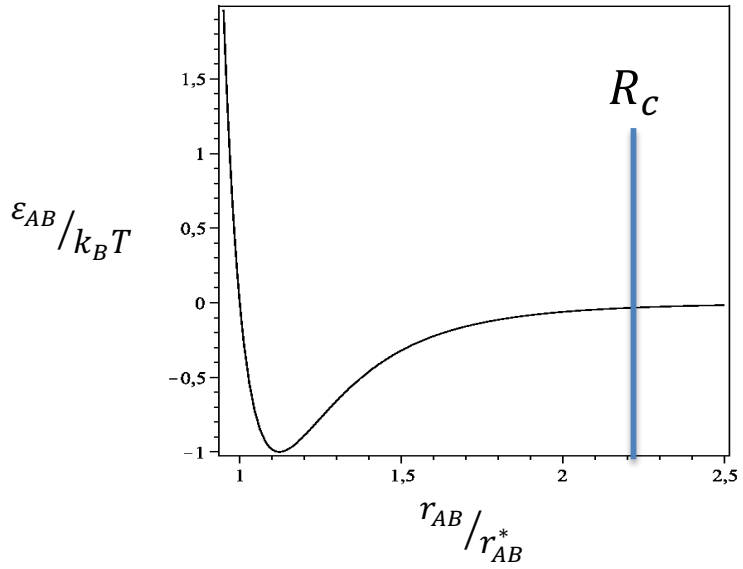

$$U^{LJ} = 4\sum_{i=1}^{N}\sum_{j>i}^{N}\varepsilon_{ij}^{*}\left[\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{12} - 2\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{6}\right] \quad O(N^2)$$

$$U^{LJ} \approx 4\sum_{i=1}^{N}\sum_{j/r_{ij}<R_c}\varepsilon_{ij}^{*}\left[\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{12} - 2\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{6}\right] \quad O(N)$$

Peut on estimer l'erreur commise en considérant un rayon de coupure ?

Pour répondre à cette question prenons le cas général d'un potentiel de la forme :

$$u_{ij}(r_{ij}) = \frac{A}{r_{ij}^{n}}$$

ISM3 – RAYON DE COUPURE ET ERREUR SUR L'ÉNERGIE

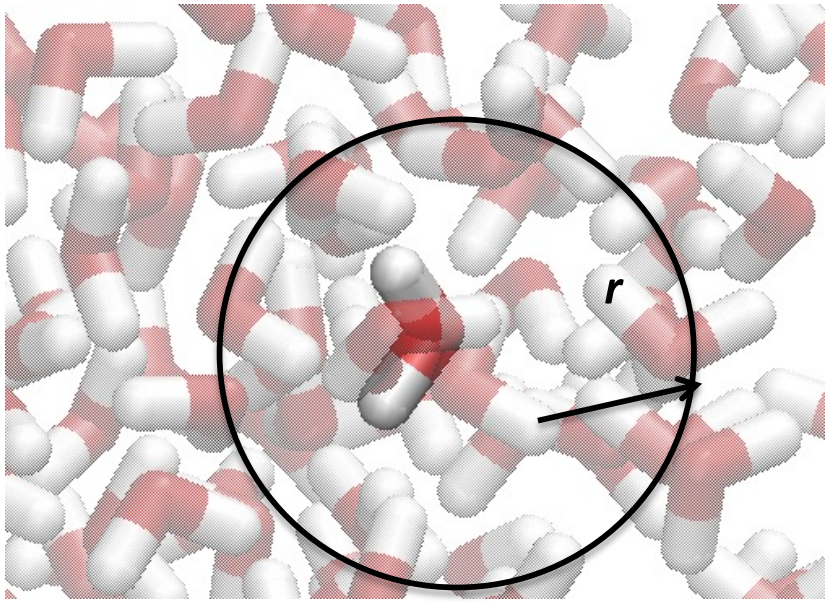

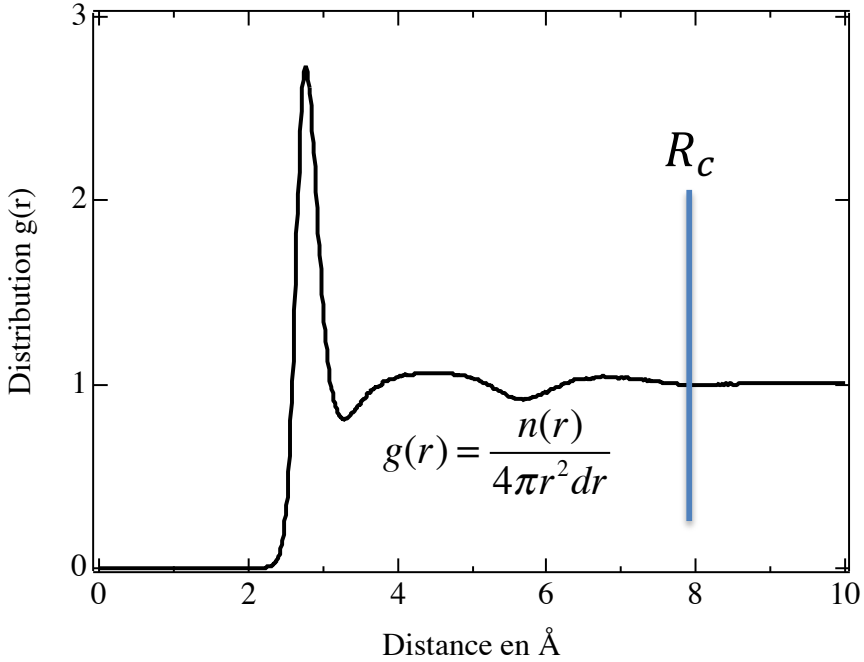

Si le rayon de coupure R_c est pris tel que $g(r) = Cte = \rho$, alors l'erreur commise sur l'énergie potentielle totale d'un atome particulier est :

$$\Delta U(R_c) = \int_{R_c}^{+\infty} \frac{A}{r^n} \times g(r) \times 4\pi r^2 dr \approx 4\pi\rho \int_{R_c}^{+\infty} \frac{A}{r^{n-2}}\, dr$$

Cette erreur est finie si et seulement si $n > 3$, et dans ce cas

$$\Delta U(R_c) \approx \left[-\frac{4\pi A\rho}{(n-3)r^{n-3}} \right]_{R_c}^{+\infty} = \frac{4\pi A\rho}{(n-3)R_c^{n-3}}$$

ISM3 RAYON DE COUPURE ET TERME LENNARD JONES

$$U^{LJ} = 4\sum_{i=1}^{N}\sum_{j>i}^{N}\varepsilon_{ij}^{*}\left[\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{12} - 2\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{6}\right] \Rightarrow \boxed{\Delta U(R_c) = 16\pi\rho\varepsilon_{ij}^{*}\left(\frac{1}{9R_c^9} - \frac{2}{3R_c^3}\right)}$$

Terme constant

Remarque sur les forces pour un potentiel centro-symétrique :

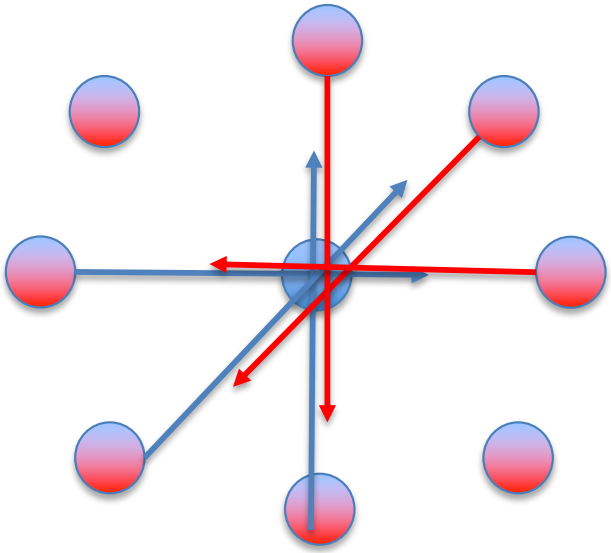

Si le paramètre ε_{ij}^{*} est identique pour tous les atomes alors la somme des forces sur l'atome central (bleu) résultant de tous les atomes au delà de R_c (rouges) est nulle :

=> La dynamique du système n'est pas affectée par R_c

ISM3 RAYON DE COUPURE ET TERME DE LENNARD JONES

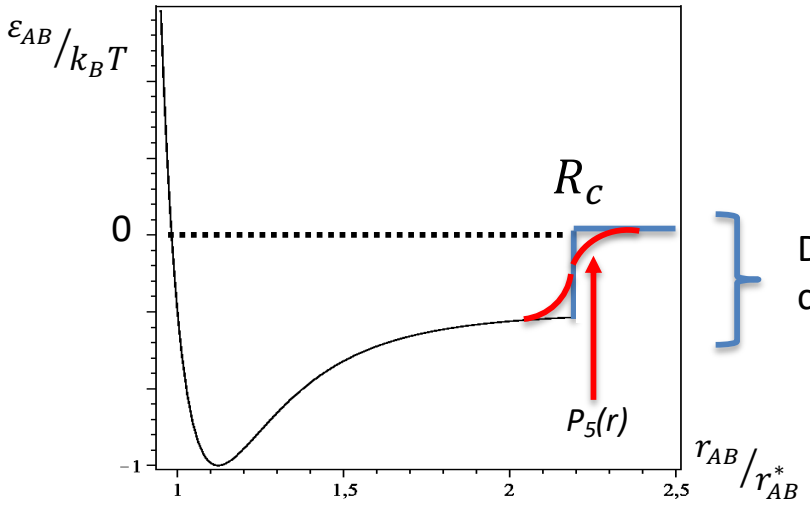

Discontinuité de l'énergie potentielle, l'énergie totale n'est pas constante lors d'une simulation de type dynamique moléculaire...

Pour retrouver un terme de Lennard Jones continu et dérivable en tout point, il suffit de considérer le polynôme :

$$P_5(x) = 1 - 10\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^3 + 15\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^4 - 6\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^5$$

Les dérivées premières et secondes de ce polynôme sont nulles en x_{min} et x_{max}. Les problèmes de discontinuité sont résolus en réécrivant le terme de Lennard Jones sous la forme (avec $x_{min/max} = R_c \pm \delta r$)

$$U^{LJ} = 4\sum_{i=1}^{N}\sum_{j/r_{ij}<x_{max}} \varepsilon^*_{ij}\left[\left(\frac{r^*_{ij}}{r_{ij}}\right)^{12} - 2\left(\frac{r^*_{ij}}{r_{ij}}\right)^{6}\right] \times P_5(r_{ij})$$

ISM3 RAYON DE COUPURE ET TERME DE COULOMB

$$U^{LJ} = \sum_{i=1}^{N} \sum_{j>i}^{N} \frac{q_i q_j}{4\pi\varepsilon_0 r_{ij}} \Rightarrow \boxed{\Delta U(R_c) \text{ DIVERGE}}$$

Il est impossible d'évaluer facilement l'erreur commise avec l'employant un rayon de coupure lors de l 'évaluation du terme de Coulomb.

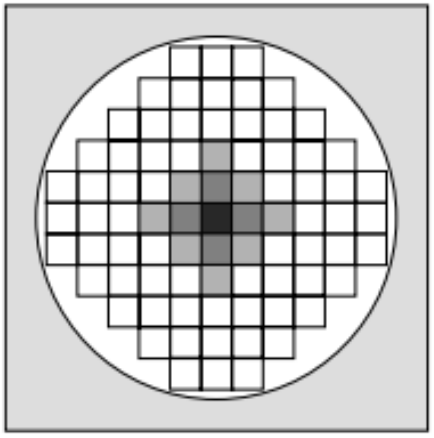

Dans le cas du terme de Coulomb, il faut donc prendre en compte les interactions entre les atomes de la boite répliquée et celles de ses images périodiques jusqu'à l'infini….

ISM3 SOMMES D'EWALD - PRINCIPE

Les sommes d'Ewald appartiennent à la grande famille mathématique des séries dont la convergence est lente mais qui peuvent être réécrites sous la forme de deux séries distinctes qui convergent chacune plus rapidement.

$$U^{Coulomb} = \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\sum_{\vec{\eta}}\frac{q_i q_j}{\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right|} = \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N} q_i q_j \sum_{\vec{\eta}}\left(f_1(\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right|) + f_2(\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right|)\right)$$

$$f_1(\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right|) = \frac{erfc(\beta\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right|)}{\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right|} \quad \text{et} \quad f_2(\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right|) = \frac{1 - erfc(\beta\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right|)}{\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right|}$$

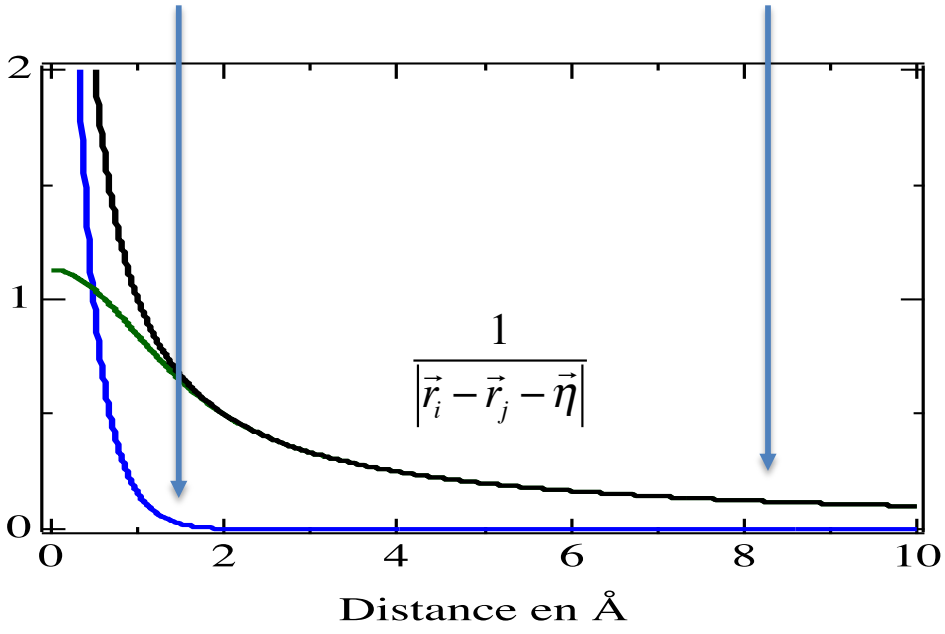

$$erfc(x) = \frac{2}{\sqrt{\pi}}\int_z^{\infty}\exp(-\xi^2)d\xi$$

ISM3 SOMMES D'EWALD – TERME DIRECT

La fonction f_1 converge rapidement vers zéro, dès lors on peut appliquer un rayon de coupure à cette fonction, i.e. on néglige dans la triple somme

$$\sum_{i=1}^{N}\sum_{j=1}^{N} q_i q_j \sum_{\vec{\eta}} f_1(\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right|)$$

tous les termes correspondant à une distance inter particules telles que

$$\left|\vec{r}_i - \vec{r}_j - \vec{\eta}\right| > R_{coupure}$$

En effet la convergence vers 0 de la fonction *erfc* étant très rapide, on peut considérer que les 27 premières images de la boite répliquée avec une erreur $\Delta U(R_c)$ très faible voire négligeable.

Ce terme d'énergie est usuellement appelé terme direct U^{dir}. Grâce à la possibilité de troncature, sa complexité algorithmique est d'ordre *O(N).* Par ailleurs le paramètre β est arbitraire. Il peut donc être choisi pour obtenir la précision que l'on souhaite

$$\frac{erfc(\beta R_{coupure})}{R_{coupure}} \leq \varepsilon_{precision}$$

ISM3 SOMMES D'EWALD – TERME RÉCIPROQUE

La triple somme concernant la fonction f_2 peut elle se réécrire, en considérant les vecteurs

$$\vec{m} = i\frac{\vec{a}_1}{L_1} + j\frac{\vec{a}_2}{L_2}k\frac{\vec{a}_3}{L_3} \quad \text{avec} \quad (\vec{a}_1, \vec{a}_2, \vec{a}_3) \quad \text{vecteur générant les images périodiques}$$

et le « facteur de structure »

$$S(\vec{m}) = \sum_{i=1}^{N} q_i \exp(2\pi i \vec{m}.\vec{r}_i)$$

sous la forme

$$\frac{1}{2\pi V}\sum_{\vec{m}\neq 0}^{\infty} \frac{\exp(-\pi^2 |\vec{m}|^2 \beta^2)}{|\vec{m}|^2} S(\vec{m})S(-\vec{m})$$

Ce terme d'énergie est usuellement appelé terme réciproque U^{rec}. La somme infinie peut également être tronquée pour des vecteur $\vec{m}$ de grande norme $|\vec{m}|$:

$$\frac{\exp(-\pi^2 |\vec{m}|^2 \beta^2)}{|\vec{m}|^2} \leq \varepsilon_{precision}$$

Malheureusement, la complexité algorithmique de ce terme est au mieux d'ordre $O(N^{3/2})$.

ISM3 TERME RÉCIPROQUE – "SELF " INTERACTION ET CAS DES ATOMES LIÉS

La formulation du terme d'énergie réciproque

$$U^{rec} = \frac{1}{2\pi V} \sum_{\vec{m}\neq 0}^{\infty} \frac{\exp(-\pi^2 |\vec{m}|^2 \beta^2)}{|\vec{m}|^2} S(\vec{m}) S(-\vec{m})$$

$$\text{avec} \quad S(\vec{m}) = \sum_{i=1}^{N} q_i \exp(2\pi i \vec{m}.\vec{r}_i)$$

Fait un apparaître des termes d'interaction non physique, en particulier, l'interaction d'une charge q_i avec elle-même mais également l'interaction « réciproque » des charges d'atomes à l'état liés.

Il faut donc introduire des termes de correction adaptés à ces deux situations, à savoir :

$$U^{self} = -\frac{\beta}{\sqrt{\pi}} \sum_{i=1}^{N} q_i^2$$

$$U^{adj} = -\sum_{ij}^{*} q_i q_j \frac{1 - erfc(|\vec{r}_i - \vec{r}_j|)}{|\vec{r}_i - \vec{r}_j|}$$

ISM3 INTERPOLATION SUR GRILLE ET SOMMES D'EWALD

Il est possible d'interpoler précisément les trois composantes de l'exponentielle complexe

$$\exp(2\pi i\vec{m}.\vec{r}_i) = \exp(2\pi i\frac{m_x x_i}{L_x})\exp(2\pi i\frac{m_y y_i}{L_y})\exp(2\pi i\frac{m_z z_i}{L_z})$$

à l'aide fonctions supports M_p bornées (par exemple des fonctions de type Cardinal B-spline)

$$\exp(2\pi i\frac{m_x u_i^x}{K_x}) \approx b(\frac{m_x}{K_x})\sum_{k=-\infty}^{k=+\infty} M_p(u_i^x - k)\times\exp(2\pi i\frac{m_x k}{K_x}) \quad \text{avec} \quad \mathrm{u}_i^x = \frac{K_x x_i}{L_x}$$

Si l'on considère la transformée de Fourier (inverse) Q^F du tableau à 3 dimensions :

$$Q^R(k_x,k_y,k_z) = \sum_{i=1}^{N} q_i \sum_{nx,ny,nz}\left[M_p(u_i^x - k_x - n_x K_x)M_p(u_i^y - k_y - n_y K_y)M_p(u_i^z - k_z - n_z K_z)\right]$$

On peut alors écrire un forme approchée du facteur de structure :

$$\tilde{S}(\vec{m}) = b(\frac{m_x}{K_x})b(\frac{m_y}{K_y})b(\frac{m_z}{K_z})Q^F(m_x,m_y,m_z) \quad \text{avec} \quad -\frac{1}{2} \le \frac{m_\alpha}{K_\alpha} \le \frac{1}{2} \quad \forall\alpha\in\{x,y,z\}$$

ISM3 INTERPOLATION SUR GRILLE ET SOMMES D'EWALD

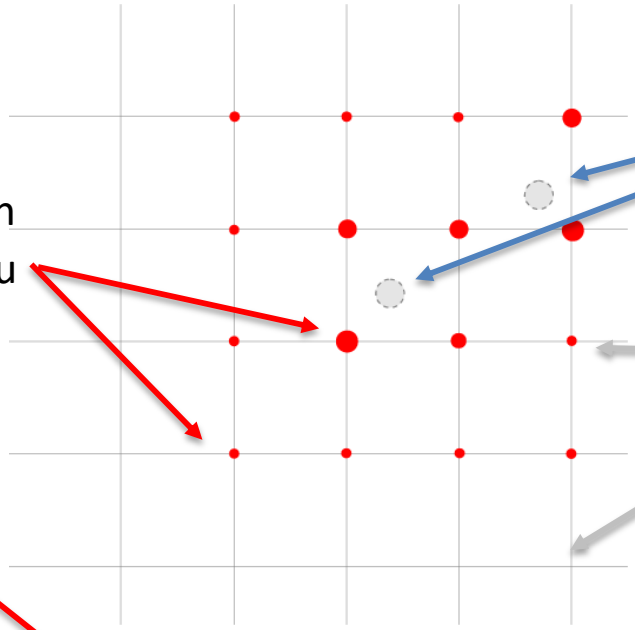

Atomes

Poids $M_p(u_i^x - k)$ en fonction de la position d'un atome au nœud considéré

Noeuds de la grille d'interpolation

$$\exp(2\pi i \frac{m_x u_i^x}{K_x}) \approx b(\frac{m_x}{K_x}) \sum_{k=-\infty}^{k=+\infty} M_p(u_i^x - k) \times \exp(2\pi i \frac{m_x k}{K_x}) \quad \text{avec} \quad \mathrm{u}_i^x = \frac{K_x x_i}{L_x}$$

ISM3 INTERPOLATION SUR GRILLE : COMPLEXITÉ ET MOMENTS INDUITS

Dès lors on peut écrire une expression approchée de l'énergie réciproque

$$\tilde{U}^{rec} = \frac{1}{2\pi V}\sum_{\vec{m}\neq 0}^{\infty}\frac{\exp(-\pi^2|\vec{m}|^2\beta^2)}{|\vec{m}|^2}\tilde{S}(\vec{m})\tilde{S}(-\vec{m}) = \frac{1}{2}\sum_{m_x}^{K_x-1}\sum_{m_y}^{K_y-1}\sum_{m_z}^{K_z-1}G^F(\vec{m}).Q^F(\vec{m}).Q^F(-\vec{m})$$

$$= \frac{1}{2}\sum_{m_x}^{K_x-1}\sum_{m_y}^{K_y-1}\sum_{m_z}^{K_z-1}Q^R(\vec{m}).\left(G^R(\vec{m})*Q^R(\vec{m})\right)$$

$$F(Q^R)(-m_x,-m_y,-m_z) = K_xK_yK_zF^{-1}(Q^R)(m_x,m_y,m_z) \quad \text{et } f*g = F^{-1}(F(f).F(g)) \quad \text{et } \sum_{\vec{m}}F(f)(\vec{m})g(\vec{m}) = \sum_{\vec{m}}f(\vec{m})F(g)(\vec{m})$$

Le produit de convolution '*' est calculé à l'aide d 'une nouvelle transformée de Fourier.

Remarques :

1 - Pour système condensé, le nombre de point de cette grille ($0 \le k_\alpha \le K_\alpha - 1$) est proportionnel au nombre d'atomes du système, donc d'ordre O(*N*). L'approche dite de « Fast Fourier Transform » (FFT, transformée de Fourier rapide) est d'une complexité calculatoire variant O(*NlogN*). **L'énergie réciproque est donc un terme d'énergie d'ordre O(*NlogN*).**

2 – Nous avons abordé ici le cas de l'interaction de Coulomb. On peut reprendre l'ensemble des équations précédentes pour l'adapter au cas des champs de force polarisable basés sur l'approche des moments dipolaires induits en considérant l'opérateur :

$$q_i \rightarrow q_i + \vec{\mu}_i.\vec{\nabla}_i$$

ISM3 CONDITIONS PÉRIODIQUES ET INTERFACES

Pour simuler une interface, on construit d'abord une boite correspondant à le densité de l'eau liquide, puis on étire une dimension (par exemple en multipliant celle-ci par un facteur 3) :

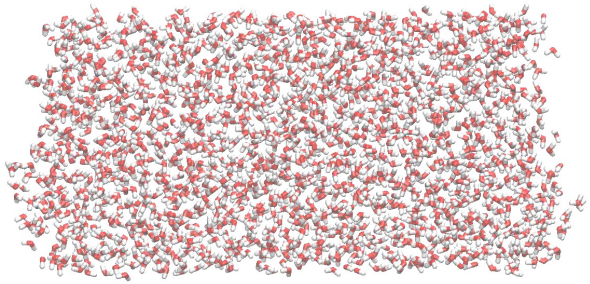

ISM3 CONDITIONS PÉRIODIQUES ET INTERFACES

Pour simuler une interface, on construit d'abord une boite correspondant à le densité de l'eau liquide, puis on étire une dimension (par exemple en multipliant celle-ci par un facteur 3) :

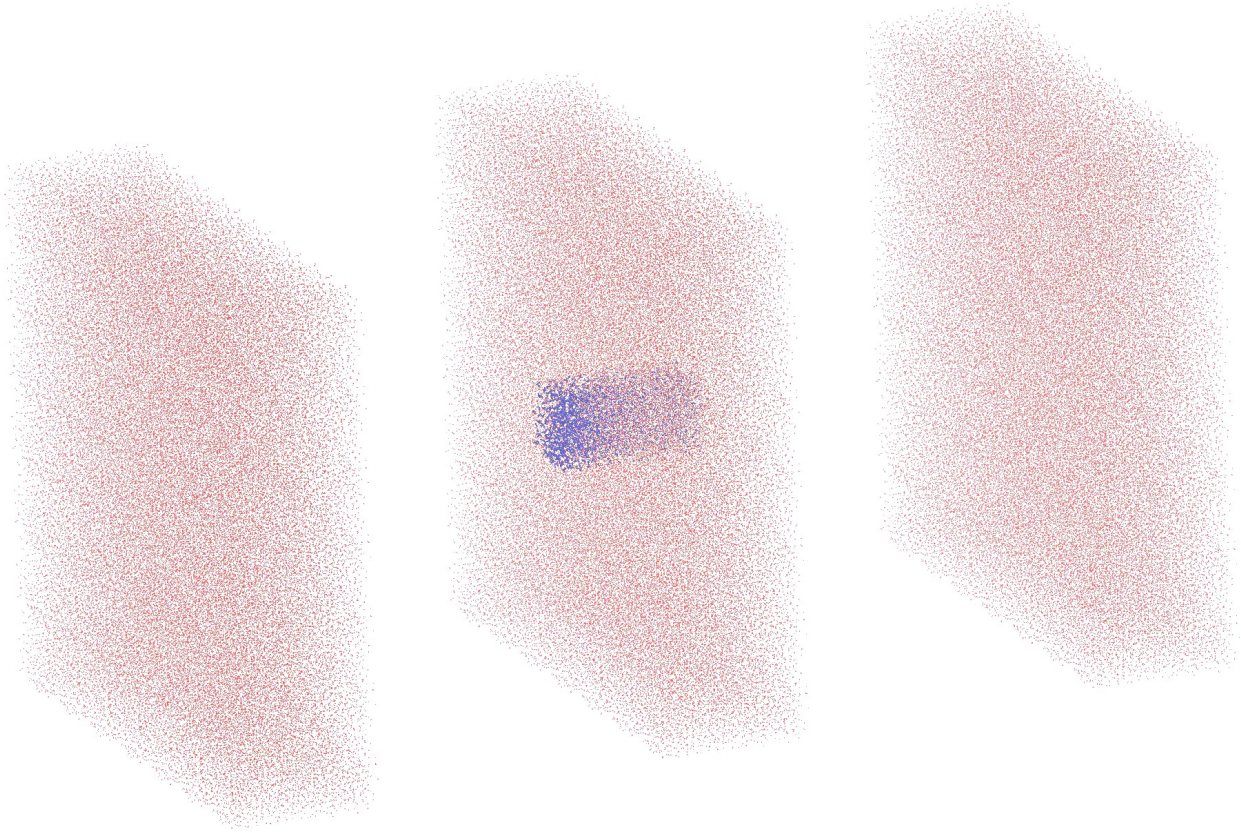

ISM3 CONDITIONS PÉRIODIQUES ET SYSTÈMES NON PÉRIODIQUES

Dans ce cas, on multiplie toutes les dimensions de la boite originale par un facteur >>1

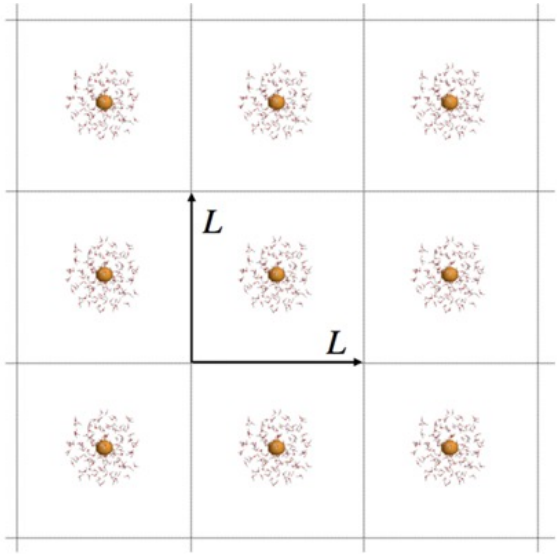

TABLE I. Timing measurements (in seconds) for the capsid systems using direct summation, FMM, and PME. For each method, we measured the time to complete the ES/EF calculation, the dipole convergence step, and the complete timestep, which includes some additional computation. For the PME approach, we used three typical grid sizes of 0.5 Å (high resolution), 1 Å (medium resolution), and 2 Å (low resolution). The analysis was performed on a single core of an Intel Core i7 1.7 GHz CPU.

	Direct (s)			FMM (s)			PME 0.5 Å (s)			PME 1 Å (s)			PME 2 Å (s)		
No. atoms	ES/EF	Dipole	Complete	ES/EF	Dipole	Complete	ES/EF	Dipole	Complete	ES/EF	Dipole	Complete	ES/EF	Dipole	Complete
21612	2.11	4.29	8.43	1.44	4.00	6.71	0.16	16.12	18.45	0.17	1.37	2.17	0.16	0.52	1.21
43224	8.36	17.02	33.40	2.87	7.99	13.38	0.33	20.44	23.92	0.33	3.56	5.22	0.33	1.12	2.50
64836	18.98	39.66	77.87	4.59	13.24	21.87	0.50	31.36	36.67	0.50	5.71	8.25	0.49	1.71	3.79
86448	34.39	69.05	138.52	5.93	16.74	27.51	0.66	48.01	55.70	0.67	7.29	10.63	0.67	2.35	5.16
108060	54.70	108.02	218.27	7.49	20.52	34.62	0.82	68.21	79.49	0.82	10.20	14.48	0.82	3.15	6.64

ISM3 ANNALE EXAMEN 2019

I.17 Soit un système composé de *N* particules dont la fonction d'énergie potentielle est de la forme $U = \sum_{i=1}^{N}\sum_{j>i}^{N}\frac{\exp(-\alpha\cdot r_{ij}^2)}{r_{ij}}$, où r_{ij} est la distance entre deux particules *i* et *j* et α un paramètre fini non nul. Sachant que l'intégrale $\int_0^{+\infty}\exp(-\alpha\cdot r^2).rdr = {}^1/_{2\alpha}$, peut-on proposer un algorithme numériquement précis permettant de calculer *U* avec une complexité algorithmique en

Réponses : O(*N*), O(*N*log*N*), O($N^{3/2}$), O(N^2), O(N^3)

I.20 La méthode « Particle Mesh Ewald » est basée sur une interpolation sur une grille dont les nœuds pavent l'espace de la boite de simulation infiniment répliquée pour modéliser une phase condensée. Le nombre de ces nœuds est-il proportionnel au nombre de particules inclues dans cette boite pour un système condensé ?

Réponse : oui, non

I.21 Quelle est la complexité algorithmique de cette interpolation sur grille ?

Réponse : une ligne maximum

I.31 L'emploi de conditions périodiques dans une simulation de type dynamique moléculaire permet-il de modéliser un système condensé infini ?

Réponse : oui, non

I.32 L'emploi de conditions périodiques dans une simulation de type dynamique moléculaire permet-il de modéliser un système microscopique fini ?

Réponse : oui, non

ISM3 – CODE DE SIMULATION MICROSCOPIQUE

Introduire les conditions périodiques signifie considéré maintenant le terme ULJ sous la forme :

$$U^{LJ} = \frac{4\varepsilon^*}{2}\sum_{i=1}^{N}\sum_{j=1,i\neq j}^{N}\left[\left(\frac{r^*}{r_{ij}}\right)^{12} - 2\left(\frac{r^*}{r_{ij}}\right)^{6}\right] \rightarrow \widetilde{U}^{LJ} = \frac{4\varepsilon^*}{2}\sum_{\{\vec{\eta}\}}\sum_{i=1}^{N}\sum_{j=1,i\neq j}^{N}\left[\left(\frac{r^*}{r_{ij}}\right)^{12} - 2\left(\frac{r^*}{r_{ij}}\right)^{6}\right]$$

On prendra r^* = 3.0 et ε^* = 0.2. Les $\{\vec{\eta}\}$ sont les 27 premières images périodiques dans le cas d'une boite répliquée cubique. Ses dimensions sont $L_x = L_y = L_z = L$ = 30.0.

1 – Introduire dans votre code sous forme de vecteur/tableau les coordonnées des *N_sym* = 27 vecteurs de translation possibles. Les coordonnées correspondant au vecteur qui laisse la boite répliquée inchangée est (0,0,0), le autres vecteurs sont de la forme (L,-L,0) ou encore (L,L,L) par exemple.

2 – Transformer la double boucle qui vous a permis de calculer U^{LJ} dans le cas non périodique au cas périodique. La nouvelle boucle qui englobe les deux précédentes correspondra aux vecteurs $\{\vec{\eta}\}$, i.e. :

```
for i_sym = 1,N_sym
    for i =1,N
        for j = 1,N…
```

Si *N_sym* est fixé à 1, faite en sorte que l'on retrouve le calcul de U^{LJ} en non périodique.

ISM3 – CODE DE SIMULATION MICROSCOPIQUE

3 – Prenez en compte les vecteurs symétrie dans les coordonnées des particules *j* de la 3ième boucle, i.e. :

Xj_loc = Xj + coordonnée X du *i_sym*ième vecteur $\{\vec{\eta}\}$
Yj_loc = Yj + coordonnée Y du *i_sym*ième vecteur $\{\vec{\eta}\}$
Zj_loc = Zj + coordonnée Z du *i_sym*ième vecteur $\{\vec{\eta}\}$

4 - Les conditions périodiques qui se réduisent au 27 premières images n'ont de sens physiques que si les interactions de Lennard-Jones sont tronquées, i.e. elles ne sont calculées que pour des distances entre particules telles que $r_{ij} < R_{cut} < L$. Ceci signifie que l'on doit calculer en fait :

$$\widetilde{U}^{LJ}(R_{cut}) = \frac{4\varepsilon^*}{2}\sum_{\{\vec{\eta}\}}\sum_{i=1}^{N}\sum_{j,r_{ij}\leq R_{cut}}\left[\left(\frac{r^*}{r_{ij}}\right)^{12} - 2\left(\frac{r^*}{r_{ij}}\right)^{6}\right]$$

On prendra ici R_{cut} = 10.0. Introduire la condition sur les distances au niveau de la troisième boucle :

```
for i_sym = 1,N_sym
    for i =1,N
        for j = 1,N…
            if (r_ij < R_cut) then
```

5 – Dans le cas périodiques avec troncature, comment adapter le calcul des forces agissant sur les particules ? Vérifier à nouveau que la somme des forces est bien nulle.

ISM3 – Equations Newtoniennes du mouvement

1 – Algorithme de verlet

2 - Contraintes

3 – Algorithme à pas de temps multiples

4 – Effets chaotiques et simulations indépendantes

ISM3 – EQUATIONS NEWTONIENNES DU MOUVEMENT

Supposons l'énergie microscopique *U* continue et dérivable, il est alors possible de calculer les forces inter-particulaires au sein du système $\mathcal{M}$

$$\vec{F}_i = -\vec{\nabla}_i U$$

Dès lors il est possible de résoudre les équations de mouvements de Newton (formalisme classique) pour l'ensemble des particules du système $\mathcal{M}$

$$m_i \frac{\partial^2 \vec{r}_i}{\partial t^2} = \vec{F}_i = -\vec{\nabla}_i U$$

Avantage : toutes les formes de mouvements au sein du système $\mathcal{M}$ sont facilement étudiables, accès aux moyennes temporelles du système $\mathcal{M}$ (coefficients de diffusion …)

Invariants le long d'une trajectoire (énergie totale constante) permettent de vérifier la qualité d'un code de dynamique moléculaire.

Inconvénient : le pas d'intégration des équations de Newton sont de l'ordre au plus de la femto-seconde (10^{-15} s), alors que nombre de phénomènes physico-chimiques ont des temps caractéristiques > 1 ms.

ISM3 – ALGORITHME DE VERLET

Soit un système de *N* particules de coordonnées $\{\vec{r}_i\}_{1\le i\le N}$ à une date *t*, par développement limité :

$$\begin{cases} \vec{r}_i(t+\delta t) = \vec{r}_i(t) + \dfrac{\partial \vec{r}_i(t)}{\partial t}\delta t + \dfrac{1}{2}\dfrac{\partial^2 \vec{r}_i(t)}{\partial t^2}\delta t^2 + \dfrac{1}{3!}\dfrac{\partial^3 \vec{r}_i(t)}{\partial t^3}\delta t^3 + O(\delta t^4) \\ \vec{r}_i(t-\delta t) = \vec{r}_i(t) - \dfrac{\partial \vec{r}_i(t)}{\partial t}\delta t + \dfrac{1}{2}\dfrac{\partial^2 \vec{r}_i(t)}{\partial t^2}\delta t^2 - \dfrac{1}{3!}\dfrac{\partial^3 \vec{r}_i(t)}{\partial t^3}\delta t^3 + O(\delta t^4) \end{cases}$$

Algorithme de Verlet $\Rightarrow \vec{r}_i(t+\delta t) = 2\vec{r}_i(t) - \vec{r}_i(t-\delta t) + \dfrac{\partial^2 \vec{r}_i(t)}{\partial t^2}\delta t^2 + O(\delta t^4)$

Cet algorithme permet d'éviter d'avoir à mettre en mémoire les vitesses du système (1967…)

$$\frac{\partial \overline{r}_i}{\partial t}(t) = \frac{\overline{r}_i(t+\delta t) - \vec{r}_i(t-\delta t)}{2\delta t}$$

ISM3 – ALGORITHME DE VELOCITY-VERLET

En remarquant que

$$\begin{cases} \dfrac{\partial \vec{r}_i}{\partial t}(t+\dfrac{1}{2}\delta t) = \dfrac{\vec{r}_i(t+\delta t)-\vec{r}_i(t)}{\delta t} \\ \dfrac{\partial^2 \vec{r}_i}{\partial t^2}(t) = \dfrac{\dfrac{\partial \vec{r}_i}{\partial t}(t+\dfrac{1}{2}\delta t)-\dfrac{\partial \vec{r}_i}{\partial t}(t-\dfrac{1}{2}\delta t)}{\delta t} = -\dfrac{1}{m_i}\vec{\nabla}_i U \end{cases}$$

On peut écrire un nouvel algorithme dit de velocity-Verlet en $O(\delta t^3)$

$$\begin{cases} m_i \dfrac{\partial \overline{r}_i}{\partial t}(t+\dfrac{1}{2}\delta t) = m_i \dfrac{\partial \overline{r}_i}{\partial t}(t) - \dfrac{1}{2}\vec{\nabla}_i U(t)\cdot\delta t \\ \vec{r}_i(t+\delta t) = \vec{r}_i(t) + \dfrac{\partial \overline{r}_i}{\partial t}(t+\dfrac{1}{2}\delta t).\delta t \\ m_i \dfrac{\partial \overline{r}_i}{\partial t}(t+\quad \delta t) = m_i \dfrac{\partial \overline{r}_i}{\partial t}(t+\dfrac{1}{2}\delta t) - \dfrac{1}{2}\vec{\nabla}_i U(t+\delta t)\cdot\delta t \end{cases}$$

ISM3 – REMARQUE OPÉRATEUR DE LIOUVILLE

Faire évoluer un système isolé entre *t* et $t+\delta t$ revient à appliquer un opérateur de Liouville au vecteur

$$\Gamma\left\{(\vec{r}_i,\vec{v}_i)\right\}_{1\le i\le N}$$

$$\Gamma(\left\{\vec{r}_i,\vec{v}_i\right\}_{1\le i\le N},t+\delta t)=e^{iL\delta t}\Gamma(\left\{\vec{r}_i,\vec{v}_i\right\}_{1\le i\le N},t)$$

L'opérateur *iL* s'écrit

$$iL=iL_r+iL_v=\sum_{1\le i\le N}\left(\vec{v}_i\frac{\partial}{\partial\vec{r}_i}-\vec{\nabla}_i U\frac{\partial}{\partial\vec{v}_i}\right)$$

Dès lors l'algorithme de velocity-Verlet peut se réécrire de manière compacte

$$\exp(iL\delta t)=\exp\left(\frac{1}{2}iL_v\delta t\right)\exp\left(iL_r\delta t\right)\exp\left(\frac{1}{2}iL_v\delta t\right)$$

ISM3 – STABILITÉ DE L'ALGORITHME DE VELOCITY-VERLET

Considérons le cas d'un oscillateur harmonique simple $U = k_k x_k^2$

Dans ce cas x_k varie de manière sinusoïdale avec le temps, avec une fréquence de vibration

$$\omega_k = \frac{1}{t_k} = \sqrt{k_k / m_k}$$

L'algorithme de Velocity-Verlet est stable si l'intégrant des équations du mouvement vérifie

$$\delta t \leq \frac{1}{10} t_k$$

➔ On doit choisir le pas de temps en fonction du mouvement le plus rapide dans le système considéré, même si celui ne correspond qu'à un faible nombre de particules…

En général, pour un système moléculaire classique avec un champ de force additif classique

$$\delta t \leq 1 \text{ fs}$$

Une telle valeur permet de maintenir l'énergie totale du système constante lors d'une dynamique moléculaire

ISM3 – STABILITÉ DE L'ALGORITHME DE VELOCITY-VERLET

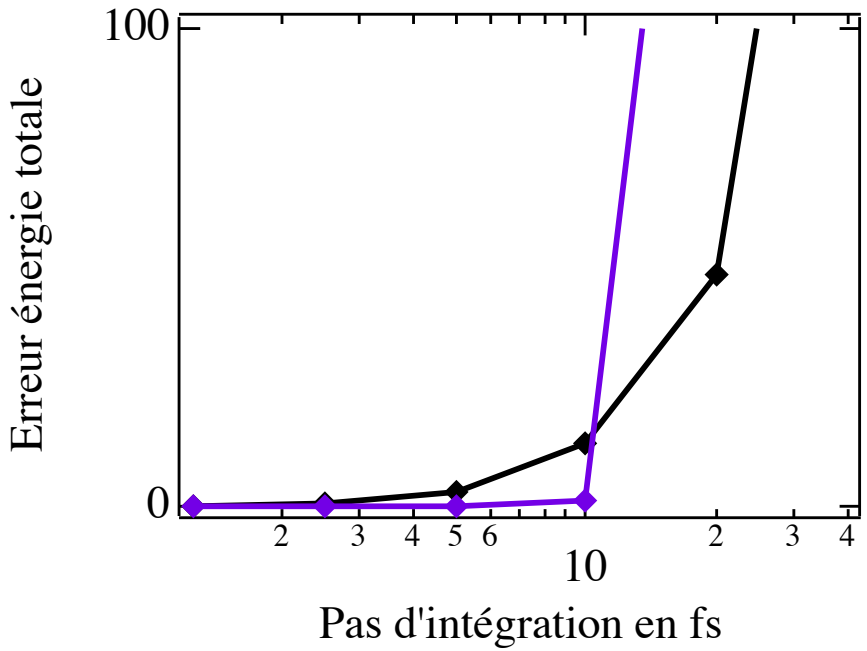

*Okunbor and Skeel, J Comput Chem, **15** (1994) 73*

En noir, l'algorithme de velocity-Verlet

En violet méthode basée sur un algorithme de type Runge-Kutta-Nyström du 4ième ordre (s = 4) :

$$
\begin{aligned}
&Q_0 = q_n \\
&\dot{Q}_0 = \dot{q}_n \\
&\textbf{for } i = 1, 2, \ldots, s \\
&\quad Q_i = Q_{i-1} + h(c_i - c_{i-1})\dot{Q}_{i-1}, \quad \textit{where } c_0 = 0 \\
&\quad \dot{Q}_i = \dot{Q}_{i-1} + hB_i f(Q_i) \\
&\textbf{end for} \\
&q_{n+1} = Q_s + h(1 - c_s)\dot{Q}_s \\
&\dot{q}_{n+1} = \dot{Q}_s
\end{aligned}
$$

where c_i and B_i are method parameters.

ISM3 – CONTRAINDRE LES LIAISONS XH

Les liaisons XH correspondent à des fréquences de vibrations les plus élevées, elles imposent donc les pas d'intégration à employer pour résoudre les équations du mouvement en dynamique moléculaire.

Une manière d'améliorer la stabilité des simulations de dynamique moléculaire est de contraindre ces liaisons XH à leur longueur idéale telle que définie dans le potentiel

$$U_{XH}^{stretch} = k_{XH}(r_{XH} - r_{XH}^{0})^2$$

Autrement dit on impose la condition suivante lors de la résolution des équations du mouvement :

$$\sigma_k = \left|\vec{r}_X^{\,k} - \vec{r}_H^{\,k}\right|^2 - d_k^2 = 0 \quad \text{avec } d_k = r_{k,XH}^{0}$$

Ce terme est interprété comme un terme d'énergie (nulle) mais qui introduit de nouvelles forces dans le système

$$-\vec{\nabla}_i \sigma_k$$

ISM3 – CONTRAINDRE LES LIAISONS XH

Pour résoudre les équations de contrainte, on considère l'approche des multiplicateurs de Lagrange. Chaque atome *i* subit des forces de « contrainte » de la forme

$$-\vec{\nabla}_i \left(\sum_{k=1}^{\text{contraintes}} \lambda_k \sigma_k \right)$$

Les paramètres λ_k sont calculés afin que les contraintes vérifiées à la date *t* :

$$\sigma_k(t) = \left| \vec{r}_X^{\,k}(t) - \vec{r}_H^{\,k}(t) \right|^2 - d_k^2 = 0$$

soient aussi vérifiées à la date $t + \delta t$:

$$\sigma_k(t+\delta t) = \left| \vec{r}_X^{\,k}(t+\delta t) - \vec{r}_H^{\,k}(t+\delta t) \right|^2 - d_k^2 = 0$$

Si l'on note $\vec{r}_{X,nc}^{\,k}$ et $\vec{r}_{H,nc}^{\,k}$ les coordonnées obtenues sans application des contraintes, les paramètres λ_k sont définis en résolvant simultanément les équations (non-linéaires) :

$$\sigma_k(t+\delta t) = \left| \vec{r}_{X,nc}^{\,k}(t+\delta t) - \vec{r}_{H,nc}^{\,k}(t+\delta t) + \sum_{k=1}^{\text{contraintes}} \lambda_k \left(\frac{1}{m_X^k} \frac{\partial \sigma_k}{\partial \vec{r}_X^{\,k}}(t) - \frac{1}{m_H^k} \frac{\partial \sigma_k}{\partial \vec{r}_H^{\,k}}(t) \right) \right|^2 - d_k^2 = 0$$

ISM3 – CONTRAINTES ET ALGORITHME DE VELOCITY VERLET

$$
\begin{cases}
m_i \dfrac{\partial \overline{r_i}}{\partial t}(t+\dfrac{1}{2}\delta t) = m_i \dfrac{\partial \overline{r_i}}{\partial t}(t) - \dfrac{1}{2}\vec{\nabla}_i U(t)\cdot\delta t \\
\vec{r_i}(t+\delta t) = \vec{r_i}(t) + \dfrac{\partial \overline{r_i}}{\partial t}(t+\dfrac{1}{2}\delta t).\delta t \\
\text{Résolution des équations de contraintes, i.e. calculs des } \lambda_k\text{, correction des positions.} \\
m_i \dfrac{\partial \overline{r_i}}{\partial t}(t+\quad \delta t) = m_i \dfrac{\partial \overline{r_i}}{\partial t}(t+\dfrac{1}{2}\delta t) - \dfrac{1}{2}\vec{\nabla}_i U(t+\delta t)\cdot\delta t \\
\text{Corrections des vitesses pour tenir compte des forces de « contrainte »}
\end{cases}
$$

ISM3 – ALGORITHME À PAS DE TEMPS MULTIPLES

Soit deux oscillateurs couplés avec deux constantes de force telles que

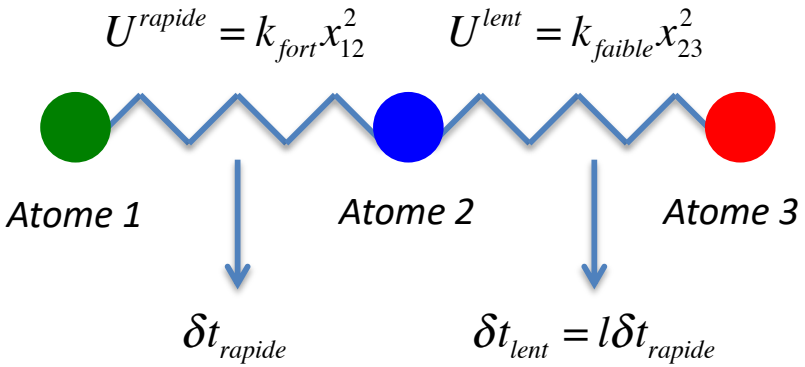

$$\frac{\delta t_{rapide}}{\delta t_{lent}} \leq \frac{t_{rapide}}{t_{lent}} \propto \left(\frac{k_{faible}}{k_{fort}}\right)^{1/2}$$

Ici, *l* est un entier. Dans ce cas on peut réécrire l'opérateur de Liouville équivalent à l'algorithme de velocity-Verlet sous la forme

$$\exp(iLl\delta t) = \exp\left(\frac{1}{2}iL_v^{lent} l\delta t\right)\left(\exp\left(\frac{1}{2}iL_v^{rapide}\delta t\right)\exp\left(iL_r\delta t\right)\exp\left(\frac{1}{2}iL_v^{rapide}\delta t\right)\right)^l \exp\left(\frac{1}{2}iL_v^{lent} l\delta t\right) + O\left((l\delta t)^3\right)$$

$$iL_v^{rapide} = -\vec{\nabla}U^{rapide}\frac{\partial}{\partial\vec{v}_k} \quad \text{et} \quad iL_v^{lent} = -\vec{\nabla}U^{lent}\frac{\partial}{\partial\vec{v}_k}$$

ISM3 – ALGORITHME À PAS DE TEMPS MULTIPLES ET VELOCITY VERLET

$$l \text{ fois } \begin{cases} m_i \dfrac{\partial \vec{r}_i}{\partial t}(t+\dfrac{1}{2}\delta t) = m_i \dfrac{\partial \vec{r}_i}{\partial t}(t) - \dfrac{1}{2}\vec{\nabla}_i U^{fort}(t)\cdot\delta t \\ \vec{r}_i(t+\delta t) = \vec{r}_i(t) + \dfrac{\partial \vec{r}_i}{\partial t}(t+\dfrac{1}{2}\delta t).\delta t \\ \\ \text{Calcul de } U^{fort} \text{ à chaque itération et de } U^{faible} \text{ toutes les } l \text{ itérations} \\ \\ m_i \dfrac{\partial \vec{r}_i}{\partial t}(t+\quad \delta t) = m_i \dfrac{\partial \vec{r}_i}{\partial t}(t+\dfrac{1}{2}\delta t) - \dfrac{1}{2}\vec{\nabla}_i U^{fort}(t+\delta t)\cdot\delta t \end{cases}$$

A l'itération *l* : Correction des vitesses pour tenir compte des forces $-\dfrac{1}{m_i}\vec{\nabla}_i U^{faible}$

Avantage : on ne calcule U^{faible} *l* fois moins de fois que U^{fort}

ISM3 – ALGORITHME À PAS DE TEMPS MULTIPLES ET TERMES NON LIÉS

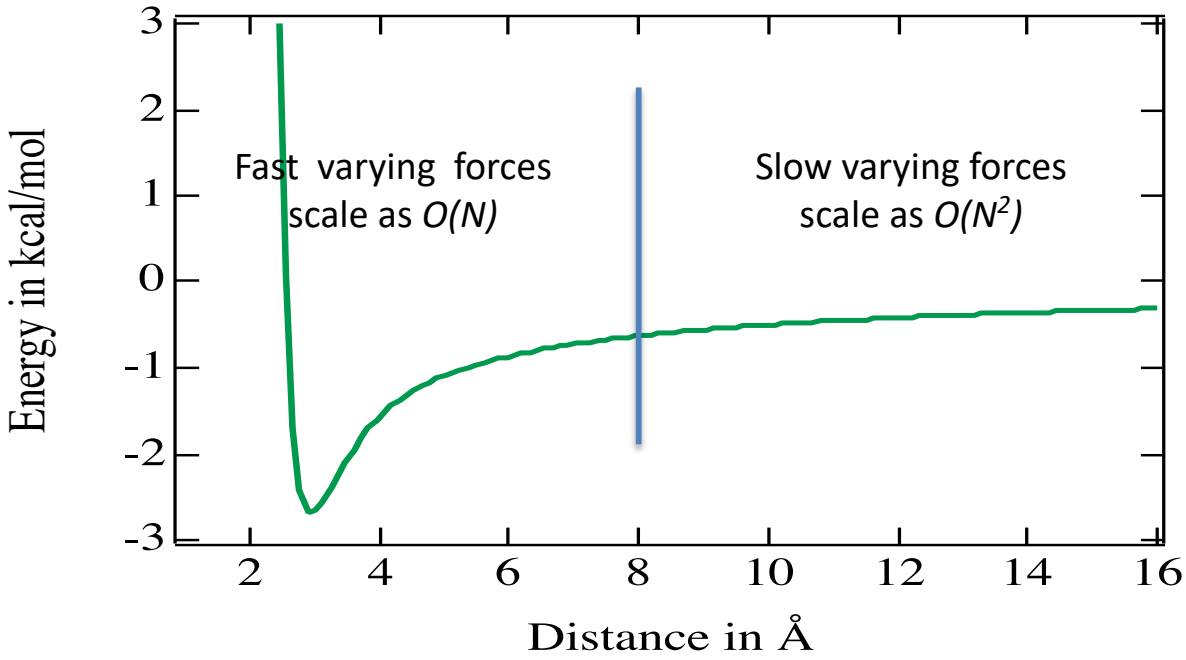

Le ratio des temps CPU pour calculer les forces “rapides” et les forces “lentes” tend vers 0 quand *N* augmente, on peut donc s’attendre à un facteur d’accélération égale à *l.*

Malheureusement, l’approche MTS est sujette à des effets de résonnance qui ne permettent de considérer que des valeurs *l* telles que

$$l\delta t \leq 5-6 \text{ fs}$$

ISM3 – EXERCICE : ALGORITHME À PAS DE TEMPS MULTIPLES

1 – Soit un mélange de particules A et B dont les énergies d'interaction pour chacun d'entre eux avec le milieu dans lequel ils sont plongés sont de la forme :

$$U^A = k_A(\vec{r}_A - \vec{r}_A^{\,0})^2 \quad \text{et} \quad U^B = k_B(\vec{r}_B - \vec{r}_B^{\,0})^2$$

Les deux types de particules ont une même masse *m*. La fréquence caractéristique de leur mouvement (fréquence de vibration) est :

$$\nu^A = \frac{1}{2\pi}\sqrt{k_A / m} \quad \text{et} \quad \nu^B = \frac{1}{2\pi}\sqrt{k_B / m}$$

a - Dans quelle rapport de proportion doivent être k_A et k_B pour que les temps d'intégration pour les mouvements de A et de B soit dans un rapport de 1 à 10 ?

b – Quel est le temps d'intégration à considérer pour traiter un mélange de particules A et B ?

c – Définissez une algorithme à pas de temps multiples pour ce système.

d – Quelle est l'accélération attendue avec un tel algorithme en fonction de la proportion des particules A et B dans le mélange ?

ISM3 – CONTRÔLE DE LA TEMPÉRATURE

Position du problème : lorsque l'on résout les équations du mouvement (le plus exactement possible), l'énergie totale du système est constante :

$$E(\{\vec{r}_i,\vec{v}_i\}_{1\le i\le N}) = U(\{\vec{r}_i\}_{1\le i\le N}) + K(\{\vec{v}_i\}_{1\le i\le N}) = U(\{\vec{r}_i\}_{1\le i\le N}) + \frac{1}{2}\sum_{i=1}^{N} m_i v_i^2 = U(\{\vec{r}_i\}_{1\le i\le N}) + \frac{1}{2}\sum_{i=1}^{N}\frac{p_i^2}{m_i}$$

Lors de la simulation le système va évoluer spontanément vers un minimum local de *U*

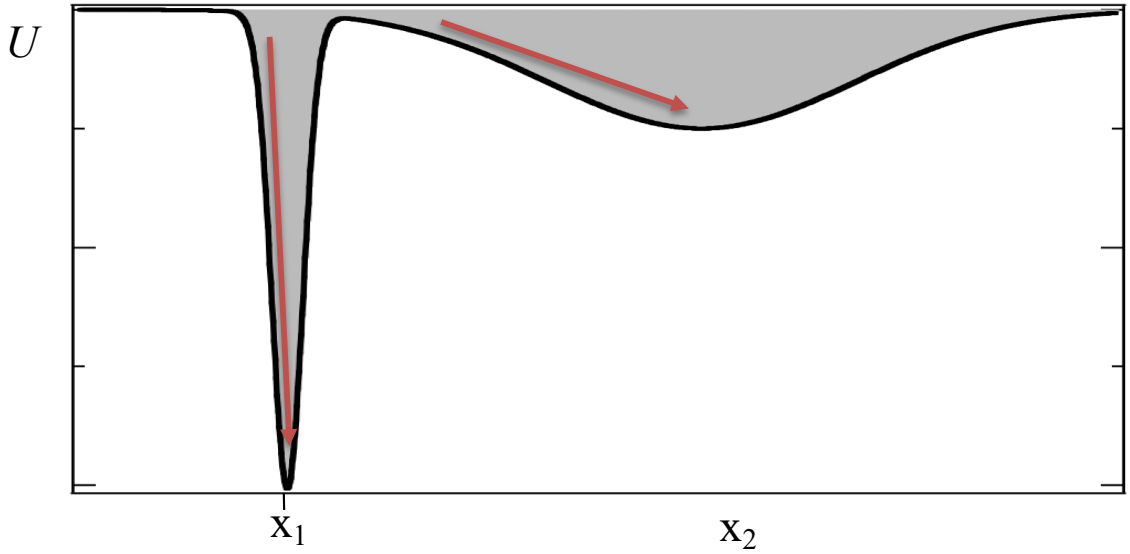

Si son énergie totale est constante alors son énergie cinétique va augmenter et donc *T* car :

$$n_{dl} k_B T = \frac{1}{2}\sum_{i=1}^{N}\frac{p_i^2}{m_i}$$

ISM3 – CONTRÔLE DE LA TEMPÉRATURE

L'objectif d'une simulation microscopique est d'étudier un système dans des conditions physiques (composition, température *T* et volume V*)* données, il faut donc pouvoir contrôler sa température pour éviter des sauts de celle-ci lors d'une simulation , comme par exemple dans le cas :

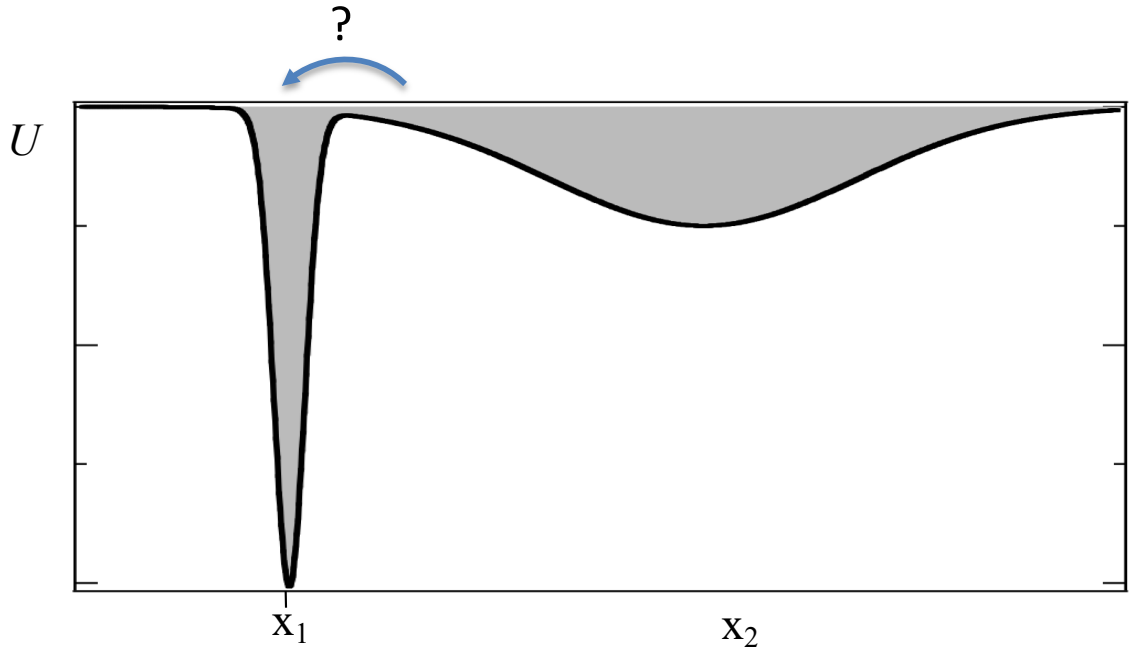

Si le système reste proche de x_2 alors sa température va osciller autour de sa valeur initiale, si il évolue de x_2 vers x_1 alors sa température va croître de manière très importante, ce qui n'est le but de la simulation…

ISM3 – COMMENT CONTRÔLER LA TEMPERATURE ?

La manière la plus simple et utilisée par l'ensemble des algorithmes de contrôle de la température *T* (algorithmes dits « thermostats ») est de modifier dynamiquement les vitesses pour qu'elles restent en moyennes proches de la température T_0 choisie :

$$m_i \frac{\partial \vec{v}_i}{\partial t} = \vec{F}_i + g(\vec{v}_i, T_0)$$

La fonction *g* s'interprète comme une 'friction' au système, dont la forme la plus simple (thermostat de Beredsen) est :

$$g(\vec{v}_i, T_0) = m_i \gamma \left(\frac{T_0}{T} - 1\right) \vec{v}_i \quad \text{avec} \quad N_{dl} k_B T = \frac{1}{2} \sum_{i=1}^{N} m_i \vec{v}_i^2 = \frac{1}{2} \sum_{i=1}^{N} \frac{\vec{p}_i^2}{m_i}$$

Cette méthode n'est pas thermodynamiquement exacte, mais elle est à la base de tous les thermostats proposés à ce jour. Numériquement elle ne permet pas de conserver l'énergie totale du système, pour cela il faut définir une énergie du thermostat : on simule un système microscopique avec un réservoir d'énergie avec lequel il est en équilibre. Enfin le paramètre γ permet de contrôler l'intensité du couplage avec ce réservoir (en général de l'ordre de 0.1 à 0.001 dt^{-1}).

Ce type d'approche se généralise au contrôle de la pression *P* (« barostats »), et à toutes les propriétés macroscopiques qui s'expriment en fonction des forces et des vitesses du système.

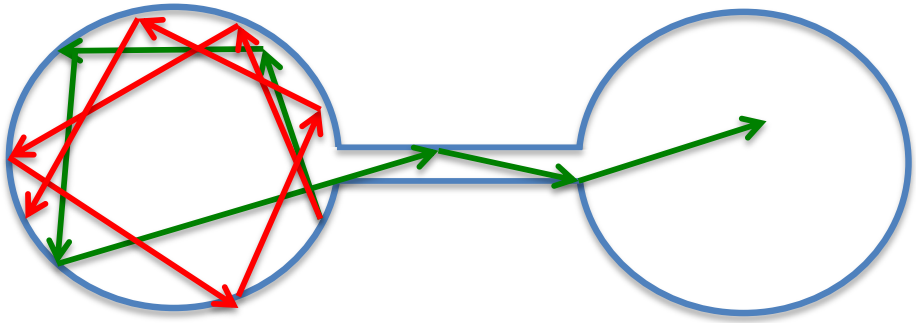

Etat A Etat B

Des variations infinitésimales des vitesses peuvent amener un système à explorer des zones totalement différentes de sa surface d'énergie potentielle.

Par exemple, inverser deux lignes dans un code de dynamique moléculaire peut affecter le dernier bit d'un nombre réel et donc induire des phénomènes chaotiques.

Ces phénomènes ne sont pas problématiques si l'on peut générer des simulations suffisamment longues (i.e. un système microscopique finirait alors par explorer toute sa surface d'énergie potentielle accessible).

Par contre, il faut systématiquement se méfier de simulations trop courtes… Surtout des résultats d'une unique simulation trop courte…

ISM3 – EQUATIONS DU MOUVEMENT ET EFFETS CHAOTIQUES

Protéine BPTI

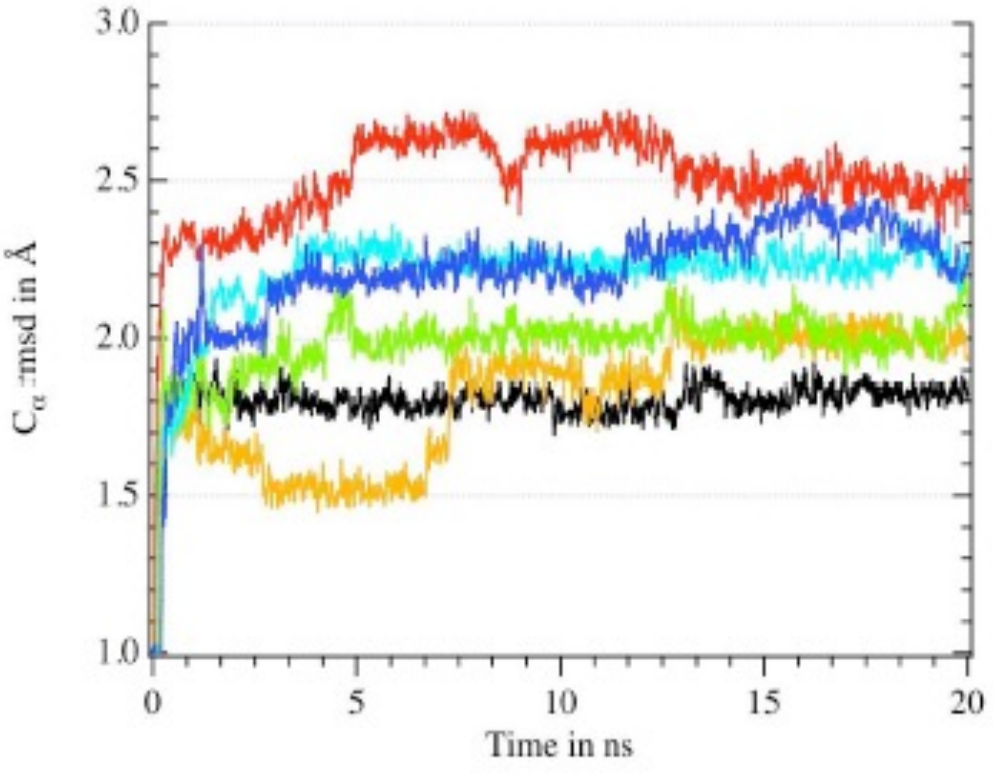

Six simulations de la protéines BPTI avec différentes conditions initiales de vitesses. Sachant qu'un bon champ de force est un champ de force qui permet d'obtenir des RMSDs < 2.0 Å, quelle est ici la probabilité d'obtenir un résultat « très encourageant » avec une seule simulation ?

ISM3 – TIRER AVANTAGE DES EFFETS CHAOTIQUES

Exemple de la méthode :

Parallel replica method for dynamics of infrequent events

A.F. Voter, Phys. Rev. B, 57 (1998) 13985

Soit un système microscopique initialement dans une structure notée S et pour lequel on dispose d'un critère permettant d'évaluer si il subit une transition (en général structurale) à une date *t*

1 – *M* trajectoires indépendantes du système sont lancées en parallèle à partir de sa structure S

2 – Si une transition S ➔ S' est observées le long d'un seule trajectoire : arrêt de toutes les trajectoires.

3 – *M* nouvelles trajectoires sont relancées en considérant comme structure initiale la nouvelle structure S' …

Si le système peut osciller entre seulement deux états S et S', alors il est possible de démontrer que le temps pour observer cette transition avec *M* simulations par rapport à une seule est

$$\overline{t}_M = \frac{1}{M}\overline{t}_1$$

ISM3 – EXEMPLE D'UNE SIMULATION

Protéine BPTI simulée pendant 600 ps (structures sauvegardées toutes les 1 ps, pas d'intégration 2 fs, liaison XH contraintes, velocity –Verlet standard, 300K, 100 ps de thermalisation)

Protéine BPTI

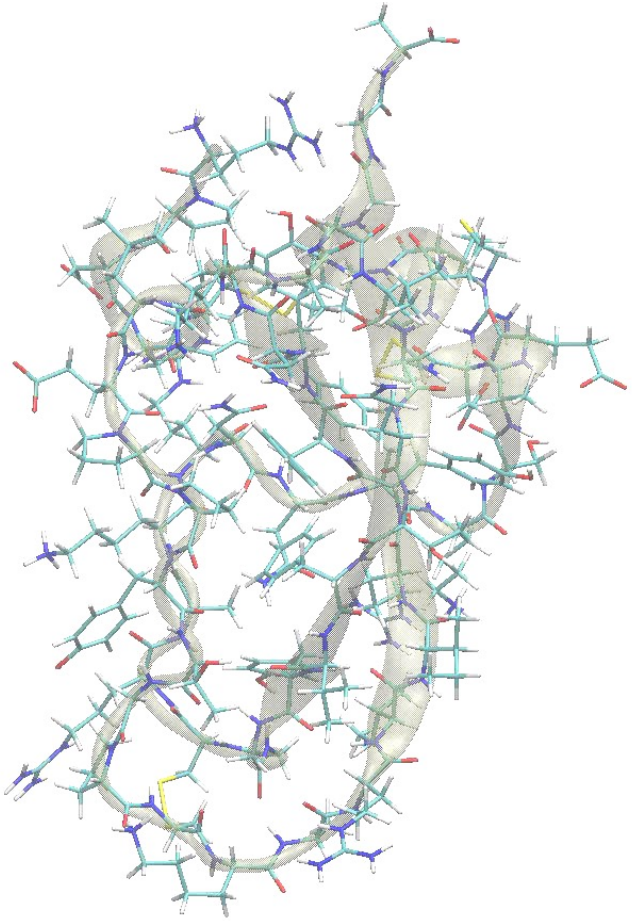

ISM3 – EXEMPLE D'UNE TRANSITION STRUCTURALE

Hexamère de polymères d'urée (sous forme d'hélice) simulé pendant 4 ns (structures sauvegardées toutes les 1 ps, pas d'intégration 2 fs, liaison XH contraintes, velocity –Verlet standard, 300K, 500 ps de thermalisation)

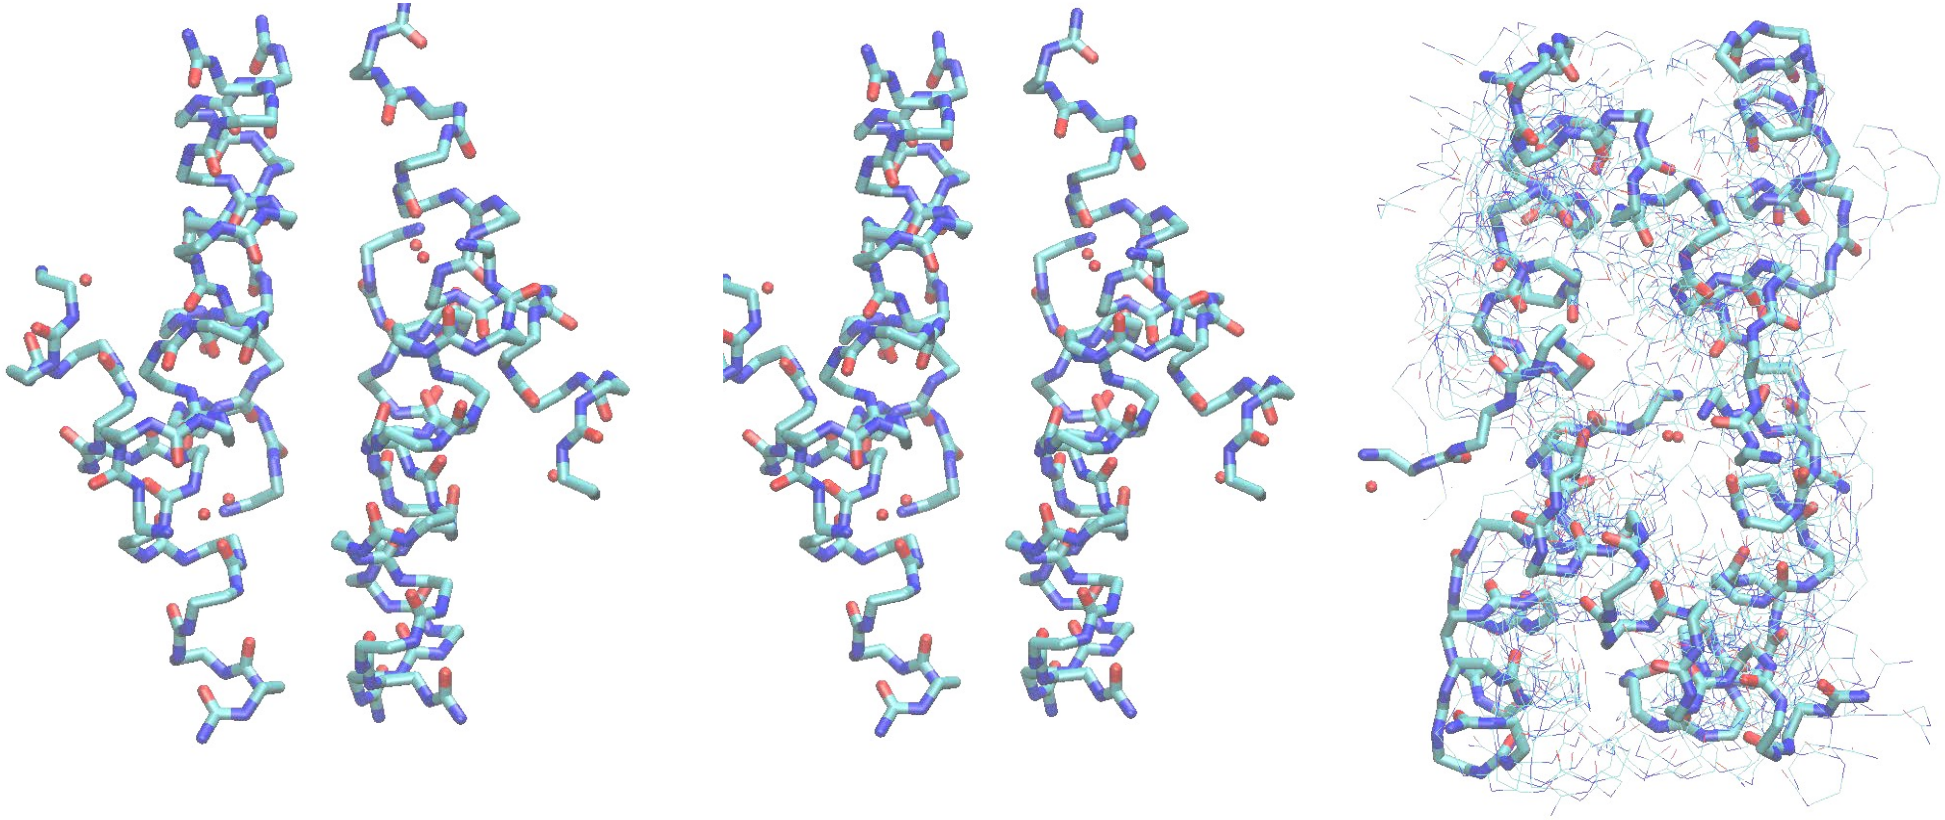

I.23 Soit un jeu A de N ressorts dont le temps caractéristique est t1 et un jeux B de N ressorts dont le temps caractéristique est t2. t1 >> t2. On applique une contrainte à chaque ressort B les empêchant de vibrer. Quel est le temps d'intégration des équations de Newton adapté à ce mélange de ressorts

Réponse : t1, t2, t1/10, t2/10, t1/100, t2/100 ?

I.24 Comment s'assurer a minima que le pas de temps employé pour résoudre les équations de Newton en dynamique moléculaire est pertinent ?

Réponse : les calculs se font rapidement, l'énergie potentielle est constante le long d'une simulation, l'énergie totale est constante le long d'une simulation, le système moléculaire considéré est stable le long d'une simulation, la surface d'énergie potentielle d'un système moléculaire est explorée correctement lors d'une simulation ?

ISM3 – CODE DE SIMULATION MICROSCOPIQUE

1 – Introduire dans votre code l'algorithme de velocity Verlet sans contrôle de la température. Les forces seront calculées sur pour le système microscopique « particle.xyz » en conditions périodiques et on introduira des vecteurs/tableaux pour les composantes du moment cinétique (p_x^i, p_y^i, p_z^i) de chaque particule (NB : moment cinétique = vitesse/masse). On pendra dt = 1 (fs) et on considérera que le facteur de conversion à appliquer aux unités de force pour obtenir des unités de moment cinétique est :

$$\text{CONVERSION_FORCE} = =0.0001*4.186.$$

2 – Introduire une routine dans votre code qui permet de calculer l'énergie cinétique de votre système microscopique, c'est à dire :

$$\text{ENERGIE_CINETIQUE} = \frac{1}{2\times\text{CONVERSION_FORCE}} \times \sum_{i=1}^{N} \frac{(p_x^i \times p_x^i + p_y^i \times p_y^i + p_z^i \times p_z^i)}{m_i}$$

Cette routine donnera également en sortie la température cinétique du système :

$$T = \frac{1}{N_{dl}\times\text{CONSTANTE_R}} \times \text{ENERGIE_CINETIQUE}$$

On prendra comme masse pour toutes les particules m_i = 18 et CONSTANTE_R = 0.00199. N_{dl} est le nombre de degrés de libertés du système, pour des conditions périodiques :

$$N_{dl} = 3\text{x}N_particules_total - 3$$

3 – Pour lancer une dynamique moléculaire, il faut générer un premier jeux de moments cinétiques aléatoires « recalibrés » pour correspondre à la température de simulation choisie, ici T_0 = 300 K :

$\mathrm{c} = \mathrm{random(seed)}$; $\mathrm{s} = \mathrm{random(seed)}$; p_x^i = fonction_signe(1.0,0.5-s)*c
$\mathrm{c} = \mathrm{random(seed)}$; $\mathrm{s} = \mathrm{random(seed)}$; p_y^i = fonction_signe(1.0,0.5-s)*c
$\mathrm{c} = \mathrm{random(seed)}$; $\mathrm{s} = \mathrm{random(seed)}$; p_z^i = fonction_signe(1.0,0.5-s)*c

Moments cinétiques recalibrés pour correspondre à la température choisie T_0 => *c*alculer l'énergie cinétique ENERGIE_CINETIQUE_INIT correspondant aux moments cinétiques précédents puis appliquer la correction RAPPORT aux moments cinétiques :

$$\mathrm{RAPPORT} = N_{dl} \times \mathrm{CONSTANTE_R} \times T_0 \ / \ \mathrm{ENERGIE_CINETIQUE_INIT}$$

$$p_x^i = \mathrm{RAPPORT} \times p_x^i$$
$$p_y^i = \mathrm{RAPPORT} \times p_y^i$$
$$p_z^i = \mathrm{RAPPORT} \times p_z^i$$

ISM3 – CODE DE SIMULATION MICROSCOPIQUE

4 – Les équations du mouvements de Newton conservent le moment cinétique (P_x,P_y,P_z) du centre de masse du système microscopique considéré. Il faut donc encore corriger les moments cinétiques précédents afin que le centre de masse ne se déplace pas. Tout d'abord calculer le moment cinétique du centre masse

$$P_x = \sum_{i=1}^{N_particule_total} p_x^i \; ; \; P_y = \sum_{i=1}^{N_particule_total} p_y^i \; ; \; P_z = \sum_{i=1}^{N_particule_total} p_z^i$$

Puis corriger les moments cinétiques des particules :

$$p_x^i = p_x^i - P_x \; ; \; p_y^i = p_y^i - P_y \; ; p_z^i = p_z^i - P_z$$

Et réitérer le point 3 du slide précédent pour obtenir un jeu de moments cinétiques qui correspond bien à la température de référence choisie T_0.

5 – Avec ce jeu de moments cinétiques, lancer votre première simulation de dynamique moléculaire. A chaque itération (i.e. à l'issue de la routine velocity-Verlet), calculer l'énergie totale du système, i.e. la somme de son énergie potentielle *U* et de son énergie cinétique. Vérifier que cette énergie totale est constante. Comment varient les composantes (P_x,P_y,P_z) du moment cinétique du centre de masse du système ? Comme varie la température du système ?

6 – Corriger après m_step d'itérations de la dynamique moléculaire les moments cinétiques à l'aide du thermostat de Berendsen :

$$p_x^i \rightarrow p_x^i + \gamma\left(\frac{T_0}{T} - 1\right)p_x^i \; ; p_y^i \rightarrow p_y^i + \gamma\left(\frac{T_0}{T} - 1\right)p_y^i \; ; p_z^i \rightarrow p_z^i + \gamma\left(\frac{T_0}{T} - 1\right)p_z^i$$

On prendra γ = 0.01, T_0 est la température cible (ici 300 K) et T est la température cinétique du système après m_step itérations. Comment varie maintenant la température T le long de votre simulation ? Même question avec l'énergie totale du système et les composantes du moment cinétique de son centre de masse.

1 – SIMULATIONS AVEC LE CODE POLARIS(MD)

HTTP://BIODEV.CEA.FR/POLARIS/

2 – VISUALISATION DE TRAJECTOIRES À L'AIDE DE VMD

HTTP://WWW.KS.UIUC.EDU/RESEARCH/VMD/

3 – CALCUL DE DISTRIBUTION AVEC GNUPLOT

HTTP://WWW.GNUPLOT.INFO/

ISM5 – INSTALLATION DE POLARIS(MD)

1 – tar –xzvf master_td_10.tar.gz

2 – binaire ‘polaris_linux’ ou ‘polaris_macos’

3 – export OMP_NUM_THREADS=1

4 – cp input/test.inp donnee

5 –‘./polaris_system’

```
-------------------------------------------------------------------------------

Structure analysee  : ./files/urea

-------------------------------------------------------------------------------

Charge electrostatique totale        :       0.000       0.000
Moment dipolaire total               :       4.155       1.250
Convergence sur les moments dipolaires :   0.8618E-06 max difference          3.16144959
Constantes de rotation en K          :      9.81     11.58      2.03
Constantes de rotation en GHz        :     2.1243    1.7994   10.2502

Norme du gradient (kcal.mol-1.atome-1) :  0.27980E+01

Decomposition de l energie :

 Termes intramoleculaires en kcal.mol-1 :

 energie de stretch       :         0.103445706450693
 energie de bending       :         0.463639742695604
 energie de torsion       :         3.519999999599694
  dont terme impropre     :         0.000000022889822
 energie interne totale   :         4.087085471635812

 Termes intermoleculaires en kcal.mol-1 :

 energie repulsif         :         2.147726848353952
 energie electrostatique  :       -16.117461604632556
 energie de polarisation  :       -14.687431973289417

 energie Elh              :       0.00        0.00
 energie dispersion       :         0.000000000000000


 Energie totale           :       -24.570081257932209       -24.57008126
```

ISM5 – VISUALISATION D'UN FICHIER DE COORDONNÉES AVEC VMD

1 – installer VMD à partir de

HTTP://WWW.KS.UIUC.EDU/RESEARCH/VMD/

2 – Exécuter VMD et dérouler le menu 'File' et charger le fichier 'files/urea.pdb'

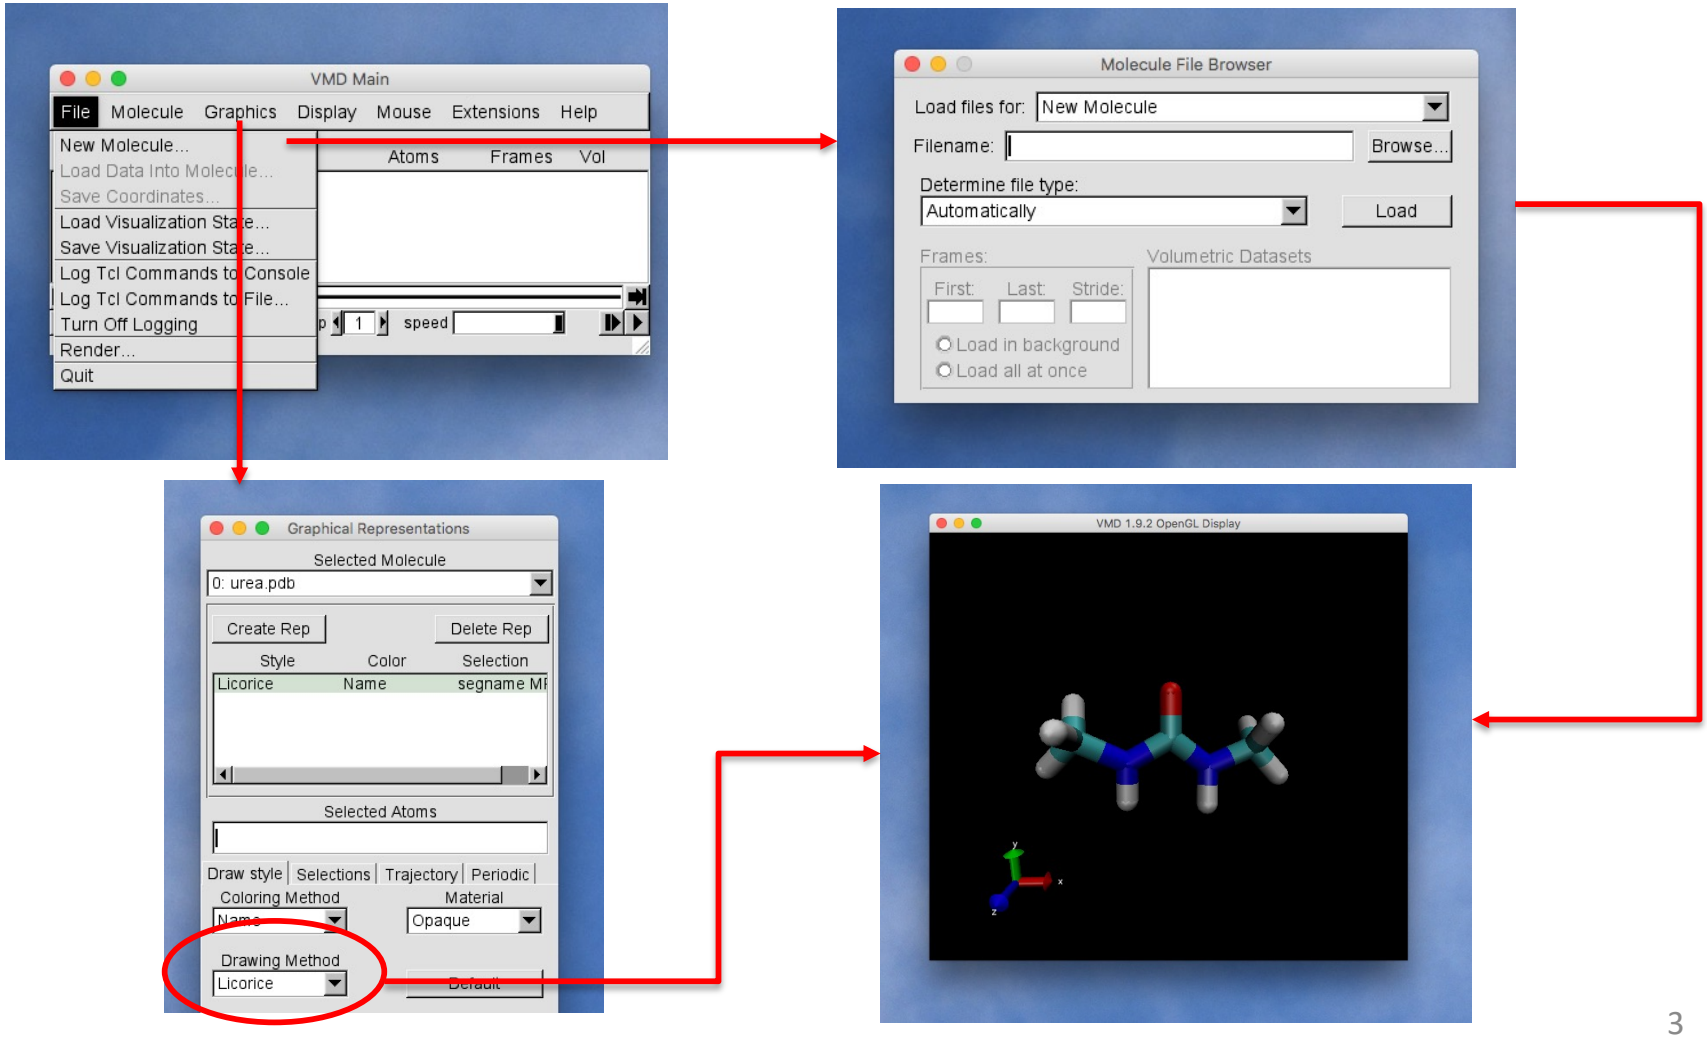

ISM5 – ETUDE DE LA STABILITÉ DES EQUATIONS DE NEWTON

Objectif : réaliser des dynamiques moléculaires de la molécule dimethyl-*N,N*' urée en faisant varier le pas d'intégration des équations de Newton

1 – Dans un des fichiers 'input/stabilite_Y.X.inp', rechercher les deux lignes

Time steps for stretch and bending terms (fs): Y.X
Main time steps (fs) : Y.X

2 – Quels sont les pas d'intégration ici testés ?

3 – Exécuter les simulations :

> cp input/stabilite_Y.X.inp donnee && ./polaris_system

4 – Récupérer les énergies totales le long des trajectoires de dynamiques moléculaires

grep '# Etot :' files/urea_Y.X.xvg | awk '{print $4}' > data_stabilite_Y.X

5 – Représenter avec GNUPLOT les 4 fichiers 'data_stabilite_Y.X'

> plot 'data_stabilite_0.25' u 1 w l, 'data_stabilite_0.50' u 1 w l, 'data_stabilite_1.00' u 1 w l …

6 - Conclusion

ISM5 – ETUDE DE LA STABILITÉ DES EQUATIONS DE NEWTON AVEC CONTRAINTES

Objectif : réaliser des dynamiques moléculaires de la molécule dimethyl-*N,N*' urée en faisant varier le pas d'intégration des équations de Newton en contraignant les liaisons XH

1 – Dans les fichiers 'input/stabilite_Y.X_rattle.inp', rechercher les deux lignes

Time steps for stretch and bending terms (fs): Y.X
Main time steps (fs) : Y.X

2 – Quels sont les pas d'intégration ici testés ?

3 – Exécuter les simulations :

> cp input/stabilite_Y.X_rattle.inp donnee && ./polaris_system

4 – Récupérer les énergies totales le long des trajectoires de dynamiques moléculaires

grep '# Etot :' files/urea_Y.X.xvg | awk '{print $4}' > data_stabilite_Y.X_rattle

5 – Représenter avec GNUPLOT les 4 fichiers 'data_stabilite_Y.X'

> plot 'data_stabilite_0.25_rattle' u 1 w l, 'data_stabilite_0.50_rattle' u 1 w l, …

6 - Conclusion

ISM5 – ASPECTS CHAOTIQUES

Objectif : évaluer l'impact de petites modifications des vitesses initiales sur une trajectoire de dynamique moléculaire d'un jeu de 512 particules avec conditions périodiques

Dans le dossier 'files', le fichier chaos_512_ref.xvg contient les positions et vitesses finales d'une dynamique moléculaire d'un système composé de particules mono-atomiques.

1 – Dans le dossier 'files', Copier le fichier de référence 'chaos_512_ref.xvg' dans un nouveau fichier 'chaos_512.xvg' et lancer un 'restart' de la dynamique moléculaire :

> cp input/chaos.inp donnee && ./polaris_system

2 – Dans le dossier 'files', 'mv' la trajectoire obtenue au format pdb, le fichier chaos_512_dyn.pdb' , dans un nouveau fichier ' (par exemple 'chaos_512_orig_dyn.pdb')

3 – Recommencer les points 1 et 2 mais en modifiant les vitesses de la dernière particule à l'itération 90000, en ajoutant « une petite valeur » à celles de la 3^{ième} colonne des trois dernières lignes du fichier 'files/chaos_512.xvg' avant l'itération 91000

```
> -1      -2.108626   0.005447489569   0.00000
> -1       2.531386   0.016109398315   0.00000
> -1      10.742073   0.096181931516   0.00000
```

4 – Visualiser les deux fichiers de simulation de la forme '*_dyn.pdb' obtenus avec VMD;

5 – Conclusion.

ISM5 –ASPECTS CHAOTIQUES – 1 : VISUALIZATION AVEC VMD

Assurez vous d'être en projection 'Orthographic'

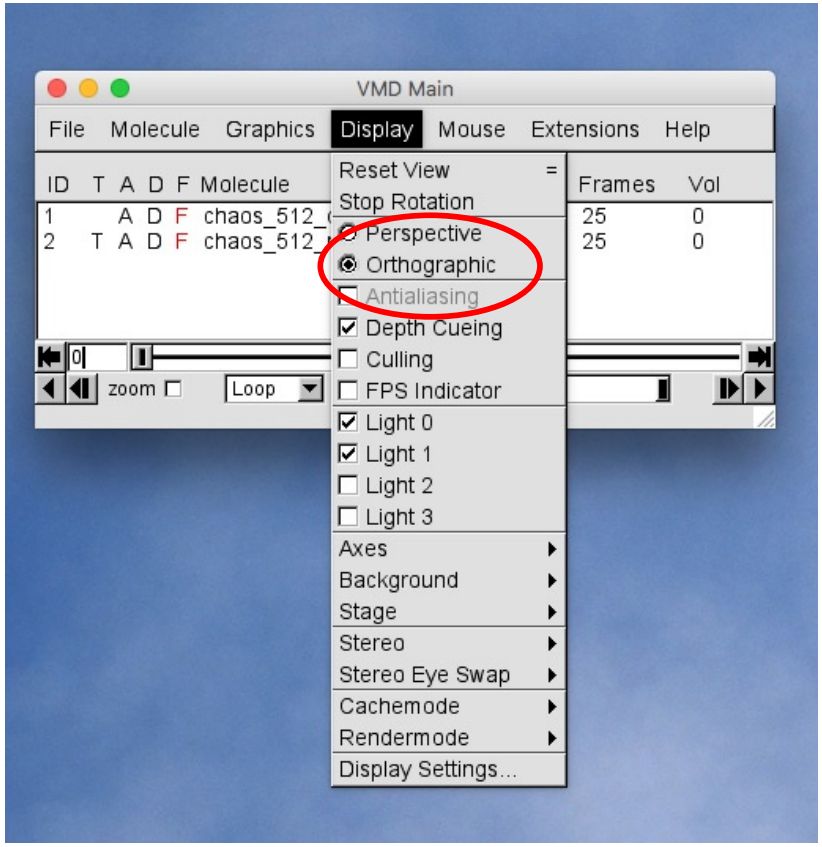

Pour jouer sur la couleur et la taille de la particule 512 :

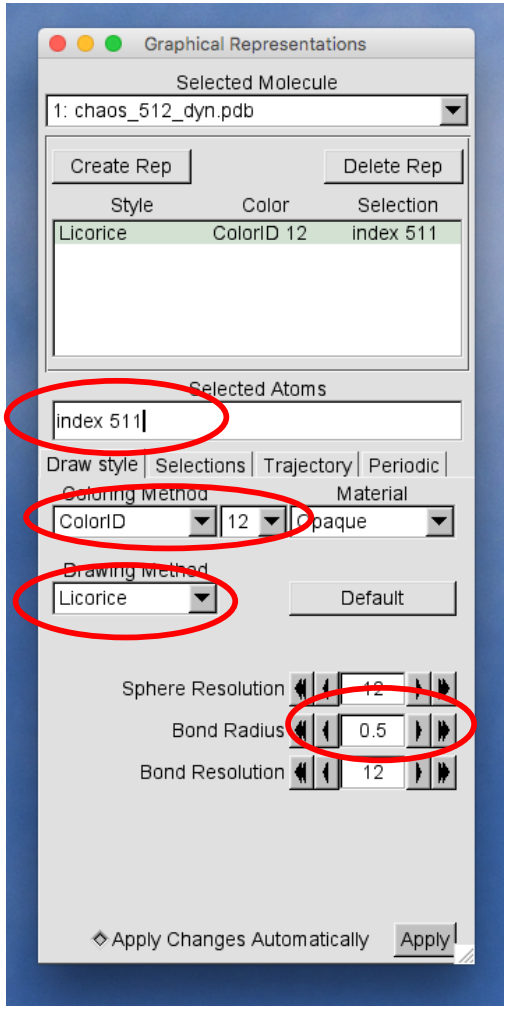

ISM5 –ASPECTS CHAOTIQUES -2 : ET IMAGES PÉRIODIQUES

Pour représenter les images périodiques, cliquer sur l'onglet 'Periodic'

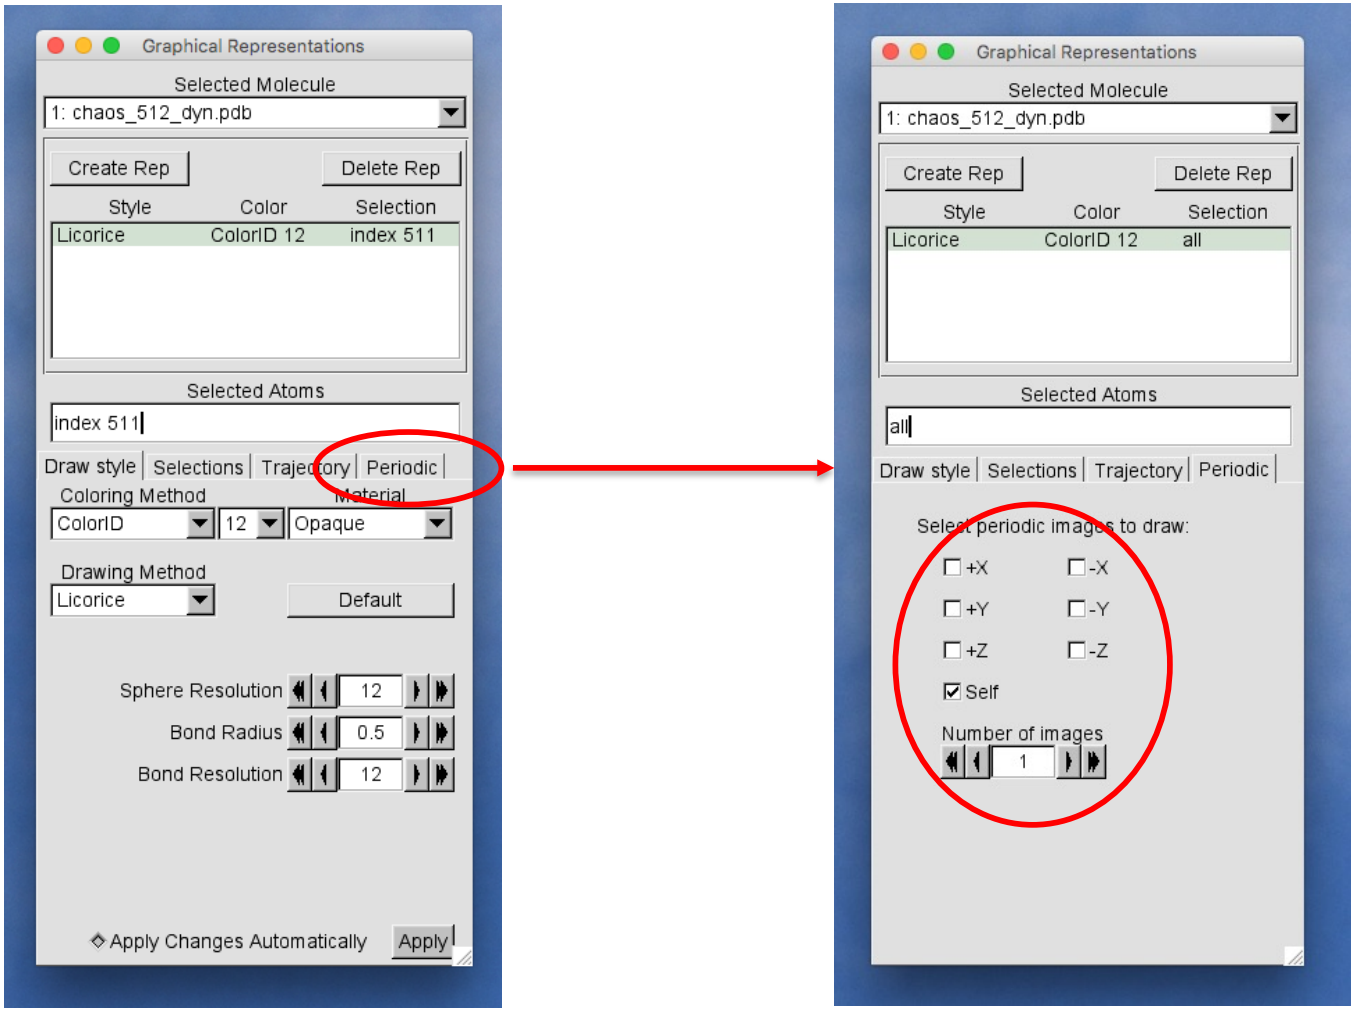

ISM5 –ASPECTS CHAOTIQUES -3 : FONCTIONS DE DISTRIBUTION RADIALE

1 - Dans VMD, aller au menu :

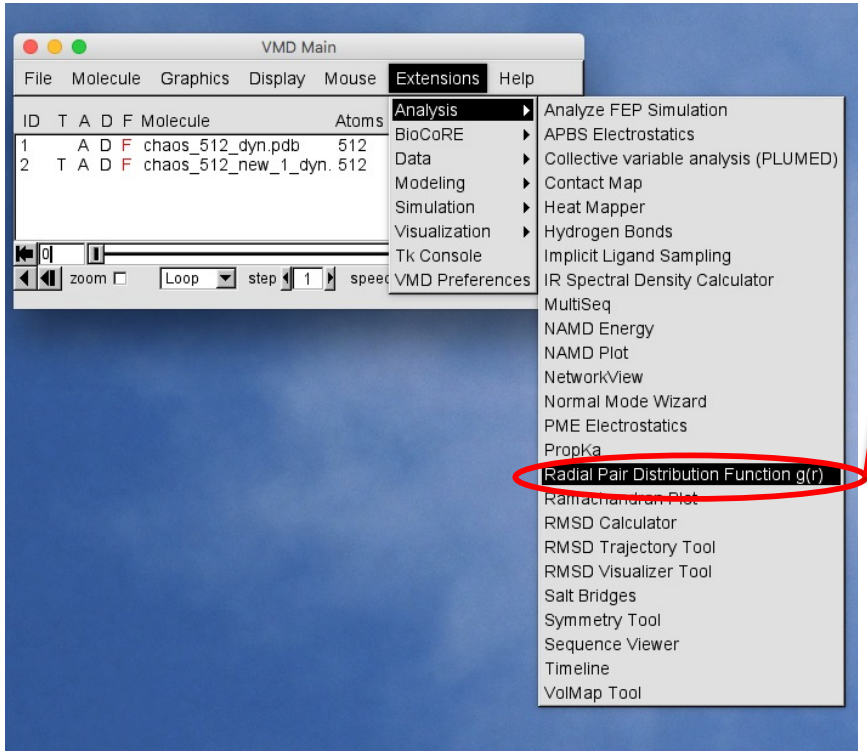

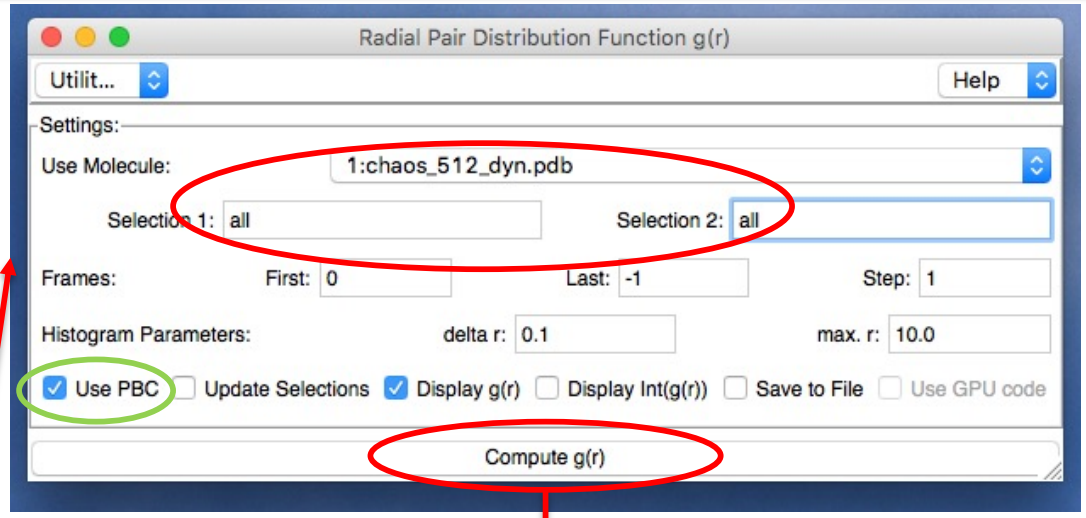

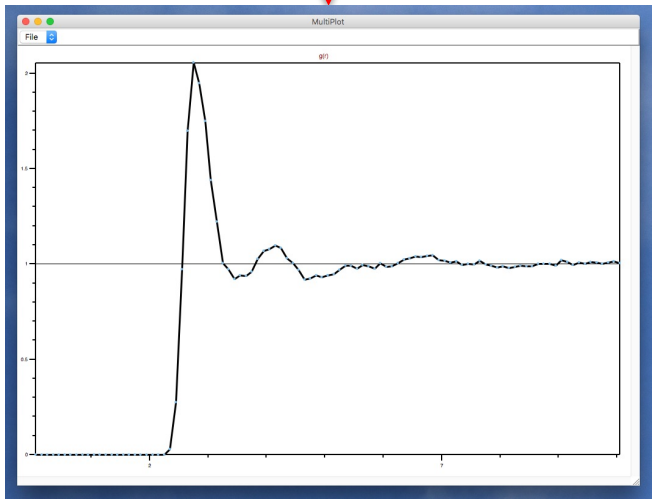

2 - Recommencer la trajectoire ‘chaos_new_1_dyn.pdb’ et comparer les fonctions obtenues, conclusion ?

3 – Recommencer avec ‘chaos_dyn.pdb’ mais en décochant la case ‘**Use PBC**’, conclusion ?

ISM5 – DYNAMIQUE MOLECULAIRE ET FLUCTUATIONS

Objectif : calculer des distributions de distance, d'angle et d'angle dihèdre à partir d'une trajectoire de dynamique moléculaire à l'aide de VMD et de GNUPLOT.
Le système considéré est ici une molécule d'urée solvatée dans une boite cubique où l'eau est modélisée par une approche gros grains (une seule particule = H_2O)

1 - Le fichier 'files/urea_hydrated_ref.xvg' contient les positions et vitesses « équilibrées » d'une dynamique moléculaire précédente. Dans le dossier 'files', copier ce fichier dans un nouveau fichier 'urea_hydrated.xvg'

2 – Dans le fichier « input/urea_hydrated.inp » rechercher la ligne

Nombre d iterations (x 1000) : XXX

Celle-ci donne la durée demandée de la dynamique moléculaire. Exprimer la en ps.

3 – Relancer la dynamique moléculaire en exécutant la commande

> cp input/urea_hydrated.inp donnee && ./polaris_system

ISM5 – DYNAMIQUE MOLECULAIRE ET FLUCTUATIONS - 2

5 - Visualiser le fichier ‘files/urea_hydrated_dyn.pdb’ à l’aide de VMD et représenter uniquement cette molécule et centrer les rotations sur un atome de l’urée après avoir sélectionner ‘Center’

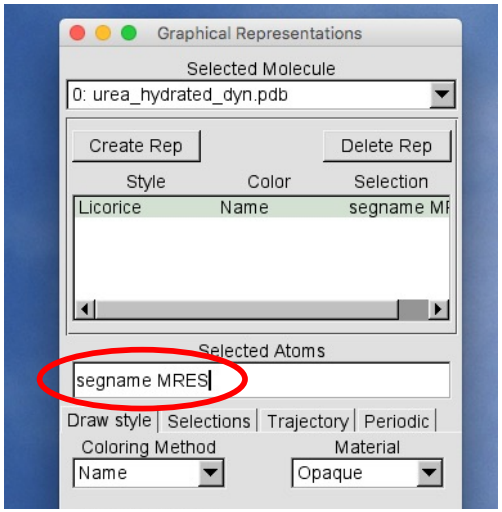

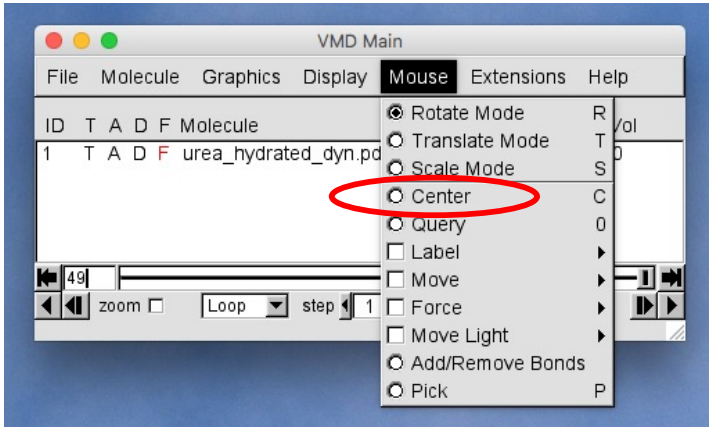

6 - Sélectionner deux atomes de la molécule urée après avoir sélectionner ‘Bonds’

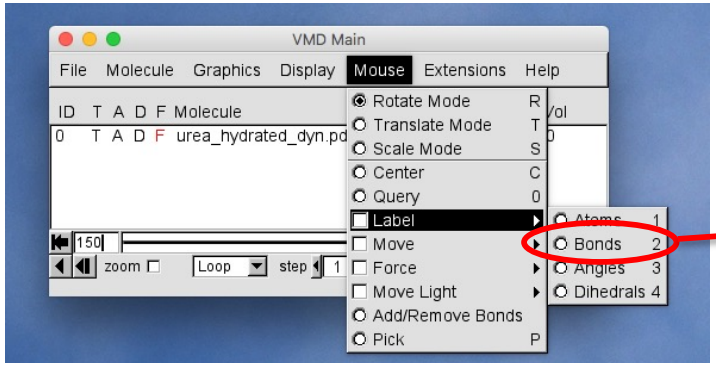

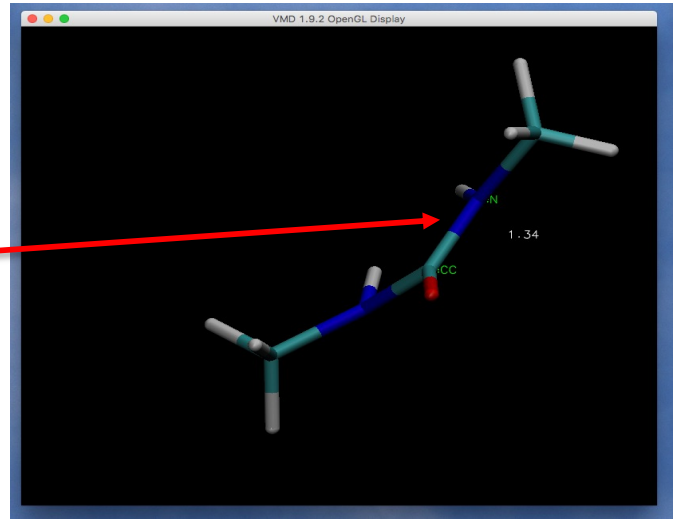

ISM5 – DYNAMIQUE MOLECULAIRE ET FLUCTUATIONS - 3

7 – Représenter les fluctuations d'une distance entre deux atomes de l'urée avec VMD

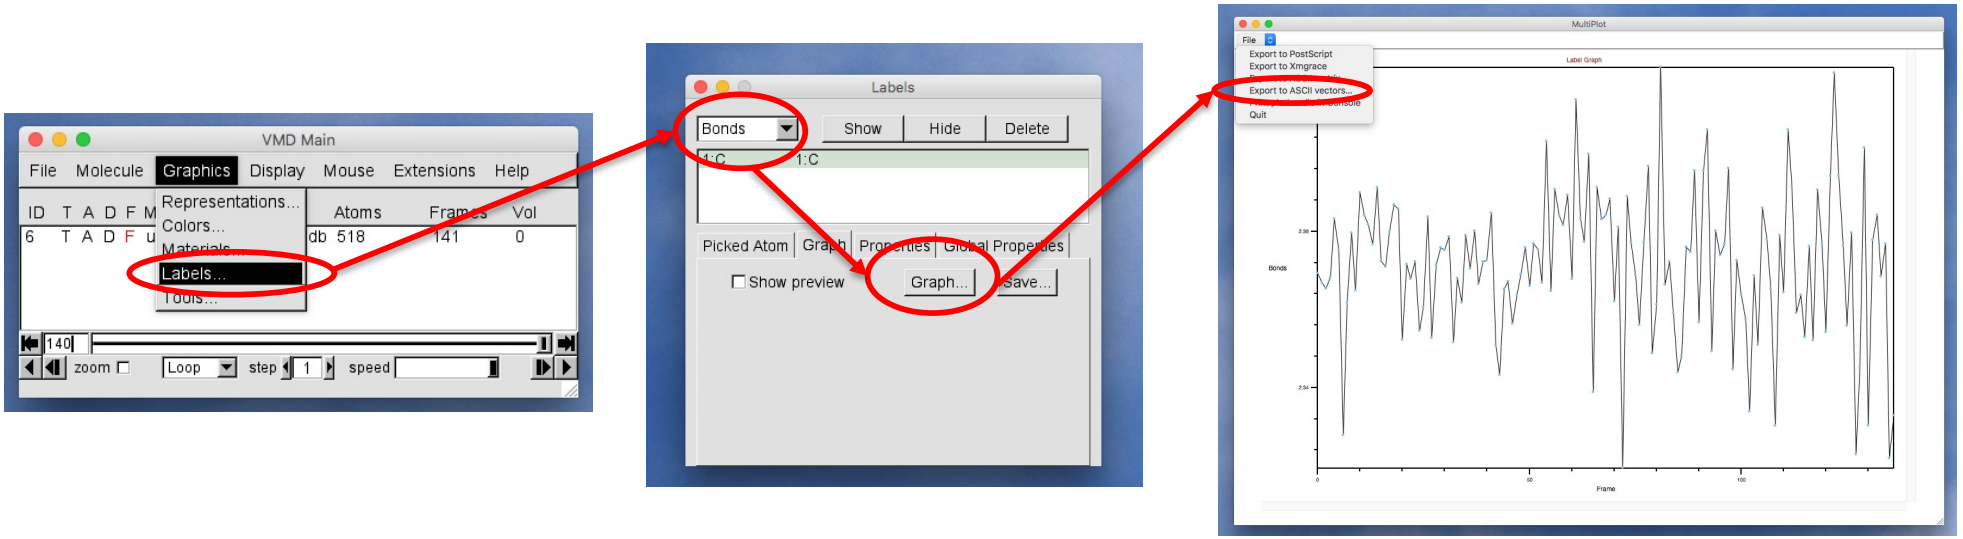

8 - Sauvegarder le fichier « multiplot.dat » et visualiser les fluctuations de cette distance avec GNUPLOT

> plot 'multiplot.dat' u 2 w l

9 - Représenter la distribution des distances avec GNUPLOT

gnuplot> binwidth=0.01
gnuplot> bin(x,width)=width*floor(x/width)
gnuplot> plot 'multiplot.dat' u (bin($2,binwidth)):(1.0) smooth freq with boxes

ISM5 – DYNAMIQUE MOLECULAIRE ET FLUCTUATIONS - 4

10 – Relancer à nouveau la dynamique moléculaire, mais en exécutant la commande

> cp input/urea_hydrated_restart.inp && ./polaris_system

11 – Réitérer le processus décrit sur le slide précédent

12 – Comment évolue la distribution ?

ISM5 – UMBRELLA SAMPLING

Objectif : Réaliser des simulations de l'ion organique guanidinium dans un film d'eau au voisinage de l'interface liquide/vapeur en contraignant la position de l'ion par rapport à cette interface

Dans le dossier 'files', le fichier ion_interface_ref.xvg contient les positions et vitesses finales d'une dynamique moléculaire du système ion/film d'eau

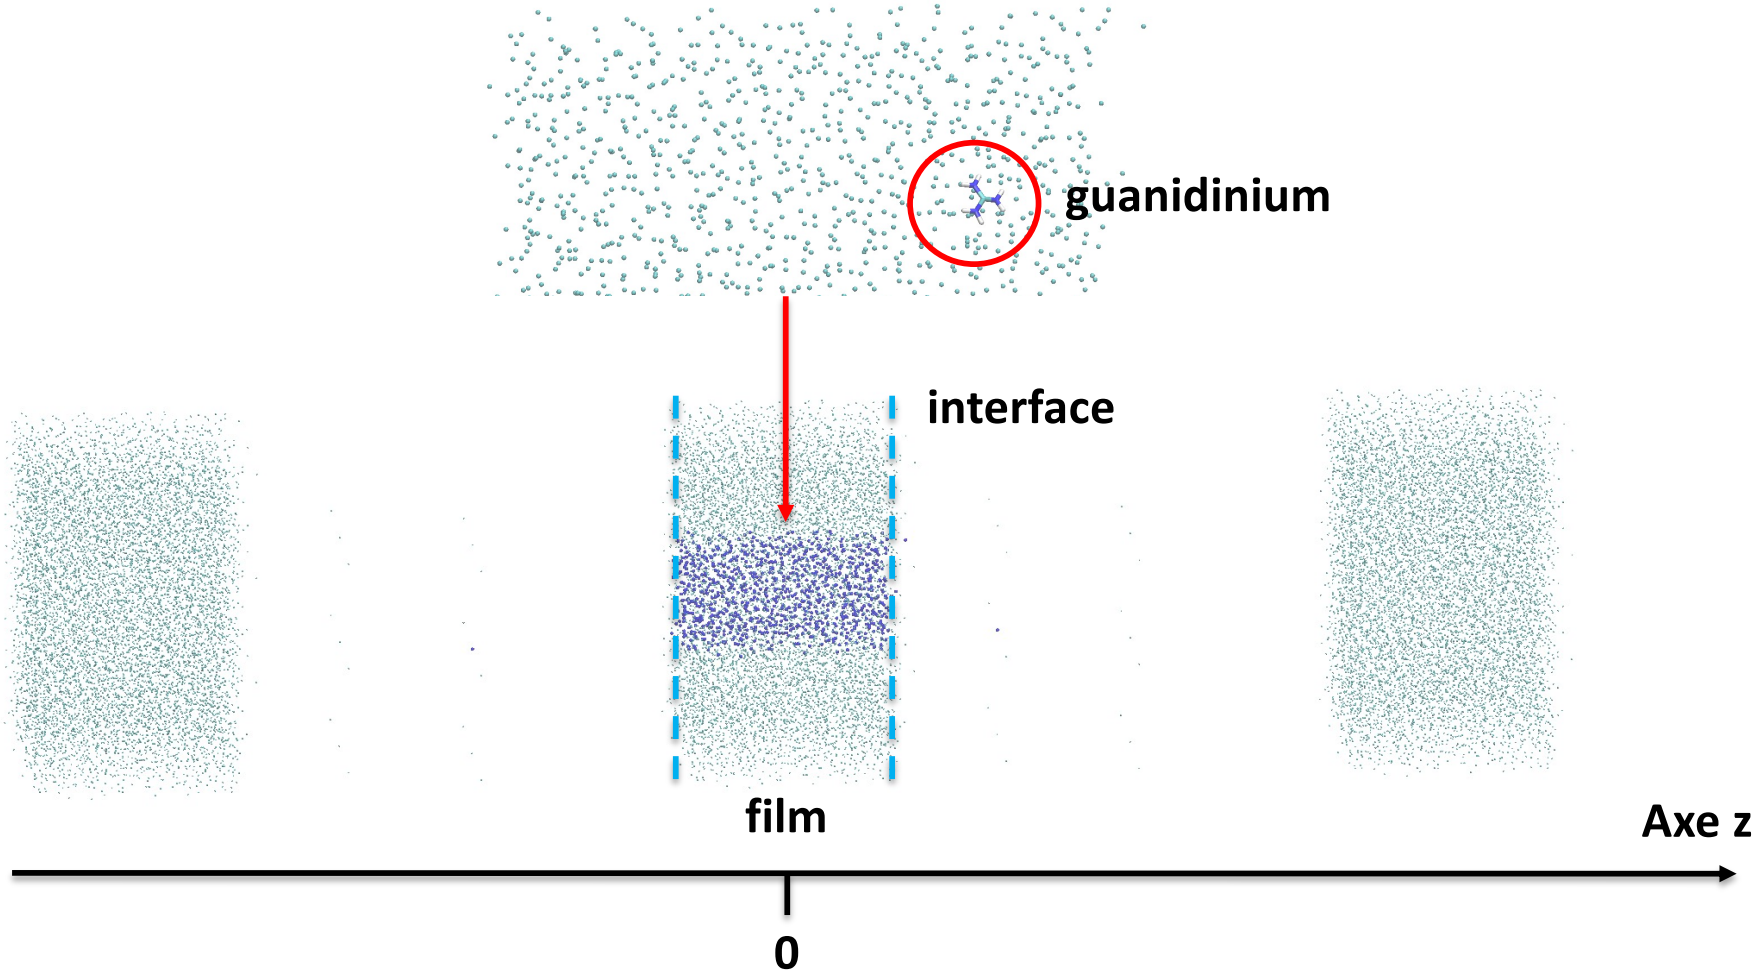

ISM5 – UMBRELLA SAMPLING - 2

1 – Lancer la dynamique moléculaire de l'ion guanidinium dans un film d'eau en exécutant la commande

> cp input/ion_interface.inp donnee && ./polaris_system

2 – Visualiser la trajectoire obtenue 'files/ion_interface_dyn.pdb' avec VMD

3 – L'ion guanidinium se déplace dans une région parallèle et proche de l'interface, ceci est le résultat du potentiel de 'biais' harmonique pris en compte lors de cette simulation

$$U^{biais} = k_{biais}(z-z_0)^2$$

Ici z_0 = 22 Å (=2,2 nm). Dans le fichier 'input/ion_interface_restart.inp', rechercher les lignes

Harmonic Umbrella Sampling constrains : Yes
- 4 F 5.0 0 0 1 22.0

4 – Choisissez une nouvelle valeur de z_0 comprise entre 0 et 28 Å et relancer la simulation

> cp input/ion_interface_restart.inp donnee && ./polaris_system

5 – Visualiser la trajectoire obtenue avec VMD, i.e. le fichier 'files/ion_interface_dyn.pdb'. Comment se comporte l'ion en fonction de la distance z_0 à l'interface ?

ISM5 – CODE DE SIMULATION : SAUVEGARDE D'UNE TRAJECTOIRE

Implémenter une routine de sortie permettant de stocker une trajectoire de dynamique moléculaire au format PDB :

1 – Cette routine sera appelée toutes les N_iterations de dynamique moléculaire

2 – Les structures seront sauvegardées au format PDB :

a – Avant chaque jeu de coordonnées XYZ, le fichier de sortie contient les lignes :

CRYST1 XDIM YDIM ZDIM 90.00 90.00 90.00 P 1
MODEL ITERATION

Ici **XDIM**, **YDIM** et **ZDIM** sont les dimensions associées aux conditions périodiques et **ITERATION** un entier correspondant à l'itération de dynamique sauvegardée.

b – Puis sauvegarder les coordonnées (X,Y,Z) des particules suivant le format :

ATOM K C 0 X Y Z MRES

K est ici le numéro (le 'label') de la $k^{ième}$ particule.

c - Enfin après chaque jeu de coordonnées, ajouter les deux lignes

TER
ENDMDL

3 – Visualiser à l'aide du logiciel VMD votre première simulation de dynamique moléculaire au format PDB

ISM6 – COMPLEXITE ALGORITHMIQUE

1 – DEFINITION

2 – ORDRE DE GRANDEURS

3 – NOMBRE D'OPÉRATION BORNÉ

4 – EXEMPLE D'ALGORITHME EN SIMULATION MICROSCOPIQUE

5 – RÉDUCTION DE COMPLEXITÉ ALGORITHMIQUE

ISM6 – DEFINITION DE LA COMPLEXITE ALGORITHMIQUE

Complexité algorithmique : comment varie le nombre de calculs élémentaires à réaliser en fonction du nombre de données *N*, i.e. comment varie le temps « CPU » idéal, pas nécessairement le temps « WCT »

La complexité algorithmique est notée $O(f(N))$ où *f* est une fonction, en général, un polymère du paramètre *N*. Dans le cas de la simulation microscopique, *N* est le nombre total d'atome ou de particule modélisant des groupements d'atome.

Quelques exemples classiques :

1 – Pour chaque atome/particule du système, le nombre de calcul à réaliser est constant => $O(N)$

2 – Pour chaque atome/particule du système, ce nombre dépend de *N* : $O(N^2)$

3 - Terme d'interaction à trois corps : $O(N^3)$

4 - Transformée de Fourier rapide et algorithme de tri (mais en moyenne) : $O(N\log N)$

ISM6 – COMPLEXITE ALGORITHMIQUE ET ORDRES DE GRANDEUR

Soit deux algorithmes $\boldsymbol{A_1}$ et $\boldsymbol{A_2}$ dont la complexité est respectivement en $O(N)$ et $O(N^2)$ mais nécessitant le même nombre de calcul pour chaque élément (=atome/particule) i ou paires d'élément (i,j) respectivement

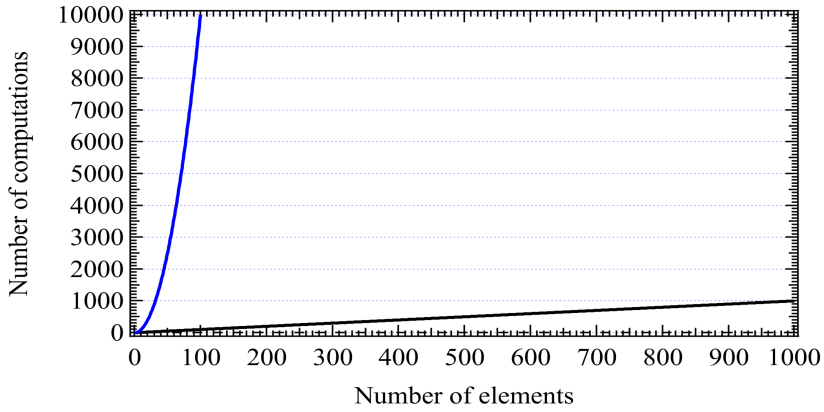

=> le rapport R des temps de calcul entre $\boldsymbol{A_2}$ et $\boldsymbol{A_1}$ est de la forme R=O(N)

Cela signifie que pour traiter un système de N éléments avec un temps de calcul moyen pour chaque élément de 1 s, il faut

N	A_1	A_2
10	10 s	1 min 40 s
100	1 min 40 s	2h et 46 min
1 000	17 min	11 jours et 14 h
1 000 000	11 jours et 14 h	**31 710 années…**

ISM6 – ORDRES DE GRANDEUR: CAS DE $O(N\log N)$

Soit trois algorithmes $\boldsymbol{A_1}$, $\boldsymbol{A_2}$ et $\boldsymbol{A_3}$ dont la complexité algorithmique est respectivement en $O(N)$, $O(N^2)$ et $O(N\log N)$ et nécessitant le même nombre de calcul pour chaque élément *i* d'un système de *N* (=atome/particule). Le rapport *R* des temps de calcul entre $\boldsymbol{A_3}$ et $\boldsymbol{A_1}$ est de la forme $R=O(\log N)$

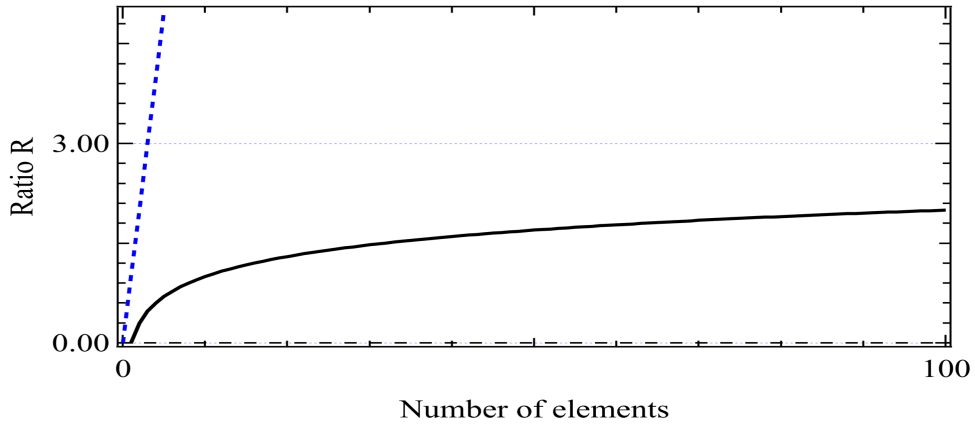

Cela signifie que pour traiter un système de *N* éléments avec un temps de calcul moyen pour chaque élément de 1 s, il faut

N	A_1	A_2	A_3
10	10 s	1 min 40 s	20 s
100	1 min 40 s	2 h et 46 min	3 min et 20 s
1 000	17 min	11 jours et 14 h	51 min
1 000 000	11 jours et 14 h	**31 710 années…**	**6 mois et 3 jours**

Ici log = $\log_{10}$

ISM6 – COMPLEXITÉ ALGORITHMIQUE : QUID DU PRÉFACTEUR ?

Soit deux algorithmes $\boldsymbol{A_1}$ (par exemple sommes d'Ewald classiques) et $\boldsymbol{A_2}$ (par exemple sommes d'Ewald sur grille du type SPME) dont la complexité algorithmique est respectivement en $O(N^{3/2})$ et $O(N\log N)$. Mais leurs temps de calcul CPU pour chaque élèment sont en fait :

$$t(\boldsymbol{A}_1) = a_1 \times N^{3/2} \quad \text{et} \quad t(\boldsymbol{A}_2) = a_2 \times N\log N$$

Supposons $\boldsymbol{a_2 = 10\, a_1}$ alors

$$R = \frac{t(\boldsymbol{A_1})}{t(\boldsymbol{A_2})}$$

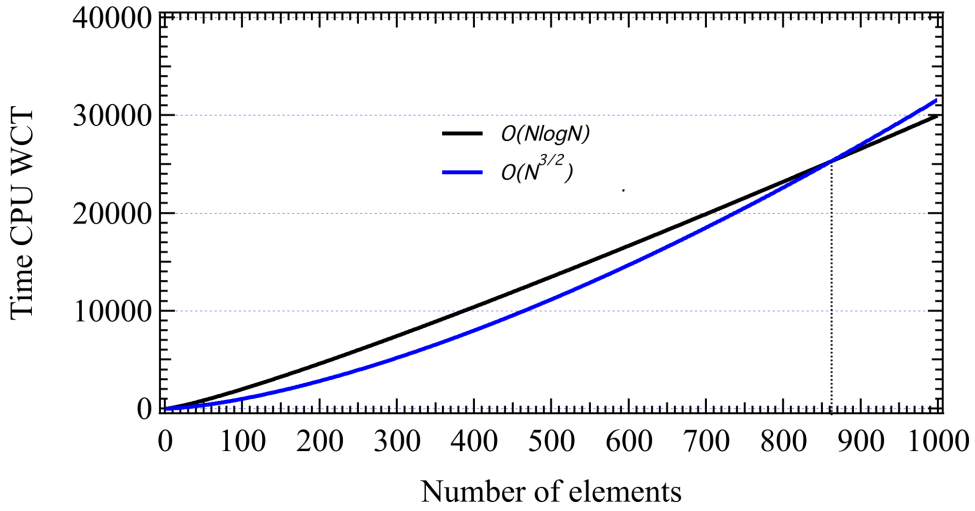

N	$R(a_2/a_1 = 1)$	$R(a_2/a_1 = 10)$	$R(a_2/a_1 = 100)$
100	5	**0.5**	**0.05**
10 000	25	2.5	**0.25**
1 000 000	167	17	1.7

ISM6 – NOMBRE D'OPERATIONS PAR ÉLÉMENT BORNÉ

Soit un algorithme $\boldsymbol{A_1}$ où le nombre d'opération pour un élément *i* d'un système contenant *N* éléments, ne peut dépasser un majorant op_{max}, quel est la complexité algorithmique de $\boldsymbol{A_1}$?

$$\forall i \in \{1 \dots N\}\, t(\boldsymbol{A_1}) \leq \tau_1 \times op_{max} \times N \quad \Longrightarrow \quad O(N)$$

τ_1 temps moyen CPU par opération élémentaire de l'algorithme $\boldsymbol{A_1}$

Exemple de majorants :

Majorant	Complexité algorithmique
$op_{max} = m - {}^{\alpha}/_{N^3}$	$O(N)$
$op_{max} = m - {}^{\alpha}/_{\sqrt{N}}$	$O(N)$
$op_{max} = m + \alpha \exp(\beta N)$	?

Conclusion : le préfacteur de la complexité algorithmique peut dépendre de *N* mais ne doit pas altérer le terme dominant de cette complexité pour $N \rightarrow +\infty$

ISM6 – EXEMPLES D'ALGORITHME EN SIMULATION MICROSCOPIQUE

Le terme dit de *stretching* modélise les interactions entre paires d'atomes liés par une liaison chimique (liaison covalente)

DO i = 1,N_liaison
  n_1 = atome_liaison(i,1)
  n_2 = atome_liaison(i,2)
  calcul distance d(n_1,n_2)
  E_stretching = E_stretching + $k_i x(d(n_1,n_2)-d_i^0)^2$
END DO

Un atome ne peut pas être lié à plus de 4 (chimie organique) ou 8 (chimie inorganique) atomes $\Rightarrow$ le nombre d'opération par atome est borné d'où:

$$\Rightarrow \boldsymbol{O(N)}$$

Pour la même raison, le terme de *bending* et de *torsion* sont en *O(N)*.

Le terme dit de Coulomb modélise les interactions électrostatiques entre paires d'atomes non-liés par une liaison chimique (liaison covalente)

DO i = 1,N-1
  DO j = i+1,N et (i,j) non lié chimiquement
    E_coulomb = E_coulomb + $\frac{q_i q_j}{r_{ij}}$
  END DO
END DO

Le nombre d'atomes non liés varie en O(N^2)

$$\Rightarrow \boldsymbol{O(N^2)}$$

ISM6 – EXEMPLES REDUCTION DE COMPLEXITE ALGORITHMIQUE

Algorithme A_1

```
DO i = 1,N
  DO j = 1,N
    Rij² = (x(i)-x(j))² + (y(i)-y(j))² + (z(i)-z(j))²
    DO k = 1,N
      Rjk² = (x(j)-x(k))² + (y(j)-y(k))² + (z(j)-z(k))²
      if (( 0 < Rij² <= Rc < +∞) then
      if (( 0 < Rjk² <= Rc < +∞) then
            gijk = f(Rij²,Rjk²)
      end if ; end if
    END DO
  END DO
END DO
```

$O(N^3)$

Algorithme A_2

```
DO i = 1,N
  nj = 0
  DO j = 1,N
     Rij² = (x(i)-x(j))² + (y(i)-y(j))² + (z(i)-z(j))²
     if ( 0 < Rij² <= Rc < +∞) then
        nj = nj + 1 ; l(i,nj) = j
     end if
  END DO
  n(i) = nj
END DO

DO i = 1,N
  DO j = 1,n(i)
    nj = l(i,j)
    Rij² = (x(i)-x(nj))² + (y(i)-y(nj))² + (z(i)-z(nj))²
    DO k = 1,n(nj)
      njk = l(nj,k)
      Rjk² = (x(nj)-x(njk))² + (y(nj)-y(njk))² + (z(nj)-z(njk))²
      gijk = f(Rij²,Rjk²)
    END DO
  END DO
END DO
```

$O(N^2)$

I.12 Rappeler la définition de complexité algorithmique en fonction de la taille *N* du système microscopique considéré.
Réponse : une ligne maximum

I.13 Quelle autre grandeur faut-il considérer pour estimer le temps de calculs 'Wall Clock Time' à partir de la complexité algorithmique ?
Réponse : une ligne maximum

I.14 Laquelle de la grandeur précédente ou de la complexité algorithmique domine généralement dans l'estimation d'un temps de calcul pour un système microscopique de petite taille ?
Réponse : une ligne maximum

I.15 Soit un système composé de *N* particules. Quelle est la complexité algorithmique d'un terme d'énergie potentielle de la forme $U = \sum_{i=1}^{N} \sum_{j\neq i,j=1}^{N} \sum_{k\neq(i,j),k=1}^{N} f(r_{ij}, r_{jk}, r_{ik})$ où les r_{lm} sont les distances entre paires de particules ?
Réponses : $O(N^{1/2})$, $O(N)$, $O(N^2)$, $O(N^3)$

I.16 Même question que la précédente mais dans le cas où f est négligeable pour toutes distances supérieures à une distance de référence finie R_c ?
Réponses : $O(N^{1/2})$, $O(N)$, $O(N^2)$, $O(N^3)$

1 - NECESSITE LE LOGICIEL GNUPLOT

HTTP://WWW.GNUPLOT.INFO/

ISM7 – COEFFICIENT DE DIFFUSION ET RELATION D'EINSTEIN

Une simulation de 20 ns de 1000 particules permettant de simuler l'eau liquide avec un potentiel d'interaction en *O(N)* et des conditions périodiques a été réalisée. Les coordonnées de 9 de ces particules ont été sauvegardées toutes les 1 000 itérations (ce qui correspond à un intervalle de temps Δt de 2 ps).

On souhaite évaluer le coefficient de diffusion *D* de ces particules suivant la relation d'Einstein :

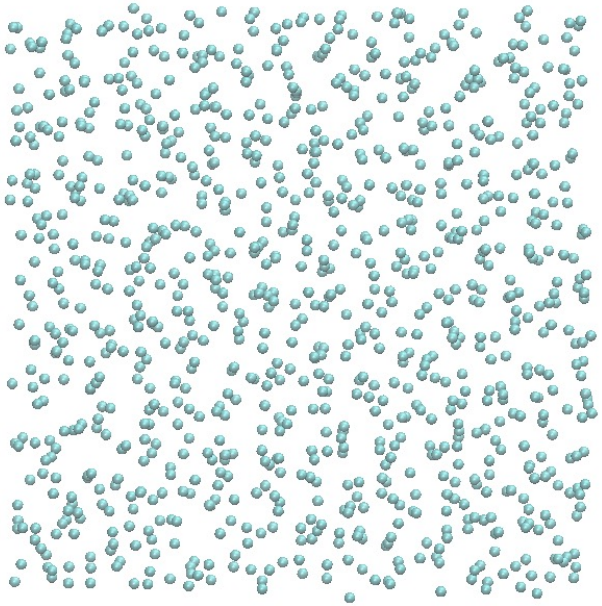

$$D = \lim_{t\to\infty} \frac{\langle|\vec{r}(t) - \vec{r}(0)|^2\rangle}{6t}$$

Rappeler ce que sont ici les vecteurs $\vec{r}(t)$ et $\vec{r}(0)$ et sur quoi porte la moyenne $\langle \dots \rangle$. A quoi faut-il faire attention concernant les vecteurs $\vec{r}(t)$?

ISM7 COORDONNÉES ET CONDITIONS PÉRIODIQUES

En conditions périodiques, on peut définir deux jeux de coordonnées, un absolu, correspondant aux coordonnées obtenues en résolvant les équations du mouvement :

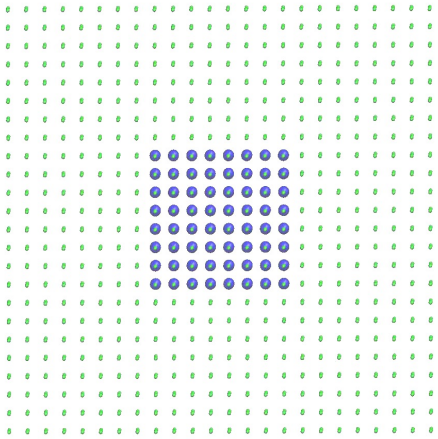

512 particules (eau) simulées à 300 K (26,5° C) en conditions périodiques, le volume
De la boite de simulation est constant le long de la trajectoire.

ISM7 COORDONNÉES ET CONDITIONS PÉRIODIQUES

Et un jeu de coordonnées ‘discontinues’, i.e. les coordonnées précédentes corrigées pour tenir compte de la périodicité :

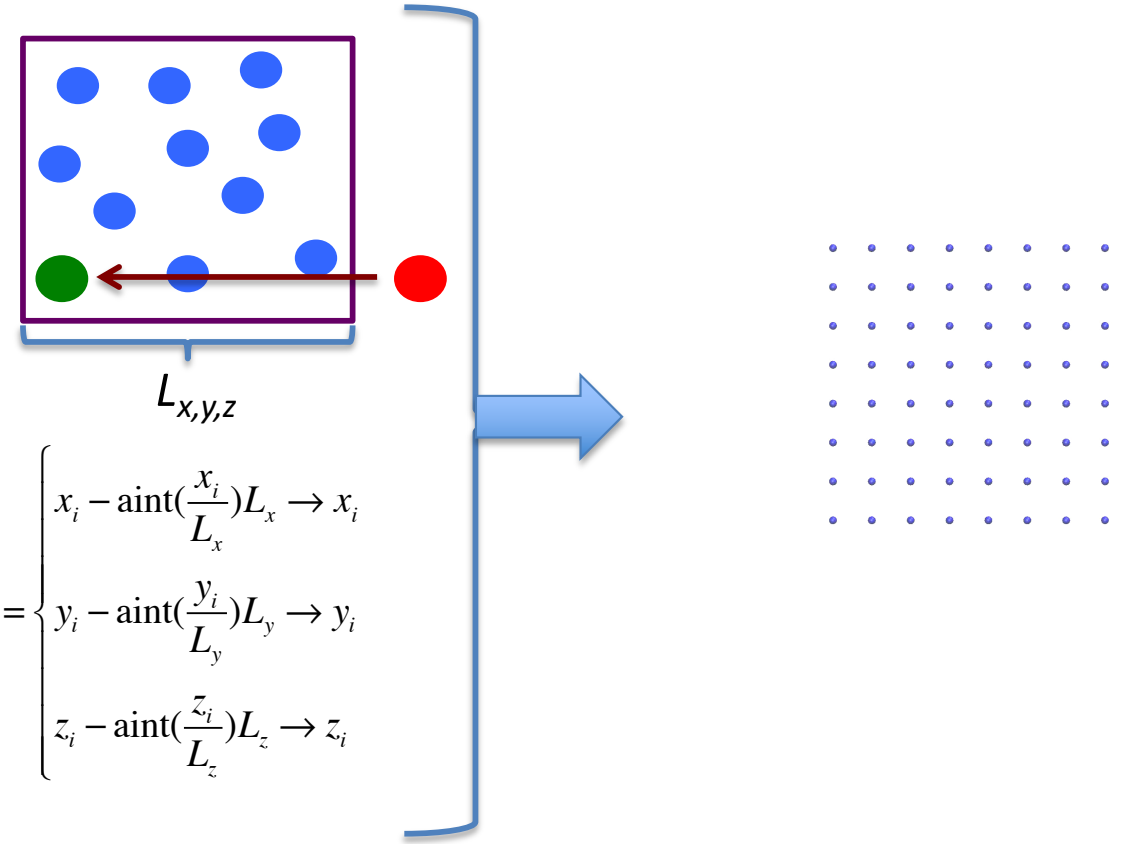

$$\vec{r}_i = \begin{cases} x_i - \text{aint}(\frac{x_i}{L_x})L_x \rightarrow x_i \\ y_i - \text{aint}(\frac{y_i}{L_y})L_y \rightarrow y_i \\ z_i - \text{aint}(\frac{z_i}{L_z})L_z \rightarrow z_i \end{cases}$$

ISM7 – COORDONNÉES ISSUES DE LA SIMULATION

Les coordonnées ‘absolues’ en fonction du temps des particules sont sauvegardées dans le fichier solv1000_dyn.pdb, suivant le format :

```
CRYST1   31.080   31.080   31.080  90.00  90.00  90.00 P           1
MODEL        1
ATOM      1  W   HOH   999       13.741  -12.026   10.369        WION
ATOM      2  W   HOH   999      -10.579   15.480    8.480        WION
ATOM      3  W   HOH   999       -0.491    8.924   10.046        WION
ATOM      4  W   HOH   999       16.352   -1.205   12.265        WION
ATOM      5  W   HOH   999       -1.317    1.057  -13.445        WION
ATOM      6  W   HOH   999        6.915   -7.863   -9.831        WION
ATOM      7  W   HOH   999      -11.991    6.473   -1.645        WION
ATOM      8  W   HOH   999      -13.418  -18.002   -6.238        WION
ATOM      9  W   HOH   999       -2.402  -10.565    2.549        WION
```

La première ligne donne les paramètres géométriques de la « boite » répliquée, la seconde correspond à l’itération de dynamique sauvegardée. Les coordonnées de chaque particule sont données à chaque ligne ‘ATOM’ en colonne 6, 7 et 8.

Extraire les coordonnées de ces 9 particules du fichier ‘solv1000_dyn.pdb’, par exemple :

```
> grep 'ATOM      3' solv1000_dyn.pdb | awk '{print $6 " " $7 " " $8}' > data3
```

Effacer les 1000 premières lignes des fichiers dataX. A quoi correspondent-ils ?

ISM7 – DONNÉES BRUTES POUR CHAQUE PARTICULE

Représenter avec gnuplot l'évolution de la quantité $\Delta r^2(t) = |\vec{r}(t) - \vec{r}(0)|^2$ pour les particules 1, 2 et 3.

Dans le cas de la particule 1 (data1), il faut d'abord extraire les coordonnées $\vec{r}(0)$:

```
> head -n 1 data1
 -8.273 166.601 -71.398
```

Représentation de $\Delta r^2(t)$ avec gnuplot :

```
gnuplot> plot 'data1' u (($1 +8.273)**2 + ($2 -166.601)**2 + ($3 +71.398)**2) w l
```

Répéter les opérations pour les particules 2 et 3 (data2 et data3).

```
gnuplot> plot 'data1' u (($1 +6.18)**2 + ($2 -169.95)**2 + ($3 +72.06)**2) w l, 'data2' u (($1 + 151.03)**2 + ($2 + 62.02)**2 + ($3 + 95.64)**2), 'data3' u (($1 + 33.64)**2 + ($2 + 21.54)**2 + ($3 + 29.78)**2)
```

Conclusion ? Peut-on calculer de manière précise le coefficient de diffusion *D* de chacune de ces particules à partir de la relation d'Einstein ?

ISM7 – CAS DES PARTICULES 1, 2 ET 3

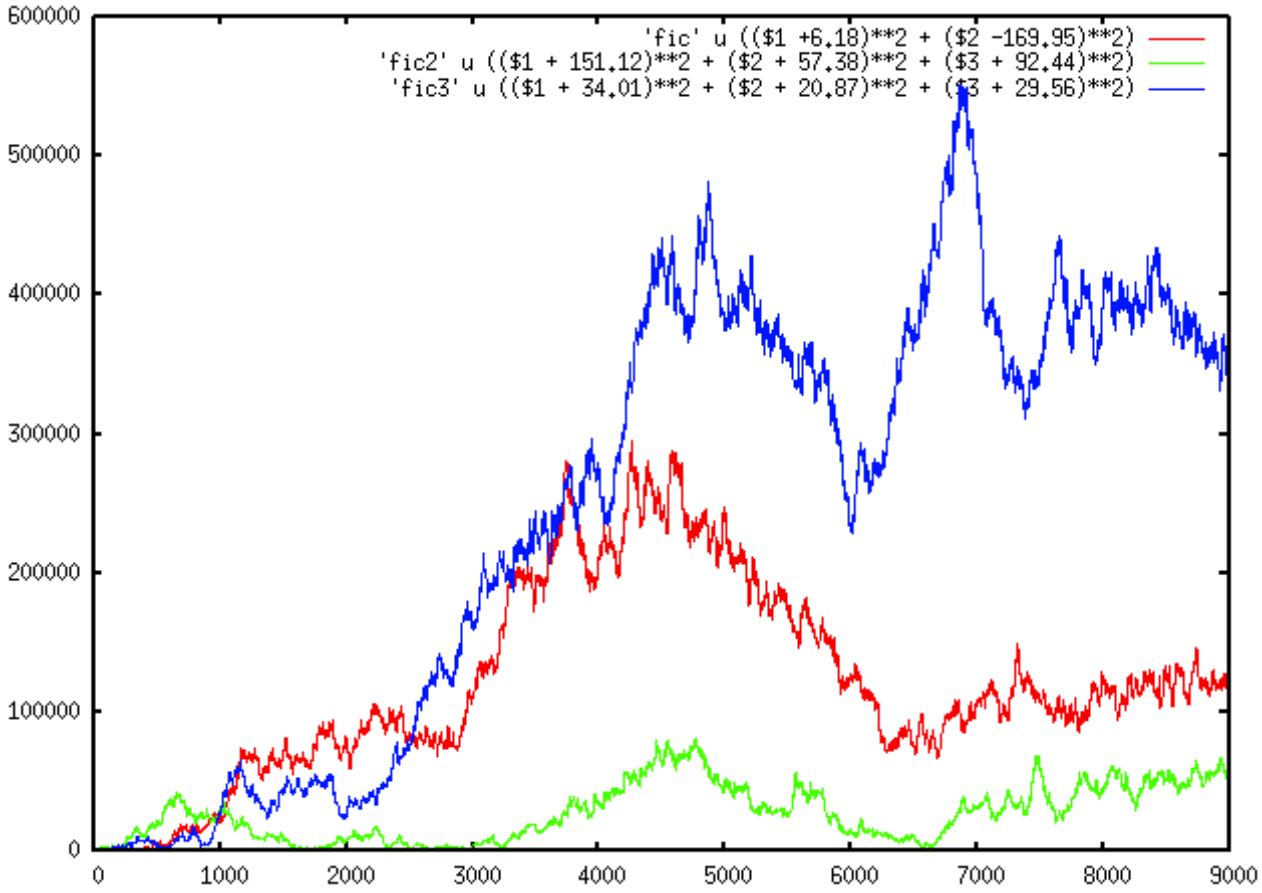

ISM7 – CODE 'COEFFICIENT_DIFFUSION.F90'

Le code 'coefficient_diffusion.f90' permet de calculer $\Delta r^2(t) = |\vec{r}(t) - \vec{r}(0)|^2$ en moyennant les données des fichiers 'dataX' sur une ou plusieurs particules et sur toutes les données ou en les décomposant en segments de longueur identique.

Avec les lignes 58 et 59 de ce code de la forme :

```
write (*,*) 'Nombre maximum de particule '
read (*,*) max_particule
write (*,*) 'Longueur des segments : '
read (*,*) max_iteration
```

Après compilation et exécution :

```
> gfortran -o coefficient_diffusion -O2 coefficient_diffusion.f90 && ./coefficient_diffusion
```

Vérifier que vous retrouver bien le comportement de $\Delta r^2(t)$ obtenu précédement avec gnuplot pour la particule 1.

Remarque le code 'coefficient_diffusion.f90' génère un fichier de sortie 'moyenne.data', dont la première colonne correspond au temps *t*, la seconde colonne à $\Delta r^2(t)$ et la troisième à $\left(\Delta r^2(t)\right)^2$.

ISM7 – MOYENNES SUR LE NOMBRE DE PARTICULES

En modifiant max_particule :

write (*,*) 'Nombre maximum de particule ' => read (*,*) max_particule

Avec X = 3, 6 et 9, vous calculez $\Delta r^2(t)$ moyenné sur les particules 1-2-3, 1-2-3-4-5-6 et sur l'ensemble des 9 premières particules. Après compilation et exécution :

```
> gfortran -o coefficient_diffusion -O2 coefficient_diffusion.f90 && ./coefficient_diffusion
> cp moyenne.data moyenne.dataX
```

Représenter $\Delta r^2(t)$ avec gnuplot pour ces trois ensembles de particules. Comment évolue cette quantité en fonction du nombre particule prise en compte ?

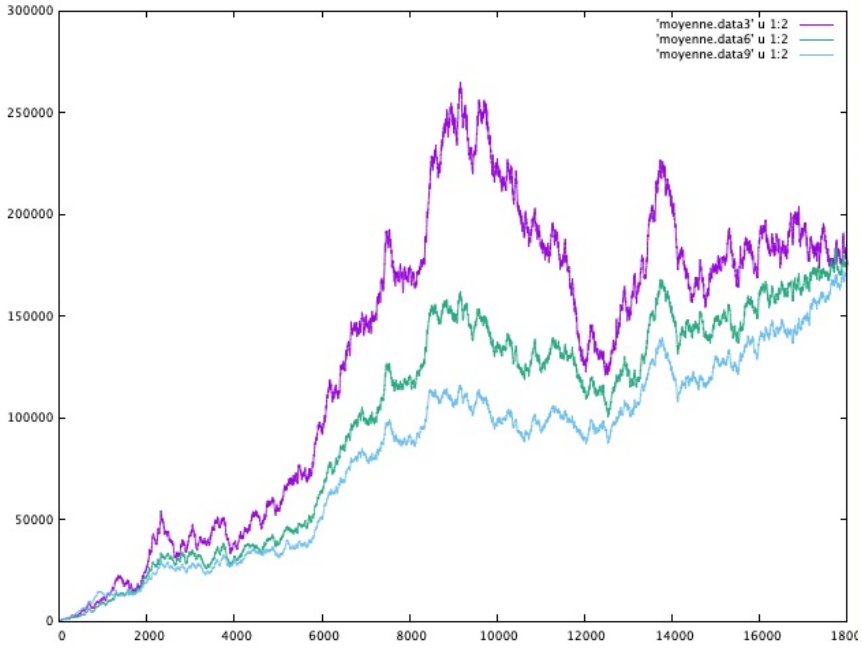

ISM7 – MOYENNES SUR LA DURÉE DE SIMULATION

Cette fois en modifiant :

write (*,*) 'Longueur des segments : ‘ => read (*,*) max_iteration

Vous définissez la longueur des segments sur lequel la quantité $\Delta r^2(t)$ sera calculée (et moyennée).

Vous calculez et moyenner $\Delta r^2(t)$ sur 9 segments de longueur ‘1000’ pour la particule 1. Calculer $\Delta r^2(t)$ pour la particule 1 pour des segments de tailles 4500, 3000, 1500, 1000 et 500. Représenter ces fonctions sur un intervalle de temps 0:1000 ps avec gnuplot. Comment évoluent-elles ? Conclusion ?

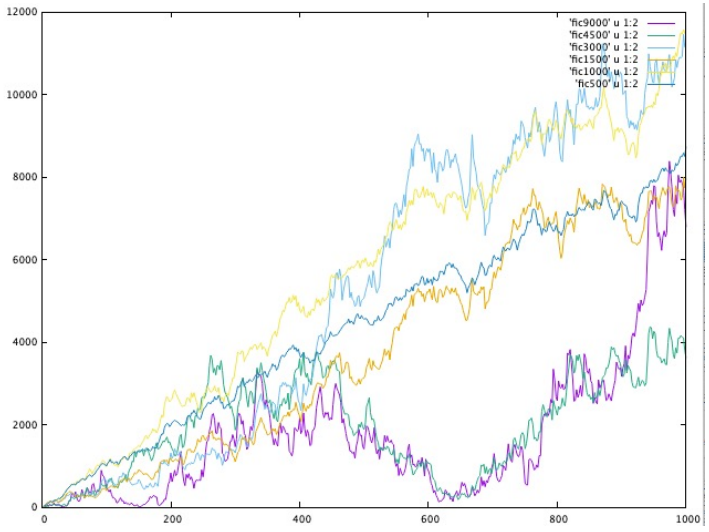

ISM7 – Moyennes sur nombre de particules et durée des simulations

Cette fois en modifiant max_particule et max_iteration

write (*,*) 'Nombre maximum de particule ' => read (*,*) max_particule
write (*,*) 'Longueur des segments : ' => read (*,*) max_iteration

Vous calculez $\Delta r^2(t)$ moyenné sur les 9 segments possibles des 9 particules. Conclusion ?

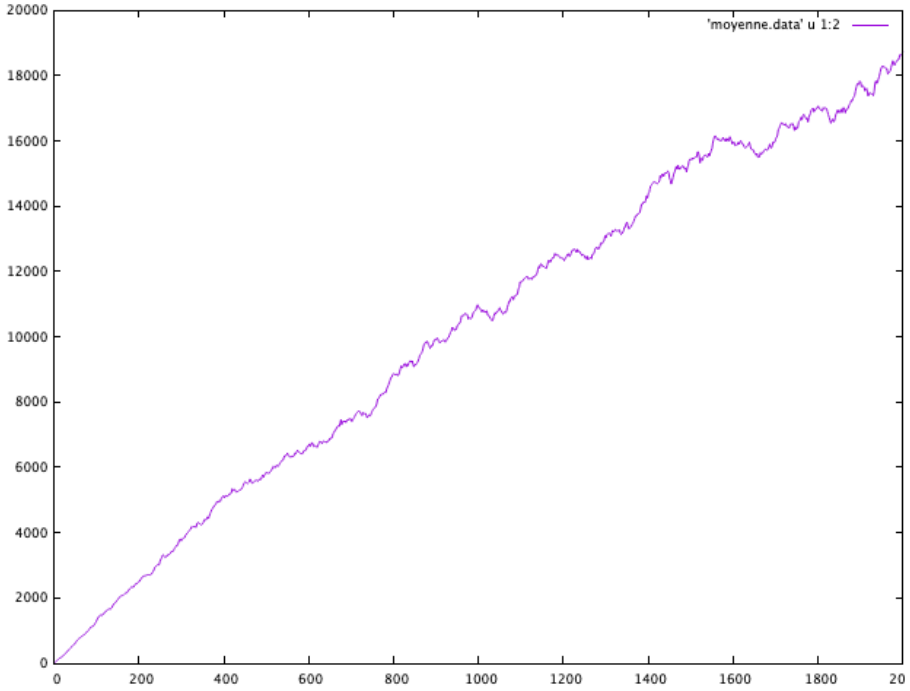

max_iteration = 1000

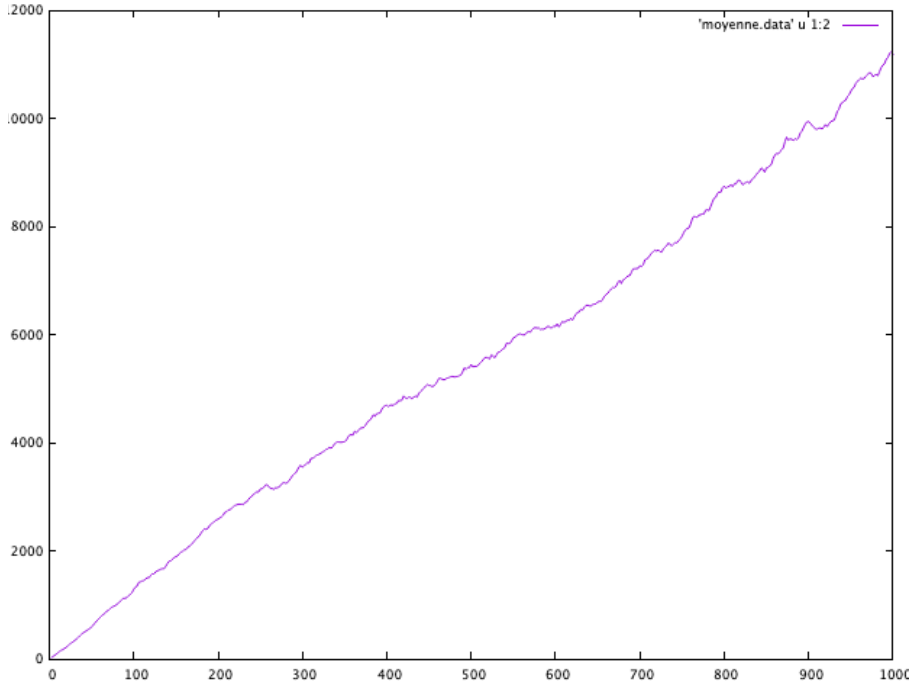

max_iteration = 500

ISM7 – CALCUL DU COEFFICIENT DE DIFFUSION D PAR LA RELATION D'EINSTEIN

Sur la base des valeurs de $\Delta r^2(t)$ calculée sur les 9 segments possibles des 9 particules, i.e. :

```
write (*,*) 'Nombre maximum de particule ' => read (*,*) max_particule
write (*,*) 'Longueur des segments : ' => read (*,*) max_iteration
```

La relation d'Einstein permet de calculer le coeeficient de diffusion D en fonction du comportement asymptotique de $\Delta r^2(t)$:

$$D = \lim_{t\to\infty} \frac{\Delta r^2(t)}{6t}$$

Définissez une fonction linéaire en temps *'diffusion(t)* = $6\times D\times t + b'$ dans gnuplot, et réaliser l'optimisation des paramètres *D* et *b* sur la base des valeurs $\Delta r^2(t)$ précédentes :

```
gnuplot> D = 1
gnuplot> b = 1
gnuplot> diffusion(t) = 6*D*t + b
gnuplot> fit diffusion(x) 'moyenne.data' u 1:2 via D,b
```

Représenter les données originales de $\Delta r^2(t)$ et la fonction 'optimisée' *diffusion(t).*

```
gnuplot> plot 'moyenne.data' u 1:2, diffusion(x)
```

ISM7 – CALCUL DU COEFFICIENT DE DIFFUSION D PAR LA RELATION D'EINSTEIN

Résultat de l'optimisation avec gnuplot :

```
gnuplot> fit diffusion(x) 'moyenne.data' u 1:2 via D,b
iter      chisq       delta/lim  lambda   D           b
   0 2.0925256705e+10   0.00e+00  4.90e+03    1.000000e+00   1.000000e+0(
...
   6 2.6976610904e+08  -6.56e-04  4.90e-03    1.513070e+00   1.102396e+03
iter      chisq       delta/lim  lambda   D           b

After 6 iterations the fit converged.
final sum of squares of residuals : 2.69766e+08
rel. change during last iteration : -6.56242e-09

degrees of freedom    (FIT_NDF)                       : 998
rms of residuals      (FIT_STDFIT) = sqrt(WSSR/ndf)    : 519.91
variance of residuals (reduced chisquare) = WSSR/ndf   : 270307

Final set of parameters            Asymptotic Standard Error
=======================            ==========================
D               = 1.51307          +/- 0.004746     (0.3137%)
b               = 1102.4           +/- 32.91        (2.985%)
```

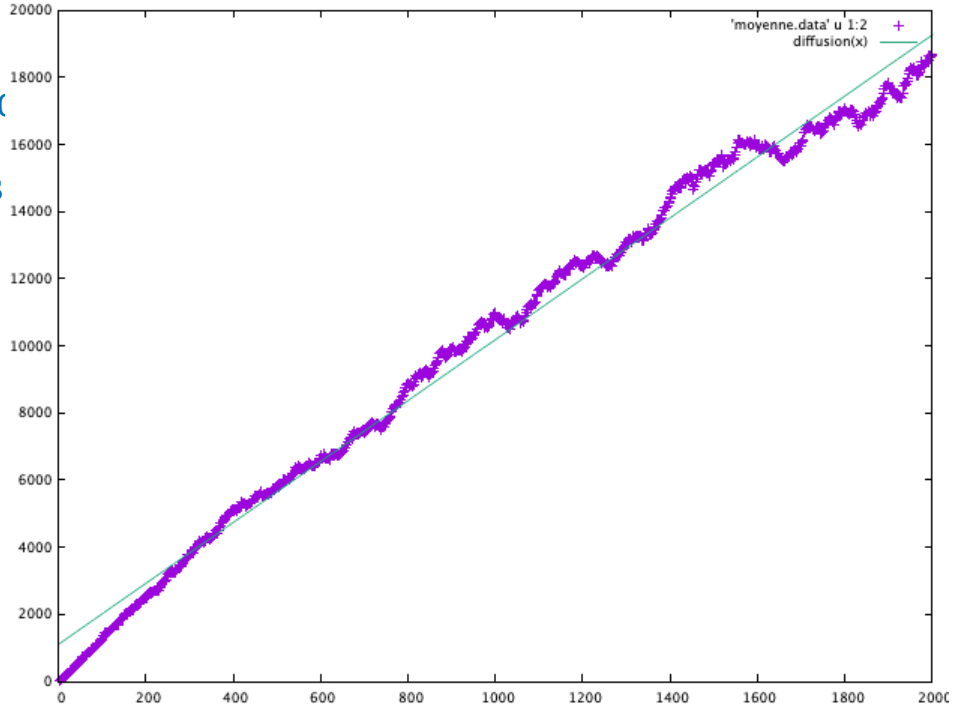

Recalculer D en moyennant $\Delta r^2(t)$ sur des segments de 500 itérations pour l'ensemble des 9 particules. Conclusion ?

ISM8 – Architecture d'un code de dynamique moléculaire

1 – Réduire la complexité d'un terme de lennard jones

2 – Terme de Lennard Jones et OPENMP

3 – Vectorisation

4 – Recherche des plus proches voisins, algorithme en *O(N)*

5 – MPI et plus proches voisins

ISM8 – TERME DE LENNARD JONES DE COMPLÉXITÉ $O(N^2)$

$$U^{LJ} = \sum_{i=1}^{N} \sum_{j=i+1}^{N} \varepsilon_{ij} \left[\left(\frac{r_{ij}^*}{r_{ij}} \right)^{12} - \left(\frac{r_{ij}^*}{r_{ij}} \right)^{6} \right]$$

Algorithmiquement, le code le plus « naïf » pour le calculer est de la forme :

```
DO i = 1,N-1
  DO j = i+1,N
      R_ij^2 = (x(i)-x(j))^2 +  (y(i)-y(j))^2 + (z(i)-z(j))^2
      Calcul des éléments de U^LJ
      Calcul du gradient analytique de U^LJ (donc des forces associées) pour
      chacun des atomes i et j
   END DO
END DO
```

Approche non efficace, tout le temps cpu est employé pour calculer une terme dont la moyenne est constante…

ISM8 – RAYON DE COUPURE ET ENERGIE

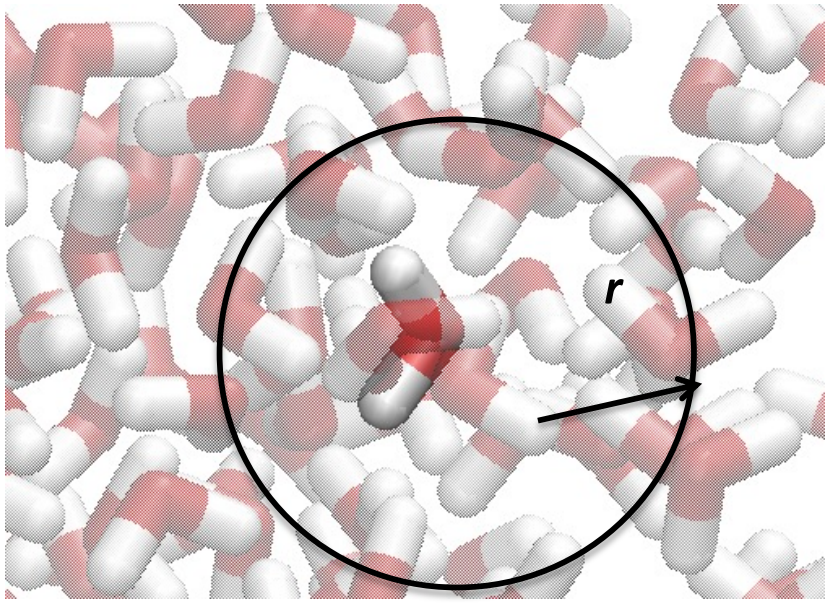

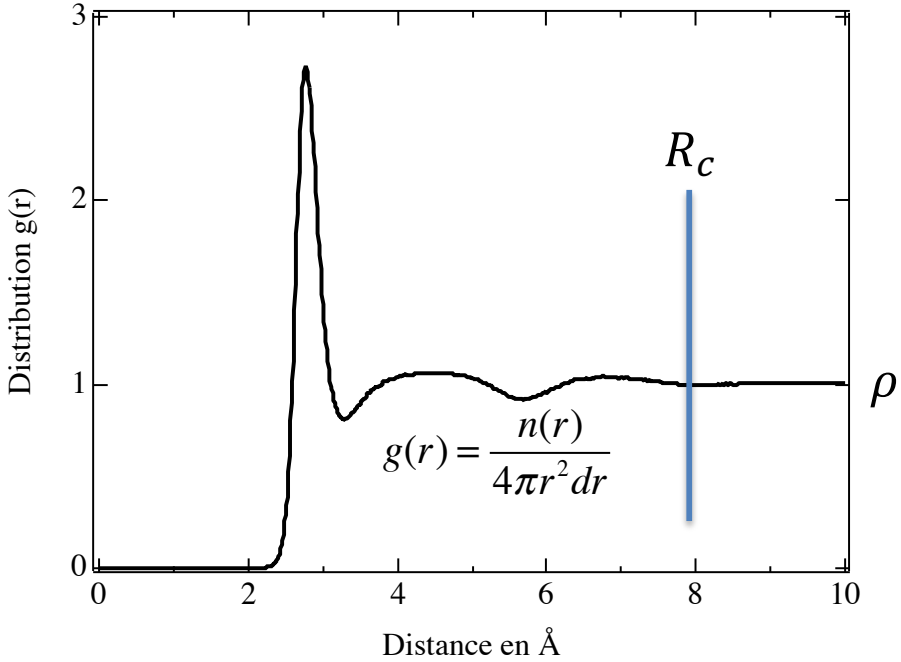

Si le rayon de coupure R_c est pris tel que $g(r) = Cte = \rho$, alors l'erreur commise sur l'énergie potentielle totale d'un atome particulier est :

$$\Delta U(R_c) = \int_{R_c}^{+\infty} \frac{A}{r^n} \times g(r) \times 4\pi r^2 dr = 4\pi\rho \int_{R_c}^{+\infty} \frac{A}{r^{n-2}} dr$$

Cette erreur est finie si et seulement si $n > 3$, et dans ce cas

$$\Delta U(R_c) = \left[-\frac{4\pi A\rho}{(n-3)r^{n-3}} \right]_{R_c}^{+\infty} = \frac{4\pi A\rho}{(n-3)R_c^{n-3}}$$

ISM8 –TERME DE LENNARD JONES ET REDUCTION DE COMPLEXITÉ

La convergence ‘rapide’ vers zéro du terme de Lennard Jones permet d’employer un rayon de coupure et donc de réduire ***a priori*** la complexité de son calcul de *O(N²)* à *O(N)* ….

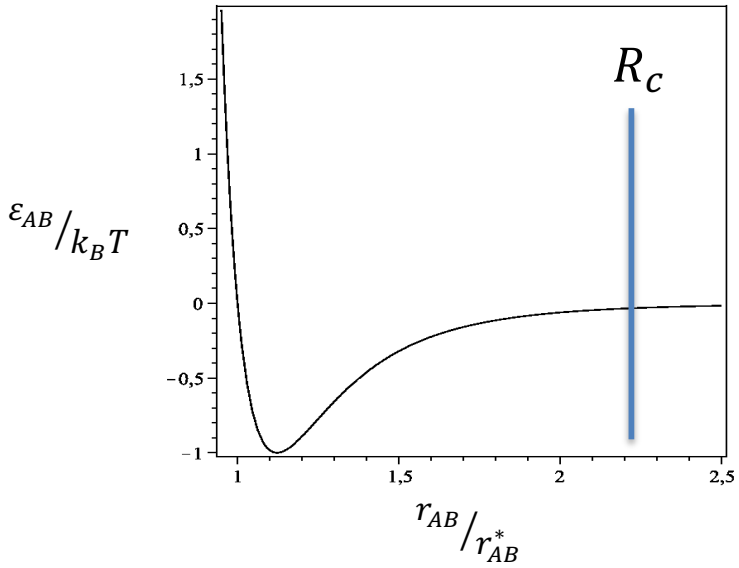

$$U^{LJ} = 4\sum_{i=1}^{N}\sum_{j>i}^{N}\varepsilon_{ij}^{*}\left[\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{12} - 2\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{6}\right] \quad O(N^2)$$

$$U^{LJ} \approx 4\sum_{i=1}^{N}\sum_{j/r_{ij}<R_c}\varepsilon_{ij}^{*}\left[\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{12} - 2\left(\frac{r_{ij}^{*}}{r_{ij}}\right)^{6}\right] \quad O(N)$$

Mais une complexité en *O(N)* sous entend ici que l’on peut identifier les paires d’atomes *(i,j)* qui vérifient $r_{ij} < R_c$ avec un algorithme lui même en *O(N)*, **sinon la recherche des plus proches voisins va imposer sa complexité algorithmique à l’ensemble du code.**

ISM8 – LISTE DE VERLET

Par définition : liste des particules/atomes situés à « proximité » de chaque particule/atome (liste des proches voisins)

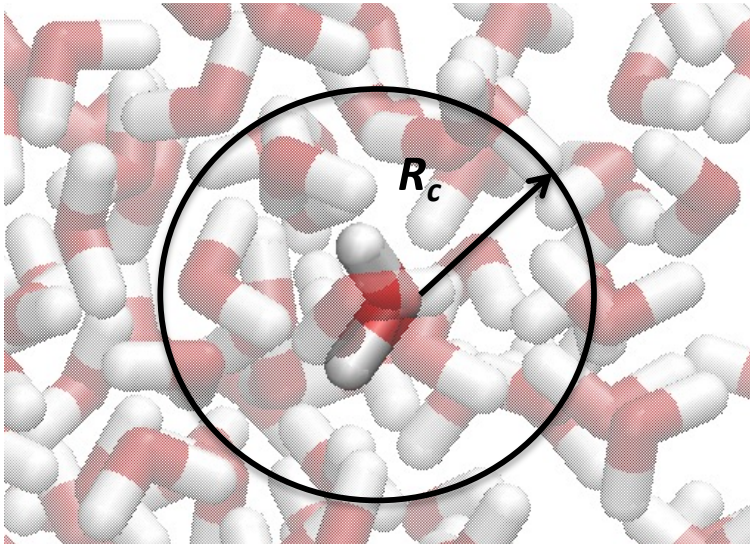

On peut bâtir ce type de liste en calculant toutes les distances :

```
DO i = 1,N-1
  DO j = i+1,N
     Rij2 = (x(i)-x(j))2 +  (y(i)-y(j))2 + (z(i)-z(j))2
     if (Rij2 < Rc*Rc) mise en mémoire de la paire
  END DO
END DO
```

=> algorithme $O(N^2)$

L'emploi d'un rayon de coupure R_c transforme le terme de Lennard Jones en une fonction discontinue en R_c. Pour corriger ce problème il faut transformer le terme de Lennard Jones tronqué en (avec n_i le nombre de proche voisin de l'atome i) :

$$U^{LJ} = \sum_{i=1}^{N}\sum_{j=i}^{n_i} \varepsilon_{ij}\left[\left(\frac{r_{ij}^*}{r_{ij}}\right)^{12} - \left(\frac{r_{ij}^*}{r_{ij}}\right)^{6}\right] \times P_5(r_{ij})$$

$$P_5(r) = 1 - 10\left(\frac{r - x_{\min}}{r_{\max} - x_{\min}}\right)^3 + 15\left(\frac{r - x_{\min}}{r_{\max} - x_{\min}}\right)^4 - 6\left(\frac{r - x_{\min}}{r_{\max} - x_{\min}}\right)^5$$

$$\text{avec} \quad x_{\min} \le x \le x_{\max} \ \text{et} \ (x_{\min} = R_c - \delta r, x_{\max} = R_c)$$

ISM8 – Mise à jour des listes de Verlet

Aux conditions ambiantes (température et pression), les molécules d'eau en phase liquide se déplacent d'environ 0,1 Å (10^{-11} m) en 1 fs et « rebondissent » les unes sur les autres.

Il suffit donc de construire des listes de Verlet correspondant à un rayon de coupure R_c plus grand. Lors d'une simulation de type dynamique moléculaire, ces listes de Verlet seront valables sur un intervalle de temps de plusieurs fs. Elles permettent donc de calculer plusieurs fois le terme de Lennard Jones sans avoir à reconstruire systématiquement ces listes.

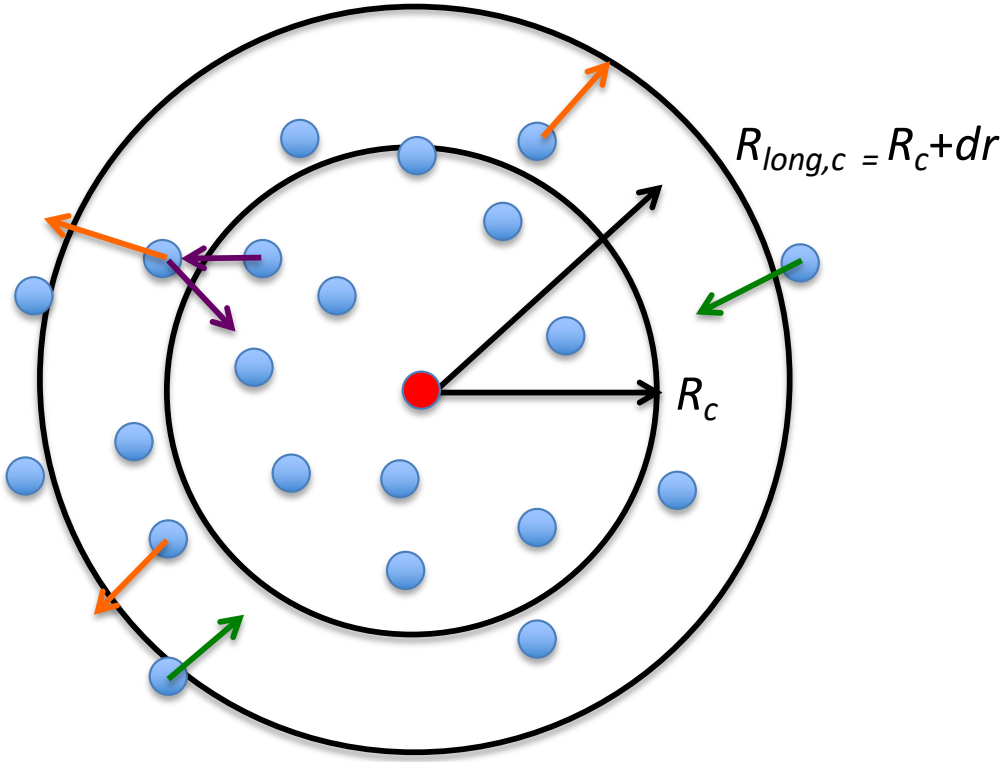

Algorithme dont l'efficacité dépend de la quantité de mémoire disponible. Ici on joue sur le préfacteur de la complexité algorithmique, ici toujours en $O(N^2)$.

ISM8 – TERME DE LENNARD JONES ET LISTES DE VERLET

Algorithmes pour le calcul de Lennard Jones…

Sans listes de Verlet 'étendues'

m itérations

```
DO i = 1,N-1
      DO j = i+1,N
          R_ij^2 = (x(i)-x(j))^2 +  (y(i)-y(j))^2 + (z(i)-z(j))^2
          if (R_ij^2 < R_c*R_c) mise en mémoire paire ij
      END DO
END DO

DO i = 1,N
  DO j = 1,n_i
      n_j = l_i(j)
      R_ij^2 = (x(i)-x(n_j))^2 +  (y(i)-y(n_j))^2 + (z(i)-z(n_j))^2
                              …
                  Calcul de l'énergie et des forces
  END DO
END DO
```

…

avec listes 'étendues'

```
DO i = 1,N-1
      DO j = i+1,N
          R_ij^2 = (x(i)-x(j))^2 +  (y(i)-y(j))^2 + (z(i)-z(j))^2
          if (R_ij^2 < R_long,c*R_long,c) mise en mémoire paire ij
      END DO
END DO
```

m itérations

```
DO i = 1,N
  DO j = 1,n_i
      n_j = l_i(j)
      R_ij^2 = (x(i)-x(n_j))^2 +  (y(i)-y(n_j))^2 + (z(i)-z(n_j))^2
      if (R_ij^2 < R_c*R_c)   Pénalité !
                  Calcul de l'énergie et des forces
  END DO
END DO
```

Avec des listes de Verlet étendues, le préfacteur de la recherche en $O(N^2)$ des proches voisins est divisé par le nombre d'itération *m*, mais il faut encore ajouter un test pour dire au code quand reconstruire les listes de Verlet….

=> *m* n'est pas constant, mais dans certain cas il peut être très grand (modélisation à basse température, modélisation d'un solide…)

ISM8 – REMARQUE : TERME DE LENNARD JONES

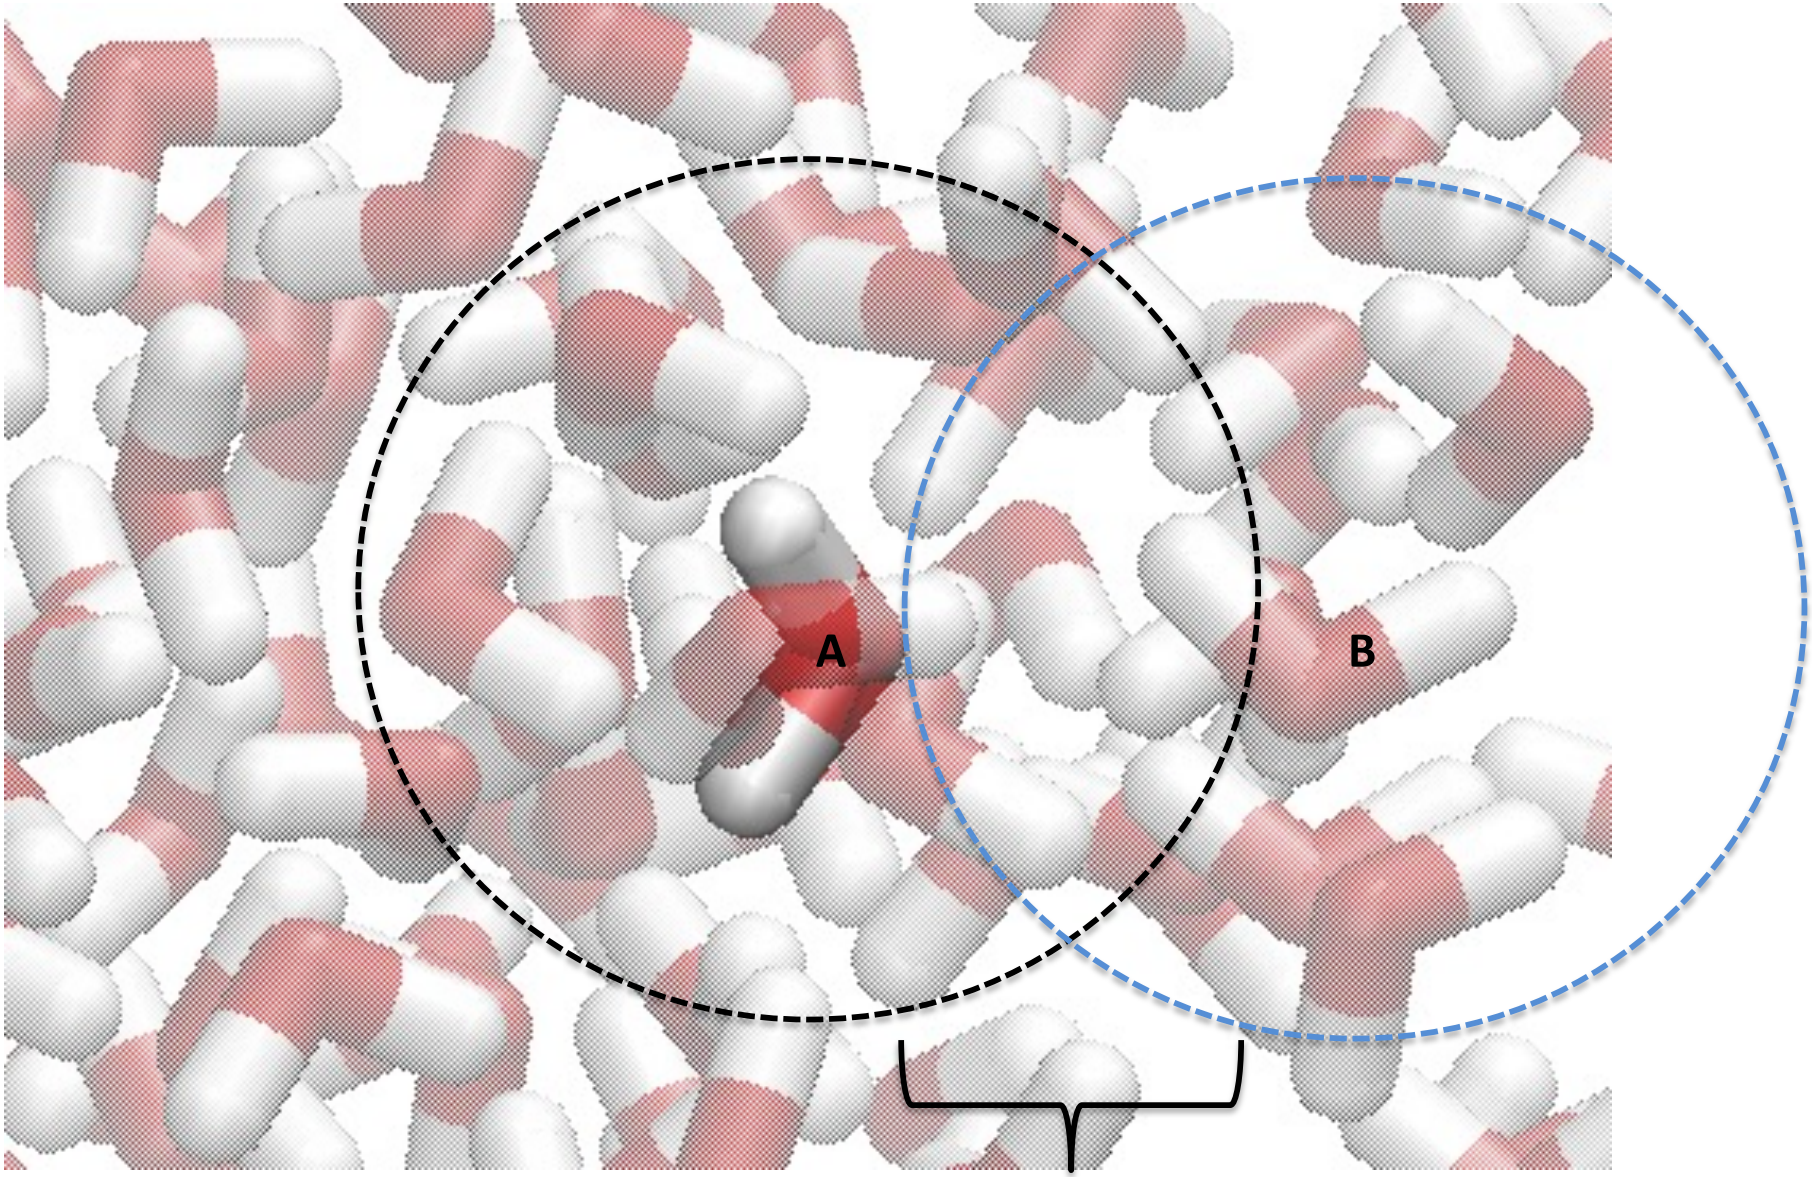

liste de voisins communs
à **A** et **B**

ISM8 – TERME DE LENNARD JONES ET OPENMP

Les directives OPENMP s'appliquent sur la première boucle du calcul du terme de Lennard Jones (quelque soit sa complexité)

```
!$OMP REDUCTION(+ : U^LJ)
!$OMP DO
DO i = 1,N
  Fxi = 0 ; Fyi = 0 ; Fzi = 0
  DO j = 1,n_i
      n_j = l_i(j)
      R_ij^2 = (x(i)-x(n_j))^2 +  (y(i)-y(n_j))^2 + (z(i)-z(n_j))^2
      ....
      Calcul de l'énergie U^LJ
      Calcul des forces sur i et calcul des forces sur n_j
        Fxi = Fxi  - ∂U^LJ/∂x_i ; Fx(n_j) = Fx(n_j) - ∂U^LJ/∂x_nj
        Fyi = Fyi  - ∂U^LJ/∂y_i ; Fy(n_j) = Fy(n_j) - ∂U^LJ/∂y_nj
        Fzi = Fzi  - ∂U^LJ/∂z_i ; Fz(n_j) = Fz(n_j) - ∂U^LJ/∂z_nj
   END DO
   Fx(i) = Fxi ; Fy(i) = Fyi ; Fz(i) = Fzi
END DO
!$OMP ENDDO
```

➔ « race condition ».

Le problème de « race condition » a pour origine le fait qu'un même atome peut être un proche voisin de deux atomes distincts…

ISM8 – FORCES DE LENNARD JONES ET OPENMP

Pour résoudre le problème de race conditions sur les forces différentes possibilités, dont :

```
!$OMP REDUCTION(+ : U^LJ)
!$OMP DO
DO i = 1,N
   ...
  DO j = 1,n_i
      n_j = l_i(j)
      R_ij^2 = (x(i)-x(n_j))^2 +  (y(i)-y(n_j))^2 + (z(i)-z(n_j))^2
      ....
      Calcul de l'énergie U^LJ
      Calcul des forces
!$OMP ATOMIC
      Fx(n_j) = Fx(n_j) - ∂U^LJ/∂x_nj
!$OMP ATOMIC
      Fy(n_j) = Fy(n_j) - ∂U^LJ/∂y_nj
!$OMP ATOMIC
      Fz(n_j) = Fz(n_j) - ∂U^LJ/∂z_nj
   END DO
   ...
END DO
!$OMP ENDDO
```

➔ **Pas efficace (pénalité de 30 à 50%)**

ISM8 – FORCES DE LENNARD JONES ET OPENMP

Les listes de proches voisins peuvent être construites en prenant tous les voisins, dans ce cas il est inutile de calculer les forces correspondant aux voisins

```
!$OMP REDUCTION(+ : U^LJ)
!$OMP DO
DO i = 1,N
   Fxi = 0 ; Fyi = 0 ; Fzi = 0
  DO j = 1,n_i
      n_j = l_i(j)
      R_ij^2 = (x(i)-x(n_j))^2 +  (y(i)-y(n_j))^2 + (z(i)-z(n_j))^2
      ....
      Calcul de l'énergie U^LJ
      Calcul des forces
      Fx(n_j) = Fx(n_j) - ∂U^LJ/∂x_nj        Fxi = Fxi  - ∂U^LJ/∂x_i
      Fy(n_j) = Fy(n_j) - ∂U^LJ/∂y_nj        Fyi = Fyi  - ∂U^LJ/∂y_i
      Fz(n_j) = Fz(n_j) - ∂U^LJ/∂z_nj        Fzi = Fzi  - ∂U^LJ/∂z_i
   END DO
   Fx(i) = Fxi ; Fy(i) = Fyi ; Fz(i) = Fzi
END DO
!$OMP ENDDO
```

➔ **Pas efficace (pénalité de 100 %)**

ISM8 – TERME DE LENNARD JONES ET OPENMP

Le vecteur des forces devient spécifique à chaque thread

!$OMP REDUCTION(+ : U^{LJ})
!$OMP DO
DO i = 1,N
…
DO j = 1,n_i
$n_j = l_i(j)$
$R_{ij}^2 = (x(i)-x(n_j))^2 + (y(i)-y(n_j))^2 + (z(i)-z(n_j))^2$
….
Calcul de l'énergie U^{LJ}
Calcul des forces
$Fx(n_j,thread) = Fx(n_j,thread) - \frac{\partial U^{LJ}}{\partial x_{n_j}}$
$Fy(n_j,thread) = Fy(n_j,thread) - \frac{\partial U^{LJ}}{\partial y_{n_j}}$
$Fz(n_j,thread) = Fz(n_j,thread) - \frac{\partial U^{LJ}}{\partial z_{n_j}}$
END DO
…
END DO
!$OMP ENDDO

Il faut alors effectuer une réduction sur les vecteurs Fxyz(:,thread) pour obtenir le vecteur force totale sur chaque atome après le calcul du terme de Lennard Jones.

Remarque : nombre de proches voisins, en général de l'ordre de 100 à 500, réaliser la réduction précédente ne présente pas un coût important sur des processeurs avec peu de cœurs…

…mais aujourd'hui les processeurs AMD ont 64, 96 voire 128 cœurs et les futurs processeurs ARM pour le HPC, 256 cœurs (!). Cela a revient à calculer deux fois le terme U^{LJ}, autrement dit il est préférable de considérer tous les voisins lors de la construction des listes de Verlet et de revenir au slide précédent.

Conclusion : aujourd'hui il faut considérer un code avec les différentes options qui seront choisies en fonction du système microscopique et du processeur lors de l'exécution.

ISM8 – REMARQUE TERME DE STRETCHING ET OPENMP

Soit un système de *N* atomes qui définissent une chaine de liaisons covalentes identiques

Chaque liaison est décrite par le terme $u = k\left(r_{\alpha\beta} - r^0\right)^2$, l'énergie de « stretch » totale est donc :

$$U^{stretch} = \sum_{(\alpha,\beta)} k\left(r_{\alpha\beta} - r^0\right)^2$$

Pour la grande majorité des liaisons covalentes pas de problèmes de type 'race condition' car chaque liaison est définie par une paire d'atomes unique et chaque atome appartient au plus à deux liaisons, par exemple les atomes l_1 ou m_1.

Il est donc possible de proposer un algorithme efficace sur la base de threads sans directive OPENMP dans la zone « OMP PARALLEL » mais nécessitant de regrouper les liaisons covalentes par groupe de liaisons indépendantes.

ISM8 – TERME DE STRETCHING ET OPENMP

Définition des groupes de liaison

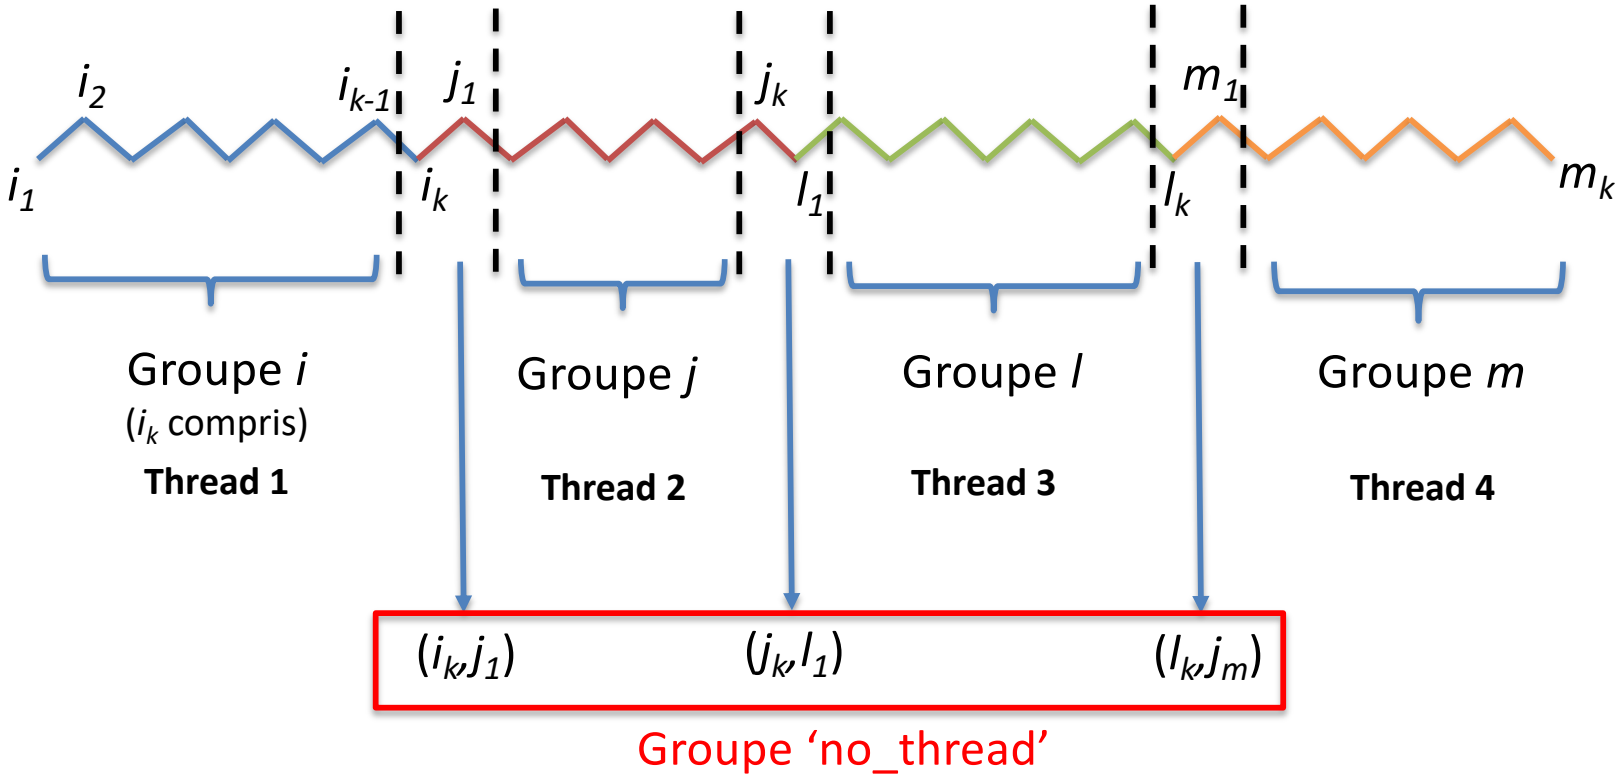

ISM8 – TERME DE LENNARD JONES ET VECTORISATION

Les directives de vectorisation s'appliquent à la deuxième boucle du calcul du terme de Lennard Jones (quelque soit sa complexité)

```
!$OMP DO
DO i = 1,N
!DIR$ SIMD REDUCTION (+ : U^LJ et éventuellement forces associées)
  DO j = 1,n_i
      n_j = l_i(j)
      R_ij^2 = (x(i)-x(n_j))^2 +  (y(i)-y(n_j))^2 + (z(i)-z(n_j))^2
     Calcul de l'énergie U^LJ
     Calcul des forces sur n_j
  END DO
END DO
!$OMP ENDDO
```

Pas de « race condition » avec les unités vectorielles, car un atome *i* ne peut avoir deux fois le même atome n_j comme voisin.

Mais les indices n_j ne sont pas à la suite => grosse pénalité lors de la lecture des données x/y/z(n_j), => les compilateurs actuels (ifort/icc) refusent même de générer un code avec des instructions vectorielles…

ISM8 – TERME DE LENNARD JONES ET VECTORISATION

Une stratégie « simple » consiste à décomposer la deuxième boucle en une boucle « load » et une boucle « computation » avec emploi de petits vecteurs locaux (déclarés comme OMP PRIVATE). Par exemple, dans le cas de listes de Verlet étendues :

```
!$OMP PRIVATE (xlocal,ylocal,zlocal)
!$OMP DO
DO i = 1,N
  xx = x(i) ; yy = y(i) ; zz = z(i)

  DO j = 1,n_i                                          load
     n_j = l_i(j)
     xlocal(j) = x(n_j) ; ylocal(j) = y(n_j) ; zlocal(j) = z(n_j)
  END DO

!DIR$ SIMD REDUCTION (+ : U^LJ)                         computation
  DO j = 1,n_i
     R_ij^2 = (xx - xlocal(j))^2 + (yy - ylocal(j))^2 + (zz - zlocal(j))^2
     Calcul de l'énergie U^LJ
  END DO

END DO
!$OMP ENDDO
```

Gain proche du nombre d'unités vectorielles disponibles sur le cœur pour les calculs en réel les plus lourds (div et/ou sqrt)

ISM8 – RECHERCHE DES ATOMES VOISINS

Objectif : transformer une recherche globale en une recherche dans un sous domaine

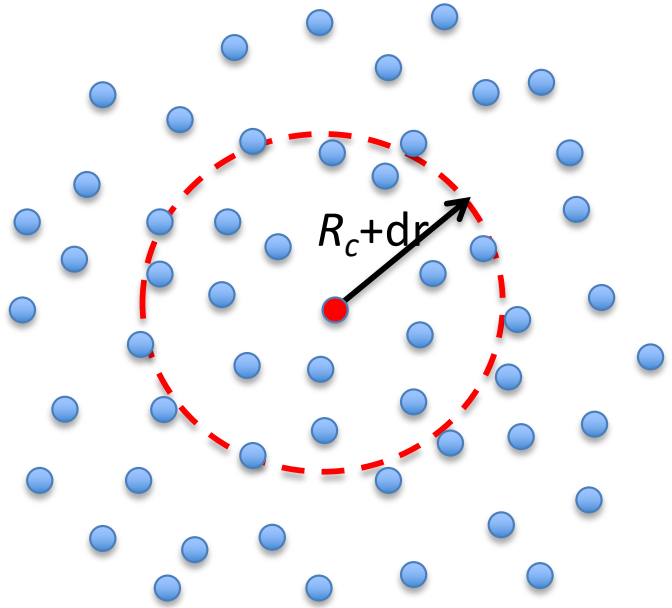

Calcul de toutes les distances
algorithme en *O(N²)*

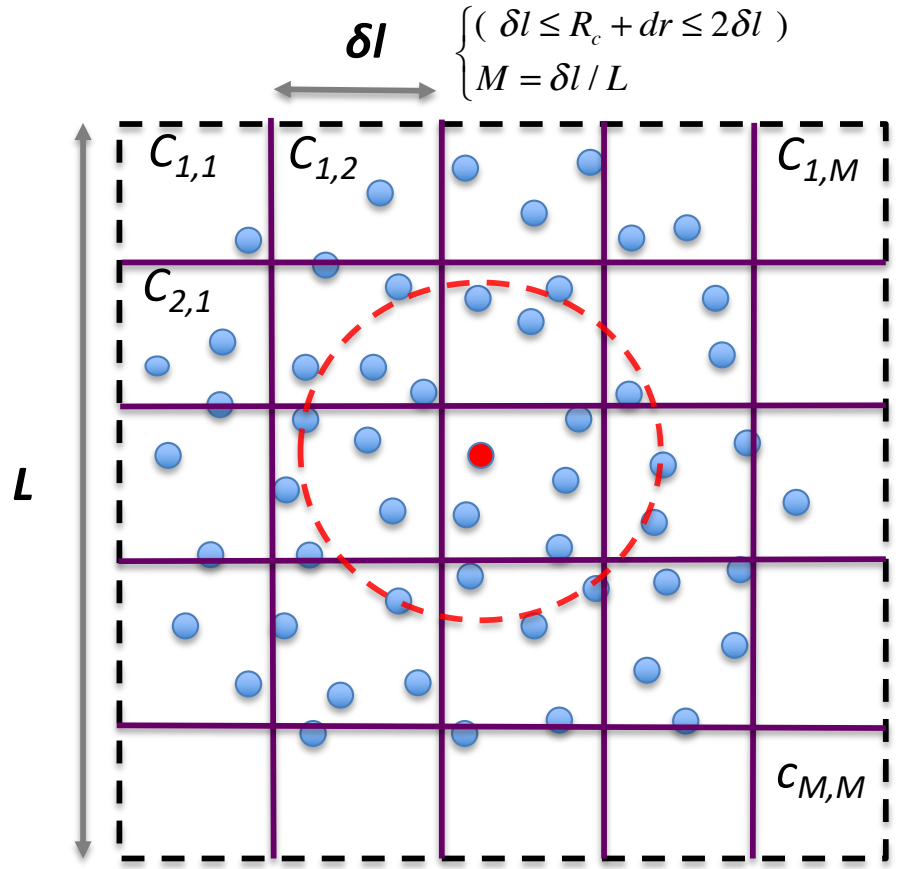

Décomposition de domaine
« Divide and Conquer »

ISM8 – ALGORITHME DE DÉCOMPOSITION DE DOMAINE

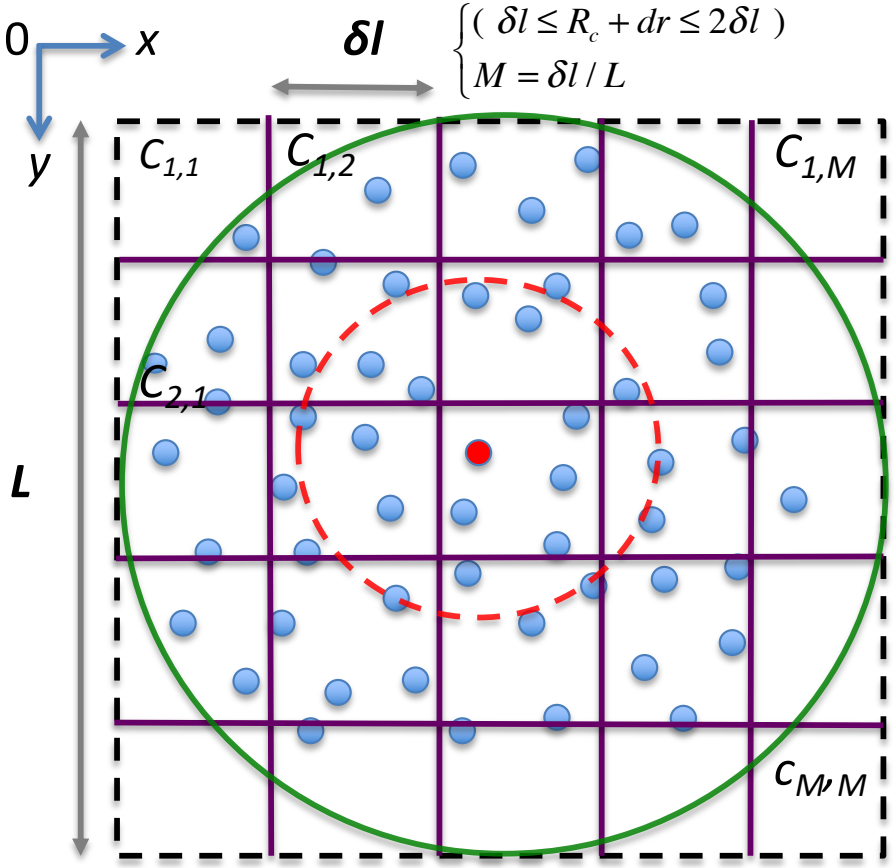

Principales étapes d'un algorithme en *O(N)*

1 – Pour chaque atome *A*, identifier sa cellule $c_{iA,jA}$

$$\begin{cases} i_A = \text{int}(x_A / \delta l) + 1 \\ j_A = \text{int}(y_A / \delta l) + 1 \end{cases} \Rightarrow \quad O(N)$$

2 – Identifier les cellules situées au plus à $2\delta l$ de $c_{iA,jA}$

$$\begin{cases} i_A - 2 \le i \le i_A + 2 \\ j_A - 2 \le j \le j_A + 2 \end{cases} \Rightarrow \quad O(N)$$

3 – Rechercher les particules à moins de R_c+dr de l'atome *A* dans le jeu de cellules précédentes

4 Conclusion : algorithme en *O(N)*

Remarque : le préfacteur de *O(N)* est grand, il est donc intéressant de faire une recherche des plus proches voisins de A pour $R_{super\ long,c} = R_c + \Delta r$, *avec Δr = Kdr et de réorganiser la liste par un algorithme classique de tri => mais vous m'aviez dit que c'est du O(NlogN) ?*

ISM8 – ALGORITHME DE DÉCOMPOSITION DE DOMAINE

Remarque : « le préfacteur de *O(N)* est grand, il est donc intéressant de faire une recherche des plus proches voisins de A pour $R_{super\ long,c}=R_c+\Delta r$, *avec* $\Delta r = Kdr$ *et de réorganiser la liste par un algorithme classique de tri =>* *mais vous m'aviez dit que c'est du O(NlogN) ? »*

Ici il ne faut pas confondre *N* (nombre total d'atome du système qui permet de définir la complexité algorithmique) et le nombre moyen $\overline{n}$ de voisins :

1 - $\overline{n}$ est borné (la densité de la manière n'est pas infinie);

2 - le tri ne s'effectue que pour ces $\overline{n}$ atomes, le temps de calcul associé est donc lui aussi borné pour un atome;

3 – donc pour chacun des *N* atomes du système j'effectue un tri pour une sous liste d'atomes dont la taille et donc le temps de calcul est borné…

Conclusion on reste bien sur une complexité algorithmique global en *O(N)*

ISM8 – TERME DE LENNARD JONES EN *O(N)* POUR LA DYNAMIQUE MOLÉCULAIRE

CALL decomposition_de_domaine(R_c,Δr)

K=dr/Δr fois

```
!$OMP PRIVATE (xlocal,ylocal,zlocal)
!$OMP DO
DO i = 1,N
  xx = x(i) ; yy = y(i) ; zz = z(i)

  DO j = 1,n_i
     n_j = l_i(j)
     xlocal(j) = x(n_j) ; ylocal(j) = y(n_j) ; zlocal(j) = z(n_j)
  END DO

!DIR$ SIMD REDUCTION (+ : U^LJ)
  DO j = 1,n_i
     R_ij^2 = (xx - xlocal(j))^2 +  (yy - ylocal(j))^2 + (zz - zlocal(j))^2
     Calcul de l'énergie U^LJ
  END DO

END DO
!$OMP ENDDO
```

CALL résolution_equations_de_Newton(x,y,z,gx,gy,gz)

ISM8 – DÉCOMPOSITION DE DOMAINE ET PARALLÉLISME MPI

En OPENMP chaque cœur CPU voit le même état de la mémoire, en MPI, il faut mettre à jour la mémoire de chaque jeu de CPUs regrouper sur un « nœud ». Conséquence sur l'algorithme de décomposition de domaine : il faut considérer une liste de particules « fantômes » sur numéraires pour chaque tâche MPI.

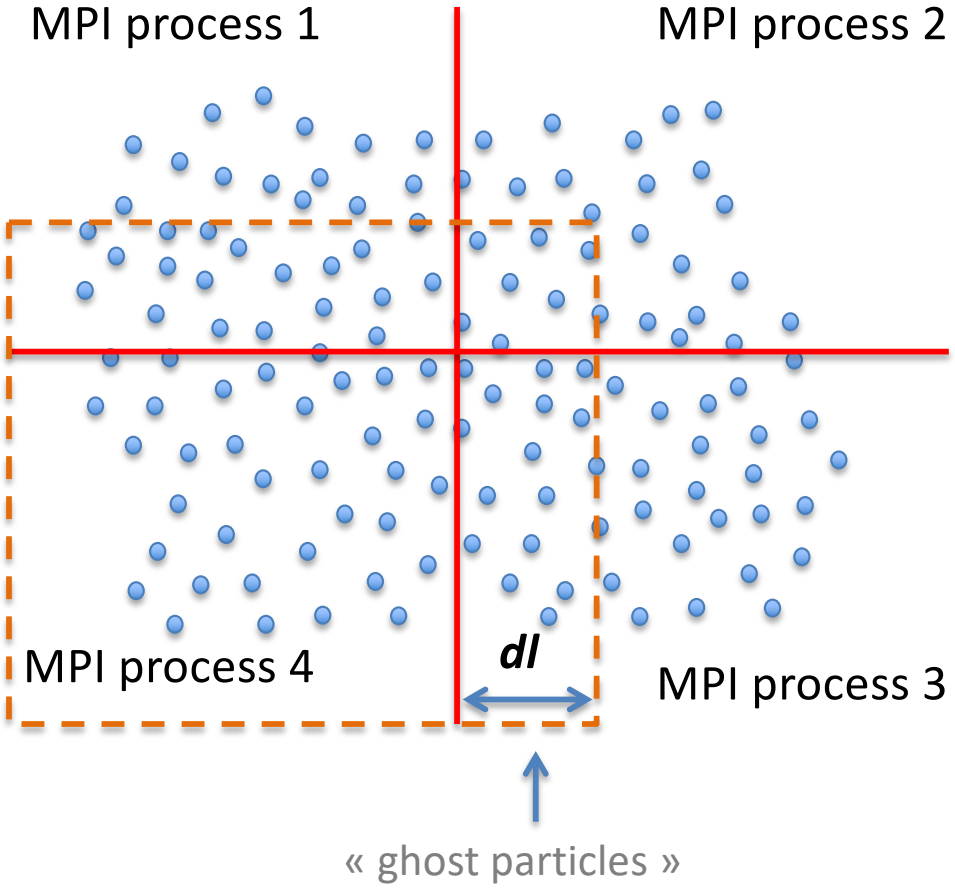

Principales étapes d'un algorithme MPI

1 – Répartir les particules entre les tâches MPI en fonction de leur coordonnées

2 – Echanger les positions de particules fantômes entre les différentes tâches MPI

$$dl = R_c + \Delta r$$

3 – Appliquer à chaque sous domaine MPI, l'algorithme *O(N)* de recherche de plus proches voisins.

Remarque : pour assurer une bonne répartition de la charge de calcul entre les tâches MPI, il faut soit que la densité de particules soit constante en tout point, soit moduler la taille des domaines géométriques correspondant à chaque tâche MPI.

ISM8 – TERME DE LENNARD JONES *O(N)* EN VERSION MPI

CALL **MPI**_répartition_echange_particule($R_c+\Delta r$)

CALL decomposition_de_domaine($R_c+\Delta r$)

K=dr/Δr fois

```
!$OMP PRIVATE (xlocal,ylocal,zlocal)
!$OMP DO
DO i = 1,N
  xx = x(i) ; yy = y(i) ; zz = z(i)

  DO j = 1,n_i   ⟶ en MPI, n_i est potentiellement plus grand => surcoût
     n_j = l_i(j)
     xlocal(j) = x(n_j) ; ylocal(j) = y(n_j) ; zlocal(j) = z(n_j)
  END DO

!DIR$ SIMD REDUCTION (+ : U^LJ)
  DO j = 1,n_i
     R_ij^2 = (xx - xlocal(j))^2 + (yy - ylocal(j))^2 + (zz - zlocal(j))^2
     Calcul de l'énergie U^LJ
  END DO

END DO
!$OMP ENDDO
CALL résolution_equations_de_Newton()
```

La liste de particules fantômes évite de faire une mise à jour MPI des forces !

ISM8 – DERNIÈRES REMARQUES

1 - Cet algorithme reste valable quelque soit le terme d'interaction « à courte portée » considéré, *i.e.* lorsque l'on considère un terme d'interaction par paire à qui on applique une troncature.

2 - Chaque tâche MPI correspond à un domaine d'espace. Afin de minimiser le coût des communications MPI, ile faut faire correspondre la topologie des tâches MPI à celle des domaines d'espace.

3 – Aujourd'hui, on arrive à pousser l'efficacité de ce type d'algorithme à 250 particules/atomes par cœur de calcul. Pour aller au delà il faudra significativement améliorer les performances des réseaux d'interconnection.

4 – Toutefois, quoique l'on fasse, on réalise au mieux des simulations à l'échelle de quelques dizaines de nanoseconde par jour sur une architecture de calcul de type CPU, et cette valeur ne va pas évoluer de manière spectaculaire dans un avenir proche…

5 - La machine ANTON est un processeur dédié de 512 cœurs dans sa version actuelle, avec une mémoire physique commune à tous.

ISM8 – EXERCICE : ATTENUATION D'UNE COUPURE

Soit le polynôme d'ordre 5 suivant

$$P_5(x) = 1 - 10\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^3 + 15\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^4 - 6\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^5$$

$$\text{avec} \quad x_{\min} \leq x \leq x_{\max}$$

1 – Quelles sont ses valeurs et celles de sa dérivée première en x_{min} et x_{max} ?

2 – Comment employer ce polynôme pour atténuer l'application d'un rayon de coupure à une interaction de type Coulombienne ou de Lennard-Jones ?

3 – Comment réécrire les dérivées d'une fonction f(x) à qui on applique le polynôme $P_5(x)$?

ISM8 – ANNALE EXAMEN 2019

I.10 Comment se comporte la fonction de distribution radiale *g*(*r*) quand $r \to +\infty$ pour un système condensé homogène ?

Réponse : une ligne maximum

I.11 Comment mettre à profit cette propriété de la fonction *g*(*r*) pour définir l'ordre de grandeur de la taille d'un système périodique (ici une boite cubique de dimension *L*) permettant de simuler le système condensé précédent ?

Réponse : deux lignes maximum

I.22 La complexité algorithmique de la méthode de recherche des plus proches voisins basé sur une décomposition de domaine est *O(N)* ou *N* est la taille (en nombre de particule) de la boite simulée avec des conditions périodiques. Une telle méthode se parallélise efficacement en MPI. Que faut-il veiller à vérifier pour que cette efficacité en MPI soit maximum ?

Réponses : la dimension géométrique des domaines doit être identique, ces domaines doivent contenir le même nombre de particule, le système microscopique présente une interface, le système microscopique est homogène

ISM8 – ANNALE EXAMEN 2019

I.38 Soit une fonction énergie potentielle de la forme $U = \sum_{i=1}^{N} \sum_{j>i}^{N} f(r_{ij})$. Un schéma de parallélisation de type OPENMP bien adapté à cette double somme consiste

Réponses : à ajouter une directive OPENMP de type !$OMP DO au niveau de la deuxième boucle du code correspondant à la deuxième somme de *U*, à ajouter une directive OPENMP de type !$OMP SINGLE au niveau de la première boucle du code correspondant à la première somme de *U*, à ajouter une directive OPENMP de type !$OMP DO au niveau de la première boucle du code correspondant à la première somme de *U*

I.39 Soit un système microscopique composé de *N* particules et dont la fonction énergie potentielle est de la forme $U = \sum_{i=1}^{N} \sum_{j>1}^{N} f(r_{ij})$ où f n'est jamais négligeable quelle que soit la distance r_{ij}. Une particule *i* de ce système

Réponses : peut interagir avec elle-même, ne peut jamais interagir simultanément deux fois avec la même particule *j*, peut interagir avec aucune particule

I.40 Soit un système microscopique composé de *N* particules et dont le fonction énergie potentielle est de la forme $U = \sum_{i=1}^{N} \sum_{i \neq j, j=1}^{N} \sum_{k \neq (i,j), k=1}^{N} f(r_{ij}, r_{jk}, r_{ik})$. Peut-on appliquer un directive de vectorisation de type !DIR SIMD à la 3ième boucle d'un code permettant de calculer cette fonction ?

Réponses : oui, non, parfois

ISM8 – CODE DE SIMULATION : INTRODUCTION DES LISTES DE VERLET EN $O(N^2)$

Introduire dans le code de simulation un tableau à deux dimensions :

neighbor (1:N_particule , 0:**2***n_max_neighbor)

Ici, n_max_neighbor est une estimation du nombre maximum de plus proche voisin d'une particule pour un rayon de coupure R_c. On peut l'estimer suivant la formule :

density = N_particule / (Lx*Ly*Lz) ; n_max_density = int(density*4*π*R_c^3) **x2**

Lx/Ly/Lz sont les dimensions de la boite périodique, le facteur **x2** permet de prendre en compte des fluctuations importantes à la densité moyenne 'density'. L'algorithme de construction des listes de Verlet en $O(N^2)$ pour des conditions périodiques sera de la forme :

```
DO i = 1,N_particule
    ni = neighbor(i,0)
    DO j = i+1,N_particule
        DO i_sym = 1,27
            Xj_loc = x(j) + coordonnée X du i_sym^ième vecteur {η}
            Yj_loc = y(j) + coordonnée Y du i_sym^ième vecteur {η}
            Zj_loc = z(j) + coordonnée Z du i_sym^ième vecteur {η}
            R_ij^2 = (x(i)- Xj_loc )^2 +  (y(i)- Yj_loc )^2 + (z(i)- Zj_loc )^2
            if (R_ij^2 < R_c*R_c)  ! mise en mémoire de la paire [i,j(i_sym)]
              ni = ni +1 ; mi = 2*ni -1  ; neighbor(i,mi) = j ; neighbor(i,mi+1) = i_sym
            end if
        END DO
    END DO
END DO
```

ISM9 – Dynamique moléculaire et barrière d'énergie

1 – Position du problème

2 – Méthodes sans introduction de biais

- trajectoires indépendantes
- Recuit simulé ("simulated annealing")

3 – Méthodes avec introduction d'un potentiel de perturbation

- Conformational Flooding
- Meta-dynamique
- Swarm-MD
- Umbrella sampling

ISM9 – POSITION DU PROBLÈME

En modélisation moléculaire, les potentiels d'interaction microscopique (champs de force) ne dépendent que des positions des atomes/particules. En conséquence, la fonction de partition des vitesses peut être 'découplée' de celle des positions

$$Z \propto Zp \times \iiint_V \exp(-\frac{U\left(\{\vec{r}_i\}\right)}{k_B T}) \Pi_{i=1}^{N} d\vec{r}_i$$

$$Zp = \iiint_V \Pi_{i=1}^{N} \exp(-\frac{m_i v_i^2}{2k_B T})\, d\vec{v}_i$$

Autrement dit, la distribution des probabilités d'observer un jeu de vitesses obéit à une loi gaussienne, ce qui implique que des vitesses très élevées même à faible température sont possibles, mais leur probabilité est très faible.

Rappel : les vitesses des particules d'un système microscopique permet de définir la température macroscopique de ce système

$$N_{df} k_B T = \bar{K} \quad \text{et} \quad K = \frac{1}{2}\sum_{i=1}^{N} m_i v_i^2$$

ISM9 – POSITION DU PROBLÈME

La distribution des probabailités des vitesses suit une loi gaussienne :

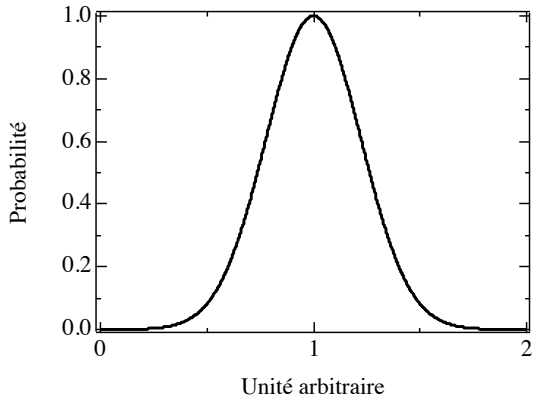

$$P_T\left(\vec{v}_i\right) = \exp\left(-\frac{m_i v_i^2}{2k_B T}\right)$$

Dès lors, il n'est pas impossible pour un système microscopique de passer des barrières d'énergie élevées lors d'une dynamique moléculaire, mais plus la barrière est élevée plus la probabilité est faible, particulièrement si la simulation est de courte durée. Pourtant, deux minima de la surface d'énergie potentielle de poids statistiques identiques peuvent être séparés par une barrière très élevée ➔ une simulation de dynamique moléculaire amènera donc à un calcul de la fonction *Z* erroné si le système ne peut passer d'un minima à l'autre.

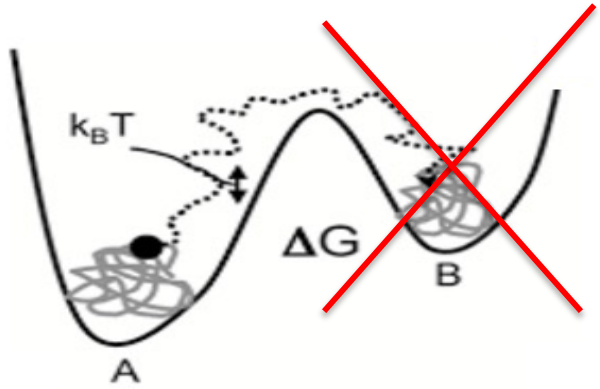

ISM9 – PASSER DES BARRIÈRES EN JOUANT SUR LES EFFETS CHAOTIQUES

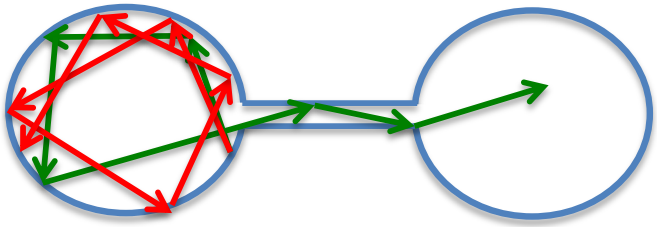

Etat A Etat B

Soit un système microscopique initialement dans une structure notée S, le protocole suivant

1 – *M* trajectoires indépendantes du système sont lancées en parallèle à partir de sa structure S

2 – Si une transition S ➔ S' est observée le long d'un seule trajectoire : arrêt de toutes les trajectoires.

3 – *M* nouvelles trajectoires sont relancées en considérant comme structure initiale la nouvelle structure S'…

Cette approche permet de réduire par un facteur *M* le temps moyen $\overline{t}_1$ obtenu à l'aide d'une seule simulation pour observer la transition structurale S → S' pour un système à deux états

$$\overline{t}_M = \frac{1}{M}\overline{t}_1$$

A.F. Voter, Phys. Rev. B, 57 (1998) 13985

ISM9 – LE PROJET FOLDING@HOME

Folding@home : des particuliers mettent à disposition leurs ordinateurs pour réaliser des jeux de simulations à très grande échelle.

Etude théorique du repliement de la protéine BBA5 (repliement de protéine : problème NP-hard)

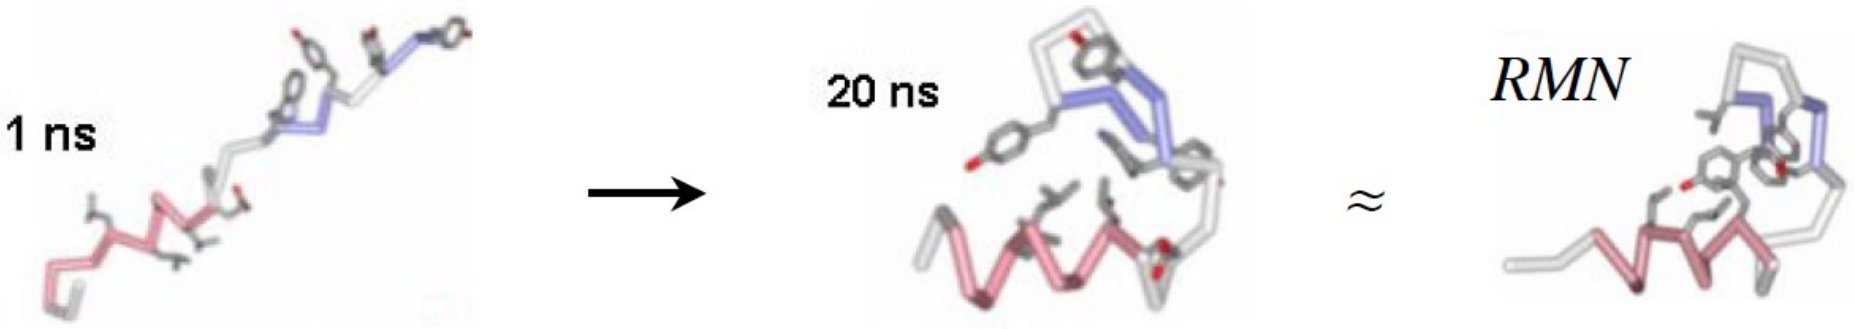

30 000 simulations de 20 ns réalisées, 100 repliements effectifs observés,
temps caractéristique de repliement 7,5 µs à comparer au 6,0 µs expérimental

Snow et al, *Nature*, 420 (2002) 102

ISM9 – RECUIT SIMULÉ

L'objectif est de générer un grand nombre de structure pouvant avoir un poids statistique significatif dans la fonction de partition du système.

Le principe est de « chauffer » le système à haute température, ce qui lui permet de passer facilement les barrières d'énergie. Un fois la simulation réalisée, on considère des structures le long de celle-ci (avec leurs vitesses) et on applique un coefficient de friction aux équations du mouvement pour pour ramener le système à T = 0 K.

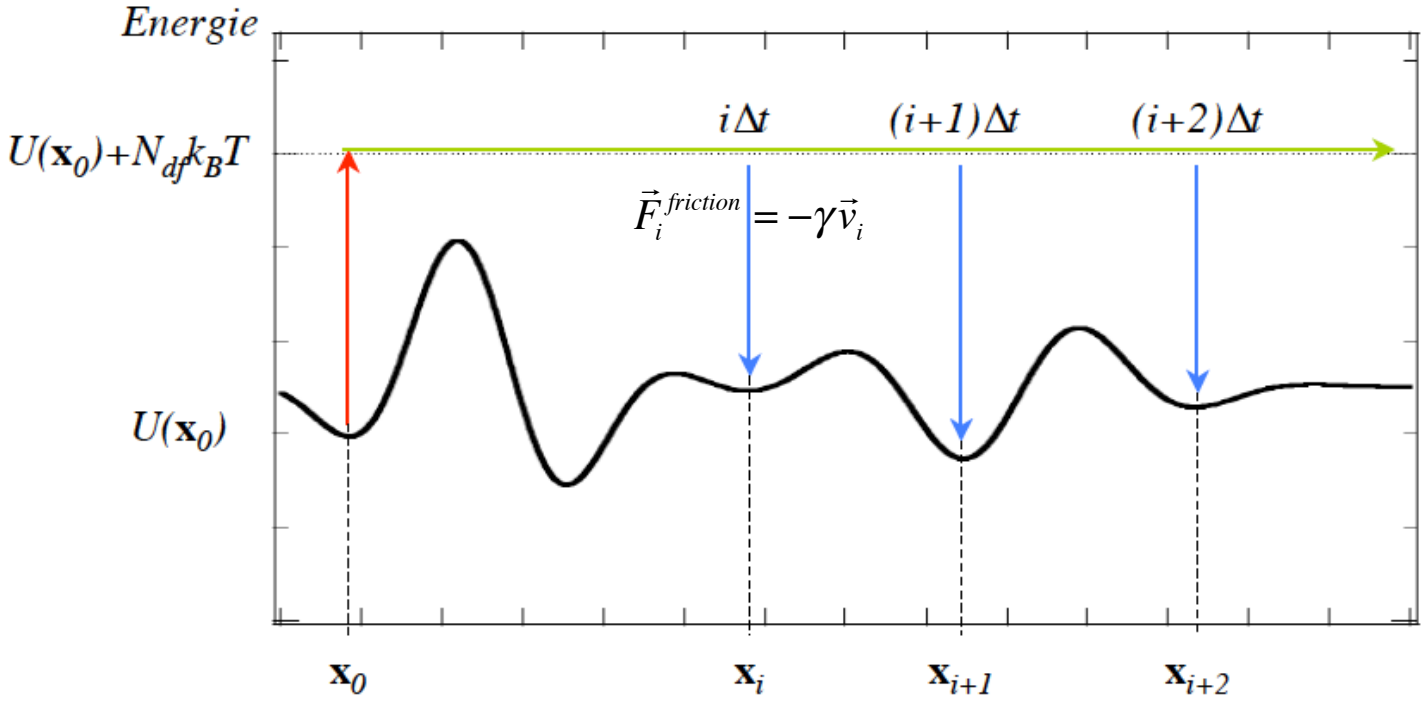

L'énergie cinétique du système est $\overline{K} = N_{df}k_BT$

Kirkpatrick et al, *Science*, 220 (1983) 671

ISM9 – REPLICA EXCHANGE AVEC COUPLAGE EN TEMPÉRATURE

La méthode de recuit simulé peut être considérée comme la couplage entre deux simulations à une température élevée *T* et à 0 K. Mais la distribution obtenue à *T* = 0 K ne permet pas de calculer directement la fonction de partition du système.

En considérant le critère de Métropolis suivant $\text{avec } 0 \le \xi_{random} \le 1$:

$$\mathrm{P}_{n-1\to n}\left\langle \vec{X}_n \middle| \vec{X}_{n-1} \right\rangle = \exp\left(-\left(\frac{1}{k_B T_n} - \frac{1}{k_B T_{n-1}} \right)\left(U_n(\vec{X}_n) - U_{n-1}(\vec{X}_{n-1}) \right) \right) < \xi_{random}$$

Il est possible de coupler un jeux de *M* simulations réalisées à différentes températures $\{T_i\}_{1\le i\le M}$ d'un même système, et générer alors des distributions de structures de ce système permettant de calculer la fonction de partition à chaque température T_i.

Périodiquement, les énergies potentielles U_i et U_j de deux trajectoires sont comparées. Si le critère de Métropolis est vérifié, les structures sont échangées entre les deux trajectoires. Une « trajectoire » ne correspond plus alors à un phénomène dynamique continu, mais contient des successions de structures localement échantillonnées.

Sugita and Okamata, *Chem. Phys. Lett.* , 314 (1999) 121

ISM9 – REPLICA EXCHANGE : CAS D'UN DIPEPTIDE

Peptides-protéines : polymères d'acides aminés

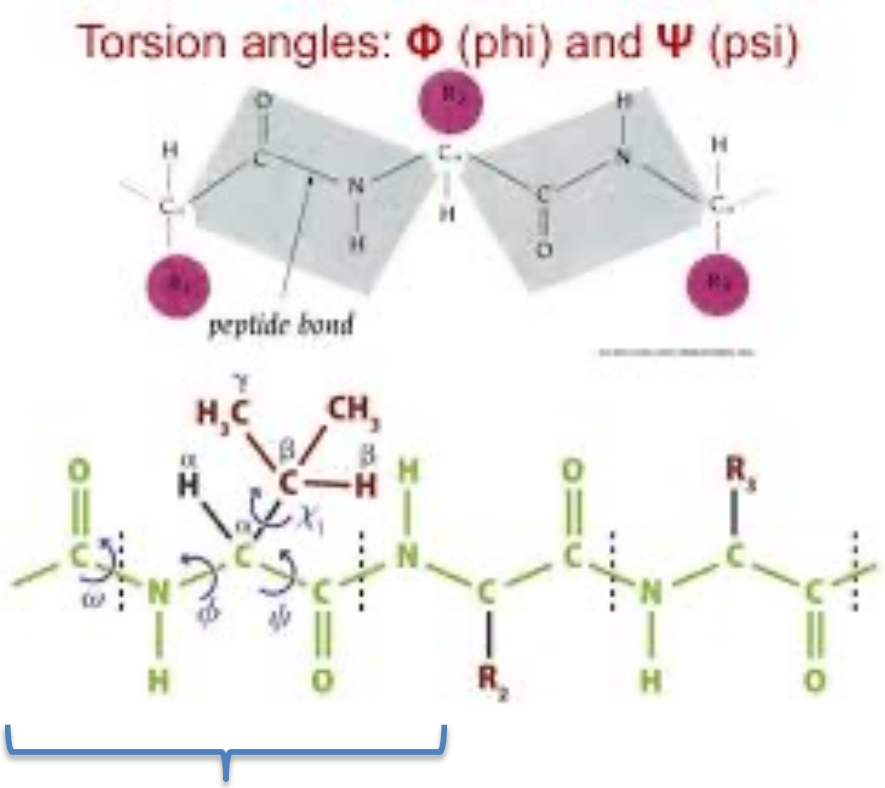

dipeptide

Contour d'énergie φ, ψ

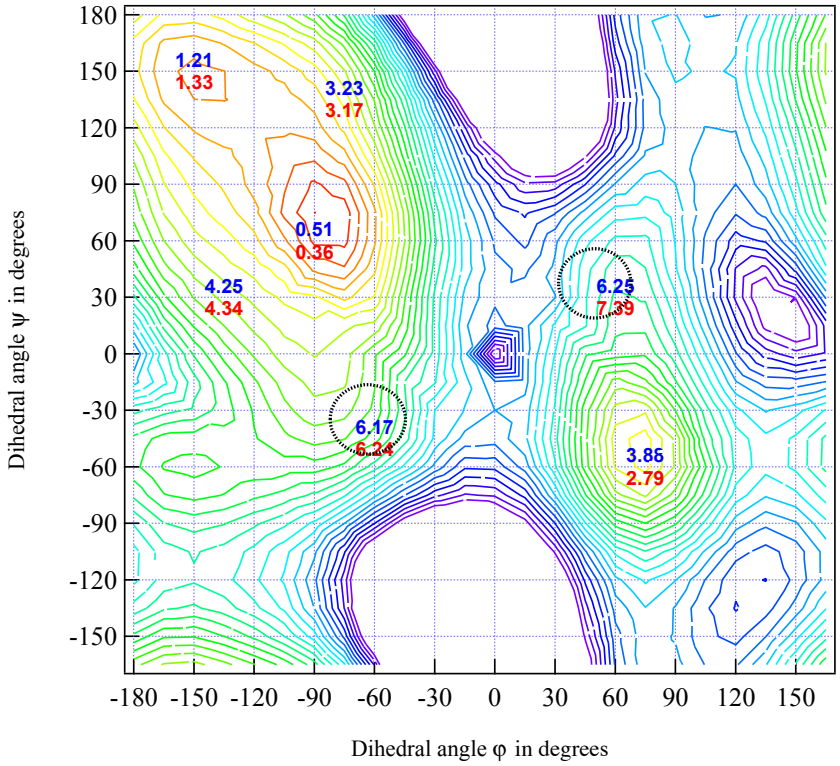

Cas du dipeptide alanine

ISM9 – REPLICA EXCHANGE AVEC COUPLAGE EN TEMPÉRATURE

Exemple : dipeptide gly-gly, températures simulées 200, 239, 286, 342, 409, 585 et 700 K. Simulation de 1 ns, transitions évaluées toutes les 10 fs.

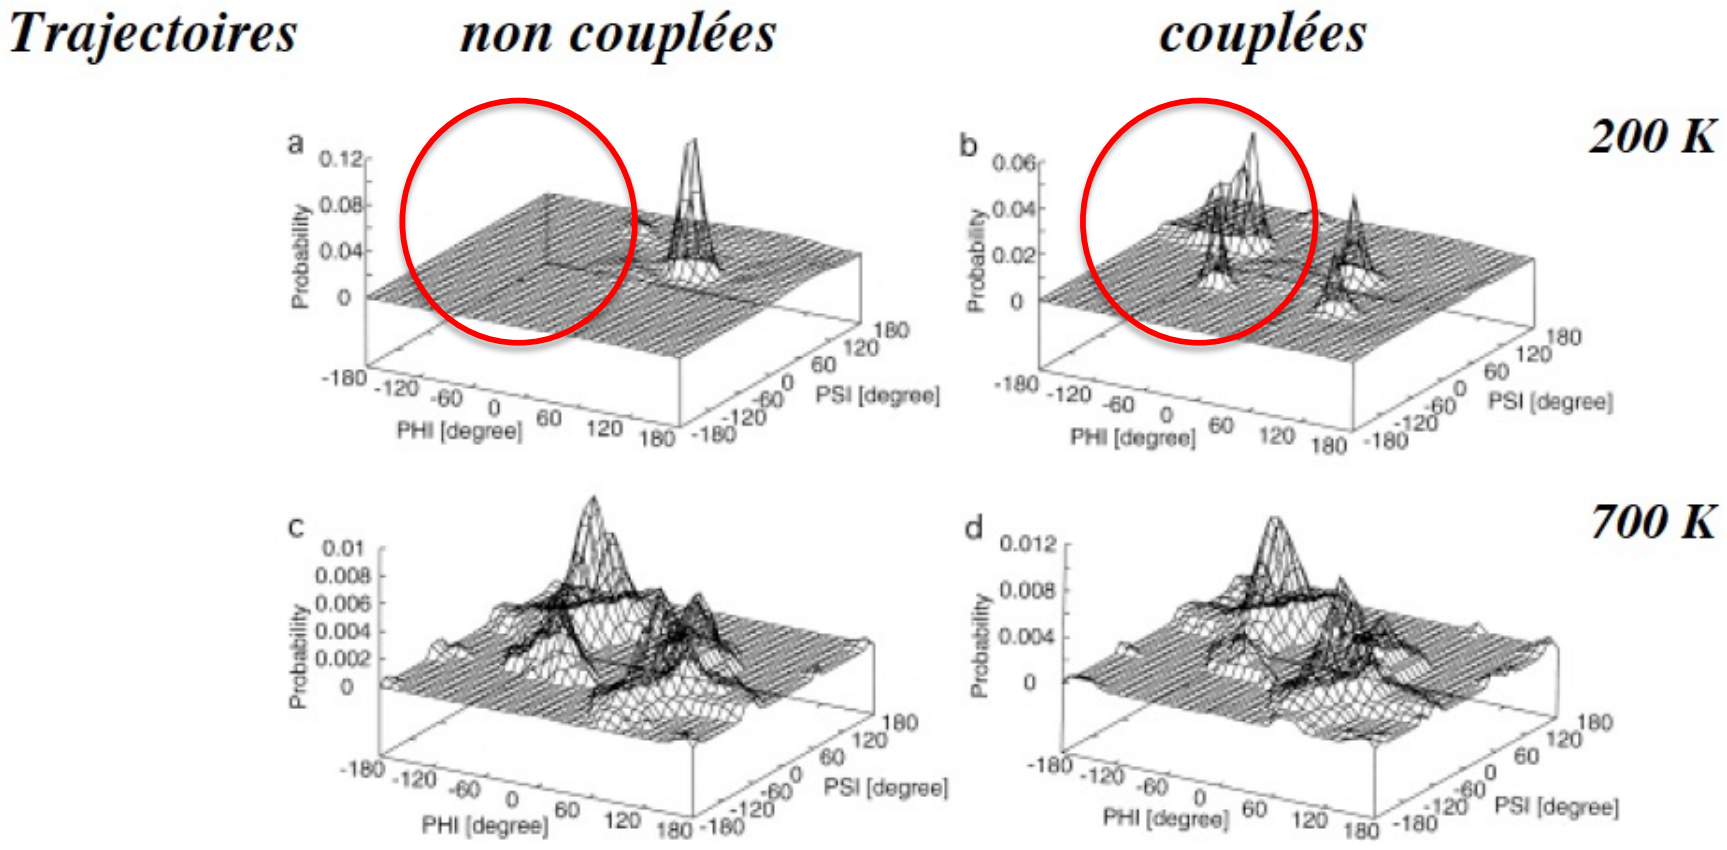

Difficulté : le champ de force est-il « transférable » à toutes les températures simulées ?

Sugita and Okamata, *Chem. Phys. Lett.* , 314 (1999) 121

ISM9 – TRANSFÉRABILITÉ D'UN CHAMP DE FORCE EN TEMPÉRATURE ?

Cas de champs de force qui simulent l'eau liquide correctement à 300 K (26,5 ° C) mais à aucune autre température… C'est le cas de tous les champs de force « efficaces » qui ne sont pas capables de reproduire la température du maximum de la densité de l'eau liquide.

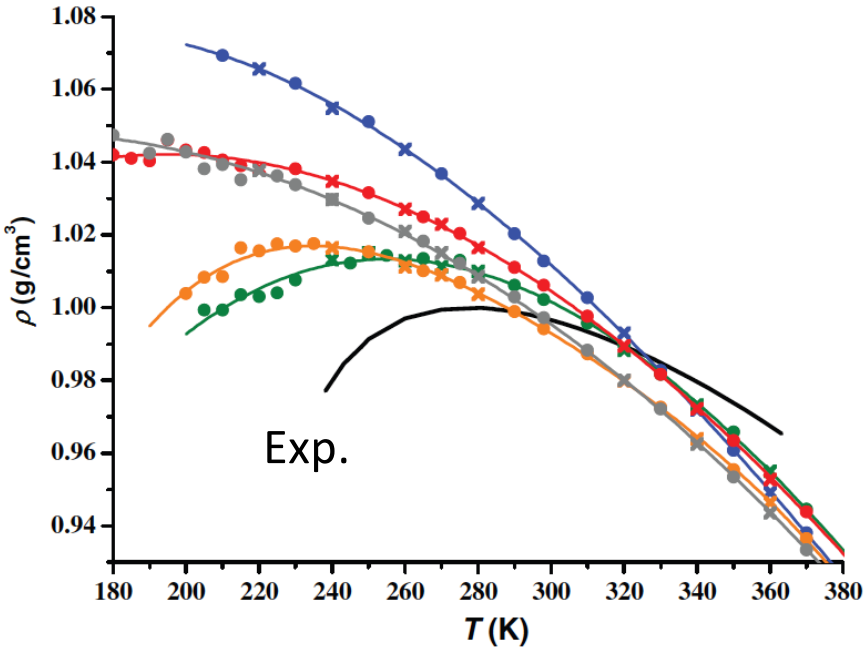

Model	TMD (K)	ρ_{TMD} (g/cm^3)
SPC	228	1.008
SPC/E	241	1.012
TIP3P	182	1.038

Kiss and Baranay, J Chem Phys, 137 (2012) 084506

Quid des quantités thermodynamiques à des températures différentes de *T* = 300 K ?

ISM9 – REPLICA EXCHANGE AVEC COUPLAGE D'HAMILTONIEN

Au lieu de simuler un même système à des températures différentes, le système sera simulé de multiples fois (*replica*) avec des Hamiltoniens (énergies totales) altérés :

Hamiltonien : $H = E_{tot} = U + K$

En fait on n'altère que la partie énergie potentielle du système, *i.e.* pour un champ de force classique :

$$U = U^{stretching} + U^{bending} + U^{torsion} + U^{Lennard-Jones} + U^{Coulomb}$$

Exemple : soit une molécule A plongée dans une boite contenant *N* molécules d'eau (système noté B), une manière d'altérer l'énergie *U* du système (A,B) pour explorer toutes les configurations possibles de A est de réécrire U sous la forme :

$$U = (U^{stretching} + U^{bending} + U^{torsion})(A + B) + U^{LJ}(A) + U^{LJ}(B) + U^{LJ}(A/B) + U^{C}(A) + U^{C}(B) + U^{C}(A/B)$$

ISM9 – REPLICA EXCHANGE AVEC COUPLAGE D'HAMILTONIEN

Chaque *replica* est associé à un Hamiltonien distinct (avec $0 \leq \lambda \leq 1$) :

$$U = (U^{stretching} + U^{bending} + U^{torsion})(A+B) + U^{LJ}(B)) + U^{C}(B) + \lambda[U^{LJ}(A) + U^{LJ}(A/B) + U^{C}(A) + U^{C}(A/B)]$$

qui tous peuvent être réécrits sous la forme plus compacte

$$U(\lambda) = U^{atomes_liés}(A+B) + U^{non_liés}(B) + \lambda\left[U^{non_liés}(A) + U^{non_liés}(A/B)\right]$$

Pratiquement, on génère *M* simulations correspondant chacune à un λ_n différent, le critère de Métropolis est alors

$$P_{n\to n+1}\left\langle \vec{X}_n \middle| \vec{X}_{n+1} \right\rangle = \exp\left(-\frac{1}{k_B T}\left(U_{n+1}\left(\vec{X}_n\right) - U_n\left(\vec{X}_{n+1}\right)\right)\right) \leq \zeta_{random}$$

http://www.chim.unifi.it/orac/MAN/node23.html

ISM9 – REPLICA EXCHANGE ET REPLIEMENT DE PROTÉINES

Les approches de type *Replica Exchange* suscitent de l'intérêt aujourd'hui pour traiter le problème du repliement des protéines à l'aide de processeurs CPU standards ou de GPUs.

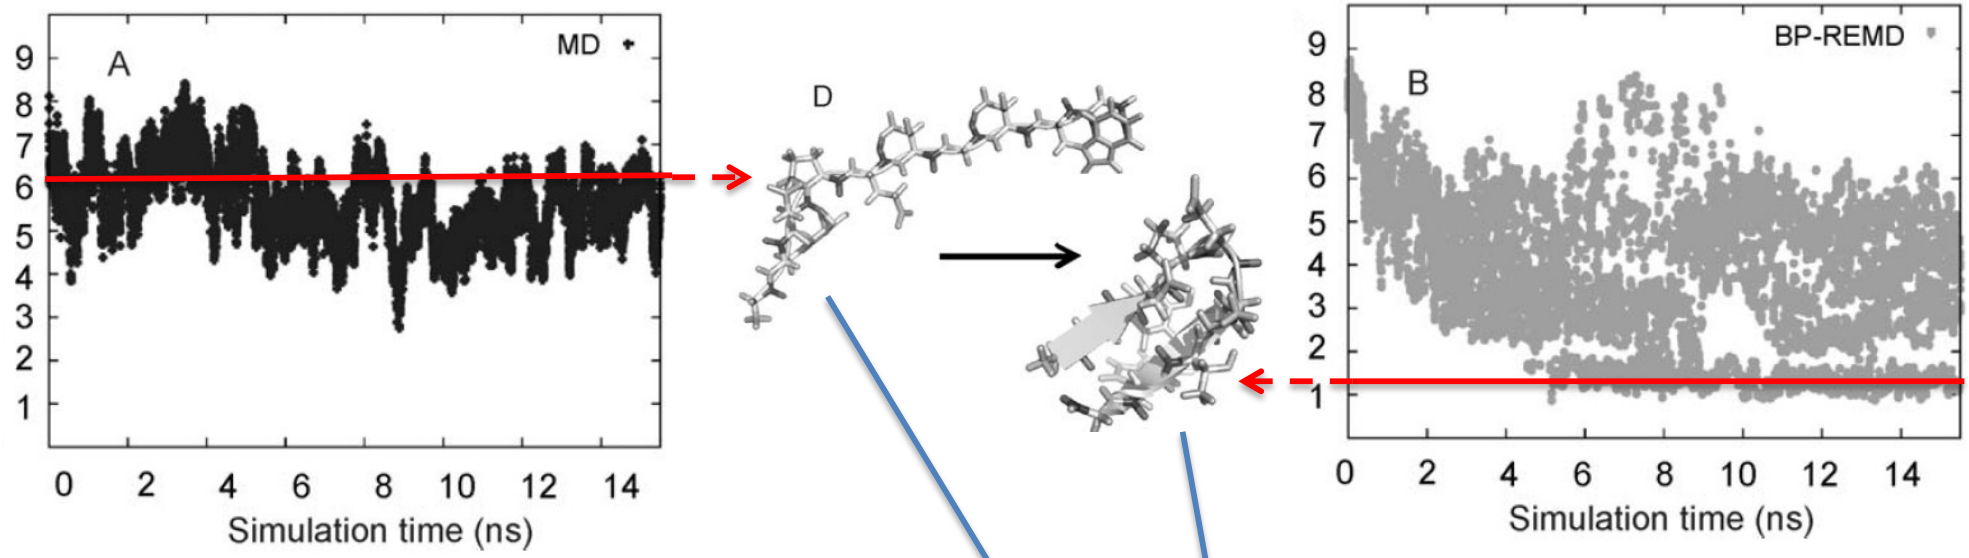

Une simulation unique

9 simulations couplées

$$RMSD(C_\alpha) = \sqrt{\frac{1}{n_\alpha}\sum_{i=1}^{n_\alpha}(\vec{R}_i - \vec{R}_i^{ref})^2}$$

Ostermeir and Zacharias, J Comput Chem, 35 (2014) 150

ISM9 – REPLICA EXCHANGE ET PARALLELISME

Replica Exchange est basé sur des simulations « faiblement » couplées. Dans ce cadre, une approche est d'évaluer les probabilités d'échange/faire les échanges de manière asynchrone (décalée).

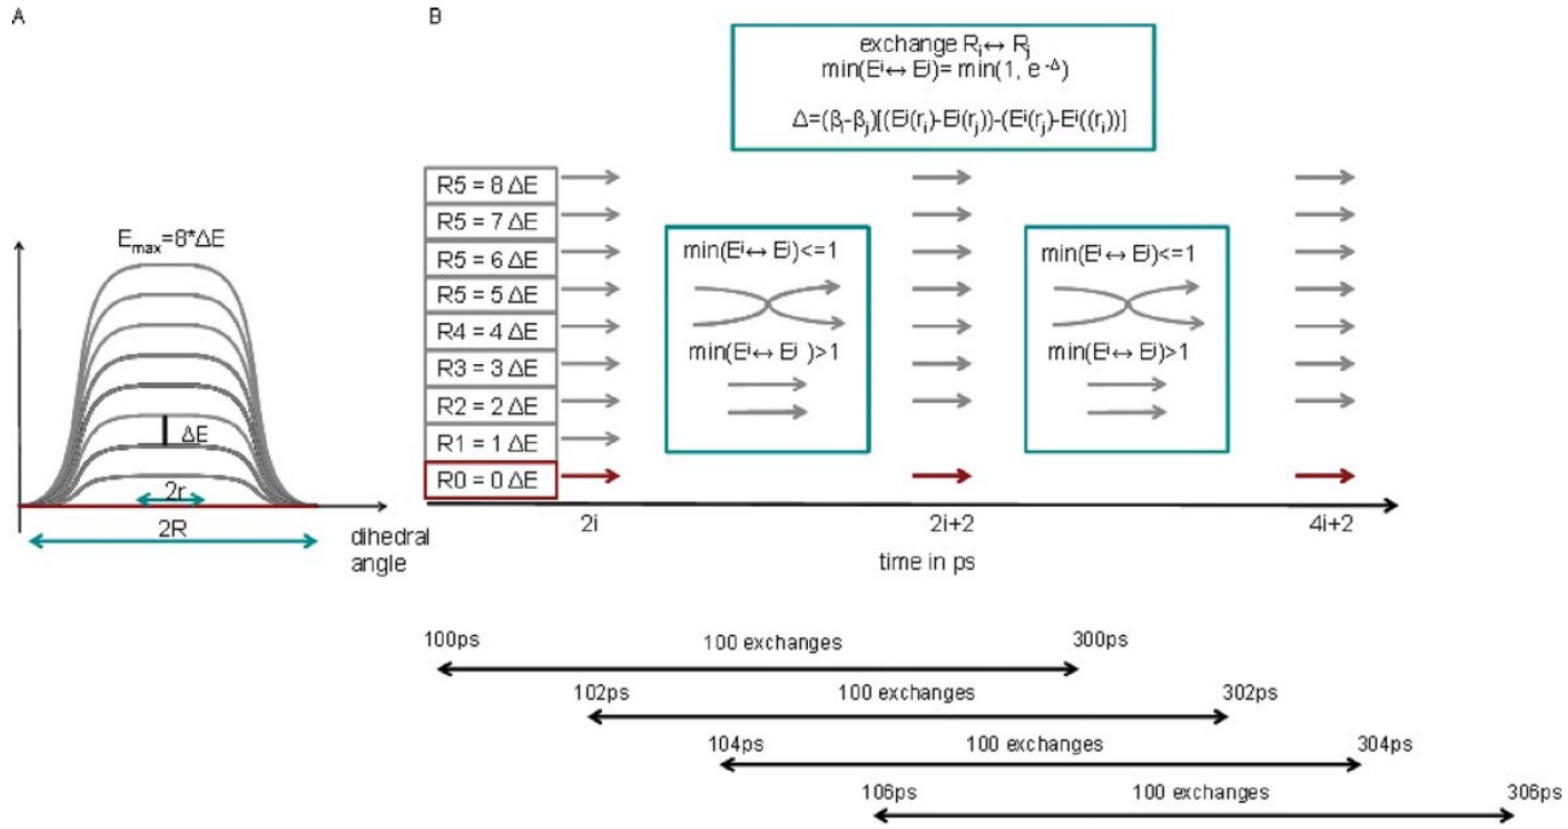

Ostermeir and Zacharias, J Comput Chem, 35 (2014) 150

ISM9 – MÉTHODES AVEC BIAIS : CONFORMATIONAL FLOODING

Le long d'une trajectoire, si un système est piégé dans un minimum, on considère le jeux de structures générées au voisinage de ce minimum $\left(\{\vec{r}_i\}_{1\le i\le N}^{k}\right)_{1\le k\le M}$. On peut alors calculer la matrice de covariance $C=\left\langle(\vec{r}_i-\langle\vec{r}_i\rangle)(\vec{r}_i-\langle\vec{r}_i\rangle)^T\right\rangle$ puis la diagonaliser et introduire alors une énergie potentielle dite de « *flooding* » :

$$U^{flooding}=\varepsilon_{flooding}\exp\left(-\frac{1}{2\gamma_{flooding}}\vec{c}\,\Lambda\vec{c}^{\,T}\right)$$

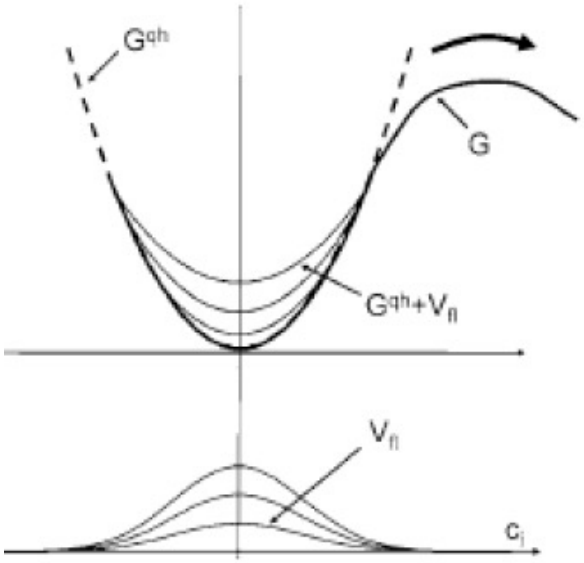

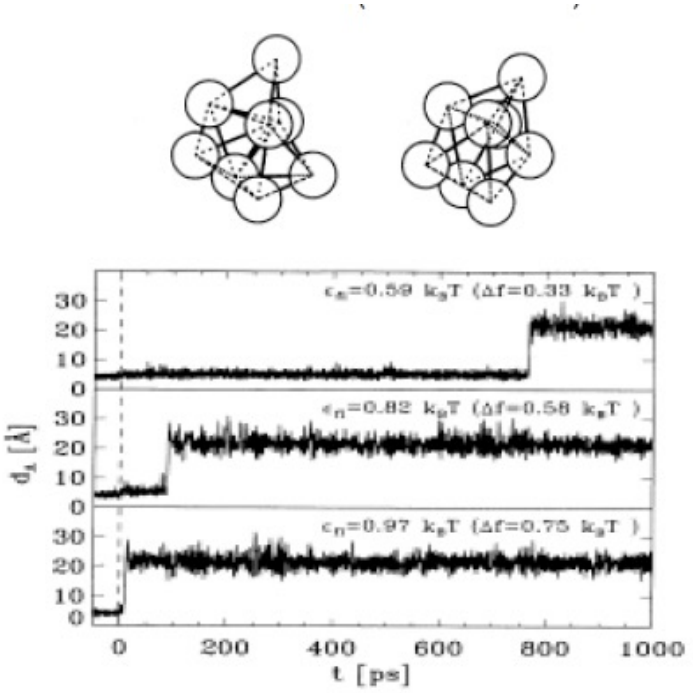

ISM9 – LA MÉTA-DYNAMIQUE

Le long d'une trajectoire, si un système est piégé dans un minimum, on considère le jeux de structures générées au voisinage de ce minimum $\left(\{\vec{r}_i\}_{1\le i\le N}^{k}\right)_{1\le k\le M}$. On peut alors calculer ~~la matrice de covariance $C=\left\langle\left(\vec{r}_i-\langle\vec{r}_i\rangle\right)\left(\vec{r}_i-\langle\vec{r}_i\rangle\right)^T\right\rangle$ puis la diagonaliser et introduire alors une énergie potentielle dite de *flooding* :~~ introduire une énergie potentielle « mémoire » du domaine exploré à des dates antérieures à une date t_{ref}

$$\underbrace{\tilde{U}(\{\vec{r}_i\})}_{\text{valable } t>t_{ref}} = \underbrace{U^{potentielle}(\{\vec{r}_i\})}_{\text{valable } \forall t} + \underbrace{U^{mémoire}(\{\vec{r}_i\})}_{\text{calculée à partir des coordonnées } \vec{r}_i\,(t<t_{ref})}$$

Toutes les *n* itérations de dynamique (i.e. tous les intervalles de temps Δt), on calcule un énergie de type « *flooding* ». A une date $t>M\Delta t$, le terme « mémoire » à ajouter aux termes classiques de l'énergie potentielle est

$$U^{mémoire}(\{\vec{r}_i\})(t>M\,\Delta t)=\varepsilon_{mémoire}\sum_{k=1}^{M}\exp\left(-\frac{1}{2}\vec{c}_k\Lambda_k\vec{c}_k^{\,T}\right)$$

Laio and Parrinello, Proc. Natl. Sci. (USA), 99 (2002) 12562

Effet du terme de mémoire sur un système à deux états *A* et *B* :

$$U^{mémoire}(\{\vec{r}_i\})(t > M\,\Delta t) = \varepsilon_{mémoire} \sum_{k=1}^{M} \exp\left(-\frac{1}{2}\vec{c}_k \Lambda_k \vec{c}_k^{\,T}\right)$$

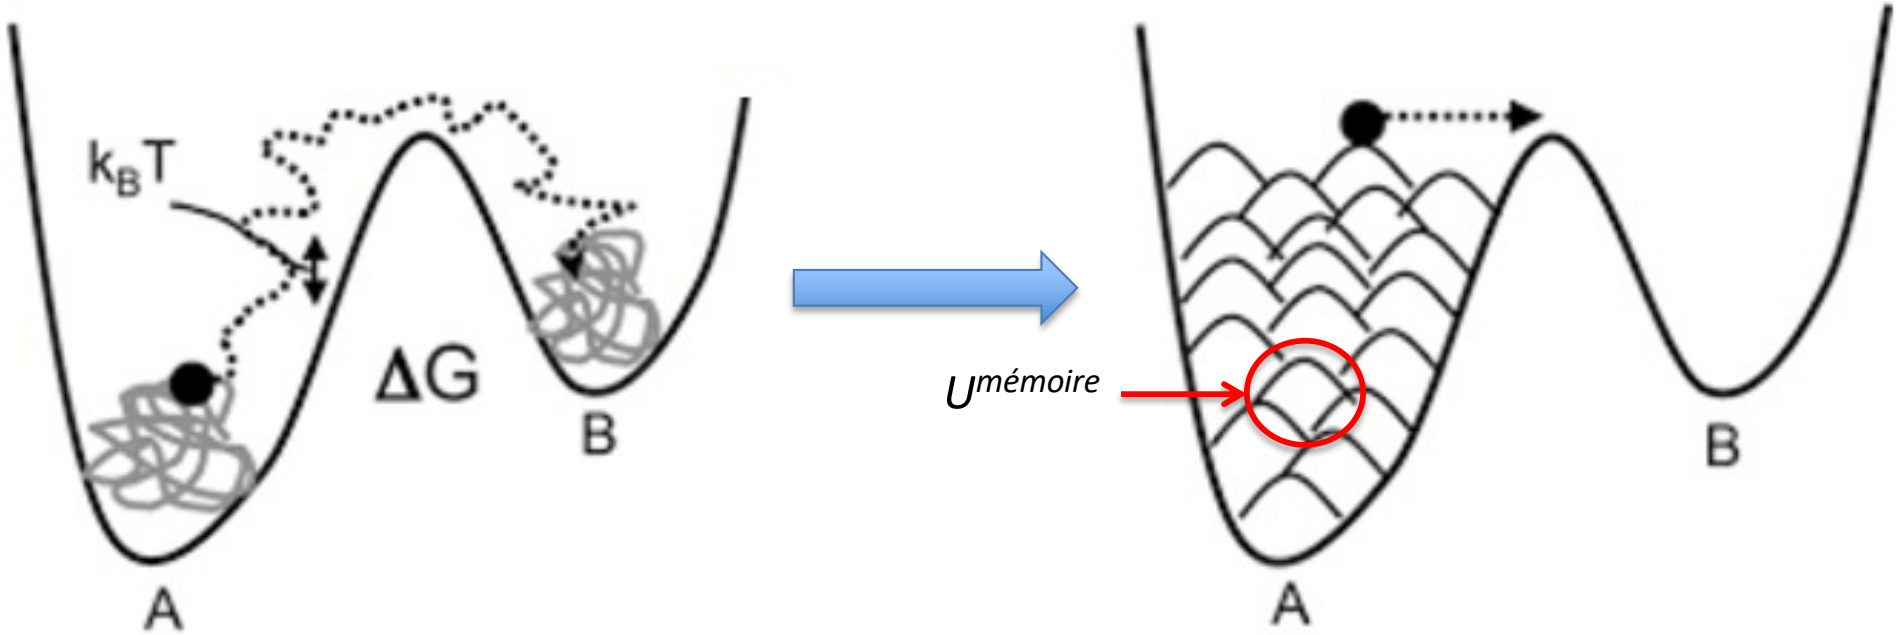

Sans terme de mémoire

Avec le terme de mémoire

Comme pour le « *conformational flooding* », cette méthode ne considère qu'une simulation unique, ce qui ne permet pas de tirer profit d'architectures de calcul parallèle. Par contre cette méthode donne accès à la différence d'énergie libre entre les deux états A et B par exemple.

ISM9 – SWARM-MD

Méthode trivialement parallélisable permettant un meilleur échantillonnage d'une surface d'énergie potentielle que la méthode de recuit simulée et se fondant également sur des termes d'énergie « mémoire ».

Prenons le cas d'une longue molécule de type polymère dont le squelette est caractérisé par N_Φ angles dièdres caractéristiques $\{\Phi_k\}_{1\le k\le N_\Phi}$ Le long de *M* simulations indépendantes, les valeurs moyennes de ces angles sont calculées, puis on construit le potentiel « mémoire »

$$U^{mémoire}(\{\Phi_k\}) = \varepsilon_{mémoire} \sum_{k=1}^{N_\Phi} \sum_{i=1}^{M} \exp\left(-\frac{(\Phi_k^i - \bar{\Phi}_k^i)^2}{\gamma_k} \right)$$

On relance alors *M* simulations avec ce potentiel. Comme dans le cas du « *conformational flooding* » et de la « méta-dynamique », cette approche permet une meilleure exploration des minima locaux du système microscopique considéré mais à l'aide de simulations faiblement couplées. Par contre cette méthode, comme la méthode recuit simulé, ne donne pas accès directement à des grandeurs thermodynamiques.

ISM9 – SWARM-MD

Exemple de la chaine carbonée CH_3-$(CH2)_{48}$-CH_3, 50 simulations indépendantes de 100 ps par recuit simulé ou couplées par l'approche SWARM-MD.

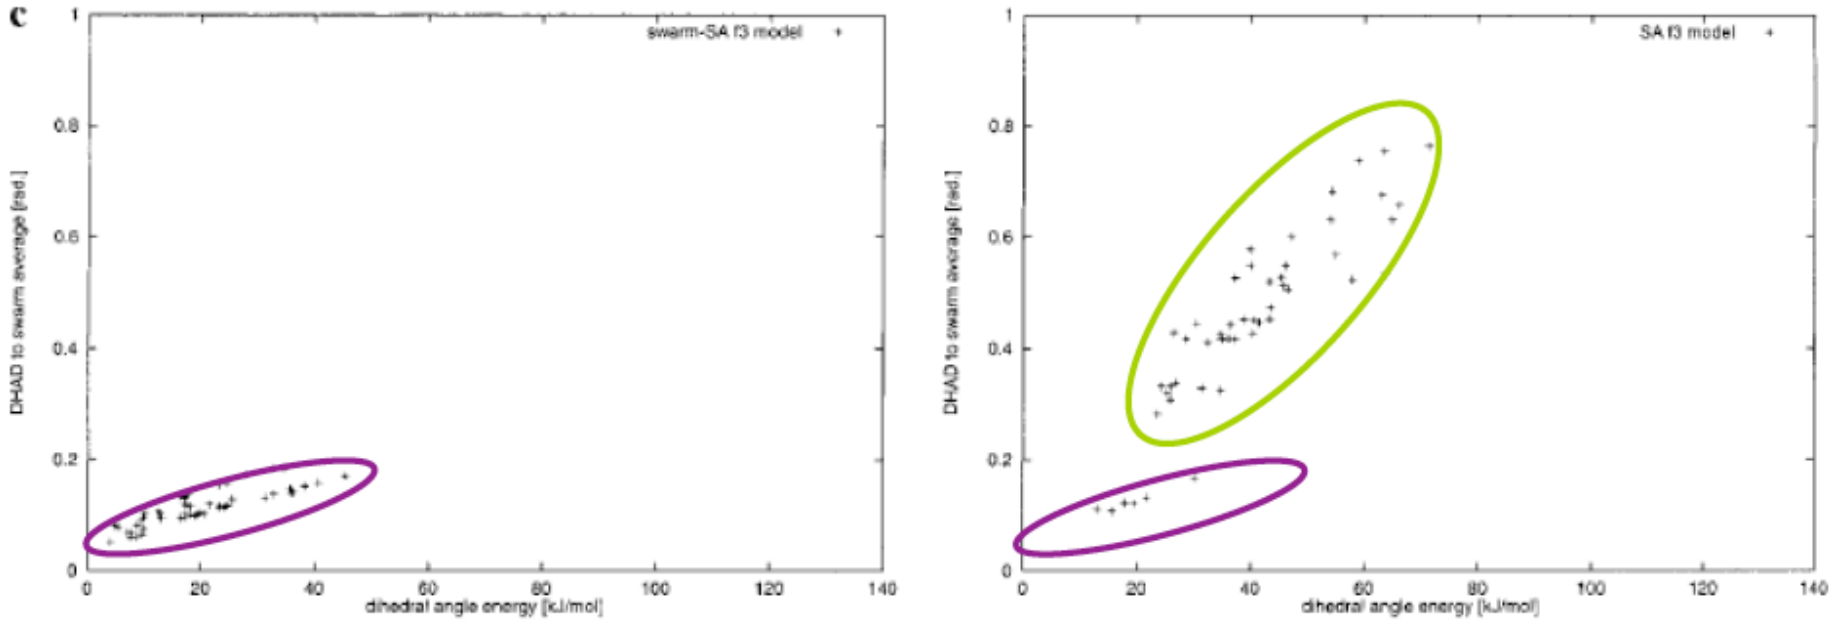

Recuit simulé SWARM-MD

DHAD : écart type moyen des angles dièdres pour les jeux de conformations obtenus par les deux méthodes (les angles dièdres de référence sont ceux de la conformation d'énergie minimum pour chacune des deux méthodes).

Huber and van Gunsteren, J. Phys. Chem A., 102 (1998) 5937

ISM9 – UMBRELLA SAMPLING

L'objectif est ici de forcer le système à explorer des zones prédéfinies, en particulier des zones de la surface d'énergie potentielle où un système microscopique à une faible probabilité de se trouver.

A la différence des méthodes de « *replica exchange* », « *conformational flooding* » et méta-dynamique, il faut connaître a priori les zones à explorer. Prenons l'exemple de deux ions plongés dans une boîte d'eau. L'objectif est d'évaluer leur potentiel d'interaction effectif *A(r)* (le potentiel apparent d'interaction des deux ions, où le rôle du solvant est implicitement pris en compte) :

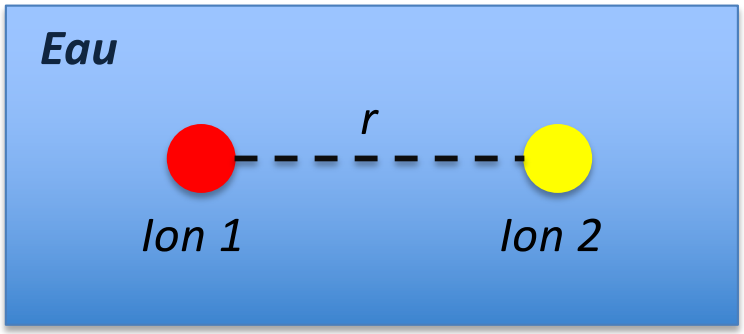

$$P(r) = \exp\left(-\frac{A(r)}{k_B T}\right)$$

A(r) tient compte de l'intégrant $\propto r^2$

Pour cela, *M* simulations indépendantes de ce système sont réalisées en ajoutant à son énergie potentielle un terme de contrainte pour chaque simulation *k* :

$$U_k^{umbrella} = k_{umbrella}\left(r - r_k^{ref}\right)^2 \quad \text{avec} \quad r_{\min} \le r_k^{ref} \le r_{\max}$$

ISM9 – UMBRELLA SAMPLING

La seule difficulté de cette approche, qui permet de tirer trivialement parti d'architectures de calcul parallèle et la phase d'analyse post-simulation où l'effet de la fonction de contrainte est corrigé.

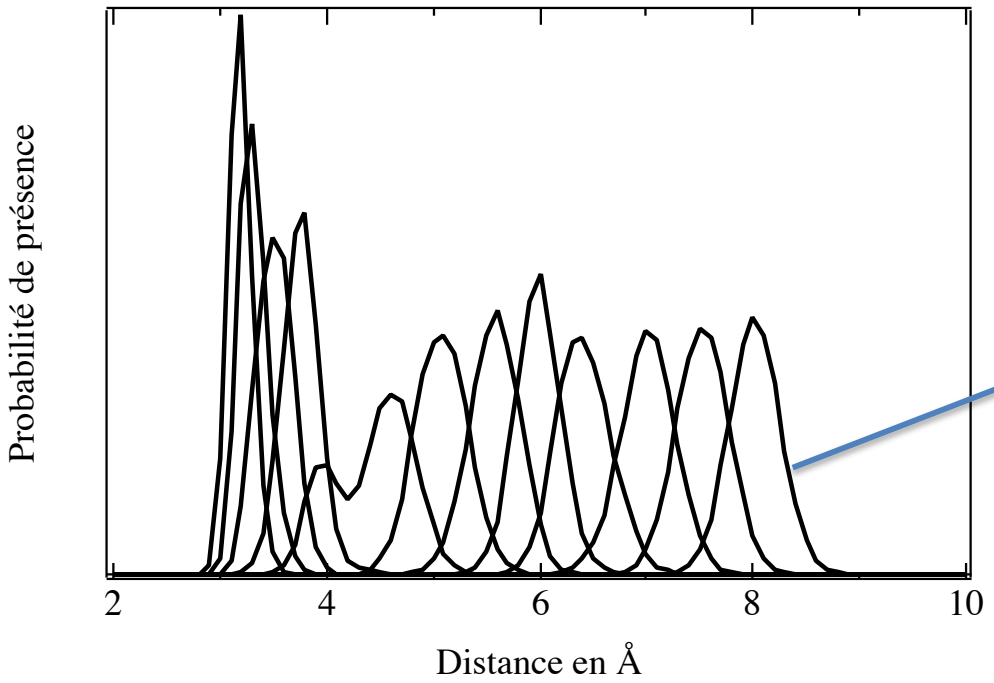

Ici, les probabilités que les deux ions précédents soient à une distance *r* sont représentées pour chaque simulation contrainte *k*.

Les probabilités sont calculées par une approche discrète (histogramme), i.e.

$$P_k^{biais}(r_l) = \frac{n_k(r_l - \delta r/2 \le r \le r_l + \delta r/2)}{N_k}$$

k : simulation correspondant à un r_k^{ref} donné

n_k : nombre de fois ou *r* est dans l'intervalle

N_k : nombre totale de structures sauvegardées le long de la simulation considérée

Les distances *r* sont échantillonnées suivant $r_l = l\delta r$

Par définition, le potentiel effectif de chaque simulation biaisée est :

$$A_k^{biais}(r) = -\frac{1}{k_B T}\ln\left(P_k^{biais}(r)\right)$$

ISM9 – UMBRELLA SAMPLING – MÉTHODE WHAM

L'objectif est donc de calculer la probabilité $P(r)$ que les deux ions soient à une distance *r* sans appliquer de contrainte, en regroupant les résultats de toutes les simulations contraintes *k.* En particulier, la probabilité globale précédente s'exprime en fonction des résultats de chaque simulation contrainte sous la forme :

$$P(r) = \frac{1}{Z_k} \exp\left(-\frac{A_k^{biais}(r) - U_k^{umbrella}(r)}{k_B T} \right) = \exp\left(-\frac{A_k^{biais}(r) - U_k^{umbrella}(r) - F_k}{k_B T} \right) \quad \forall \mathrm{k} \in \{1, M\}$$

Les F_k , énergies libres de la simulation *k*, sont des constantes qu'il faut évaluer afin que la fonction *P(r)* soit indépendante de la simulation considérée (autrement dit « continue ») ➔ approche WHAM (« Weighted Histogram Analysis Method »)

$$\mathrm{P}(r) = \frac{\sum_{k=1}^{M} n_k(r)}{\sum_{k=1}^{M} N_k \exp\left(-\frac{1}{k_B T}\left(F_k - U_k^{umbrella}(r) \right) \right)} \quad \text{et} \quad \exp\left(-\frac{F_k}{k_B T} \right) = \left[\sum_{l=1}^{L} P(r_l) \exp\left(-\frac{U_k^{umbrella}(r_l)}{k_B T} \right) \right]$$

Ici les r_l sont les valeurs discrètes de *r* définissant les histogrammes du slide précédent. Les deux équations couplées précédentes sont résolues de manière itérative.

ISM9 – UMBRELLA SAMPLING – UMBRELLA INTEGRATION

En remarquant que les termes F_k de chaque trajectoire sont constants, une astuce est de considérer les dérivées par rapport à *r* des différentes fonctions de l'expression :

$$P_k(r) = \frac{1}{Z_k}\exp\left(-\frac{A(r)+U_k^{umbrella}(r)}{k_BT}\right) \quad \text{avec} \quad \begin{cases} A_k^{biais}(r) = A(r)+U_k^{umbrella}(r) \\ Z_k = \exp\left(-\frac{F_k}{k_BT}\right) \text{ avec } Z_k \text{ et } F_k \text{ constants} \end{cases}$$

Autrement dit, il est possible d'écrire la dérivée de la fonction *A(r)* recherchée sur la base des résultats de chaque simulation en tout point *r (*qui a été échantillonné) *:*

$$\frac{\partial A(r)}{\partial r} = -\sum_{k=1}^{M}\frac{n_k(r)}{N_{tot}(r)}k_BT\frac{\partial \ln\left(P_k(r)\right)}{\partial r} + \frac{\partial U_k^{umbrella}(r)}{\partial r} \quad \text{avec} \quad N_{tot}(r) = \sum_{k=1}^{M} n_k(r)$$

Les dérivées des fonctions $P_k(r)$ sont calculées numériquement aux points échantillonnés

$$\frac{\partial P_k(r_l)}{\partial r} \approx \frac{P_k(r_l+\delta r) - P_k(r_l-\delta r)}{2\delta r}$$

ISM9 – UMBRELLA SAMPLING

Résultat du post-traitement pour les deux ions

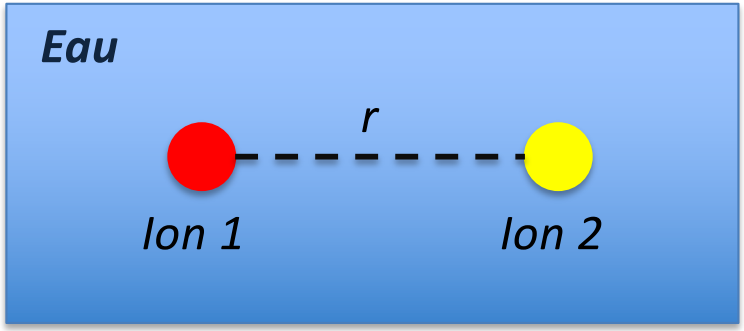

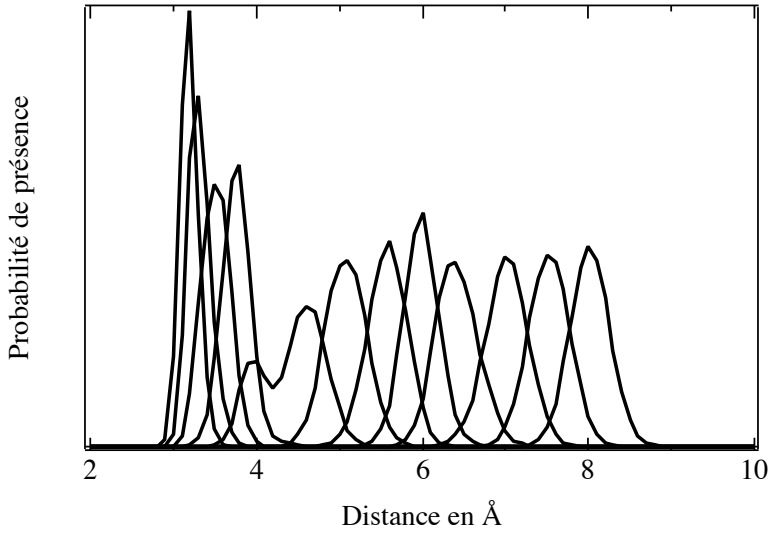

Probabilités biaisées $P_k^{biais}(r)$

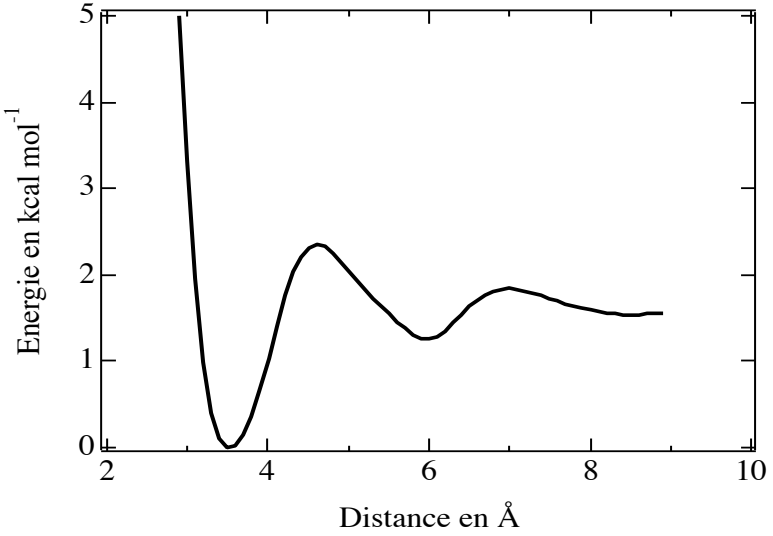

Potentiel sous-jacent : $A(r)+2k_BT\ln(r)$

I.16 Les effets chaotiques sont inhérents à la résolution des équations du mouvement. Sont-ils
Réponse : seulement négatifs, on peut en tirer profit, ils n'ont aucun effet sur les moyennes calculées le long d'une simulation de type dynamique moléculaire ?

I.17 Les effets chaotiques peuvent-ils être à l'origine de biais importants si l'on peut générer un nombre infini de simulations de courte durée ?
Réponse : oui, non ?

I.18 Quelle est la difficulté majeure lorsque l'on réalise une simulation moléculaire par dynamique moléculaire :
Réponse : le système microscopique évolue trop vite, difficulté à passer les barrières d'énergie entre deux minima, définir les conditions initiales, bien échantillonner localement la surface d'énergie potentielle du système moléculaire considéré ?

I.19 Quel est le point commun entre les méthodes de *conformational flooding* et *méta-dynamique* ?
Réponse à développer (maximum deux lignes)

ISM10 – Clustering, Machine Learning et Intelligence Artificielle

1 – Analyses de simulation par des algorithmes de clustering

2 – Machine Learning et optimization de champ de force

3 – Champs de Force IA ‘black box’

ISM10 : CLUSTERING , POSITION DU PROBLÈME

Simulation de la réaction d'association entre l'hydrazine (N_2H_4, un anti oxydant cancérigène mais très puissant) avec le dioxygène O_2 (un puissant oxydant)

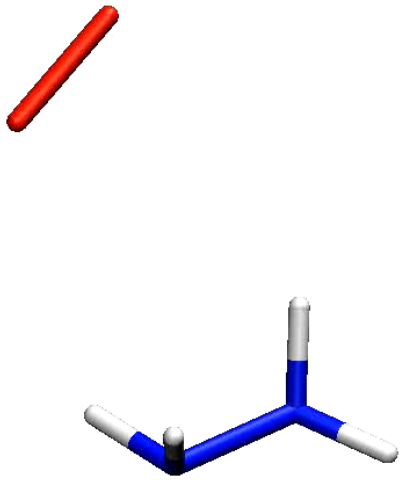

Simulation de 50 ns à 300 K dans l'eau, les molécules d'eau ne sont pas représentées

Objectif des simulations : identifier des structures N_2H_4/O2 pouvant amener au transfert d'un hydrogène de N_2H_4 vers O_2 => **cela signifie d'identifier des structures qui apparaissent régulièrement le long des simulations.**

ISM10 : ALGORITHME DE CLUSTERING : EXEMPLE K-MEAN

Leur objectif est d'identifier de manières autonomes et automatiques un nombre maximum de *k* clusters de structures « similaires ».

Soit une structure *S* (par exemple, la conformation d'un assemblage de molécules) définie par *M* paramètres géométriques $\{\omega_m\}_{m=1-M}$ (a priori des distances inter atomiques, des angles et des angles dièdres). Autrement dit *S* est un vecteur de dimension *M*.

La similarité de deux structures S_i et S_j se mesure à l'aide d'une métrique euclidienne :

$$d_{ij} = \sum_{m=1}^{M} \left(\omega_m^i - \omega_m^j\right)^2$$

Parmi toutes les *N* structures S_i on choisit *K* structures définissant les centres initiaux des clusters. Par exemple une structure S_α choisie aléatoirement définit le premier cluster, puis les *K*-1 autres clusters suivant par différentes approches basées sur les distances $d_{\alpha j}$.

On itère ensuite jusqu'à obtenir au plus *K* clusters « stables » $\{\Omega_k\}_{k\leq K}$:

$$\Omega_k = \left\{ S_l^k : \sum_{m=1}^{M} \left(\omega_m^l - \overline{\omega}_k\right)^2 \leq \sum_{m=1}^{M} \left(\omega_m^l - \overline{\omega}_h\right)^2 \ \forall h \in (1,K) \right\} \quad \text{et} \quad \overline{\omega}_k = \frac{1}{size(\Omega_k)} \sum_{l\in\Omega_k} \omega_m^l$$

ISM10 : ALGORITHME DE CLUSTERING : EXEMPLE K-MEAN

Recherche de deux clusters avec des structures à une dimension (des points) dans un plan à deux dimensions :

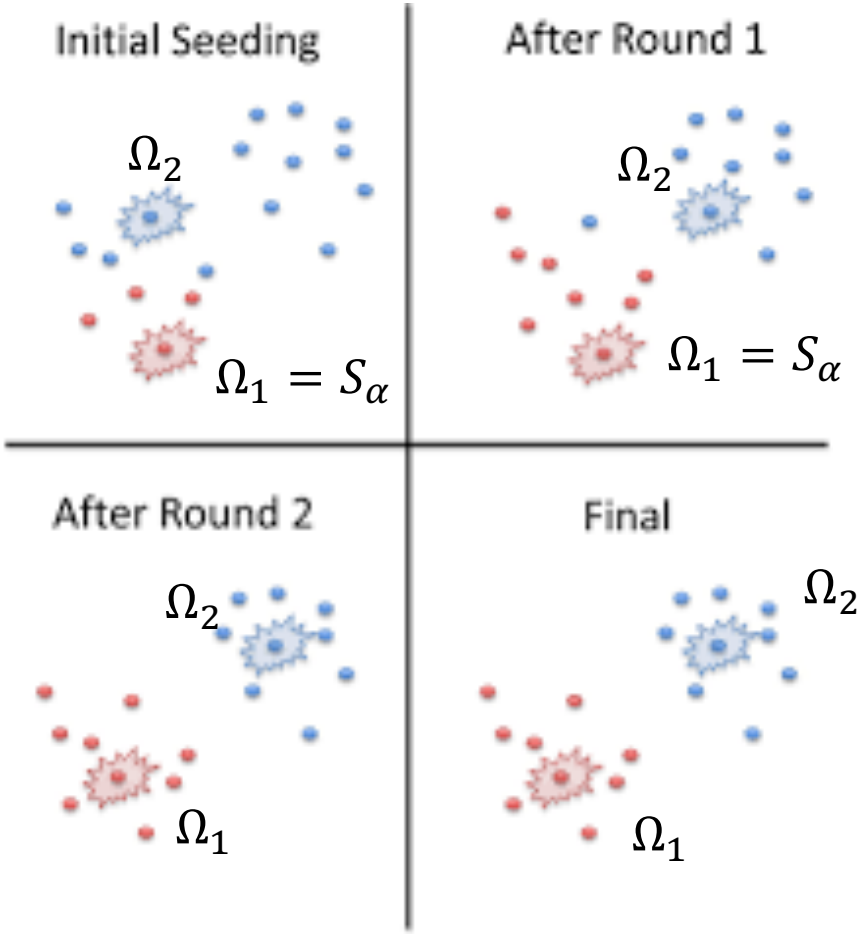

Figure from https://devopedia.org/k-means-clustering

ISM10 : DÉFINITION D'UNE 'MÉTRIQUE'

Par exemple, pour le cas N2H4/O2, une 'métrique' possible est de considérer :

1 - Les 2x4 distances R(H---O) qui peuvent être définie dans le complexe

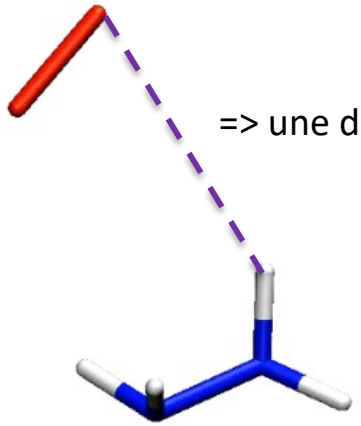

=> une des 8 distances R(N---H)

2 – L'angle Θ entre les axes NN et OO

La difficulté ici est l'indiscernabilité des 8 distances R(H---O), une manière de contourner le problème est de définir un vecteur *S* à 9 dimensions, dont les 8 premiers éléments sont les R(H---O) ordonnées par ordre croissant

=> L'identité des hydrogènes H et des oxygènes O n'a pas de signification d'un point de vue chimique, la 'structure' *S* (le vecteur) à neuf dimensions précédente prend en compte cet aspect.

ISM10 : CLUSTERS IDENTIFIÉS

A l'aide d'un algorithme de type K-mean et de des vecteurs *S*, 8 principaux clusters sont identifiés, les nombres correspondent à l'angle Θ et à la plus petite et plus grande des distances R(H---O)

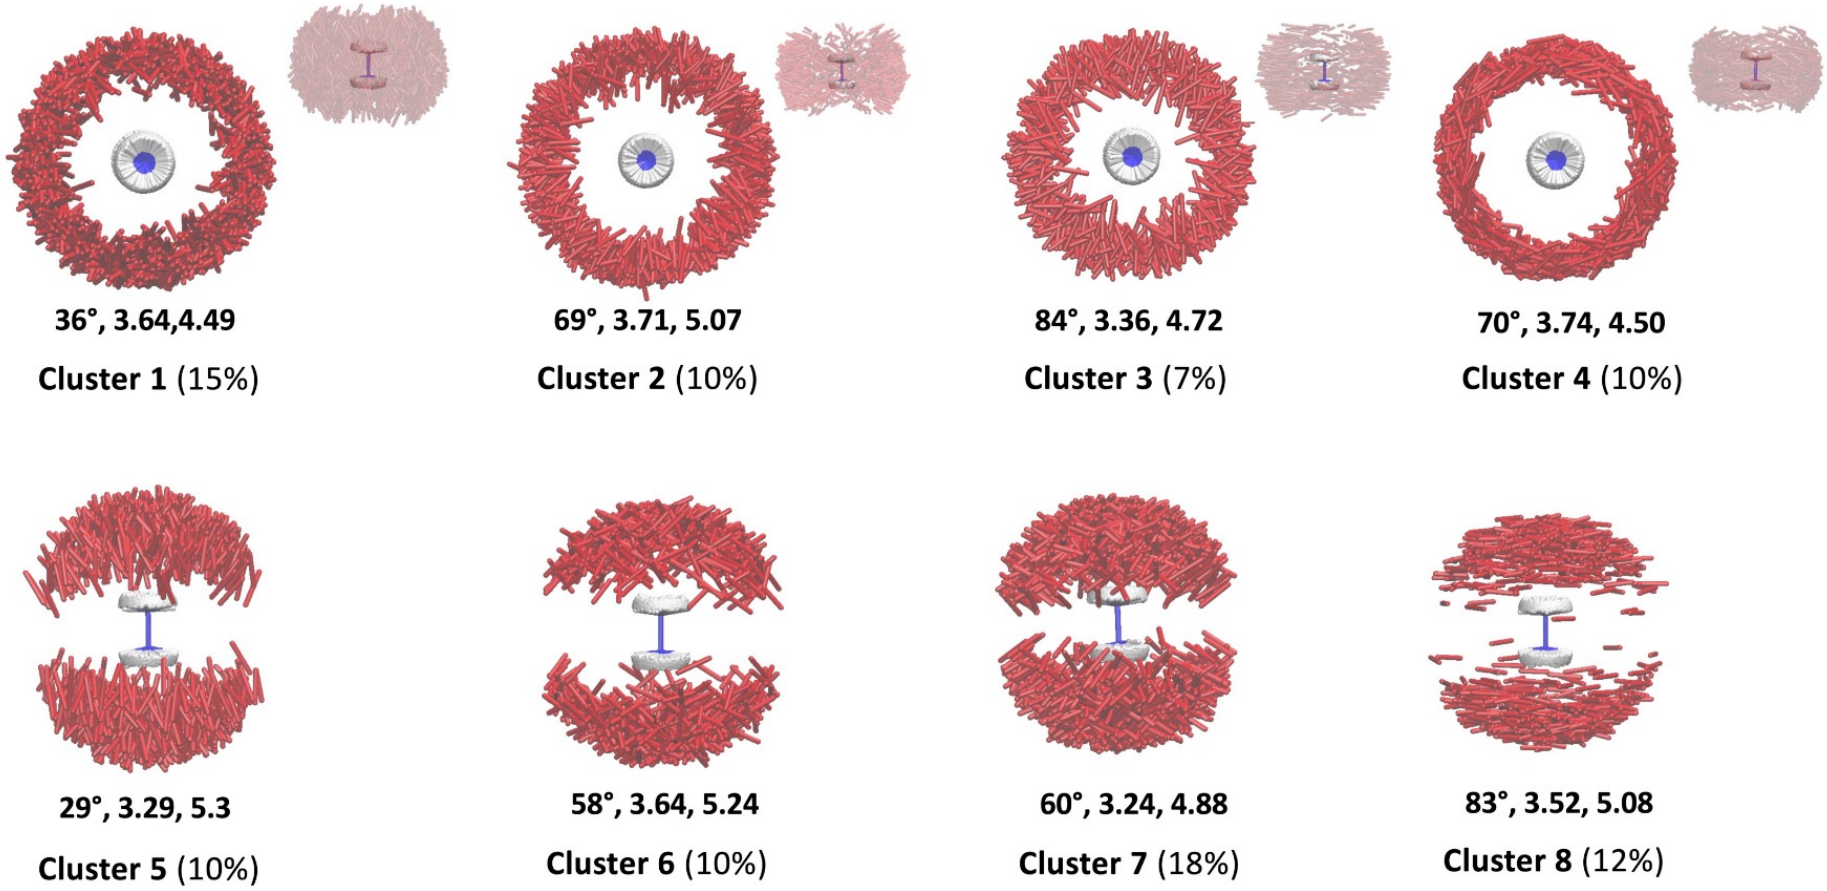

Figure issue de J Phys Chem A, 127 (2023) 10104

ISM10 : Clusters Identifies : Centres des Distributions

Les algorithmes de clustering permettent également d'identifier la conformation (géométrie) la plus représentative des différents clusters, par exemple pour N_2H_4/O_2

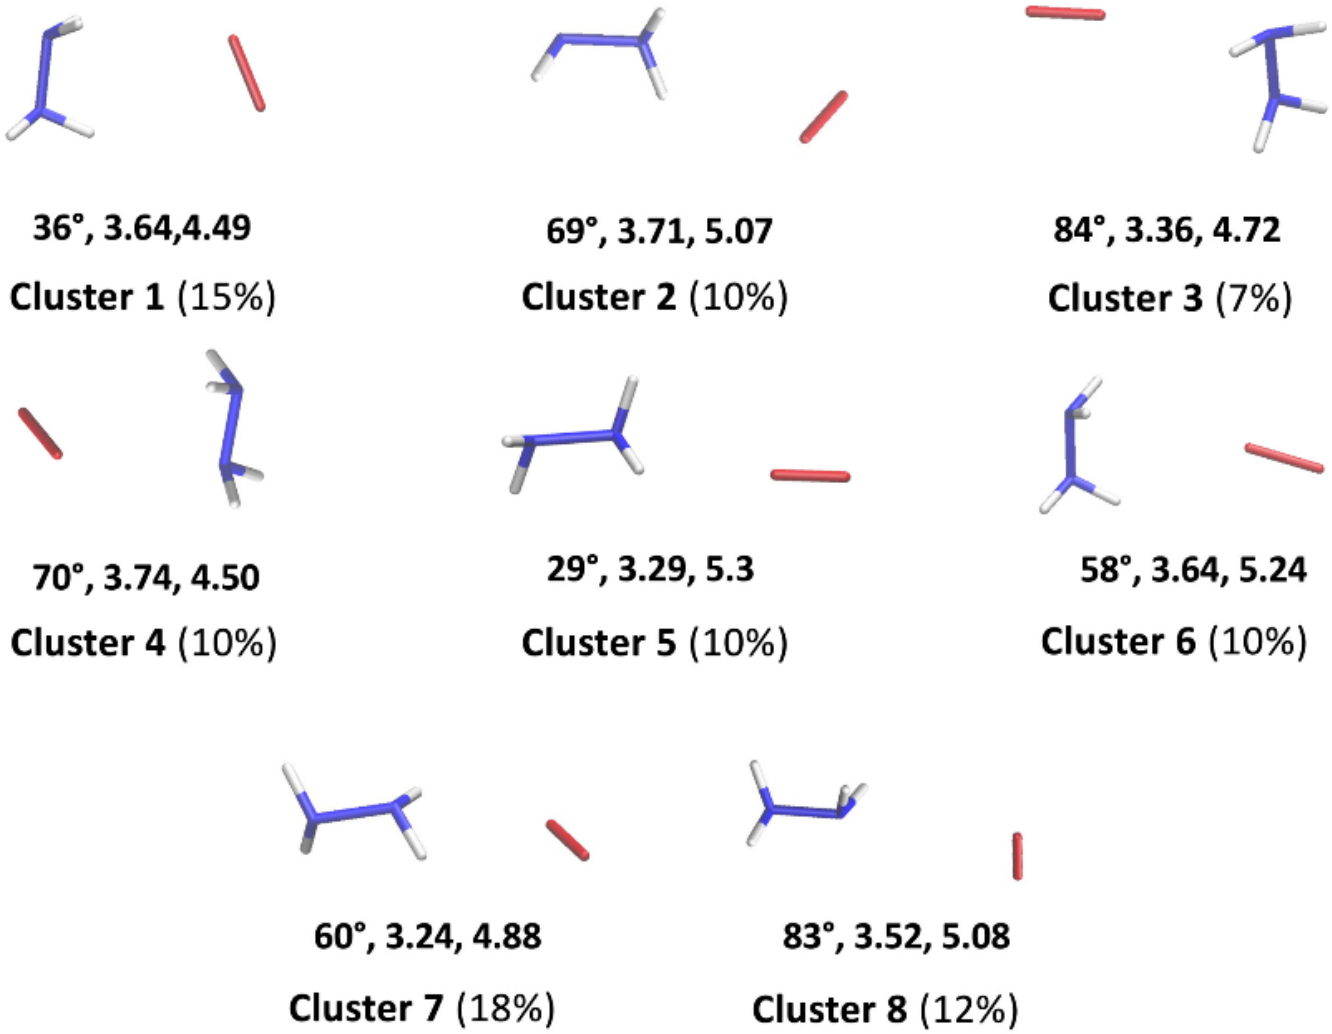

Figure issue de J Phys Chem A, 127 (2023) 10104

ISM10 : CLUSTERING : CONCLUSION

1 - Les algorithmes de clustering sont particulièrement efficaces pour fouiller, plutôt 'ordonner' et identifier des sous ensembles 'pertinents' de grand volumes de données sans intervention humaine. Ces algorithmes font donc parti des techniques de Machine Learning ;

2 - Mais l'utilisateur humain joue un rôle prépondérant en amont de l'application d'un algorithme de clustering. C'est lui qui définit la 'structure' *S* correspondant aux données à trier ;

3 – La « structure » *S* contient l'information physique ou chimique dans les algorithmes de clustering, elle doit donc en refléter les lois fondamentales ;

4 – En dehors des aspects propres aux algorithmes de clustering, la qualité du clustering dépend de la pertinence de la « structure » *S* choisie, le rôle de l'utilisateur humain n'est donc plus un travail répétitif de comparaison de données entre-elles mais de réflexion en amont visant à la définition de règles permettant de cataloguer aux mieux les données.

Un champ de force est un potentiel d'interaction **empirique** dont il n'est pas toujours facile de définir des paramètres de bonne qualité.

Historiquement, les paramètres des champs de force sont définis afin de reproduire un ensemble de données expérimentales. Ceci était réalisé par une approche itérative :

1 – Simulation avec un jeux de paramètres de champ de force
2 – Calcul des propriétés comparables à des données expérimentales
3 – Définition d'un nouveau jeu de paramètres et retour au point 1

Le choix du jeu de paramètres était laissé à l'initiative d'un « expert », i.e. un utilisateur humain.

La montée en puissance des ressources de calcul et la prise en compte enfin (…) d'algorithme d'optimisation (comme les algorithmes « génétiques ») permet aujourd'hui de réaliser l'approche itérative précédente de manière automatique.

=> Le rôle de l'expert humain reste pourtant central : il définit les propriétés expérimentales à prendre en compte et vérifie que les simulations (durée, échantillonnage..) donnent bien des résultats statistiquement significatifs.

ISM10 : ALGORITHMES D'OPTIMISATION "GÉNÉTIQUES"

Ces algorithmes (proposés dès les années 1950…) se veulent une analogie du processus Darwinien de sélection naturelle. Ils se décomposent en 4 étapes, une fois un jeu de conditions à atteindre défini (par exemple reproduire ***K*** propriétés expérimentales physico-chimiques d'un système microscopique, propriétés notées ***P***). Les 4 étapes :

1 – Choix de ***M*** jeux de paramètres de champ de force $\{\xi_i\}_{i=1,M}$ initiaux permettant de calculer des propriétés expérimentales *P* à l'aide de simulations => ***Parent Solutions***

2 - Calcul d'un fonction de pertinence (***fitness functions***) $\chi(\xi_i)$ des différents jeux de paramètres

$$\chi(\xi_i) = \sum_{k=1}^{K} \left[\frac{P_{exp} - P(\xi_i)}{\gamma_k} \right]^2$$

3 – Mélange et mutation (***Crossover and mutations***) des ***Parent solutions*** :

$\tilde{\xi}_j = \sum_{j=1}^{M} \alpha_{ji} \times \xi_i$ => mélange des solutions précédentes

$\tilde{\xi}_j^* = \tilde{\xi}_j + \sigma_j \times \mathcal{N}(0,1) \Rightarrow$ mutations des nouvelles solutions

4 – Calcul des ***K*** propriétés sur la base des nouveaux paramètres $\{\tilde{\xi}_j^*\}$ et ***Selection*** d'un jeu 'pertinent' de ces paramètres à considérer comme ***Parent Solutions*** et retour au point 1.

ISM10 : ALGORITHMES D'OPTIMISATION "GÉNÉTIQUES"

De manière théorique rien à redire, une fois l'algorithme lancé plus d'intervention de l'utilisateur humain, mais celui-ci doit avoir non seulement défini les ***P*** propriétés expérimentales pertinentes et leur « poids » γ_k mais aussi les « taux de mutation à chaque génération » $\{\sigma_j\}$

$$\tilde{\xi}_j^* = \tilde{\xi}_j + \sigma_j \times \mathcal{N}(0,1)$$

Il n'y a pas aujourd'hui de règle pour définir les paramètres $\{\sigma_j\}$, c'est à l'expert humain en Machine Learning de le faire…. Et il n'y a pas plus de règles pour le processus final de ***Selection***.

Remarque les α_{ji} du processus de ***Crossover*** $\tilde{\xi}_j = \sum_{j=1}^{M} \alpha_{ji} \times \xi_i$ peuvent être définis de manière aléatoire et gardés constants en amont de la boucle d'optimisation ou redéfinis à chaque itération. A priori l'intervention ici de l'expert humain est donc plus limitée.

Le problème essentiel reste aujourd'hui le temps nécessaire pour estimer une propriété expérimentale ***K*** sur la base de simulations microscopiques (en particulier estimation de l'erreur associée à celle-ci => **qualité des données considérées**).

ISM10 : Qualité des Données Considérées

Utiliser un algorithme d'optimisation de paramètres (comme les algorithmes génétiques) permet de définir avec précision et de manière automatique les paramètres d'un champ de force, avec une intervention humaine réduite.

Dans le cas d'un potentiel de Lennard-Jones, ces algorithmes permettent a priori de définir de manière automatique les paramètres ε^* et r^*. Par exemple afin que ce type de potentiel puisse reproduire un nombre prédéfini de *K* propriétés P_{exp} du système microscopique considéré, la précision du champ de force obtenu étant quantifiée par

$$\chi(\varepsilon^*, r^*) = \sum_{k=1}^{K} \left[\frac{P_{exp} - P(\varepsilon^*, r^*)}{\gamma_k} \right]^2$$

De manière implicite l'emploi d'un algorithme d'optimisation génétique implique de pouvoir évaluer un très grand nombre de jeux de paramètres (ε^*, r^*). **Or le calcul de propriétés comme la densité d'un fluide à une température et une pression données nécessite de réaliser une simulation microscopique suffisamment longue.**

Schéma d'optimisation des paramètres d'un champ de force

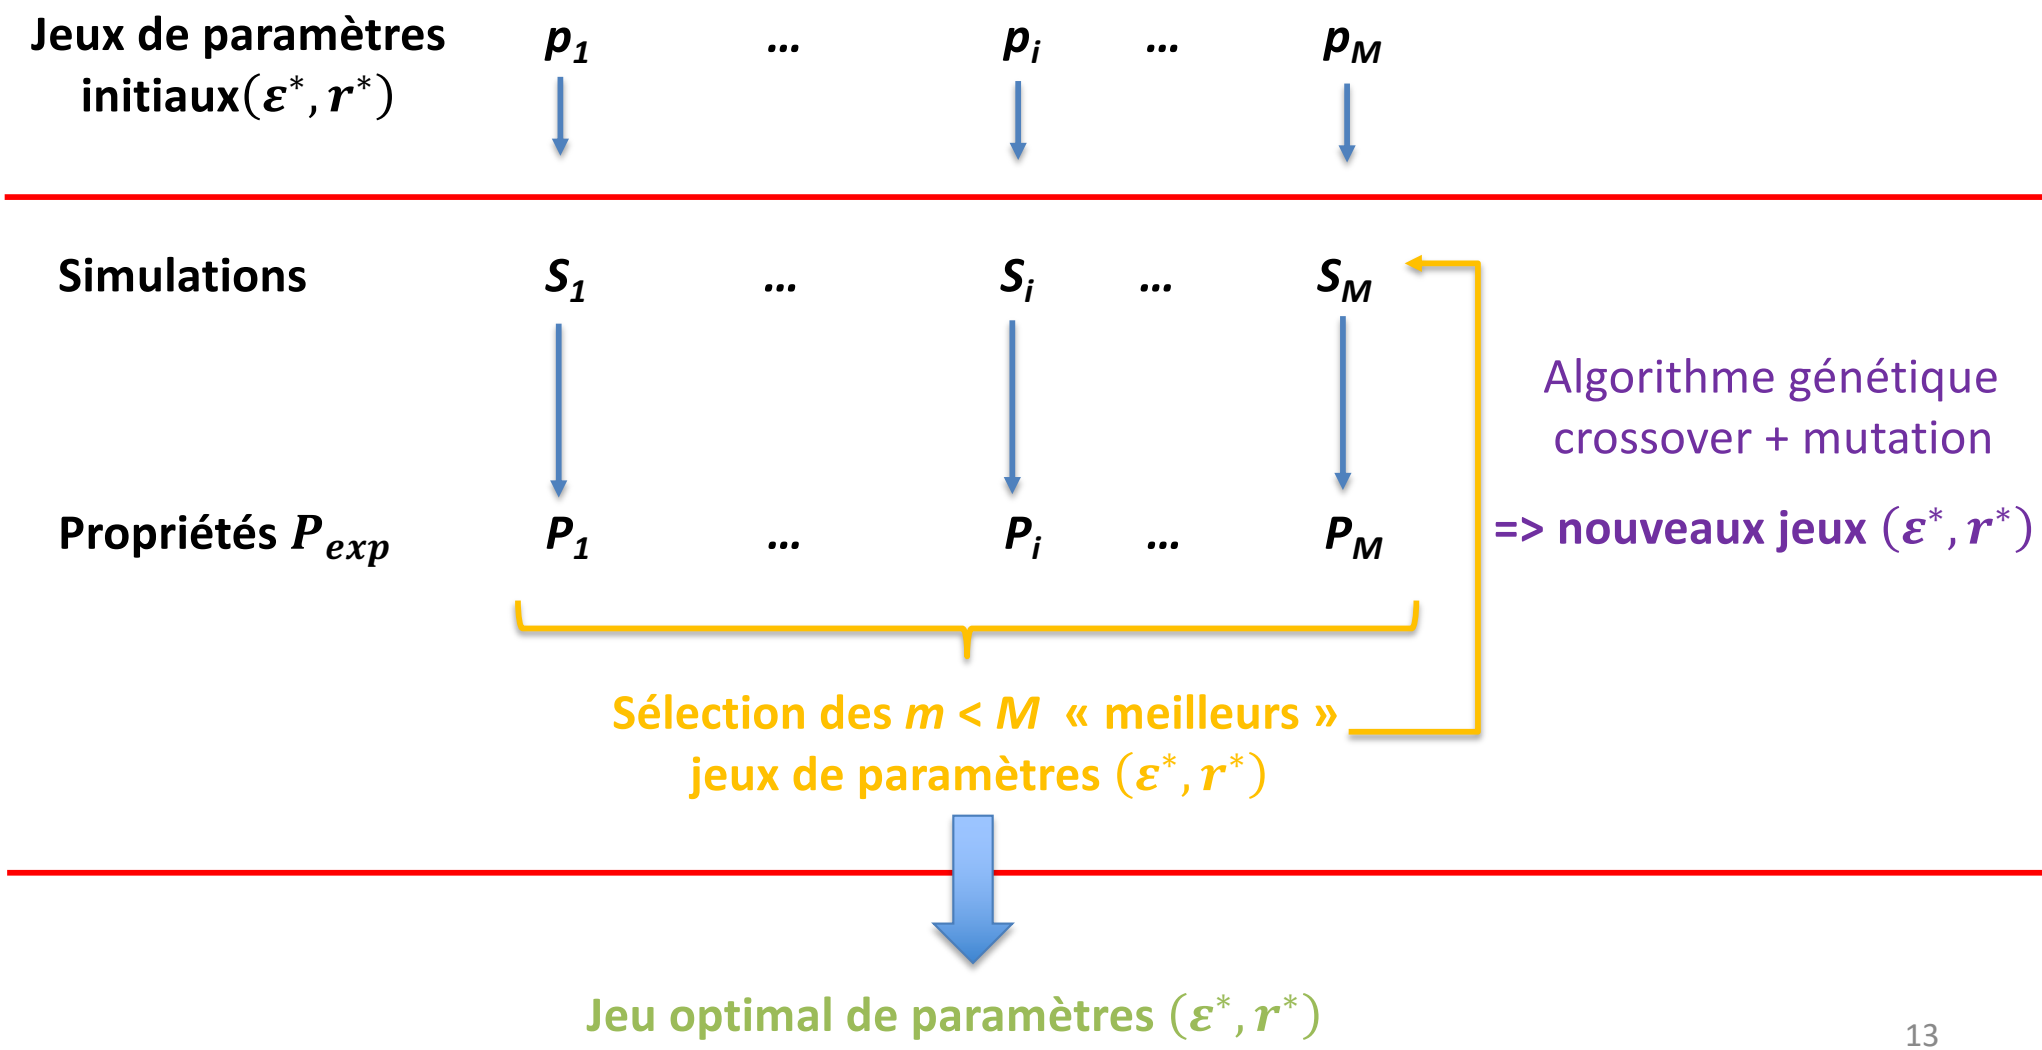

ISM10 : Simulation microscopique et Modèles "Gaussian Process"

Les potentiels de Lennard Jones (sans charge électrostatique) ont été proposés historiquement pour pouvoir calculer analytiquement les fonctions de partition et donc les fonctions thermodynamiques de systèmes microscopiques (cf. équation de Van der Waals).

Cet aspect « calculable analytiquement » a amené des développements en physique théorique permettant d'estimer efficacement avec une bonne précision une propriété de type $P(\varepsilon^*, r^*)$ sans avoir à réaliser de simulation microscopique (comme les techniques de « Gaussian process surrogate modeling »).

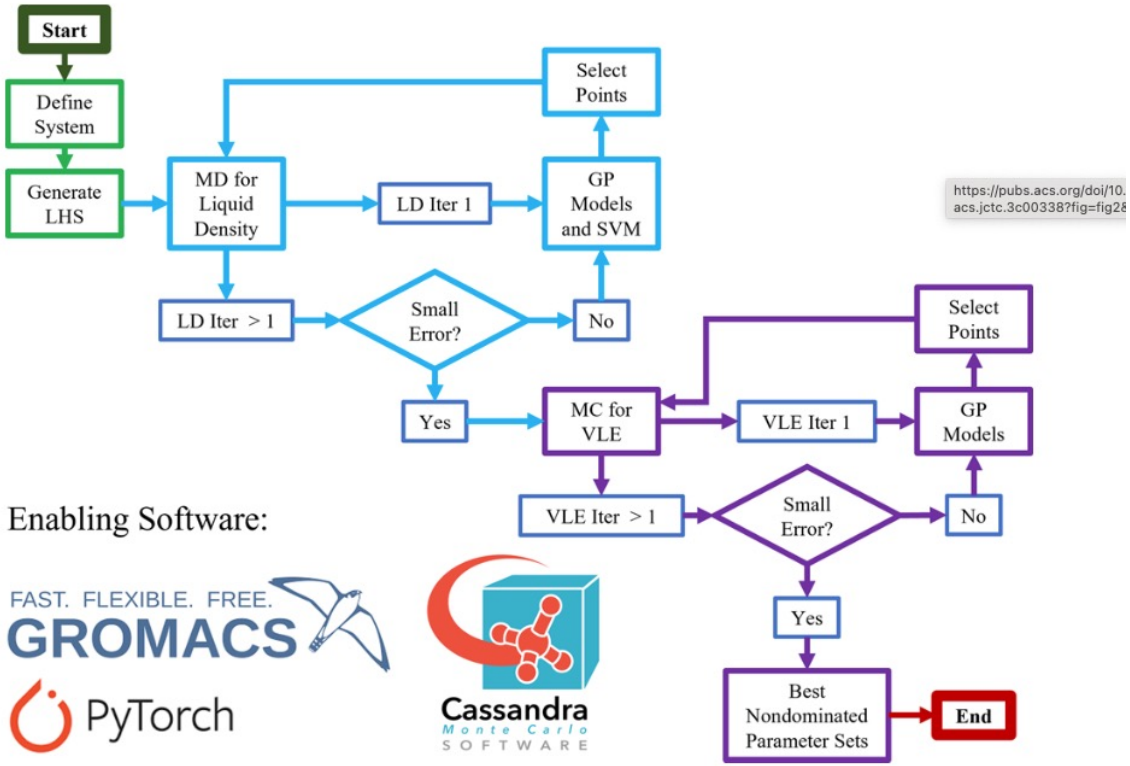

GP = Gaussian Process
LD = fluid density
MC = MonteCarlo simulations
MD = Molecular dynamics simulation
VLE = vapor-liquid equilibrium

J Chem Theor and Comput, 10 (2023) 4546

ISM10 : Optimisation de Champ de Force par Machine Learning

L'approche 'Gaussian Process surrogate modeling' est effectivement suffisamment précise pour accélérer le processus de d'optimisation des paramètres d'un champ de force de type Lennard-Jones pure.

Ecarts pour différentes propriétés P_{exp} entre l'approche Gaussian Process et une simulation microscopique

Table 3. Overall MAPEs of Liquid Density, Vapor Density, Vapor Pressure, and Enthalpy of Vaporization between GP Predictions and MD or GEMC Results of HFC-143a, HFC-134a, R-50, R-170, and R-14 for all LD or VLE Iterations

Property	Simulation	HFC-143a	HFC-134a	R-50	R-170	R-14
ρ_l	MD	0.89%	0.63%	0.61%	0.84%	0.69%
ρ_l	GEMC	0.3%	0.2%	0.2%	0.2%	0.2%
ρ_v	GEMC	4.6%	9.6%	2.7%	2.9%	4.9%
P_{vap}	GEMC	2.5%	7.6%	1.9%	1.8%	6.5%
ΔH_{vap}	GEMC	0.5%	0.3%	0.2%	0.3%	0.2%

MAPE = « mean absolute percent errors »

Optimisation de champ de force de type Lennard Jones pour modéliser des molécules réfrigérantes

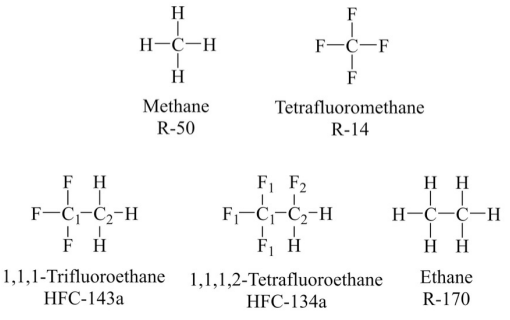

J Chem Theor and Comput, 10 (2023) 4546

ISM10 : Optimisation de Champ de Force par Machine Learning

Optimisation de champ de force de type Lennard Jones pour modéliser des molécules réfrigérantes

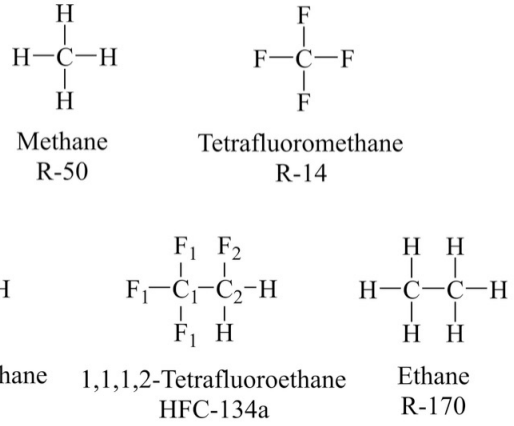

MAPE = « mean absolute percent errors »

Table 5. MAPEs of Liquid Density (ρ_l), Vapor Density (ρ_v), Vapor Pressure (P_{vap}), and Enthalpy of Vaporization (ΔH_{vap}) of Parameter Sets from This Work (Recommended), GAFF,[12] Literature,[19,66] and TraPPE[65] for HFC-134a, HFC-143a, R-170, R-50, and R-14[a]

Refrigerant	Model	MAPE$_{\rho_l}$	MAPE$_{\rho_v}$	MAPE$_{P_{vap}}$	MAPE$_{\Delta H_{vap}}$	
HFC-143a	This work	**1.1%**	**2.6%**	**2.8%**	**2.3%**	
	GAFF[12]	4.3%	33.0%	22.3%	28.4%	→ 2004
HFC-134a	This work	**0.3%**	**1.6%**	**1.9%**	**0.5%**	
	Peguin[19]	0.7%	4.4%	3.1%	2.2%	→ 2009
R-50	This work	3.4%	**1.4%**	2.5%	2.7%	
	GAFF[12]	14.5%	90.8%	59.8%	33.4%	→ 2004
	Potoff[66]	1.4%	3.7%	**0.8%**	8.4%	→ 2009
2014 ←	TraPPE[65]	**0.8%**	6.5%	8.0%	**1.1%**	
R-170	This work	1.8%	**1.6%**	2.1%	**2.0%**	
	GAFF[12]	22.4%	180.3%	83.0%	50.5%	
	Potoff[66]	2.1%	3.2%	**1.9%**	14.4%	→ 2009
2014 ←	TraPPE[65]	**0.8%**	4.6%	4.0%	8.2%	
R-14	This work	0.6%	**1.5%**	1.3%	**0.7%**	
	GAFF[12]	6.7%	72.0%	62.9%	61.5%	
	Potoff[66]	**0.4%**	1.9%	**0.5%**	2.0%	→ 2009

J Chem Theor and Comput, 10 (2023) 4546

ISM10 : CHAMPS DE FORCE IA

Les approches champ de force empirique classique (comme le potentiel de Lennard Jones) sont basées sur des potentiels d'interaction inter atomique dont la forme analytique se veut une traduction fidèle de la nature des interactions au sein d'un système microscopique :

$$U^{LJ} = 4\varepsilon_{AB}\left[\underbrace{\left(\frac{r^{*}_{AB}}{r_{AB}}\right)^{12}}_{répulsion} - \underbrace{\left(\frac{r^{*}_{AB}}{r_{AB}}\right)^{6}}_{dispersion}\right]$$

Avec la montée en puissance des approches d'intelligence artificielle, l'aspect « traduction fidèle des interactions » est remplacer par une boite noire (« black box ») dont on comprend mal l'origine de sa capacité prédictive :

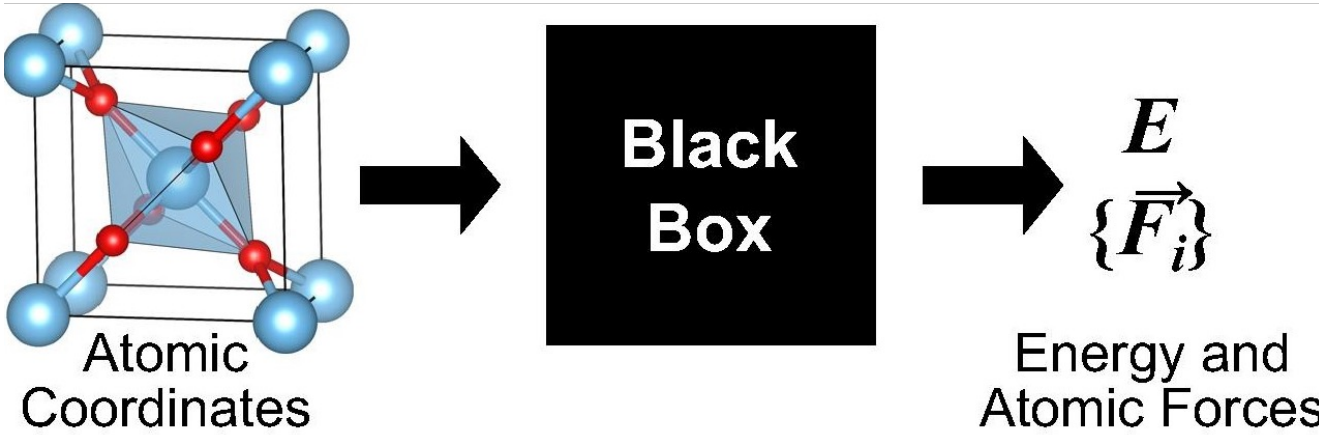

Images issues de Comput Mater Sci, 114 (2016) 135

ISM10 : THE IA BLACK BOX

Soit un réseau de neurone de profondeur 3

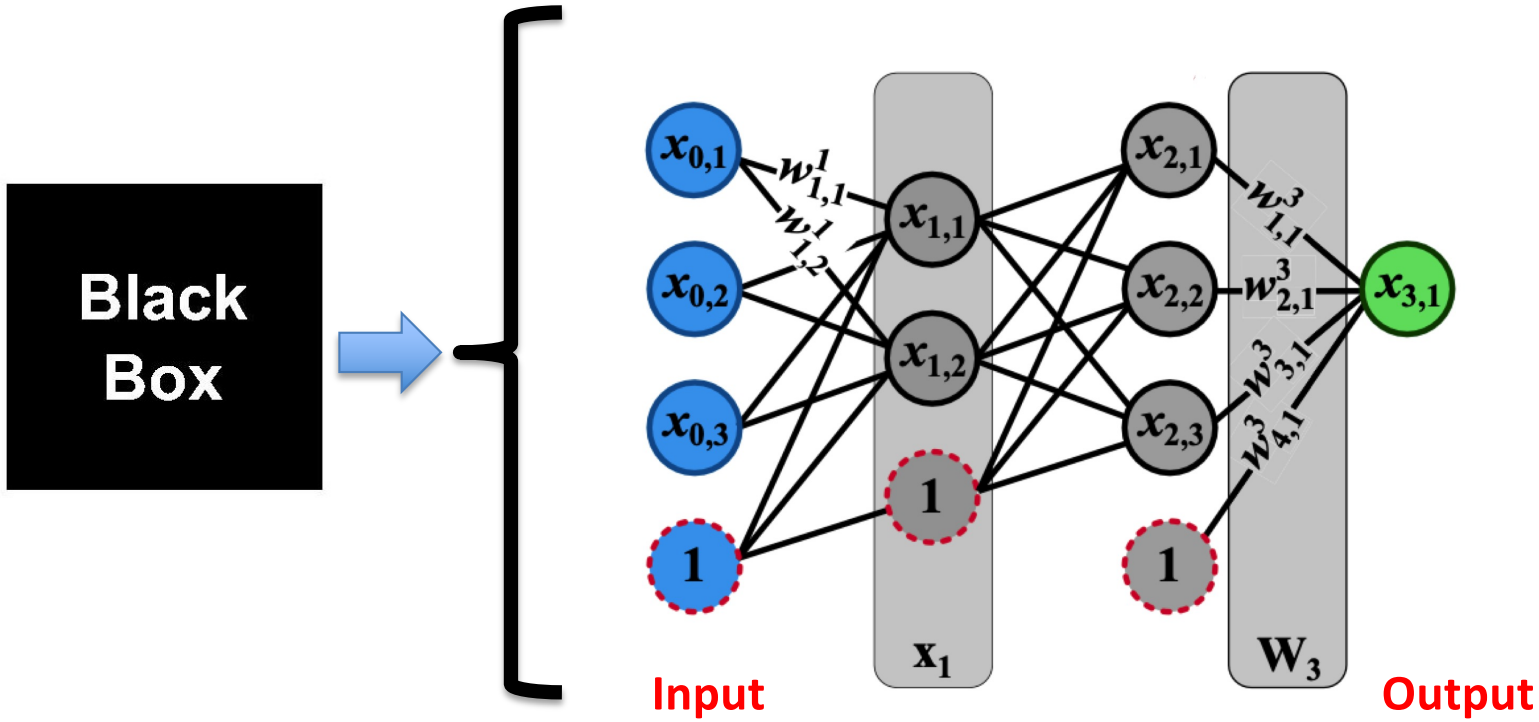

En entrée du réseau de neurone, une vecteur de données $\mathbf{X_0}$ qui sera « transformé » en un vecteur de $\mathbf{X_3}$ par les opérations successives

$$\mathcal{F}(\mathbf{X}_3) = f_3\{\mathbf{W}_3 f_2(\mathbf{W}_2 f_1(\mathbf{X}_0))\}$$

Images issues de Comput Mater Sci, 114 (2016) 135

ISM10 : THE IA BLACK BOX

Vecteur de données $\mathbf{X}_0$ « transformé » en un vecteur de $\mathbf{X}_{n=3}$ par les opérations successives

$$\mathcal{F}(\mathbf{X}_3) = f_3\{\mathbf{W}_3 f_2(\mathbf{W}_2 f_1(\mathbf{X}_0))\}$$

Les $\mathbf{W}_j$ sont des poids qui modulent le signal reçu par des neurones *j* du fait de chaque élément du vecteur signal $\mathbf{X}_{j-1}$ des neurones *j-1,* et les fonctions d'activation f_j modulent le signal global (somme des signaux de chaque neurone *j-1*) avec différents choix de lois possibles :

$$f_{linear}(x) = x, \qquad f_{tanh}(x) = \tanh(x), \qquad f_{logistic}\ (x) = \frac{1}{1+e^{-x}}$$

Le processus d'entrainement du réseau de neurones (***Training Process***) n'est en fait qu'une tâche d'optimisation de l'ensemble des poids$\{\mathbf{W}_j\}$ du réseau afin de minimiser la fonction :

$$\epsilon(n) = \mathcal{F}(\mathbf{X}_n) - \mathbf{Y}_n$$

Le vecteur $\mathbf{Y}_n$ est l'ensemble des données cibles (***target***) qui correspondent à $\mathbf{X}_0$, par exemple l'énergie potentielle et les forces sur chaque atome dans le cas où $\mathbf{X}_0$ est le vecteur de toutes les coordonnées des atomes.

Le processus d'optimisation se fait à l'aide d'opérations matricielles standards (des bibliothèques) qui tirent pleinement profit des unités de calcul vectorielles (GPU…)

ISM10 : Entrainement d'un Champ de Force IA, Quelles Données en entrée ?

Soit un système microscopique composé de *N* atomes dont les coordonnées cartésiennes $\left(x_j, y_j, z_j\right)_{j=1-N}$ sont stockées dans un vecteur $\mathbf{X}_0$. L'approche naïve serait d'entrainer le réseau sur la base du vecteur $\mathbf{X}_0$

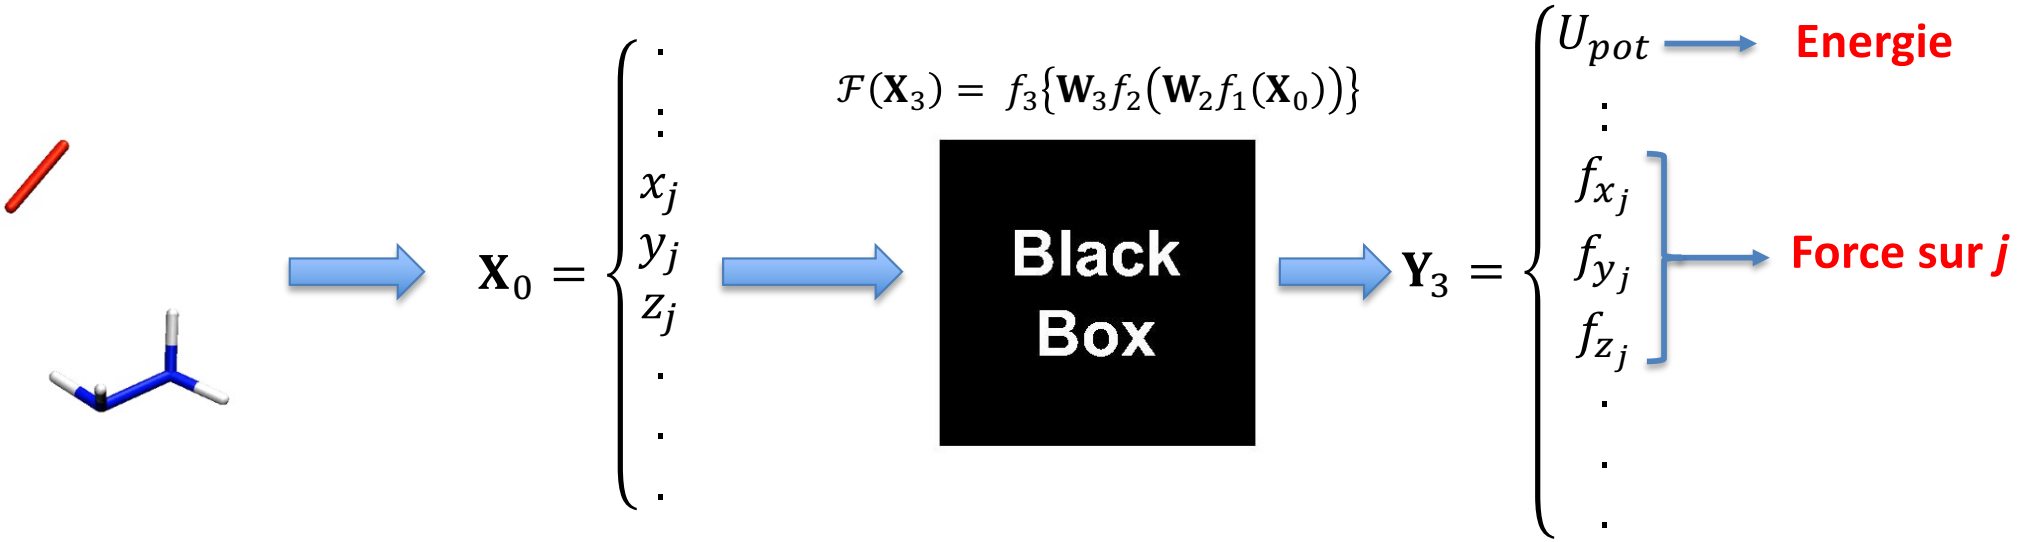

Mais le système de coordonnées cartésiennes $\left(x_j, y_j, z_j\right)_{j=1-N}$ n'est pas absolu, i.e. toute rotation du référentiel choisi ne doit pas modifier U_{pot} et ne doit pas modifier les vecteurs forces élémentaires inter atomiques $\mathbf{F}_{ij}$ projetés sur l'axe connectant les paires d'atomes *i* et *j*.

ISM10 : Approche naïve et cas de N_2H_4/O_2

Cas de N_2H_4/O_2, le résultat du clustering d'une simulation à 300 K par dynamique moléculaire à l'échelle de 50 ns semble être « exhaustif »

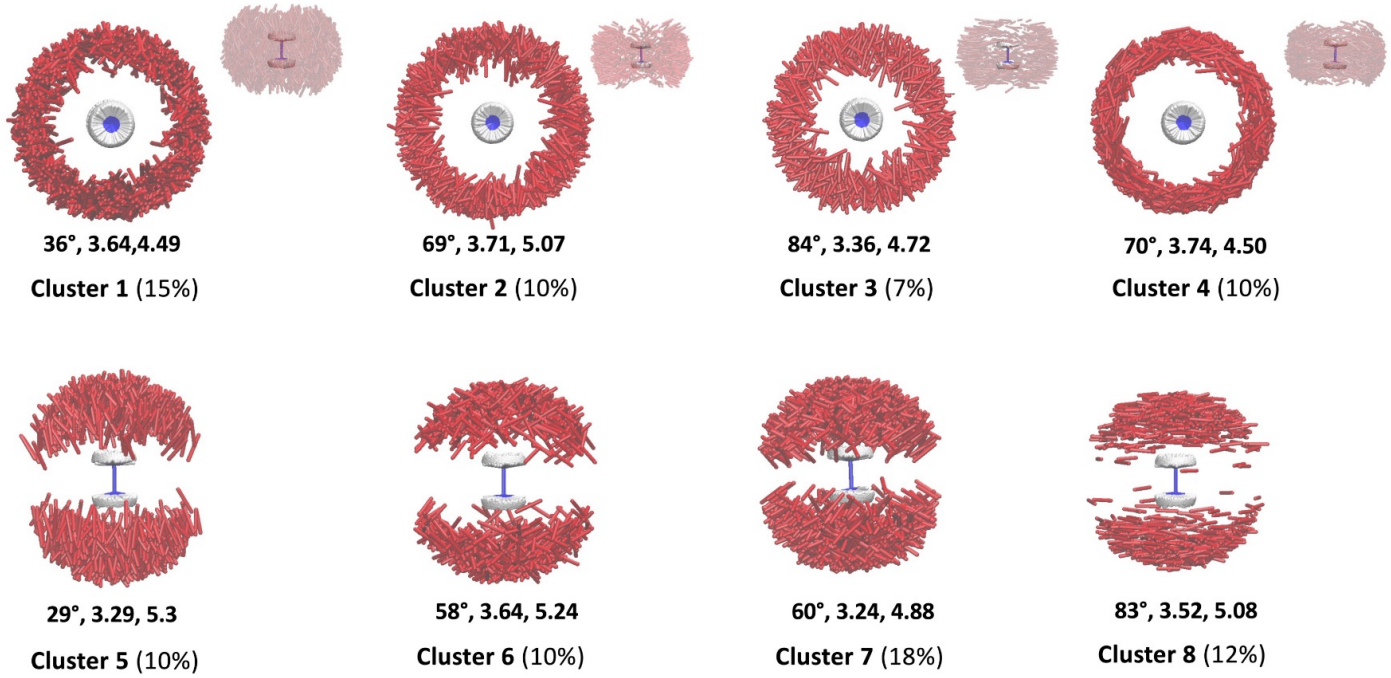

NB : figure après superposition des différentes conformations afin de minimiser la fonction RMSD correspondant aux atomes N

$$\mathrm{RMSD(N)} \propto \left|\mathbf{X}_{\mathrm{N}}^{1} - \mathbf{X}_{\mathrm{N}}^{2}\right|^{2}$$

A priori l'approche naïve pourrait être employée dans ce cas, mais le réseau de neurone ne serait pas seulement entrainé pour calculer des forces et des énergies, mais également pour reconnaître (implicitement) des géométries similaires…

ISM10 : Données en Entrée Pertinentes : Fonctions d'Environnement

Sur la base d'une fonction de coupure (***Cutoff***), comme par exemple la fonction *G :*

$$G(r, R_{cut}, \delta R) = \begin{cases} 1 & \text{if} \quad r \leq R_{cut} \\ 0 & \text{if} \quad r \geq R_{cut} + \delta R \\ P_5(r) & \text{if} \quad R_{cut} < r < R_{cut} + \delta R \end{cases} \longrightarrow P_5(x) = 1 - 10\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^3 + 15\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^4 - 6\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^5$$

Il est possible de construire un jeu de fonctions $\{F_l\}_i$ permettant de caractériser avec précision l'environnement d'une atome *i*, i.e. quels sont ses atomes voisins et comment ces atomes voisins se disposent dans l'espace autour de l'atome *i*.

Pour bâtir un champ de force AI, il suffit alors de substituer le vecteur en entrée $\mathbf{X}_0$ par $\widetilde{\mathbf{X}}_0$

$$\mathbf{X}_0 = \begin{Bmatrix} \cdot \\ \vdots \\ x_j \\ y_j \\ z_j \\ \cdot \\ \cdot \\ \cdot \end{Bmatrix} \text{ Coordonnées de } j \qquad \Longrightarrow \qquad \widetilde{\mathbf{X}}_0 = \begin{Bmatrix} \cdot \\ \cdot \\ F_j^1 \\ \cdot \\ \cdot \\ F_j^L \\ \cdot \\ \cdot \end{Bmatrix} \text{ Fonctions } \{F_l\}_j \text{ caractérisant l'environnement de } j$$

ISM10 : EXEMPLES DE FONCTIONS D'ENVIRONNEMENT

La fonction 'composition d'environnement', dans le cas d'un système homogène (tous les atomes sont du même type) donne le nombre de voisins à une distance inférieure à R_{cut}

$$\Omega_1^i = \sum_{j \neq i, j=1}^{N} G(R_{ij}, R_{cut}, \delta R)$$

La fonction 'densité locale' à une distance $R_s < R_{cut}$ donnant plus de détails sur la structure radiale

$$\Omega_2^i = \sum_{j \neq i, j=1}^{N} \exp\left(-\frac{\left(R_{ij} - R_s\right)^2}{\gamma}\right) \times G(R_{ij}, R_{cut}, \delta R)$$

La fonction 'de distribution angulaire locale' :

$$\Omega_2^i \propto \sum_{j \neq i, j=1}^{N} \sum_{k \neq (i,j), k=1}^{N} \left[(1 + \lambda \cos(\Theta_{ijk}))\right]^{\zeta} \times \exp\left(-\frac{R_{ij}^2 + R_{ik}^2 + R_{jk}^2}{\gamma}\right) \times G(R_{ij}) \times G(R_{ik}) \times G(R_{jk})$$

ISM10 : Entrainement d'un Champ de Force IA, Approche Itérative

Les champs de force IA n'ont de sens que si :

1 – il est difficile de proposer une fonction champ de force empirique suffisamment précise (où si l'on ignore quelle forme analytique elle doit avoir);

2 – si ils est possible de calculer de manière « efficace » des énergies potentielles et des forces atomiques par des méthodes de chimie quantique, en particulier de type DFT.

=> Ceci explique que ce type d'approche est surtout employée actuellement pour modéliser des systèmes 'métalliques' sur la base de données calculées par des approches de chimie quantique de type DFT.

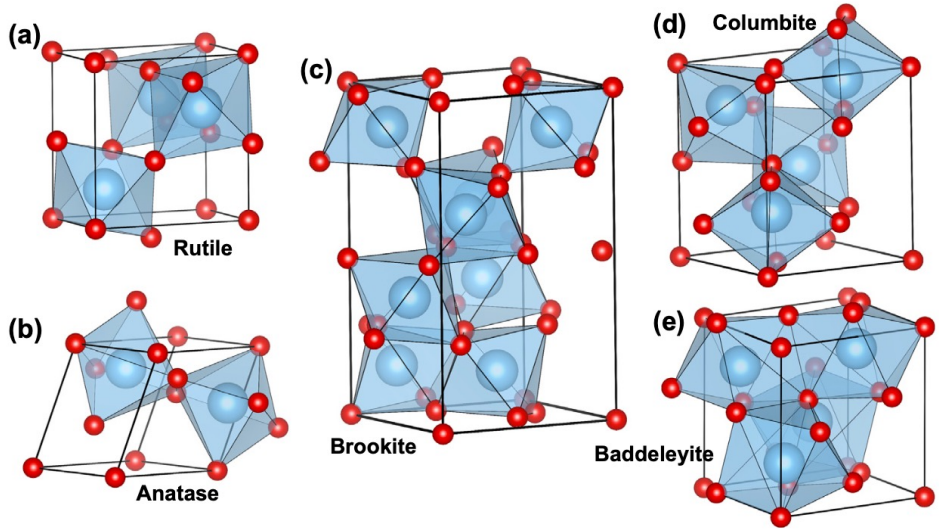

Exemple d'application : matériaux à base d'oxyde de titane TiO2

ISM10 : Optimisation de Champ de Force IA et Par Approche Itérative

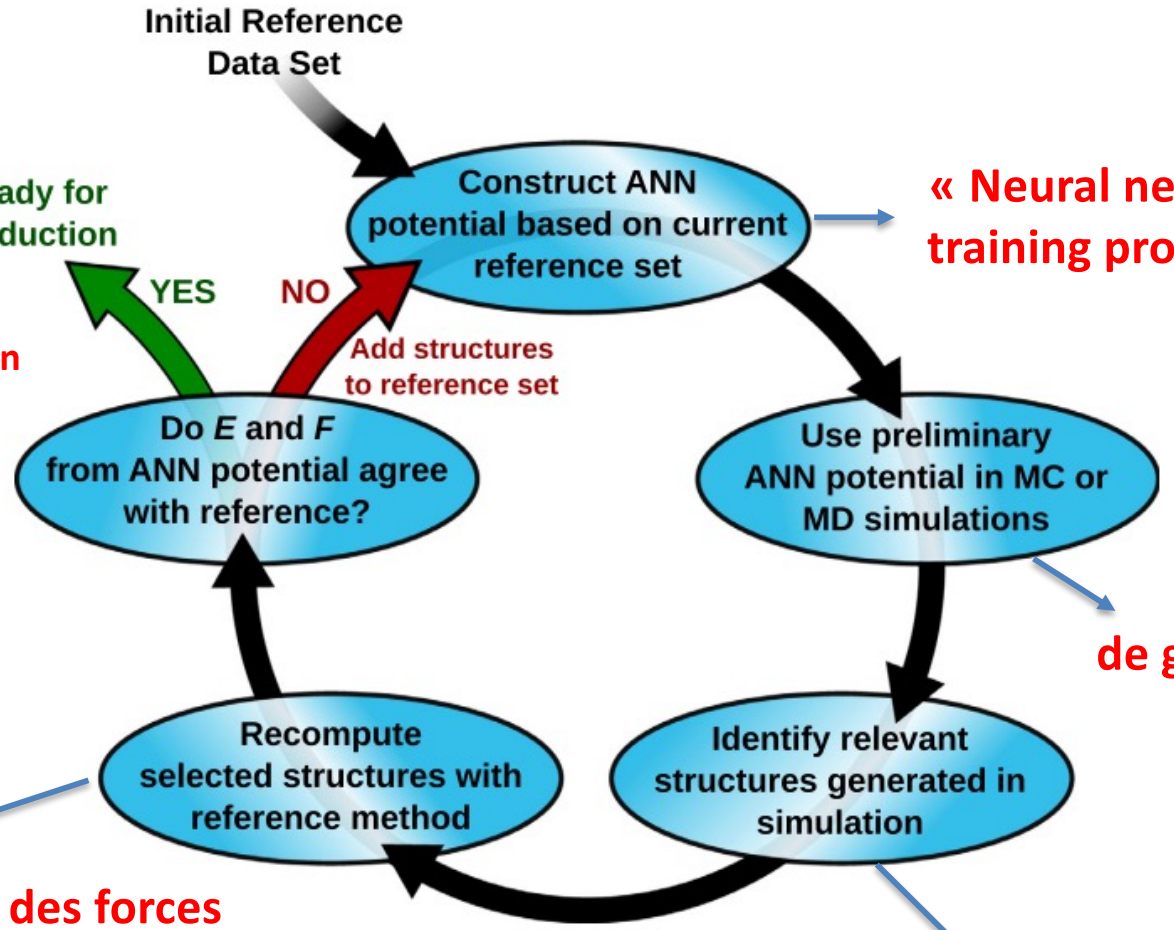

« Neural network training process »

Nombre d'itérations pour atteindre la convergence non précisé…

Simulations de grands systèmes

Calculs des énergies et des forces pour de nouvelles conformation avec peu d'atomes avec une Méthode de référence

Clustering : Identification de conformations particulières avec peu d'atomes

ISM10 : Optimisation de Champ de Force et Approche Itérative

L'approche itérative de test systématique d'un champ de force par clustering de simulations microscopiques intermédiaires est indépendante de l'approche champ de force choisi (classique ou IA) , par exemple

Properties of the tetravalent actinide series in aqueous phase from a microscopic simulation self-consistent engine

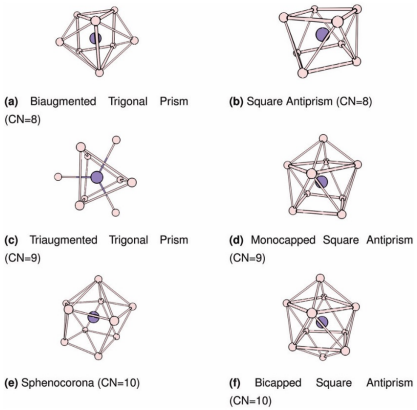

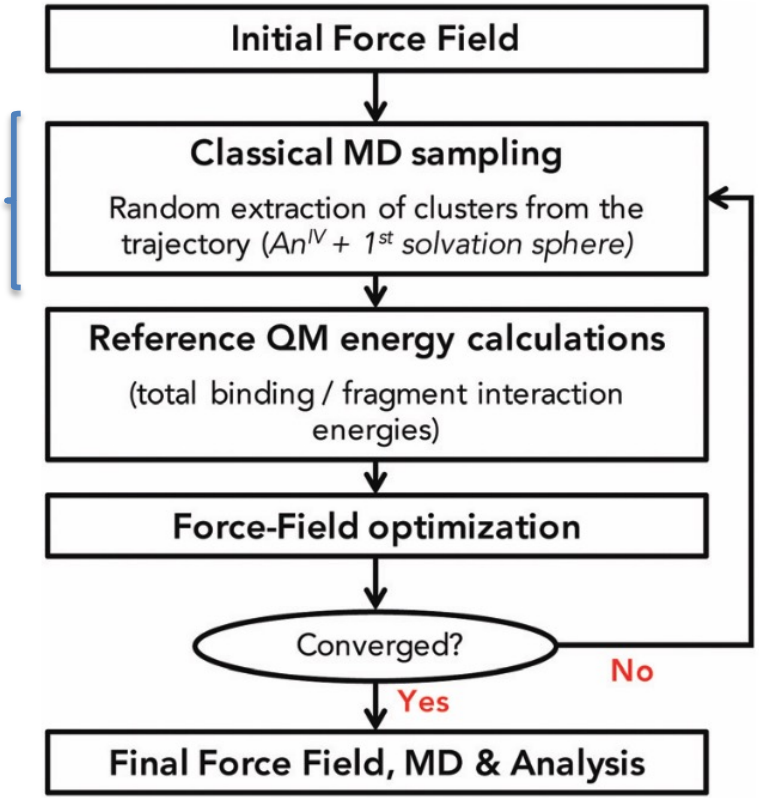

Simulations + Clustering

Optimisation par la méthode de moindre carrée classique

PCCP, 22 (2020) 2343

ISM10 : Optimisation de Champ de Force et Approche Itérative

Properties of the tetravalent actinide series in aqueous phase from a microscopic simulation self-consistent engine

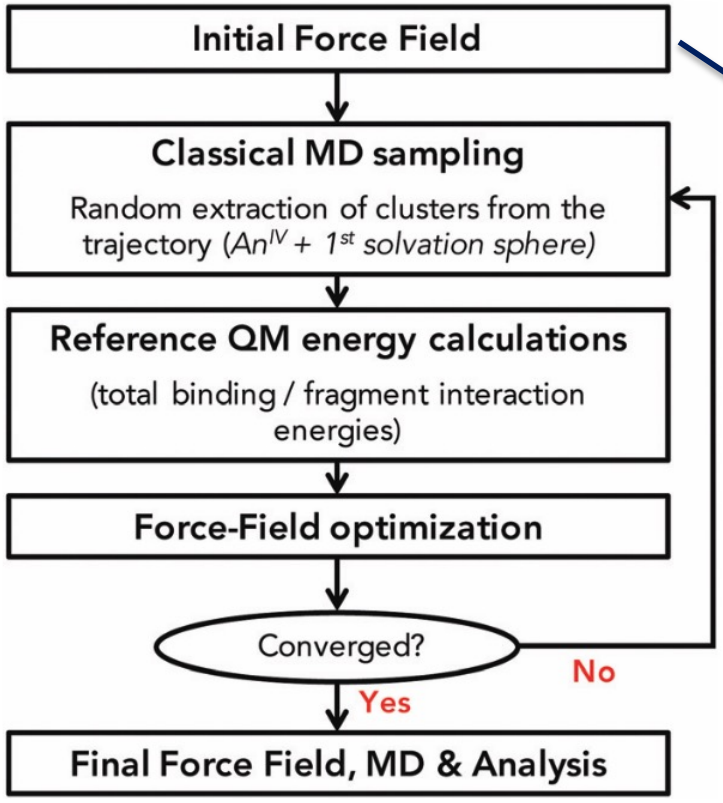

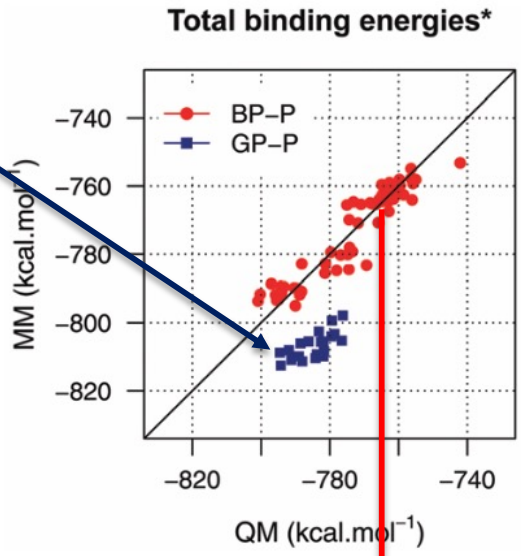

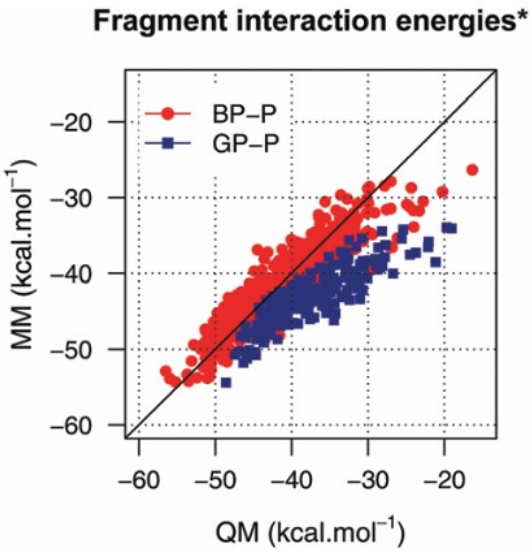

Paramètres du champ de force optimisé en 6 itérations

PCCP, 22 (2020) 2343

ISM10 : Entrainement d'un Champ de Force IA, Approche Itérative

Simulation de matériaux TiO2, **70** paramètres (fonctions) d'environnement en entrée par atome, deux couches de neurone (***hidden layers***) comprenant chacune *N* nœuds (neurones), une seule donnée en sortie, i.e. l'énergie potentielle de la conformation de TiO2 (7 700 structures prises en compte, chacune comprenant de 6 à 95 atomes).

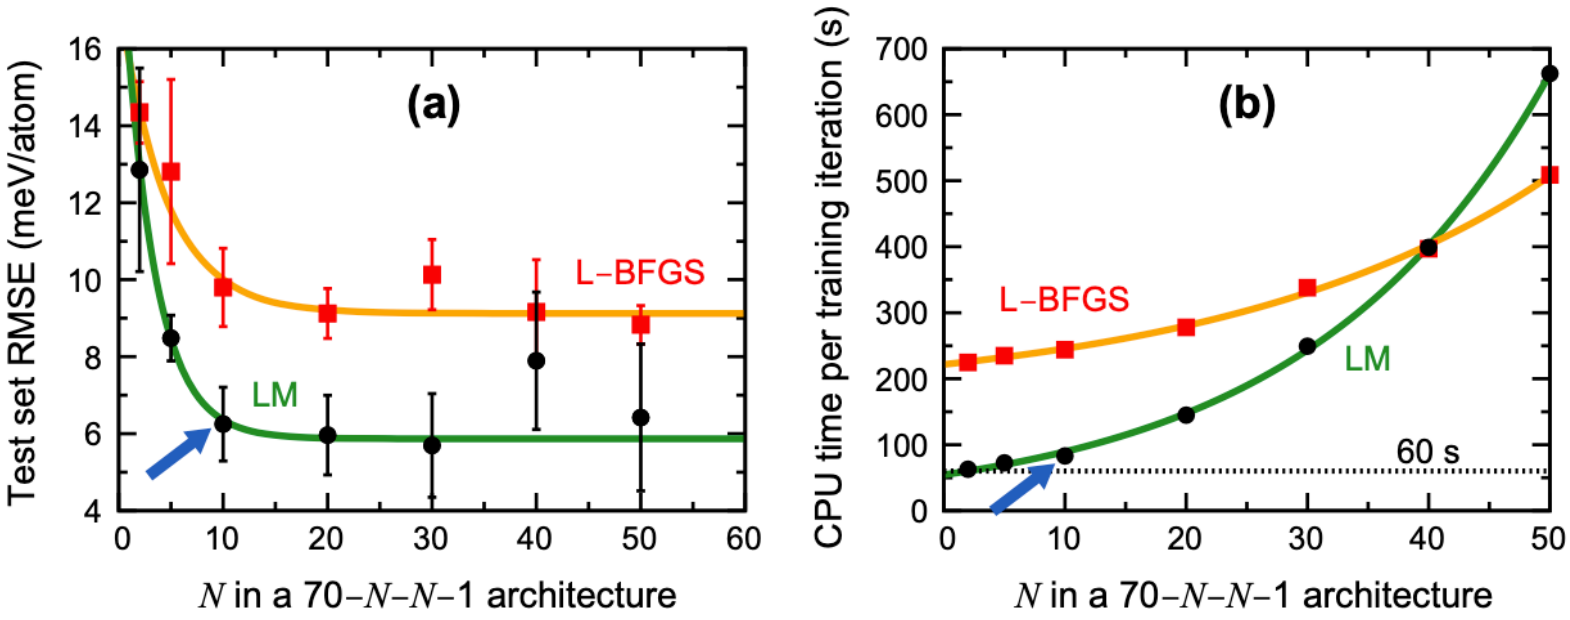

Convergence en fonction du nombre de nœuds et temps d'entrainement

ISM10 : Entrainement d'un Champ de Force IA, Approche Itérative

Erreur pour chacune des structures en entrée :

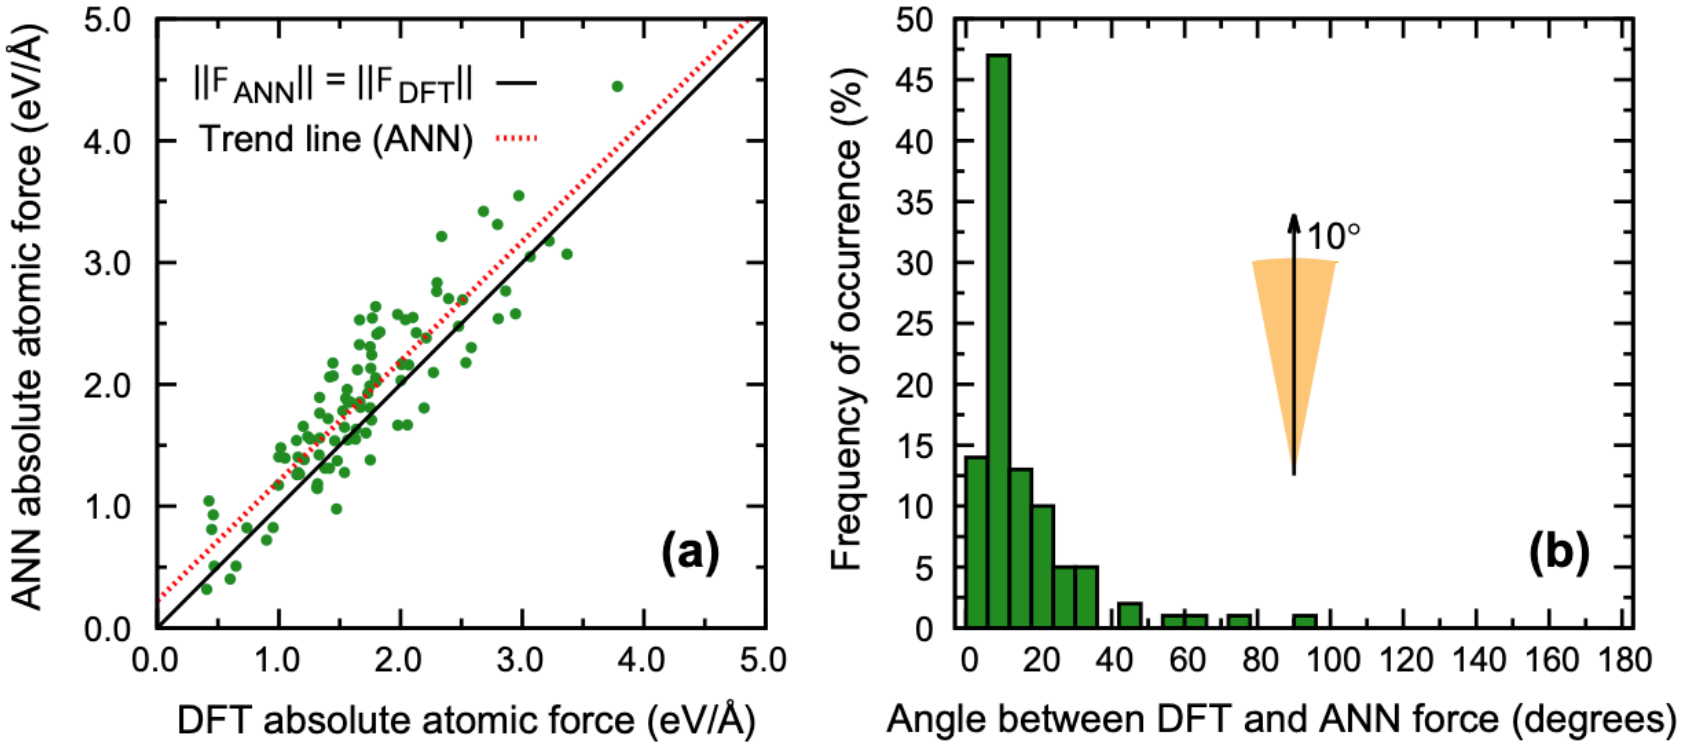

ISM13 – Calcul de Grandeurs dépendantes du temps

1 – Exemple du coefficient de diffusion

2 – Integrale de Green Kubo

3 – Cas de la Viscosité

4 – Intégration de fonctions auto-correlation : gestion de l'accumulation de l'erreur

5 – Temps de residence moyen

6 – autocorrelation et erreur à la moyenne

ISM11 : EXEMPLE DU COEFFICIENT DE DIFFUSION

Considérons le nombre de particules (molécules/atomes) dN qui traverse une surface *S* pendant un temps *dt*

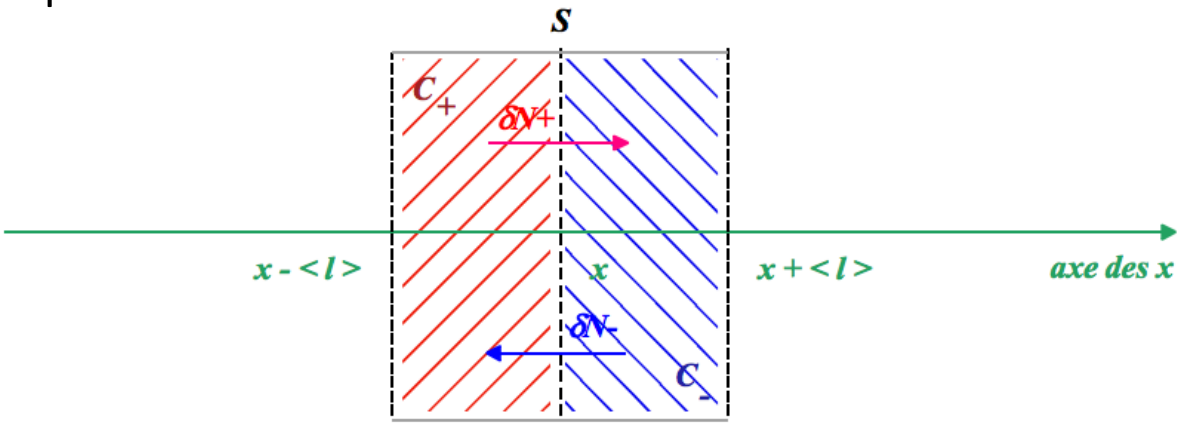

$$\rho(x,t) = \frac{dN(x,t)}{Sdx}$$

Soit *J* et ρ le courant de particules et la densité particulaire, d'après la loi de Fick

$$J(x,t) = -D\frac{\partial\rho(x,t)}{\partial x}$$

D est le coefficient de diffusion s'exprimant en $m^2\ s^{-1}$. Dans le cas d'un liquide, loi Stokes-Einstein

$$D = \frac{k_B T}{6\pi r\mu}$$

Avec r le rayon de la molécule considérée comme sphérique et μ la viscosité.

La difficulté : que faire quand on ignore la valeur de la viscosité $\Longrightarrow$ dynamique moléculaire…

ISM11 : COEFFICIENT DE DIFFUSION ET DYNAMIQUE MOLÉCULAIRE

D'après la relation dite d'Einstein, le coefficient de diffusion est la limite pour des temps suffisamment longs du déplacement quadratique particulaire moyen

$$D = \lim_{t\to\infty} \frac{\langle|\vec{r}(t) - \vec{r}(0)|^2\rangle}{6t}$$

Le long d'un simulation de dynamique moléculaire, il suffit de

1 - suivre la déplacement de chaque particule d'un type défini *i* sur une succession d'intervalles de temps Δt « longs » (segments de trajectoire) et de moyenner le déplacement quadratique sur le nombre de molécules de type *i* à tous les temps *t* compris entre 0 et Δt de chaque segment;

2 – calculer *D* en effectuant une régression linéaire du déplacement quadratique moyen en fonction du temps *t.*

Difficulté : importante fluctuation du déplacement quadratique moyen dans le cas d'une particule unique amenant à une grande incertitude sur *D* pour cette particule :

Exemple : un ion en concentration très diluée dans l'eau liquide.

ISM11 : COEFFICIENT DE DIFFUSION ET DYNAMIQUE MOLÉCULAIRE

Variabilité du déplacement quadratique moyen le long de simulations indépendantes

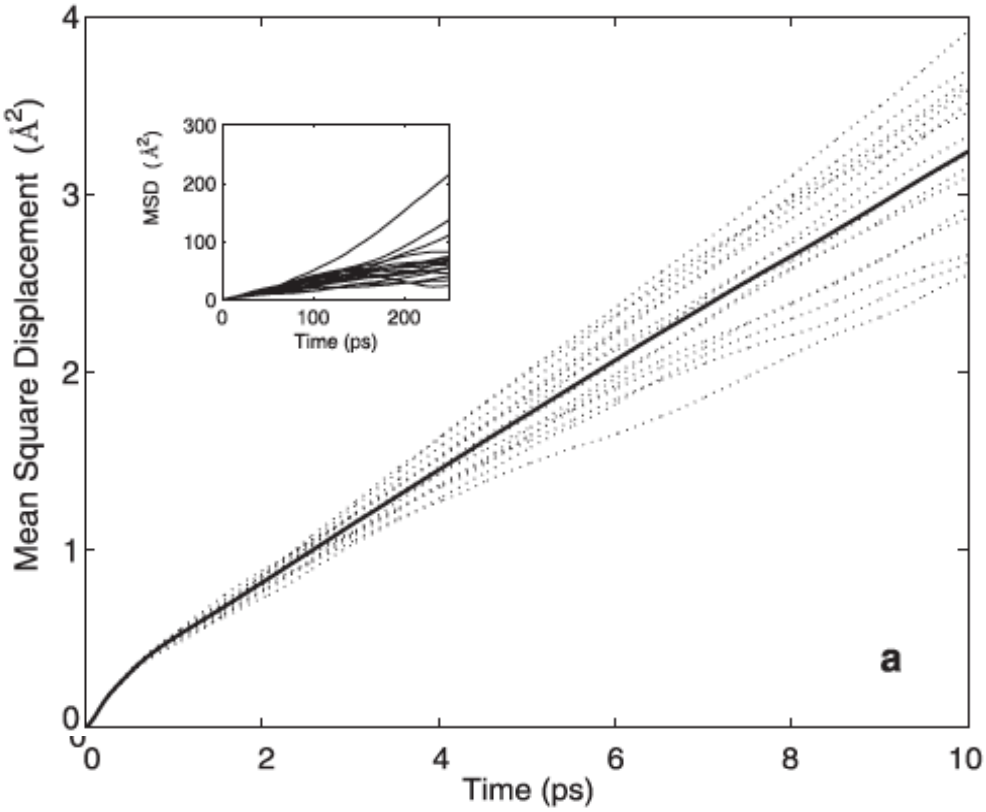

$$MSD(t) = \langle |\vec{r}(t) - \vec{r}(0)|^2 \rangle$$

Fig. 2. (a) Example of MD-calculated mean square displacement of CO_3^{2-} at 298 K based on a set of 16 simulations (dotted lines). The solid line indicates the mean value of all runs. Note that results shown are for $N = 216$ (to obtain final values, system-size correction needs to be applied). Inlet: note different axes limits.

Zeebe R.E. , Geochimica and Cosmochimica Acta, 75 (2011) 2483

ISM11 : Relation de Green-Kubo

La relation de Green-Kubo permet d'exprimer la relation entre un coefficient de transport γ et la grandeur temporelle à laquelle il est associé

$$\gamma = \int_0^\infty \langle A(\dot{t})A(\dot{0})\rangle dt$$

Dans le cas du coefficient de diffusion, on obtient

$$D = \frac{1}{3}\int_0^\infty \langle \dot{\boldsymbol{r}}(t)\cdot\dot{\boldsymbol{r}}(0)\rangle dt = \frac{1}{3}\int_0^\infty \langle \boldsymbol{v}(t)\cdot\boldsymbol{v}(0)\rangle dt$$

Le principal avantage : bien adapté au cas d'une molécule unique (comme un ion dans l'eau)

Difficultés :

1 - nécessite de sauvegarder les vitesses sur des intervalles de temps courts, comparable au pas d'intégration des équations du mouvement, *i.e.* à l'échelle de la fs.

2 – du fait des petites fluctuations de la fonction d'autocorrélation sur les temps longs, l'intégrale de celle-ci diverge lorsqu'elle est calculée sur la base de données discrètes

⟹ *Zwanzig and Ailawadi, Phys Rev, 182 (1969) 2890*

ISM11 : RAPPEL : FONCTIONS D'AUTO-CORRÉLATION

Fonction d'auto-corrélation F_{AC} associée à une grandeur temporelle $a(t)$:

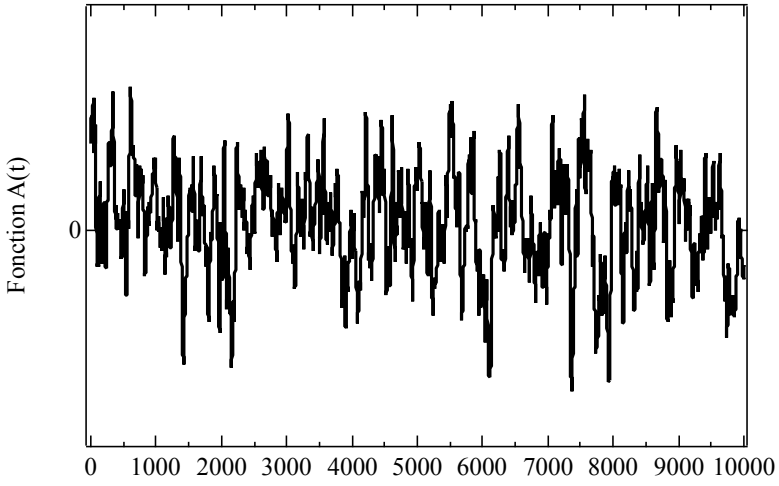

$$AC(A,t) = \langle A(t).A(0) \rangle$$

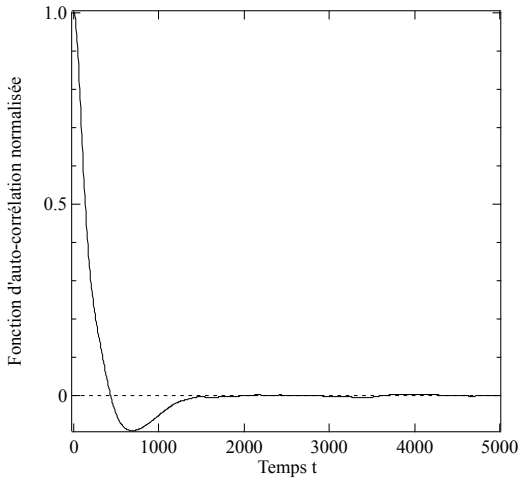

Algorithme en $O(N^2)$

Remarque, $AC(A,t)$ peut être calculée efficacement à l'aide de la Transformée de Fourier Rapide (FFT) dont la complexité varie en *O(NlogN)* (théorème de Wiener-Khintchine) :

$$AC(A,t) = \langle A(t).A(0) \rangle = \mathrm{FFT}^{-1}\left(\mathrm{FFT}(A) * \mathrm{FFT}(A)\right)$$

Les fonctions *AC* sont souvent associées à la notion de fonctions « mémoires » car elles permettent d'évaluer le temps moyen au bout duquel un phénomène n'est plus « influencé» par des évènements antérieurs.

ISM11 : AUTO-CORRELATION ET COEFFICIENT DE DIFFUSION

Exemple de fluctuations de la fonction d'auto-corrélation des vitesses d'un ion le long de trajectoires indépendantes sur des temps courts et impact sur le calcul du coefficient de diffusion.

Fonctions d'auto corrélation des vitesses

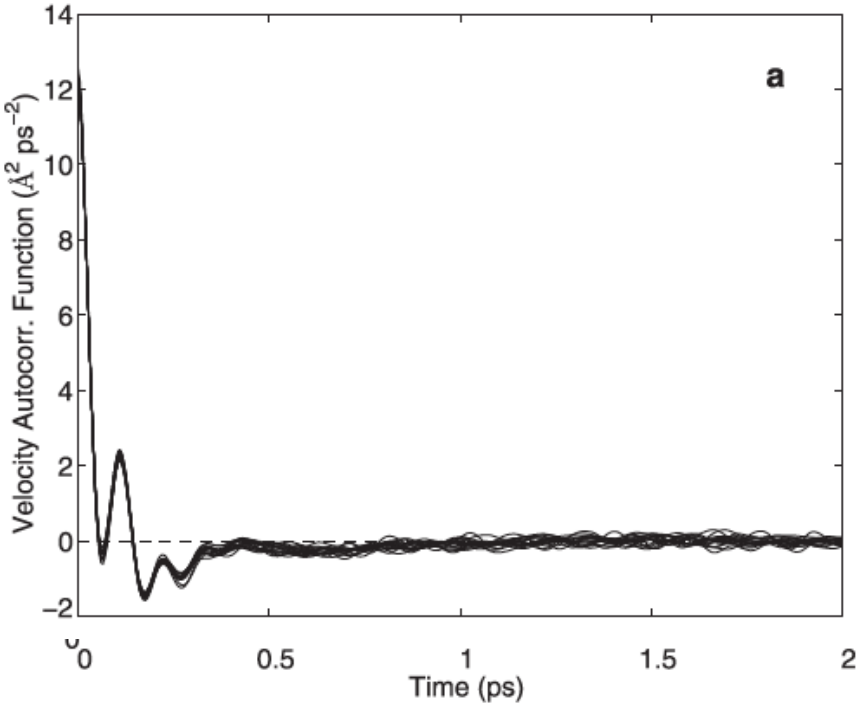

Intégrales des fonctions d'auto corrélation des vitesses

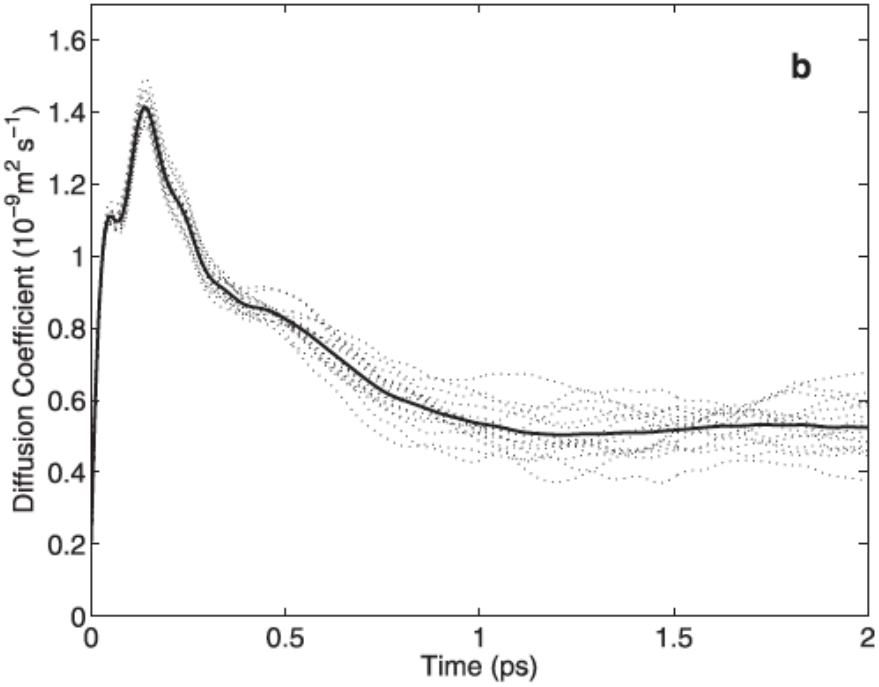

Fig. 3. (a) Example of MD-calculated velocity autocorrelation function VAF(t) of CO_3^{2-} at 298 K based on a set of 16 simulations. (b) Diffusion coefficient calculated by integrating VAF(t) over time (see text). Dotted lines: all 16 runs; solid line: mean value.

Zeebe R.E. , Geochimica and Cosmochimica Acta, 75 (2011) 2483

ISM11 : COEFFICIENT DE DIFFUSION ET CONDITIONS PÉRIODIQUES

Coefficients de diffusion, calculés suivant la relation de Green Kubo, de l'eau pure à différentes températures pour différentes tailles de boites de simulation et conditions périodiques.

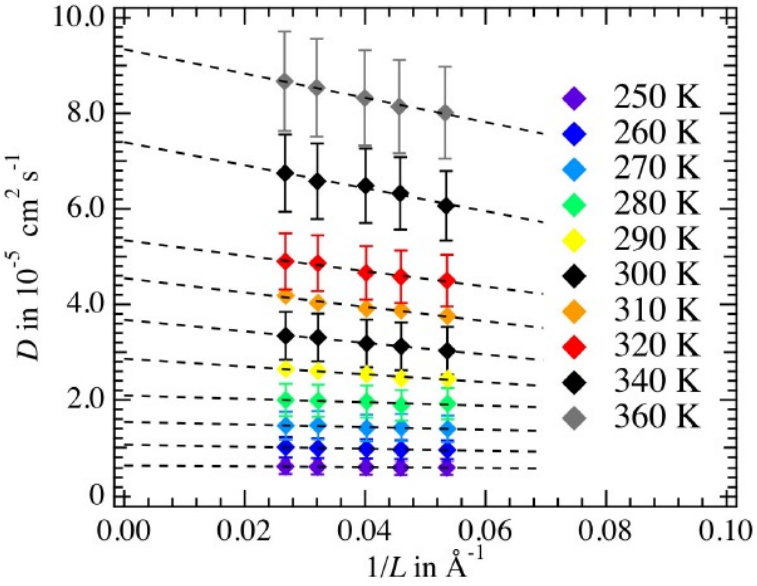

FIG. 7: Coefficients of diffusion D_{sim} computed for various water cubic boxes, whose size is L, for different temperatures, at P = 1 atm. The linear regression fits providing the coefficients of diffusion D_∞ and the shear viscosities η are shown is dashed lines.

Réal et al, J Chem Phys, 139 (2013) 114502

D'après Yeh et Hummer, le coefficient de diffusion D_{CP} calculé à l'aide de simulations en conditions périodiques est une fonction de la taille L de la boite de simulation principale cubique :

$$D_{CP} = D - \frac{k_B T \xi}{6\pi\mu L}$$

qui converge pour $L \to \infty$ vers la valeur du coefficient de diffusion D d'un système « réel » condensé et infini.

Ici, μ est la viscosité de la phase condensée simulée et ξ est une constante ≈2,837297.

Yeh and Hummer, J. Phys. Chem. B 108, 15873

ISM11 : CALCUL DE LA VISCOSITÉ

Viscosité : mesure la résistance d'un fluide à la déformation. Elle résulte des frictions internes entre les différentes couches du fluide. Propriété fondamentale en cosmétique. Par exemple, la viscosité d'un shampoing peut être fortement altéré lors de l'ajout d'un alcool, c'est à dire de parfums.

Comme le coefficient de diffusion, elle se calcule par la relation de Green-Kubo en considérant le tenseur du viriel (tenseur de pression) :

$$V\Pi_{\alpha\beta} = \sum_{i=1}^{N} \vec{F}_{\alpha}^{i} \cdot \vec{r}_{\beta}^{i}$$

$\vec{r}_{\beta}^{i}$ coordonnée β d'une particule et $\vec{F}_{\alpha}^{i}$ composante α de la force agissant sur elle, *V* volume de la phase condensée considérée. Remarque, la pression au sein de cette phase condensée :

$$\mathrm{P}V = Nk_BT + \frac{1}{6}V\left(\overline{\Pi}_{\alpha\alpha} + \overline{\Pi}_{\beta\beta} + \overline{\Pi}_{\gamma\gamma}\right)$$

Relation de Green-Kubo permettant de calculer la viscosité dynamique :

$$\eta = \frac{V}{k_BT}\int_0^{\infty} \left\langle \overline{\Pi}_{\alpha\beta}(t).\,\overline{\Pi}_{\alpha\beta}(0) \right\rangle dt$$

Toute les remarques concernant le coefficient de diffusion s'applique ici sauf a priori la dépendance de cette grandeur à la taille de boite de simulation.

ISM11 : Intégrale d'une fonction d'autocorrelation : minimiser l'erreur

Divergence de l'intégrale de la fonction d'autocorrélation des vitesses sur des temps longs : comme dans le cas du coefficient de diffusion, cette divergence dépend des effets chaotiques inhérents à une simulation de dynamique moléculaire.

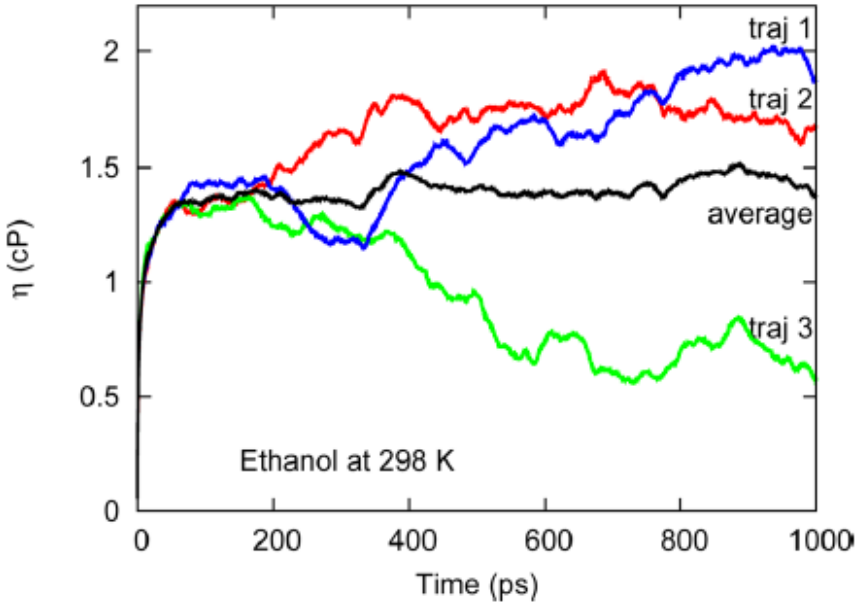

Figure 1. Example results of viscosity calculations using the Green–Kubo relation based on three independent 10 ns trajectories generated for ethanol at 298 K. Due to the well-known long time noise in the pressure autocorrelation function, the three running integrals deviate in less than 100 ps and end up at significantly different values at 1 ns, which makes it very difficult to derive a reliable viscosity from such calculation. The average of the three running integrals is also provided in the plot, which is much smoother than each individual integral.

Cas du calcul de la viscosité de l'éthanol pure à l'état liquide, avec vitesses sauvegardées toutes les 1 fs. Ici résultats concernant 3 simulations indépendantes réalisées avec des conditions initiales différentes.

Zhang et al, J Chem Theor Comput, 11 (2015) 3537

ISM11 : Intégrale d'une fonction d'autocorrelation : minimiser l'erreur

Exemple de divergence de l'intégrale de la fonction d'auto-corrélation du tenseurs des pression (calcul de la viscosité cf. plus avant) sur des temps longs à l'échelle de 100 ps

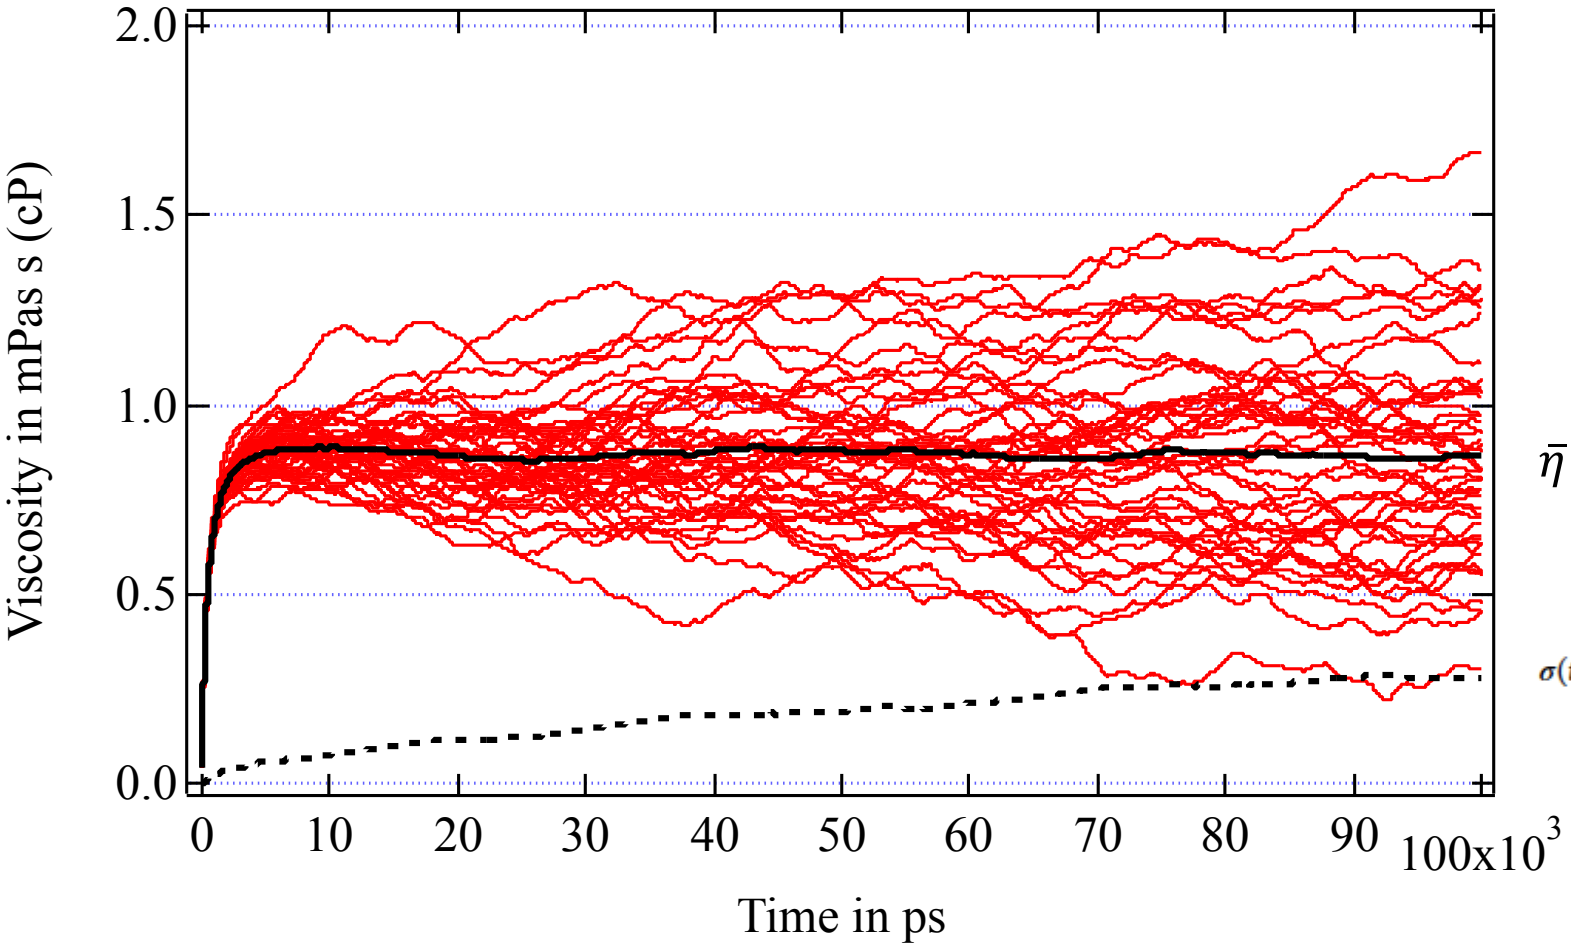

$$\bar{\eta}(t) = \frac{1}{N}\sum_{i=1}^{N} \eta_i(t)$$

$$\sigma(t) = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N} (\eta(t)_i - \langle \eta(t) \rangle)^2}$$

Zhang et al, J Chem Theor Comput, 11 (2015) 3537

ISM11 : INTÉGRALE D'UNE FONCTION D'AUTOCORRELATION : MINIMISER L'ERREUR

Hypothèse, jouer sur les effets chaotiques pour réduire l'erreur concernant les intégrales de Green Kubo en moyennant celles-ci sur une grand nombre de trajectoires indépendantes :

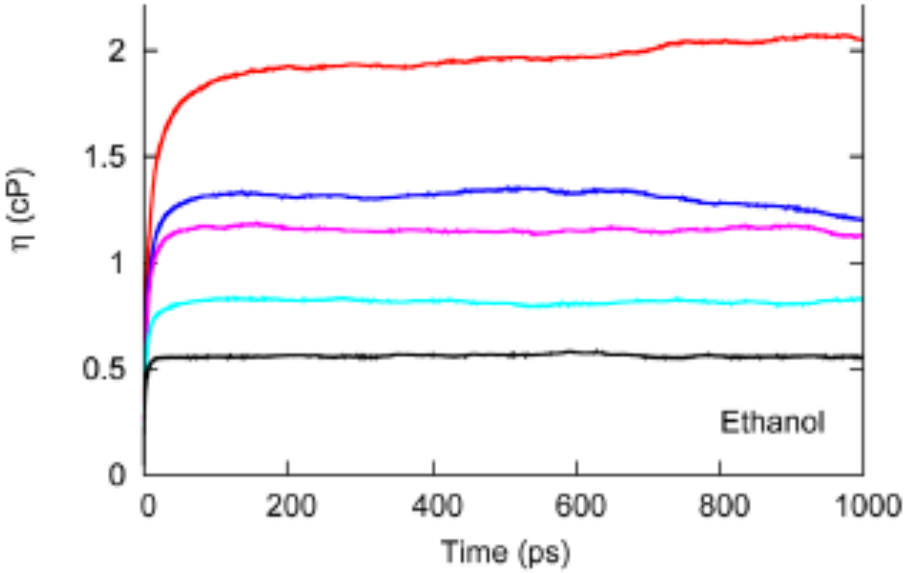

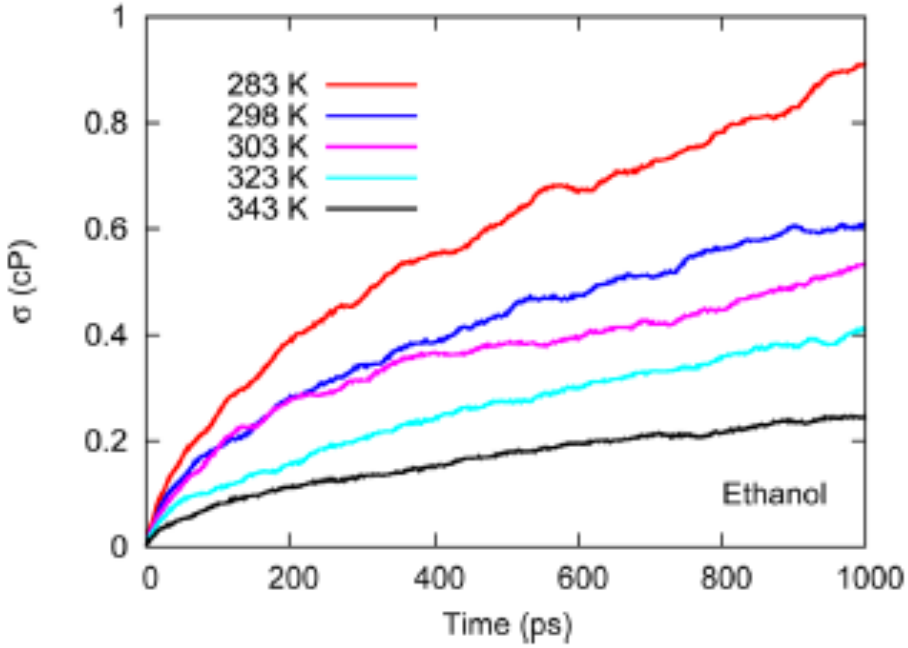

Figure 3. Calculated averaged running integral (eq 1) and standard deviation (eq 3) from 100 independent 5 ns long equilibrium MD trajectories for ethanol at different temperatures.

$$\sigma(t) = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N}(\eta(t)_i - \langle\eta(t)\rangle)^2}$$

Zhang et al, J Chem Theor Compt, 11 (2015) 3537

ISM11 : TEMPS DE RESIDENCE MOYEN

Soit une molécule ou particule A dans une phase condensée homogène ou hétérogène, nombre de techniques expérimentales permettent de mesurer une propriété (une grandeur physique) dépendant du temps de présence d'autres particules au voisinage de A.

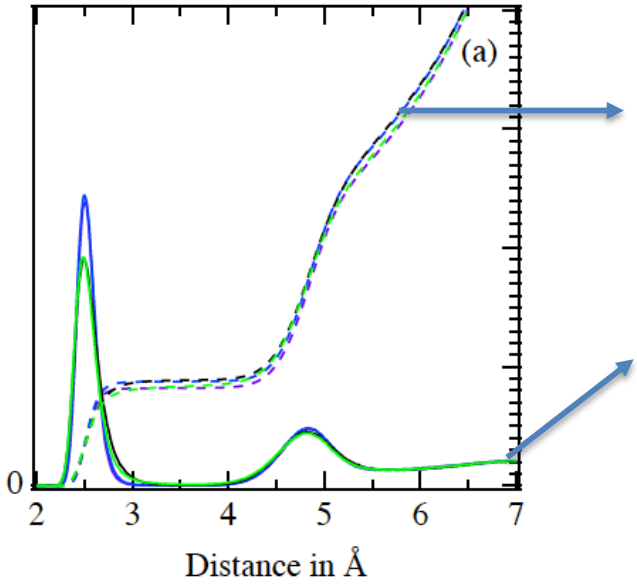

Cas de l'ion Th4+ dans l'eau à température ambiante

$N(R) = 4\pi \int_0^R g(r) r^2 dr$, nombre de coordination

$g(r) = \frac{\bar{n}(r)}{4\pi r^2 dr}$, fonction de distribution radiale, permet de définit le Potential of Mean Force PMF :

$$\mathrm{PMF}(r) = exp - (\frac{g(r)}{k_B T})$$

Ici, le temps moyen de résidence en 1ère sphère de coordination correspond au temps moyen passé par les molécules/particules à une distance *R* < 3-4 Å de la particule A.

ISM11 : TEMPS DE RESIDENCE MOYEN

Temps de résidence moyen : nécessite de définir la zone de résidence des particules

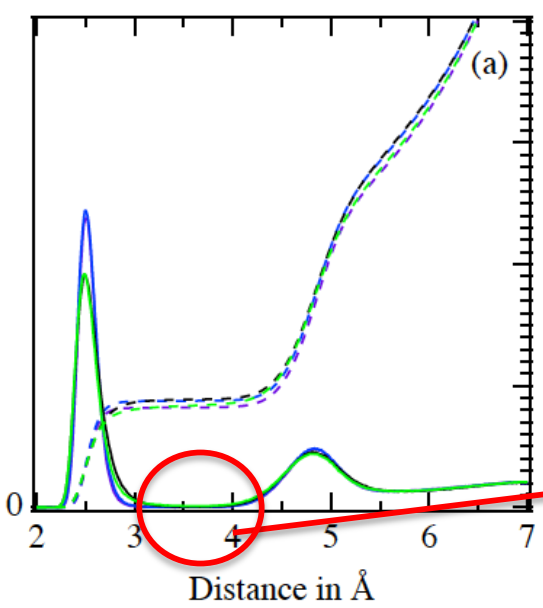

Cas de l'ion Th4+ dans l'eau à température ambiante

?

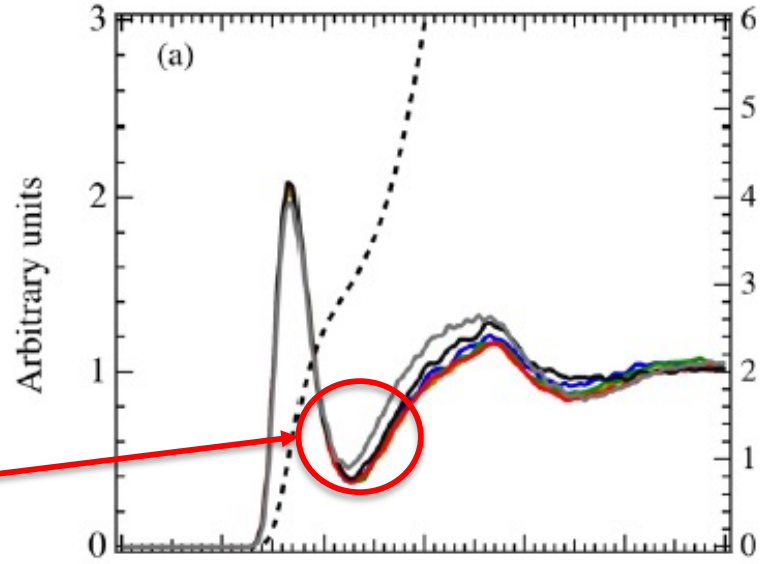

Cas de l'ion carboxylate dans l'eau liquide et à température ambiante

La 1ère sphère de coordination est toujours bien définie pour des ions très chargés, beaucoup moins pour des ions courants ($HCOO^-$, NH_4^+) et des molécules neutres…

ISM11 : TEMPS DE RESIDENCE MOYEN : MÉTHODE D'IMPEY

Soit une zone de résidence autour d'une particule A arbitrairement définie. Une trajectoire de dynamique moléculaire est échantillonnée tout les intervalles de temps τ^*.

On définit la probabilité de survie $p_A(t_0, t_0 + t, \tau^*)$ à une date t d'une particule B au voisinage de A de la manière suivante. Si :

1 - à la date t_0, B est au voisinage de A ($r_{AB} < R$);
2 - dans toutes les k structures échantillonnées telles que $k\tau^* \leq t$, B est toujours au voisinage de A :

ALORS $p_A(t_0, t_0 + t, \tau^*) = 1$ SI NON $p_A(t_0, t_0 + t, \tau^*) = 0$

Sur la base de cette probabilité de survie, on calcule alors la fonction de corrélation :

$$C(t) = \frac{1}{\bar{n}} \left\langle \sum_{i=1}^{n(t_0)} p_A(t_0, t_0 + t, \tau^*) \right\rangle_{t_0} = \bar{n} \times \exp\left(-\frac{t}{T_{res}}\right)$$

Temps de résidence moyen

Ici, $n(t_0)$ nombre de B au voisinage de A à la date t_0 et $\bar{n}$ nombre moyen de B au voisinage de A.

Impey et al, J Phys Chem, 87 (1983) 5071

ISM11 : TEMPS DE RESIDENCE MOYEN : MÉTHODE D'IMPEY

La méthode d'Impey est très sensible à l'intervalle d'échantillonnage τ^* des trajectoires de dynamiques moléculaires

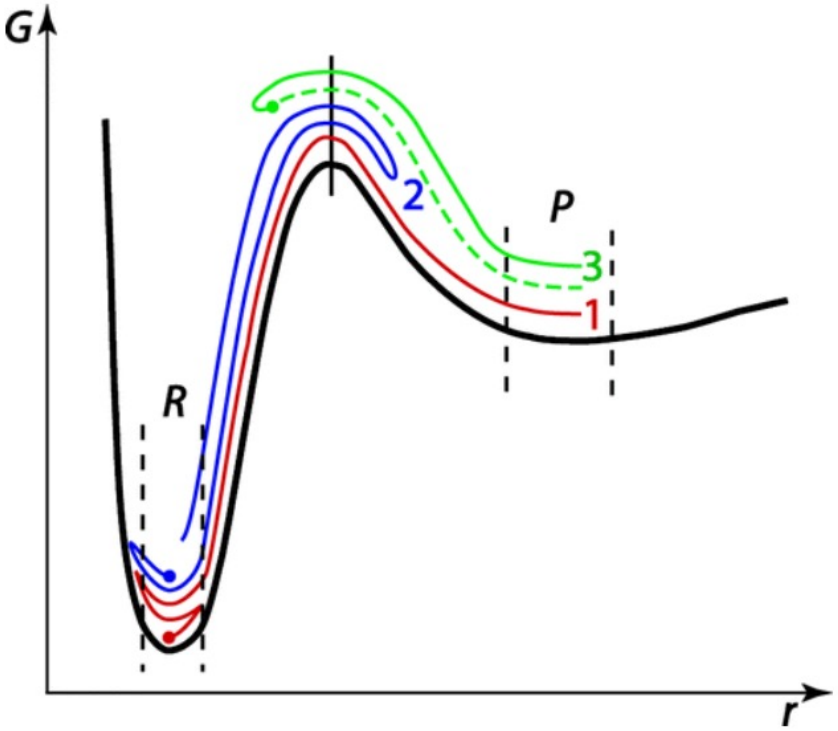

Profil classique de PMF i.e. $-k_B \mathrm{T} \ln\big(g(r)\big)$ avec différentes « trajectoires » d'une molécule/particule B au voisinage d'un atome A.

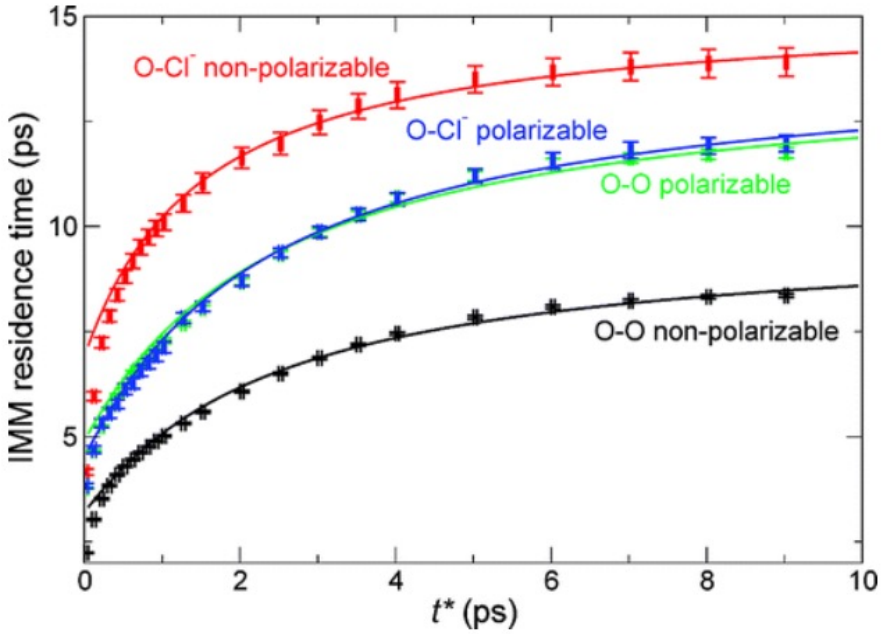

Convergence de T_{res} au sens d'Impey en fonction de τ^* pour différents champs de force modélisant l'eau liquide.

Laage and Hynes, J Phys Chem B, 112 (2008) 7697

ISM11 : VALEUR MOYENNE D'UNE GRANDEUR LE LONG D'UN TRAJECTOIRE

Soit une trajectoire de dynamique moléculaire échantillonnée tous les intervalles de temps τ^*.

Quelle est l'incertitude due à la durée finie $\Delta t = n\tau^*$ de cette trajectoire sur la moyenne d'une grandeur *F* quelconque (distance entre atomes, énergie potentielle, etc…) ?

Valeur moyenne le long de la trajectoire $$\bar{F}_n = \frac{1}{n}\sum_{i=1}^{n} F(i)$$

Incertitude à cette moyenne $$0 \leq \bar{F}_\infty - \bar{F}_n \leq \delta\bar{F}$$

Mathématiquement si toutes les conformations échantillonnées le long de la trajectoire ne sont pas temporellement corrélées alors

$$\delta\bar{F} = \frac{1}{\sqrt{n}}\sqrt{\frac{\overline{F_n^2} - \bar{F}_n^2}{n}}$$

Ecart type

Remarque si $n \to \infty$ alors $\delta\bar{F} \to 0$

ISM11 : VALEUR MOYENNE D'UNE GRANDEUR LE LONG D'UN TRAJECTOIRE

Mais si les conformations échantillonnées **SONT** temporellement corrélées alors

$$\delta\bar{F} = \frac{\sqrt{\overline{F_n^2} - \bar{F}_n^2}}{n} \times \left(1 + 2\sum_{i=1}^{n}\left(1 - \frac{i}{n}\right)C(i\tau^*)\right) = \delta\bar{F}_{nc} + \delta\bar{F}_{correc}$$

Ici, $C(t)$ est la fonction d'auto-corrélation de F à la date $t = i\tau^*$

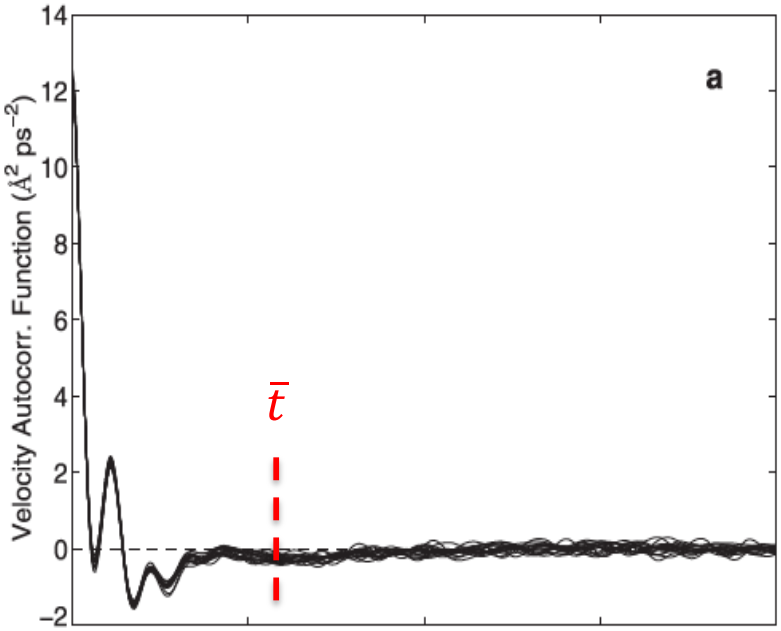

Exemple de fonction d'auto-corrélation $C(t)$

1 - Si τ^* est petit, i.e. plus petit que le temps moyen $\bar{t}$ au bout duquel $C(t > \bar{t}) \approx 0$, alors $\delta\bar{F}_{correc}$ n'est pas négligeable…

2 - Si τ^* grand, plus grand que $\bar{t}$ alors $\delta\bar{F} = \delta\bar{F}_{nc} = \frac{\sqrt{\overline{F_n^2} - \bar{F}_n^2}}{n}$

3 - Si τ^* petit, mais *n* très grand alors $\delta\bar{F} = \delta\bar{F}_{nc} + \delta\bar{F}_{correc}$ est négligeable…

ISM11 : MOYENNES TEMPORELLES - DERNIÈRE REMARQUE

Soit un système microscopique dont la surface d'énergie potentielle présente deux minima

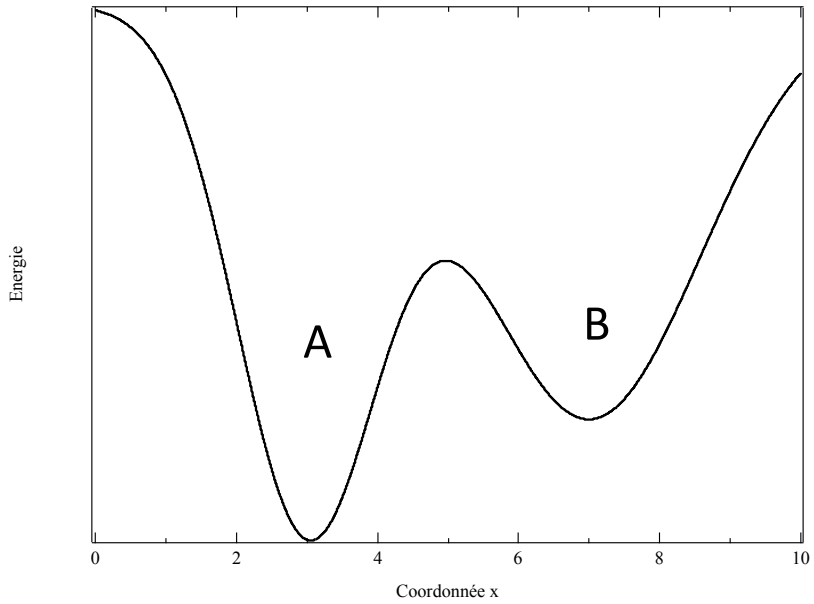

Les deux minima d'énergie sont proches en énergie mais séparés par une barrière d'énergie qui peut être grande…

⇒ **bien échantillonner la surface d'énergie de ce système signifie bien échantillonner ces deux minima.**

Car sinon même si $\tau^* > \bar{t}$, la moyenne calculée sera « fausse », mais au sens d'un échantillonnage thermodynamique biaisé ;

Par contre si $\tau^* > \bar{t}$ et que le système reste prisonnier dans le minimum A par exemple, alors toutes les moyennes $\bar{F}_n(A)$ calculées correspondrons au système dans son état minimum A avec pour incertitude :

$$\delta\bar{F}(A) = \sqrt{\frac{\overline{F_n^2}(A) - \bar{F}_n^2(A)}{n^2}}$$

ISM11 : ANNALES EXAMENS 2019

I.25 Quelle(s) approche(s) permet(tent) de calculer des propriétés temporelles d'un système microscopique
Réponse : dynamique moléculaire standard, méthode Monte Carlo, Replica Exchange, Umbrella Sampling ?

I.26 Est-il pertinent de calculer des propriétés temporelles (par exemple la viscosité) le long d'une trajectoire réalisée à l'aide de l'approche méta-dynamique ? Pourquoi ?
Réponse à développer (une ligne)

I.27 Soit la surface d'énergie potentielle S d'un système moléculaire. L'approche Replica Exchange couplée à des simulations de type dynamique moléculaire permet
Réponse : de toujours accélérer l'exploration de toute cette surface S, d'avoir recours à des dynamiques moléculaires courtes, ne nécessite aucune communication de type MPI, de favoriser le passage de toutes les barrières d'énergie de la surface S ?

I.30 Est-il nécessaire d'explorer intensivement toute la surface d'énergie potentielle d'un système moléculaire lors de l'estimation d'une grandeur temporelle ?
Réponse : oui, non ?

I.31 Si il était possible de réaliser « rapidement » des simulations de type dynamique moléculaire correspondant à des temps de simulation infinis, les approches méta-dynamique, Umbrella Sampling et Replica-Exchange seraient-elles
Réponse : toujours nécessaires, obsolètes, parfois encore utiles ?