ISM9 – Dynamique moléculaire et barrière d'énergie

1 – Position du problème

2 – Méthodes sans introduction de biais

- trajectoires indépendantes
- Recuit simulé ("simulated annealing")

3 – Méthodes avec introduction d'un potentiel de perturbation

- Conformational Flooding
- Meta-dynamique
- Swarm-MD
- Umbrella sampling

ISM9 – POSITION DU PROBLÈME

En modélisation moléculaire, les potentiels d'interaction microscopique (champs de force) ne dépendent que des positions des atomes/particules. En conséquence, la fonction de partition des vitesses peut être 'découplée' de celle des positions

$$Z \propto Zp \times \iiint_V \exp(-\frac{U\left(\{\vec{r}_i\}\right)}{k_B T}) \Pi_{i=1}^{N} d\vec{r}_i$$

$$Zp = \iiint_V \Pi_{i=1}^{N} \exp(-\frac{m_i v_i^2}{2k_B T}) d\vec{v}_i$$

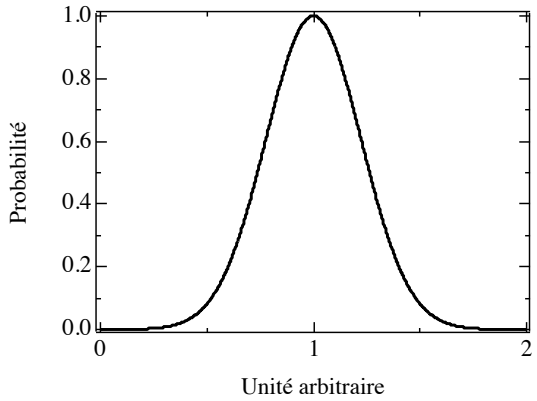
Autrement dit, la distribution des probabilités d'observer un jeu de vitesses obéit à une loi gaussienne, ce qui implique que des vitesses très élevées même à faible température sont possibles, mais leur probabilité est très faible.

Rappel : les vitesses des particules d'un système microscopique permettent de définir la température macroscopique de ce système

$$N_{df} k_B T = \bar{K} \quad \text{et} \quad K = \frac{1}{2} \sum_{i=1}^{N} m_i v_i^2$$

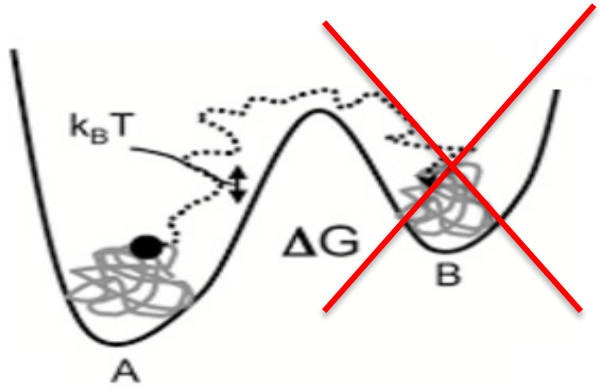
ISM9 – POSITION DU PROBLÈME

La distribution des probabailités des vitesses suit une loi gaussienne :

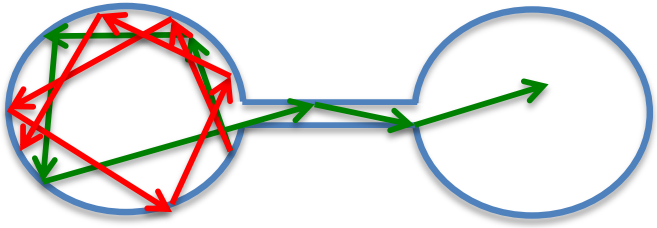


$$P_T\left(\vec{v}_i\right) = \exp\left(-\frac{m_i v_i^2}{2k_B T}\right)$$

Dès lors, il n'est pas impossible pour un système microscopique de passer des barrières d'énergie élevées lors d'une dynamique moléculaire, mais plus la barrière est élevée plus la probabilité est faible, particulièrement si la simulation est de courte durée. Pourtant, deux minima de la surface d'énergie potentielle de poids statistiques identiques peuvent être séparés par une barrière très élevée ➔ une simulation de dynamique moléculaire amènera donc à un calcul de la fonction *Z* erroné si le système ne peut passer d'un minima à l'autre.



ISM9 – PASSER DES BARRIÈRES EN JOUANT SUR LES EFFETS CHAOTIQUES



Etat A Etat B

Soit un système microscopique initialement dans une structure notée S, le protocole suivant

1 – *M* trajectoires indépendantes du système sont lancées en parallèle à partir de sa structure S

2 – Si une transition S ➔ S' est observée le long d'une seule trajectoire : arrêt de toutes les trajectoires.

3 – *M* nouvelles trajectoires sont relancées en considérant comme structure initiale la nouvelle structure S'…

Cette approche permet de réduire par un facteur *M* le temps moyen $\overline{t}_1$ obtenu à l'aide d'une seule simulation pour observer la transition structurale S → S' pour un système à deux états

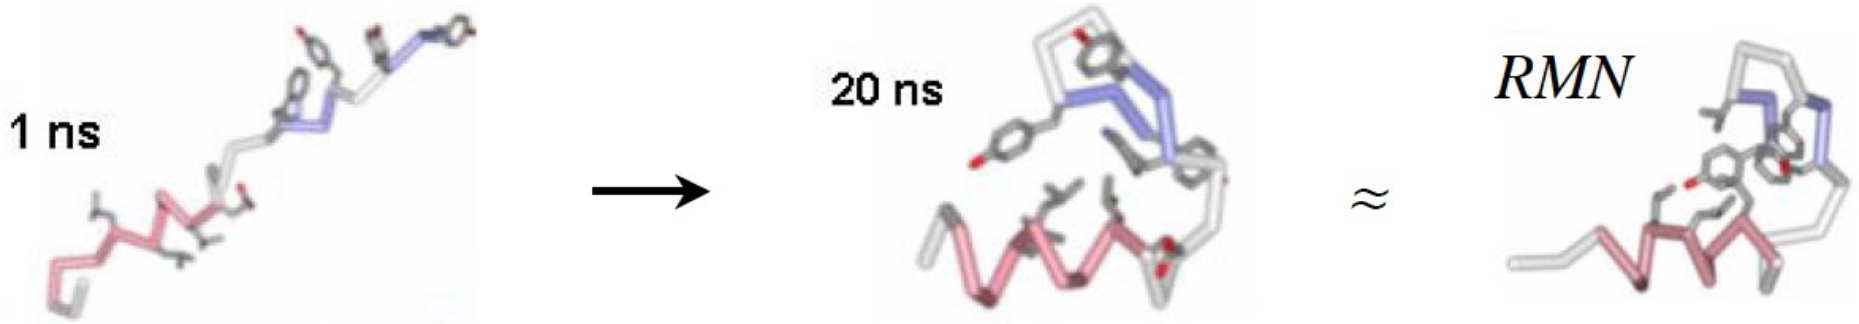
$$\overline{t}_M = \frac{1}{M}\overline{t}_1$$

A.F. Voter, Phys. Rev. B, 57 (1998) 13985

ISM9 – LE PROJET FOLDING@HOME

Folding@home : des particuliers mettent à disposition leurs ordinateurs personnels pour réaliser des jeux de simulations à très grande échelle.

Etude théorique du repliement de la protéine BBA5 (repliement de protéine : problème NP-hard)



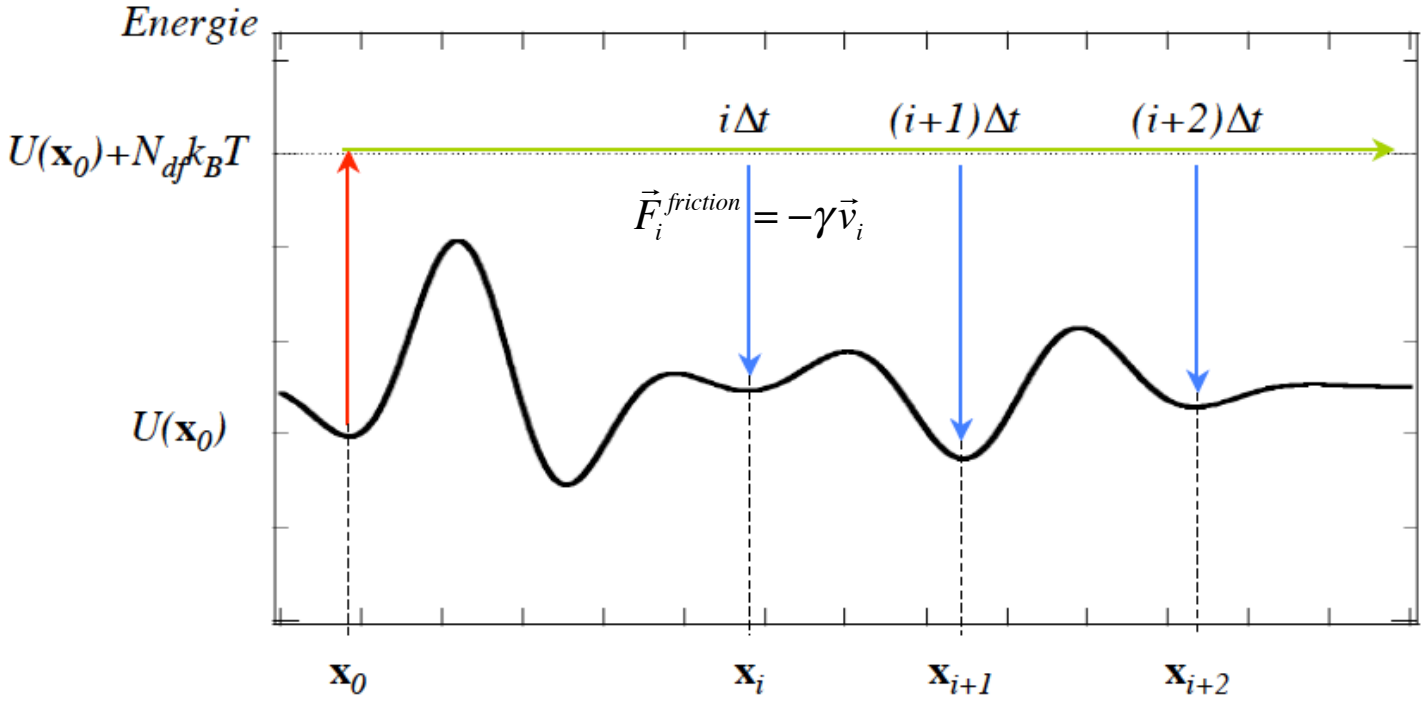
30 000 simulations de 20 ns réalisées, 100 repliements effectifs observés,
temps caractéristique de repliement 7,5 µs à comparer au 6,0 µs expérimental

Snow et al, *Nature*, 420 (2002) 102

ISM9 – RECUIT SIMULÉ

L'objectif est de générer un grand nombre de structure pouvant avoir un poids statistique significatif dans la fonction de partition du système.

Le principe est de « chauffer » le système à haute température, ce qui lui permet de passer facilement les barrières d'énergie. Un fois la simulation réalisée, on considère des structures le long de celle-ci (avec leurs vitesses) et on applique un coefficient de friction aux équations du mouvement pour pour ramener le système à T = 0 K.



L'énergie cinétique du système est $\overline{K} = N_{df}k_BT$

Kirkpatrick et al, *Science*, 220 (1983) 671

ISM9 – REPLICA EXCHANGE AVEC COUPLAGE EN TEMPÉRATURE

La méthode de recuit simulé peut être considérée comme le couplage entre deux simulations à une température élevée *T* et à 0 K. Mais la distribution obtenue à *T* = 0 K ne permet pas de calculer directement la fonction de partition du système.

En considérant le critère de Métropolis suivant $\text{avec } 0 \le \xi_{random} \le 1$:

$$\mathrm{P}_{n-1\to n}\left\langle \vec{X}_n \middle| \vec{X}_{n-1} \right\rangle = \exp\left(-\left(\frac{1}{k_B T_n} - \frac{1}{k_B T_{n-1}} \right)\left(U_n(\vec{X}_n) - U_{n-1}(\vec{X}_{n-1}) \right) \right) < \xi_{random}$$

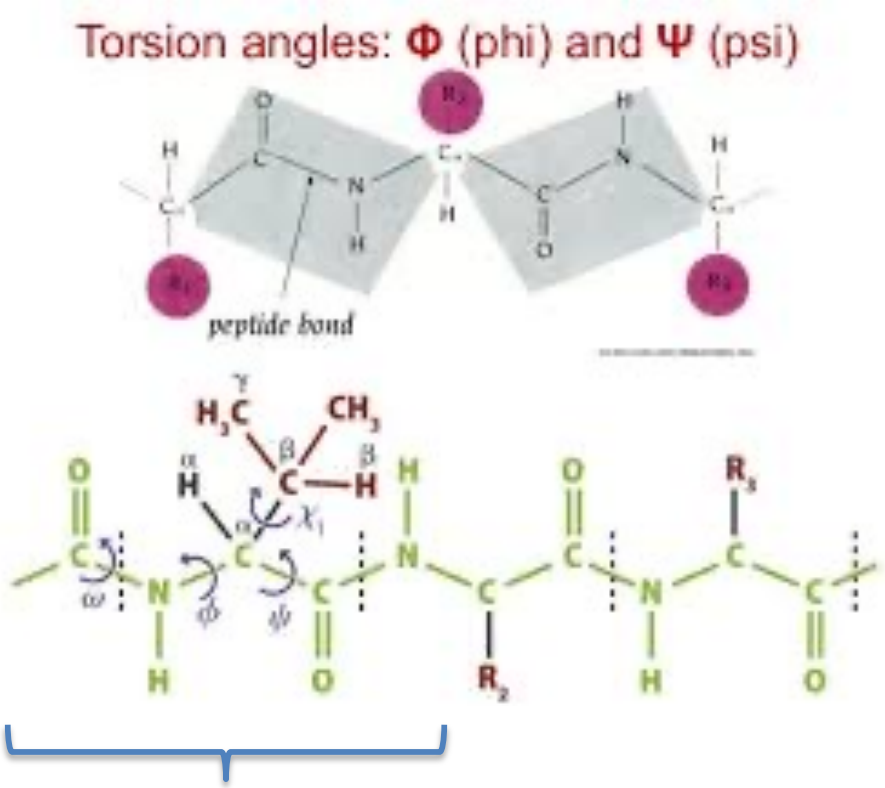
Il est possible de coupler un jeu de *M* simulations réalisées à différentes températures $\{T_i\}_{1\le i\le M}$ d'un même système, et générer alors des distributions de structures de ce système permettant de calculer la fonction de partition à chaque température T_i.

Périodiquement, les énergies potentielles U_i et U_j de deux trajectoires sont comparées. Si le critère de Métropolis est vérifié, les structures sont échangées entre les deux trajectoires. **Une « trajectoire » ne correspond plus alors à un phénomène dynamique continu, mais contient des successions de structures localement échantillonnées.**

Sugita and Okamata, *Chem. Phys. Lett.* , 314 (1999) 121

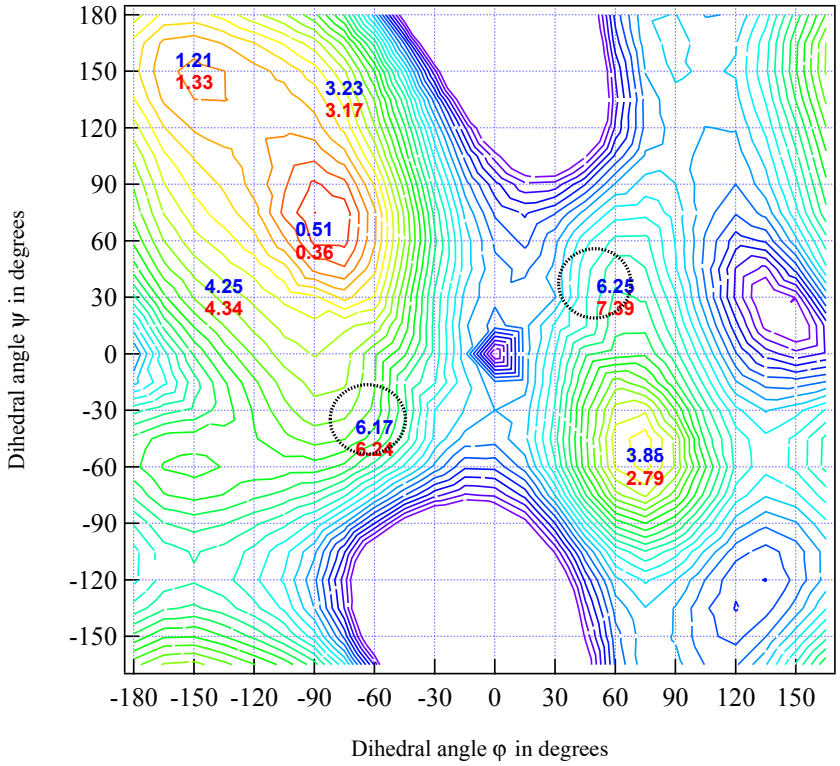
ISM9 – REPLICA EXCHANGE : CAS D'UN DIPEPTIDE

Peptides-protéines : polymères d'acides aminés



dipeptide

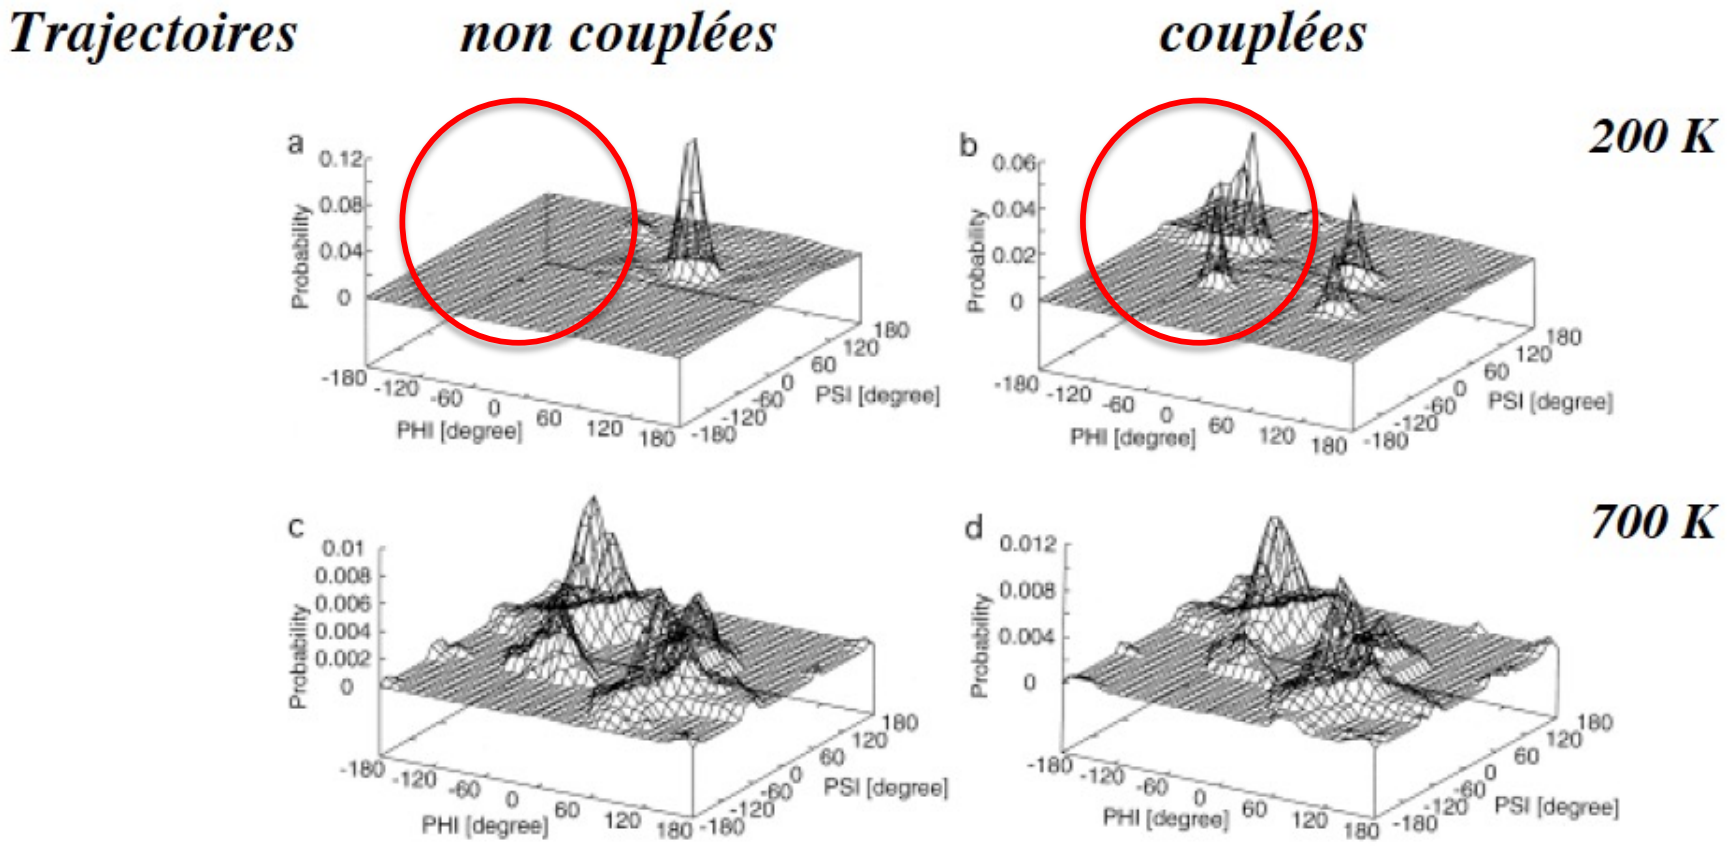
Contour d'énergie φ, ψ



Cas du dipeptide alanine
(bleu : résolution équation de Schrödinger)

ISM9 – REPLICA EXCHANGE AVEC COUPLAGE EN TEMPÉRATURE

Exemple : dipeptide gly-gly, températures simulées 200, 239, 286, 342, 409, 585 et 700 K. Simulation de 1 ns, transitions évaluées toutes les 10 fs.

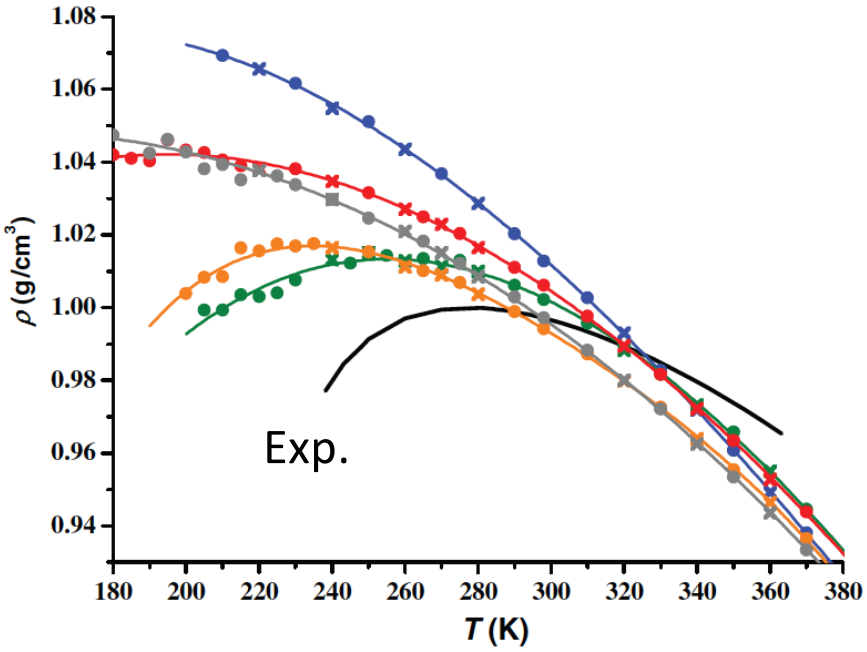


Difficulté : le champ de force est-il « transférable » à toutes les températures simulées ?

Sugita and Okamata, *Chem. Phys. Lett.* , 314 (1999) 121

ISM9 – TRANSFÉRABILITÉ D'UN CHAMP DE FORCE EN TEMPÉRATURE ?

Cas de champs de force qui simulent l'eau liquide correctement à 300 K (26,5 ° C) mais à aucune autre température… C'est le cas de tous les champs de force « efficaces » qui ne sont pas capables de reproduire la température du maximum de la densité de l'eau liquide.



Model	TMD (K)	ρ_{TMD} (g/cm^3)
SPC	228	1.008
SPC/E	241	1.012
TIP3P	182	1.038

Kiss and Baranay, J Chem Phys, 137 (2012) 084506

Quid des quantités thermodynamiques à des températures différentes de *T* = 300 K ?

ISM9 – REPLICA EXCHANGE AVEC COUPLAGE D'HAMILTONIEN

Au lieu de simuler un même système à des températures différentes, le système sera simulé de multiples fois (*replica*) avec des Hamiltoniens (énergies totales) altérés :

Hamiltonien : $H = E_{tot} = U + K$

En fait on n'altère que la partie énergie potentielle du système, *i.e.* pour un champ de force classique :

$$U = U^{stretching} + U^{bending} + U^{torsion} + U^{Lennard-Jones} + U^{Coulomb}$$

Exemple : soit une molécule A plongée dans une boite contenant *N* molécules d'eau (système noté B), une manière d'altérer l'énergie *U* du système (A,B) pour explorer toutes les configurations possibles de A est de réécrire U sous la forme :

$$U = (U^{stretching} + U^{bending} + U^{torsion})(A + B) + U^{LJ}(A) + U^{LJ}(B) + U^{LJ}(A/B) + U^{C}(A) + U^{C}(B) + U^{C}(A/B)$$

ISM9 – REPLICA EXCHANGE AVEC COUPLAGE D'HAMILTONIEN

Chaque *replica* est associé à un Hamiltonien distinct (avec $0 \leq \lambda \leq 1$) :

$$U = (U^{stretching} + U^{bending} + U^{torsion})(A + B) + U^{LJ}(B)) + U^{C}(B) + \boldsymbol{\lambda}\left[\boldsymbol{U^{LJ}(A) + U^{LJ}(A/B) + U^{C}(A) + U^{C}(A/B)}\right]$$

qui tous peuvent être réécrits sous la forme plus compacte

$$U(\lambda) = U^{atomes_liés}(A + B) + U^{non_liés}(B) + \boldsymbol{\lambda}\left[\boldsymbol{U^{non_liés}(A) + U^{non_liés}(A/B)}\right]$$

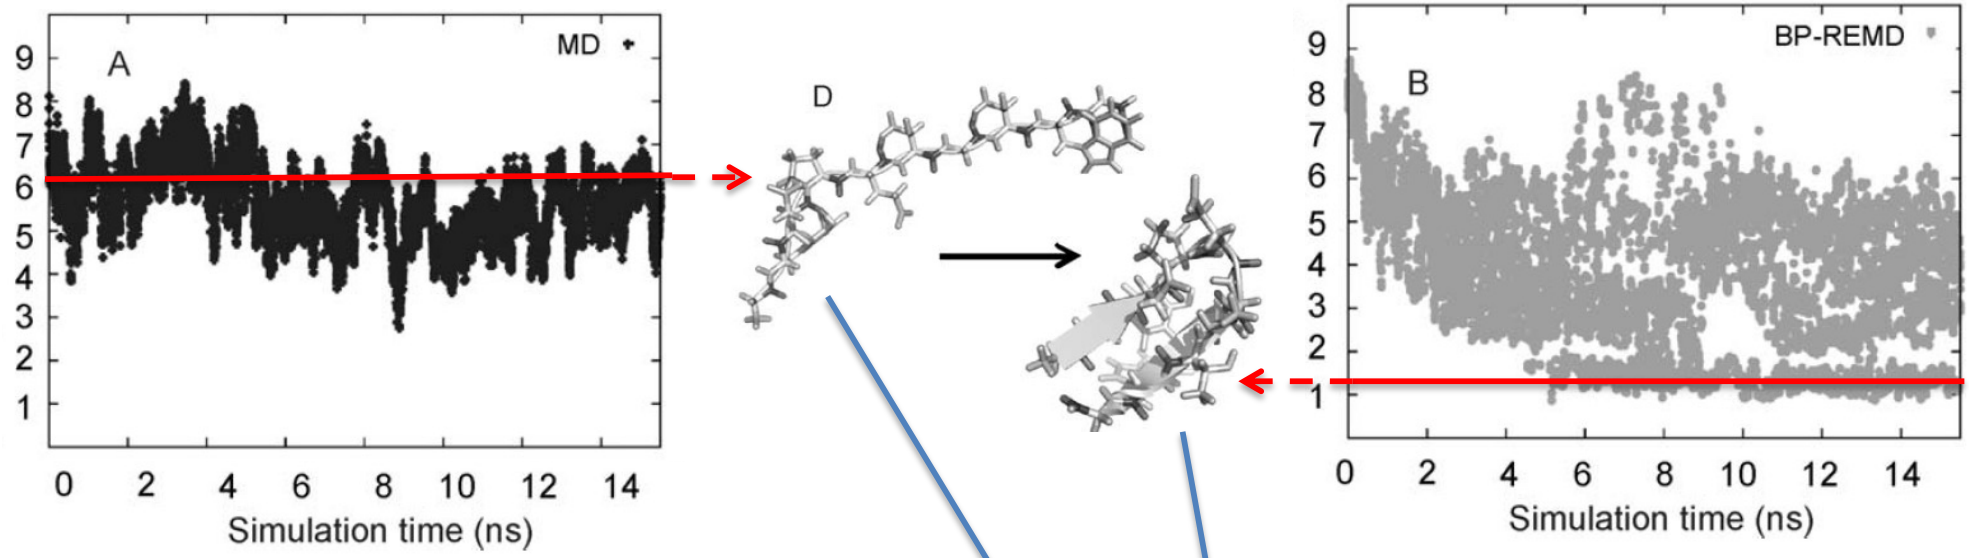
Pratiquement, on génère *M* simulations correspondant chacune à un λ_n différent, le critère de Métropolis est alors

$$P_{n \to n+1}\left\langle \vec{X}_n \middle| \vec{X}_{n+1} \right\rangle = \exp\left(-\frac{1}{k_B T}\left(U_{n+1}(\vec{X}_n) - U_n(\vec{X}_{n+1})\right)\right) \leq \zeta_{random}$$

http://www.chim.unifi.it/orac/MAN/node23.html

ISM9 – REPLICA EXCHANGE ET REPLIEMENT DE PROTÉINES

Les approches de type *Replica Exchange* suscitent de l'intérêt aujourd'hui pour traiter le problème du repliement des protéines à l'aide de processeurs CPU standards ou de GPUs.



Une simulation unique

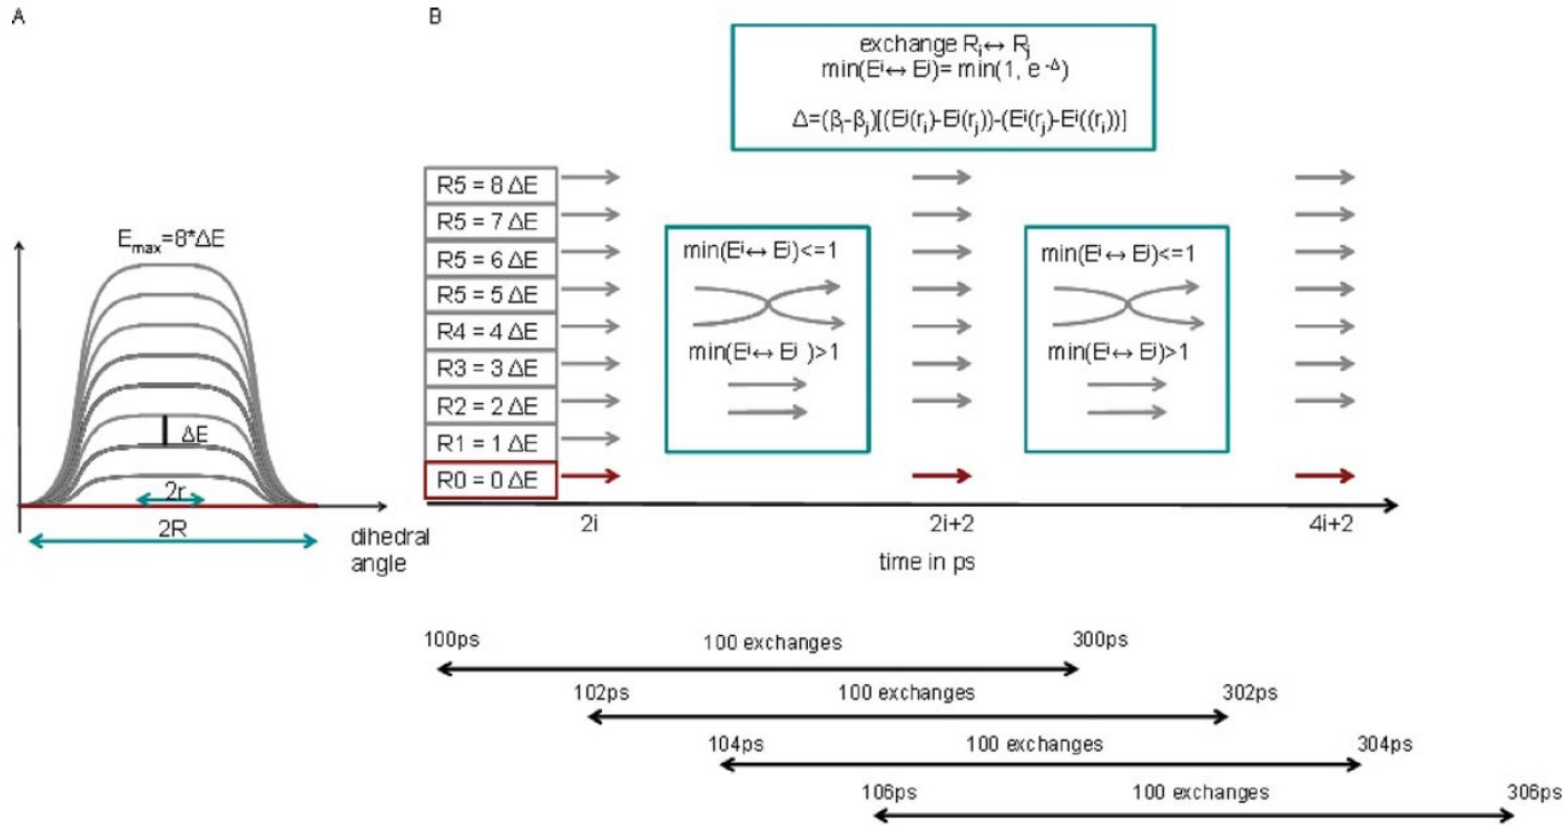
9 simulations couplées

$$RMSD(C_\alpha) = \sqrt{\frac{1}{n_\alpha}\sum_{i=1}^{n_\alpha}(\vec{R}_i - \vec{R}_i^{ref})^2}$$

Ostermeir and Zacharias, J Comput Chem, 35 (2014) 150

ISM9 – REPLICA EXCHANGE ET PARALLELISME

Replica Exchange est basé sur des simulations « faiblement » couplées. Dans ce cadre, une approche est d'évaluer les probabilités d'échange/faire les échanges de manière asynchrone (décalée).

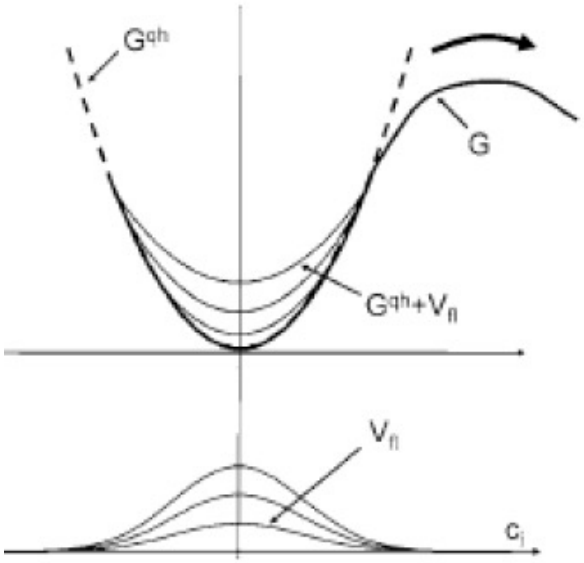


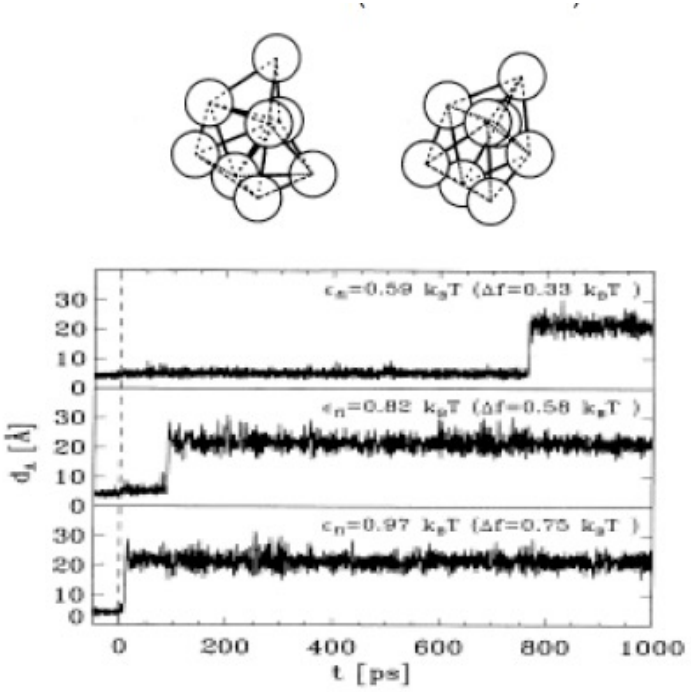
Ostermeir and Zacharias, J Comput Chem, 35 (2014) 150

ISM9 – MÉTHODES AVEC BIAIS : CONFORMATIONAL FLOODING

Le long d'une trajectoire, si un système est piégé dans un minimum, on considère le jeu de structures générées au voisinage de ce minimum $\left(\{\vec{r}_i\}_{1\le i\le N}^{k}\right)_{1\le k\le M}$. On peut alors calculer la matrice de covariance $C=\left\langle\left(\vec{r}_i-\langle\vec{r}_i\rangle\right)\left(\vec{r}_i-\langle\vec{r}_i\rangle\right)^T\right\rangle$ puis la diagonaliser et introduire alors une énergie potentielle dite de « *flooding* » :

$$U^{flooding}=\varepsilon_{flooding}\exp\left(-\frac{1}{2\gamma_{flooding}}\vec{c}\,\Lambda\vec{c}^{\,T}\right)$$





ISM9 – LA MÉTA-DYNAMIQUE

Le long d'une trajectoire, si un système est piégé dans un minimum, on considère le jeux de structures générées au voisinage de ce minimum $\left(\{\vec{r}_i\}_{1\le i\le N}^{k}\right)_{1\le k\le M}$. On peut alors calculer ~~la matrice de covariance $C=\left\langle\left(\vec{r}_i-\langle\vec{r}_i\rangle\right)\left(\vec{r}_i-\langle\vec{r}_i\rangle\right)^T\right\rangle$ puis la diagonaliser et introduire alors une énergie potentielle dite de *flooding* :~~ introduire une énergie potentielle « mémoire » du domaine exploré à des dates antérieures à une date t_{ref}

$$\underbrace{\tilde{U}(\{\vec{r}_i\})}_{\text{valable } t>t_{ref}} = \underbrace{U^{potentielle}(\{\vec{r}_i\})}_{\text{valable } \forall t} + \underbrace{U^{mémoire}(\{\vec{r}_i\})}_{\text{calculée à partir des coordonnées } \vec{r}_i(t<t_{ref})}$$

Toutes les n itérations de dynamique (i.e. tous les intervalles de temps Δt), on calcule une énergie de type « *flooding* ». A une date $t > M\Delta t$, le terme « mémoire » à ajouter aux termes classiques de l'énergie potentielle est

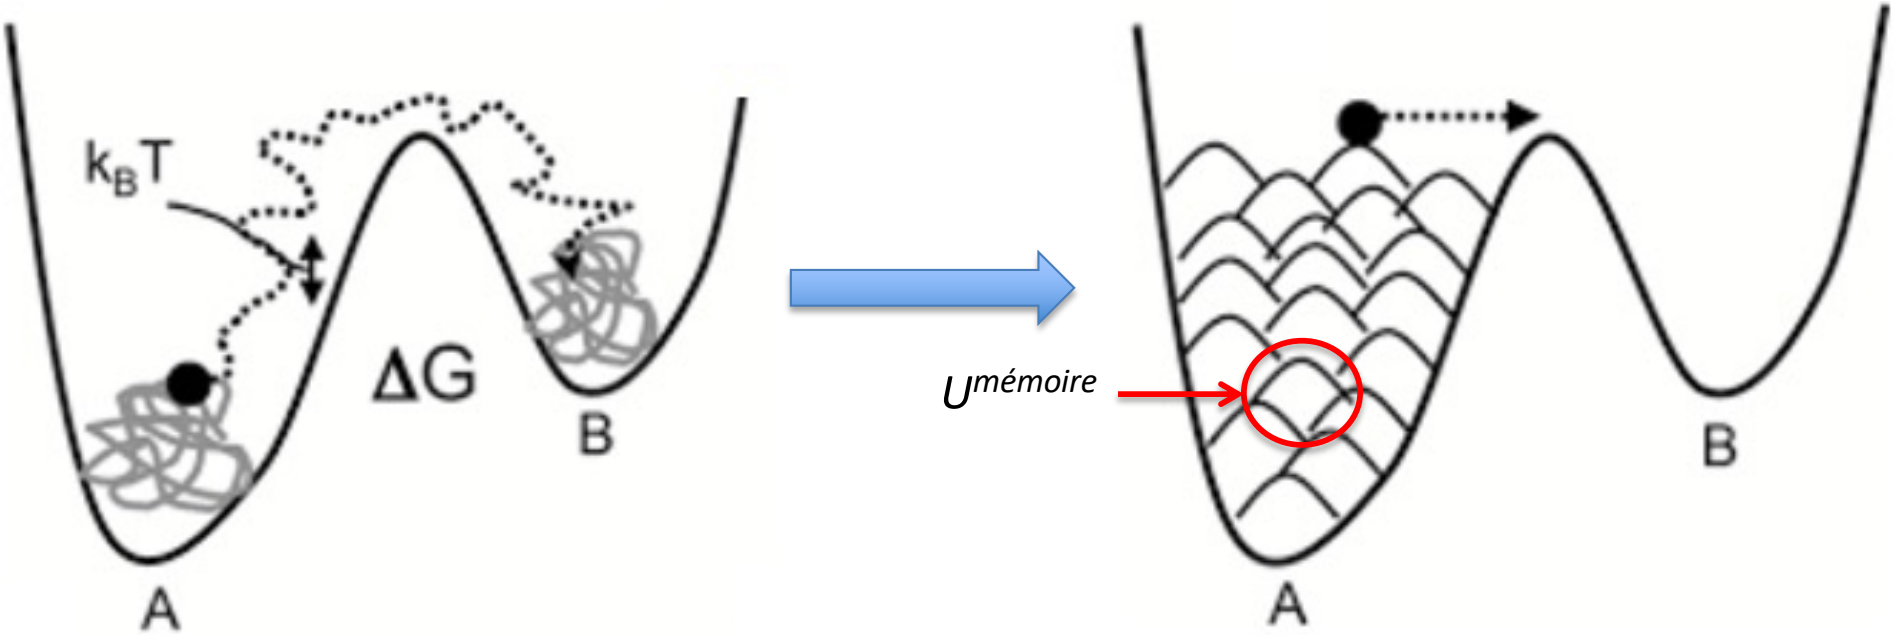
$$U^{mémoire}(\{\vec{r}_i\})(t > M\,\Delta t) = \varepsilon_{mémoire}\sum_{k=1}^{M}\exp\left(-\frac{1}{2}\vec{c}_k\Lambda_k\vec{c}_k^{\,T}\right)$$

Laio and Parrinello, Proc. Natl. Sci. (USA), 99 (2002) 12562

ISM9 – LA MÉTA-DYNAMIQUE

Effet du terme de mémoire sur un système à deux états *A* et *B* :

$$U^{mémoire}(\{\vec{r}_i\})(t > M\,\Delta t) = \varepsilon_{mémoire} \sum_{k=1}^{M} \exp\left(-\frac{1}{2}\vec{c}_k \Lambda_k \vec{c}_k^{\,T}\right)$$



Sans terme de mémoire

Avec le terme de mémoire

Comme pour le « *conformational flooding* », cette méthode ne considère qu'une simulation unique, ce qui ne permet pas de tirer profit d'architectures de calcul parallèle. Par contre cette méthode donne accès à la différence d'énergie libre entre les deux états A et B par exemple.

ISM9 – SWARM-MD

Méthode trivialement parallélisable permettant un meilleur échantillonnage d'une surface d'énergie potentielle que la méthode de recuit simulée et se fondant également sur des termes d'énergie « mémoire ».

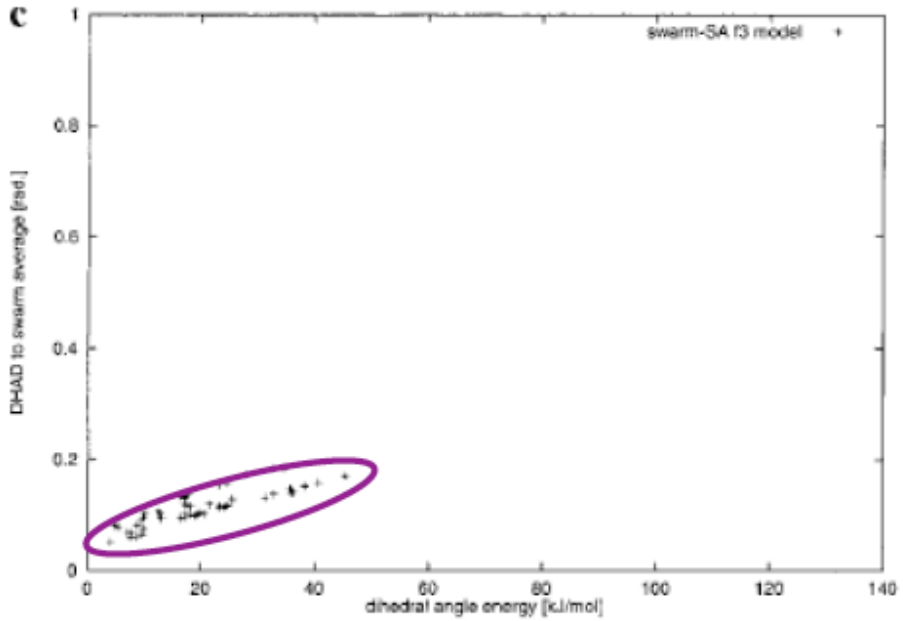
Prenons le cas d'une longue molécule de type polymère dont le squelette est caractérisé par N_Φ angles dièdres caractéristiques $\{\Phi_k\}_{1\le k\le N_\Phi}$. Le long de *M* simulations indépendantes, les valeurs moyennes de ces angles sont calculées, puis on construit le potentiel « mémoire »

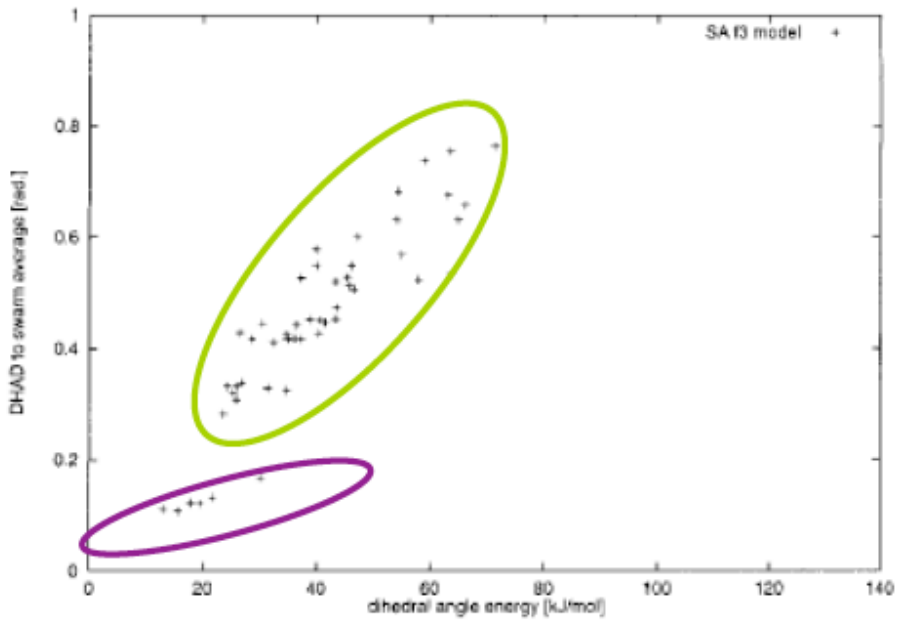
$$U^{mémoire}(\{\Phi_k\}) = \varepsilon_{mémoire} \sum_{k=1}^{N_\Phi} \sum_{i=1}^{M} \exp\left(-\frac{(\Phi_k^i - \bar{\Phi}_k^i)^2}{\gamma_k} \right)$$

On relance alors *M* simulations avec ce potentiel. Comme dans le cas du « *conformational flooding* » et de la « méta-dynamique », cette approche permet une meilleure exploration des minima locaux du système microscopique considéré mais à l'aide de simulations faiblement couplées. **Par contre cette méthode, comme la méthode recuit simulé, ne donne pas accès directement à des grandeurs thermodynamiques**.

ISM9 – SWARM-MD

Exemple de la chaine carbonée CH_3-$(CH2)_{48}$-CH_3, 50 simulations indépendantes de 100 ps par recuit simulé ou couplées par l'approche SWARM-MD.





Recuit simulé SWARM-MD

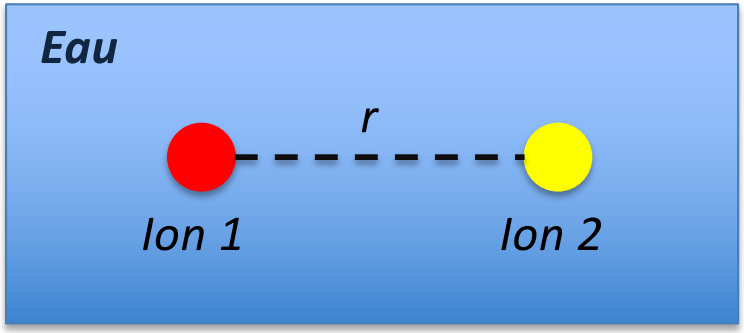
DHAD : écart type moyen des angles dièdres pour les jeux de conformations obtenus par les deux méthodes (les angles dièdres de référence sont ceux de la conformation d'énergie minimum pour chacune des deux méthodes).

Huber and van Gunsteren, J. Phys. Chem A., 102 (1998) 5937

ISM9 – UMBRELLA SAMPLING

L'objectif est ici de forcer le système à explorer des zones prédéfinies, en particulier des zones de la surface d'énergie potentielle où un système microscopique à une faible probabilité de se trouver.

A la différence des méthodes de « *replica exchange* », « *conformational flooding* » et méta-dynamique, **il faut connaître a priori les zones à explorer.** Prenons l'exemple de deux ions plongés dans une boîte d'eau. L'objectif est d'évaluer leur potentiel d'interaction effectif *A(r)* (le potentiel apparent d'interaction des deux ions, où le rôle du solvant est implicitement pris en compte) :



$$P(r) = \exp\left(-\frac{A(r)}{k_B T}\right)$$

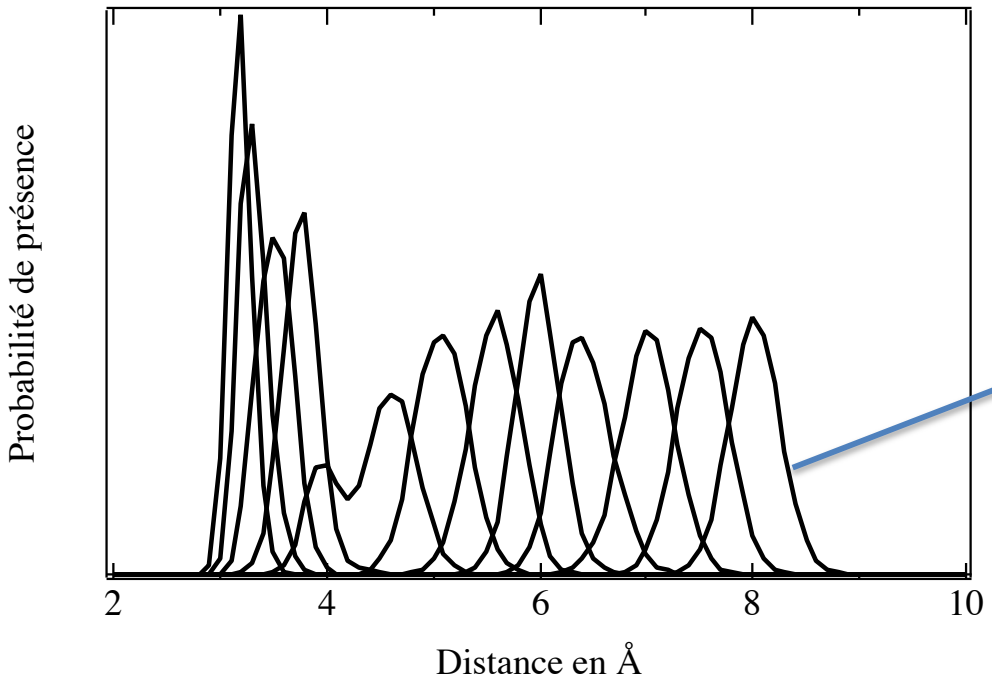
A(r) tient compte de l'intégrant $\propto r^2$

Pour cela, *M* simulations indépendantes de ce système sont réalisées en ajoutant à son énergie potentielle un terme de contrainte pour chaque simulation *k* :

$$U_k^{umbrella} = k_{umbrella}\left(r - r_k^{ref}\right)^2 \quad \text{avec} \quad r_{\min} \le r_k^{ref} \le r_{\max}$$

ISM9 – UMBRELLA SAMPLING

La seule difficulté de cette approche, qui permet de tirer trivialement parti d'architectures de calcul parallèle et la phase d'analyse post-simulation où l'effet de la fonction de contrainte est corrigé.



Ici, les probabilités que les deux ions précédents soient à une distance *r* sont représentées pour chaque simulation contrainte *k*.

Les probabilités sont calculées par une approche discrète (histogramme), i.e.

$$P_k^{biais}(r_l) = \frac{n_k(r_l - \delta r/2 \le r \le r_l + \delta r/2)}{N_k}$$

k : simulation correspondant à un r_k^{ref} donné

n_k : nombre de fois ou *r* est dans l'intervalle

N_k : nombre totale de structures sauvegardées le long de la simulation considérée

Les distances *r* sont échantillonnées suivant $r_l = l\delta r$

Par définition, le potentiel effectif de chaque simulation biaisée est :

$$A_k^{biais}(r) = -\frac{1}{k_B T}\ln\left(P_k^{biais}(r)\right)$$

ISM9 – UMBRELLA SAMPLING – MÉTHODE WHAM

L'objectif est donc de calculer la probabilité $P(r)$ que les deux ions soient à une distance *r* sans appliquer de contrainte, en regroupant les résultats de toutes les simulations contraintes *k*. En particulier, la probabilité globale précédente s'exprime en fonction des résultats de chaque simulation contrainte sous la forme :

$$P(r) = \frac{1}{Z_k} \exp\left(-\frac{A_k^{biais}(r) - U_k^{umbrella}(r)}{k_B T} \right) = \exp\left(-\frac{A_k^{biais}(r) - U_k^{umbrella}(r) - F_k}{k_B T} \right) \quad \forall k \in \{1, M\}$$

Les F_k , énergies libres de la simulation *k*, sont des constantes qu'il faut évaluer afin que la fonction *P(r)* soit indépendante de la simulation considérée (autrement dit « continue ») ➔ approche WHAM (« Weighted Histogram Analysis Method »)

$$\mathrm{P}(r) = \frac{\sum_{k=1}^{M} n_k(r)}{\sum_{k=1}^{M} N_k \exp\left(-\frac{1}{k_B T}\left(F_k - U_k^{umbrella}(r)\right) \right)} \quad \text{et} \quad \exp\left(-\frac{F_k}{k_B T} \right) = \left[\sum_{l=1}^{L} P(r_l) \exp\left(-\frac{U_k^{umbrella}(r_l)}{k_B T} \right) \right]$$

Ici les r_l sont les valeurs discrètes de *r* définissant les histogrammes du slide précédent. Les deux équations couplées précédentes sont résolues de manière itérative.

ISM9 – UMBRELLA SAMPLING – UMBRELLA INTEGRATION

En remarquant que les termes F_k de chaque trajectoire sont constants, une astuce est de considérer les dérivées par rapport à *r* des différentes fonctions de l'expression :

$$P_k(r) = \frac{1}{Z_k}\exp\left(-\frac{A(r)+U_k^{umbrella}(r)}{k_BT}\right) \quad \text{avec} \quad \begin{cases} A_k^{biais}(r) = A(r)+U_k^{umbrella}(r) \\ Z_k = \exp\left(-\frac{F_k}{k_BT}\right) \text{ avec } Z_k \text{ et } F_k \text{ constants} \end{cases}$$

Autrement dit, il est possible d'écrire la dérivée de la fonction *A(r)* recherchée sur la base des résultats de chaque simulation en tout point *r (*qui a été échantillonné) *:*

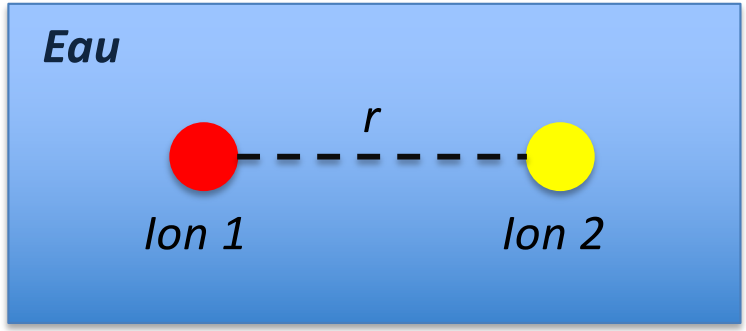
$$\frac{\partial A(r)}{\partial r} = -\sum_{k=1}^{M}\frac{n_k(r)}{N_{tot}(r)}k_BT\frac{\partial \ln\left(P_k(r)\right)}{\partial r} + \frac{\partial U_k^{umbrella}(r)}{\partial r} \quad \text{avec} \quad N_{tot}(r) = \sum_{k=1}^{M} n_k(r)$$

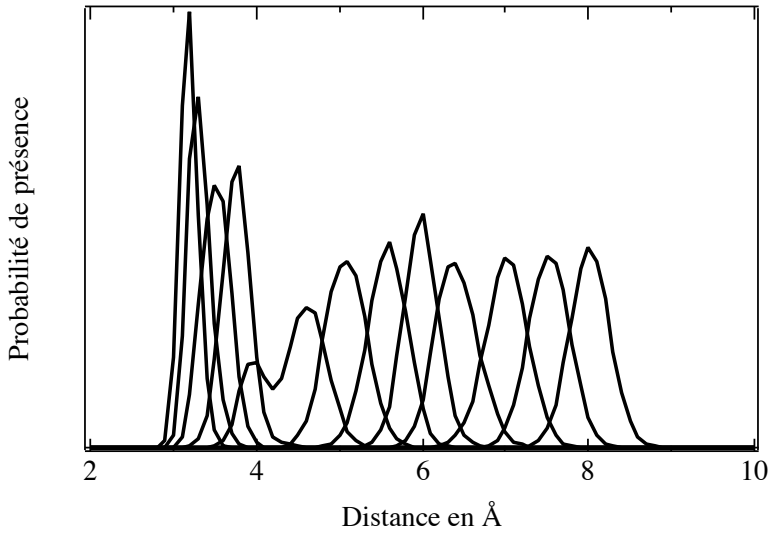
Les dérivées des fonctions $P_k(r)$ sont calculées numériquement aux points échantillonnés

$$\frac{\partial P_k(r_l)}{\partial r} \approx \frac{P_k(r_l+\delta r) - P_k(r_l-\delta r)}{2\delta r}$$

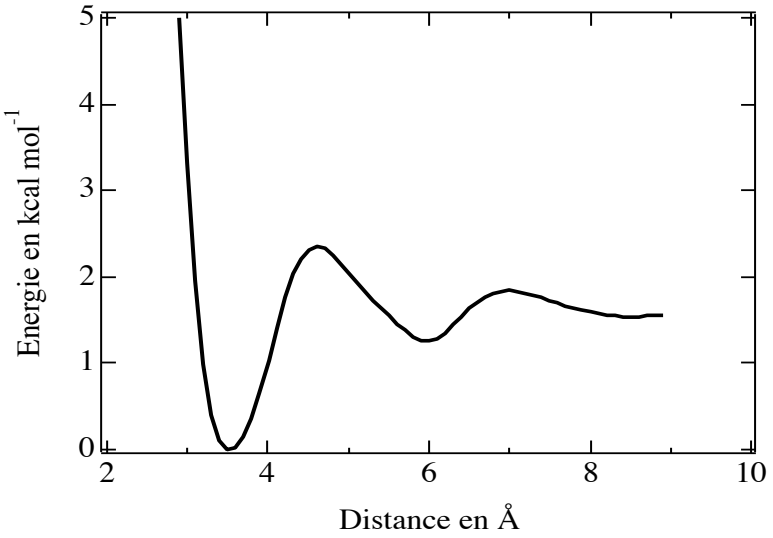
ISM9 – UMBRELLA SAMPLING

Résultat du post-traitement pour les deux ions





Probabilités biaisées $P_k^{biais}(r)$



Potentiel sous-jacent : $A(r)+2k_BT\ln(r)$

I.16 Les effets chaotiques sont inhérents à la résolution des équations du mouvement. Sont-ils
Réponse : seulement négatifs, on peut en tirer profit, ils n'ont aucun effet sur les moyennes calculées le long d'une simulation de type dynamique moléculaire ?

I.17 Les effets chaotiques peuvent-ils être à l'origine de biais importants si l'on peut générer un nombre infini de simulations de courte durée ?
Réponse : oui, non ?

I.18 Quelle est la difficulté majeure lorsque l'on réalise une simulation moléculaire par dynamique moléculaire :
Réponse : le système microscopique évolue trop vite, difficulté à passer les barrières d'énergie entre deux minima, définir les conditions initiales, bien échantillonner localement la surface d'énergie potentielle du système moléculaire considéré ?

I.19 Quel est le point commun entre les méthodes de *conformational flooding* et *méta-dynamique* ?
Réponse à développer (maximum deux lignes)