ISM10 – Clustering, Machine Learning et Intelligence Artificielle

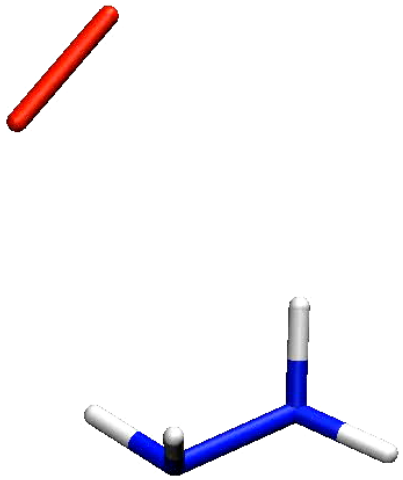
1 – Analyses de simulation par des algorithmes de clustering

2 – Machine Learning et optimization de champ de force

3 – Champs de Force IA ‘black box’

ISM10 : CLUSTERING , POSITION DU PROBLÈME

Simulation de la réaction d'association entre l'hydrazine (N_2H_4, un anti oxydant cancérigène mais très puissant) avec le dioxygène O_2 (un puissant oxydant)



Simulation de 50 ns à 300 K dans l'eau, les molécules d'eau ne sont pas représentées

Objectif des simulations : identifier des structures N_2H_4/O_2 pouvant amener au transfert d'un hydrogène de N_2H_4 vers O_2 => **cela signifie d'identifier des structures qui apparaissent régulièrement le long des simulations.**

ISM10 : ALGORITHME DE CLUSTERING : EXEMPLE K-MEAN

Leur objectif est d'identifier de manières autonomes et automatiques un nombre maximum de *k* clusters de structures « similaires ».

Soit une structure *S* (par exemple, la conformation d'un assemblage de molécules) définie par *M* paramètres géométriques $\{\omega_m\}_{m=1-M}$ (a priori des distances inter atomiques, des angles et des angles dièdres). Autrement dit *S* est un vecteur de dimension *M*.

La similarité de deux structures S_i et S_j se mesure à l'aide d'une métrique euclidienne :

$$d_{ij} = \sum_{m=1}^{M} \left(\omega_m^i - \omega_m^j\right)^2$$

Parmi toutes les *N* structures S_i on choisit *K* structures définissant les centres initiaux des clusters. Par exemple une structure S_α choisie aléatoirement définit le premier cluster, puis les *K*-1 autres clusters suivant par différentes approches basées sur les distances $d_{\alpha j}$.

On itère ensuite jusqu'à obtenir au plus *K* clusters « stables » $\{\Omega_k\}_{k\leq K}$:

$$\Omega_k = \left\{ S_l^k : \sum_{m=1}^{M} \left(\omega_m^l - \overline{\omega}_k\right)^2 \leq \sum_{m=1}^{M} \left(\omega_m^l - \overline{\omega}_h\right)^2 \ \forall h \in (1,K) \right\} \quad \text{et} \quad \overline{\omega}_k = \frac{1}{size(\Omega_k)} \sum_{l\in\Omega_k} \omega_m^l$$

ISM10 : ALGORITHME DE CLUSTERING : EXEMPLE K-MEAN

Recherche de deux clusters avec des structures à une dimension (des points) dans un plan à deux dimensions :

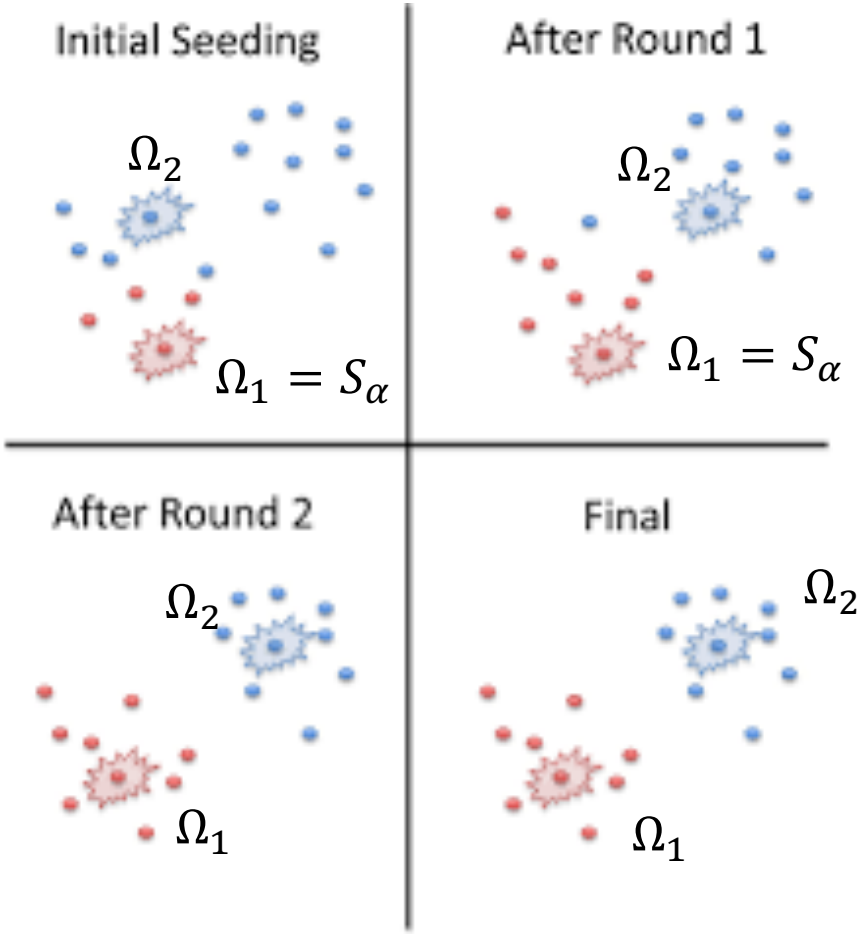
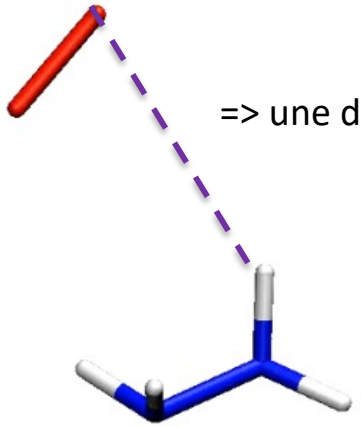


Figure from https://devopedia.org/k-means-clustering

ISM10 : DÉFINITION D'UNE 'MÉTRIQUE'

Par exemple, pour le cas N2H4/O2, une 'métrique' possible est de considérer :

1 - Les 2x4 distances R(H---O) qui peuvent être définie dans le complexe



=> une des 8 distances R(N---H)

2 – L'angle Θ entre les axes NN et OO

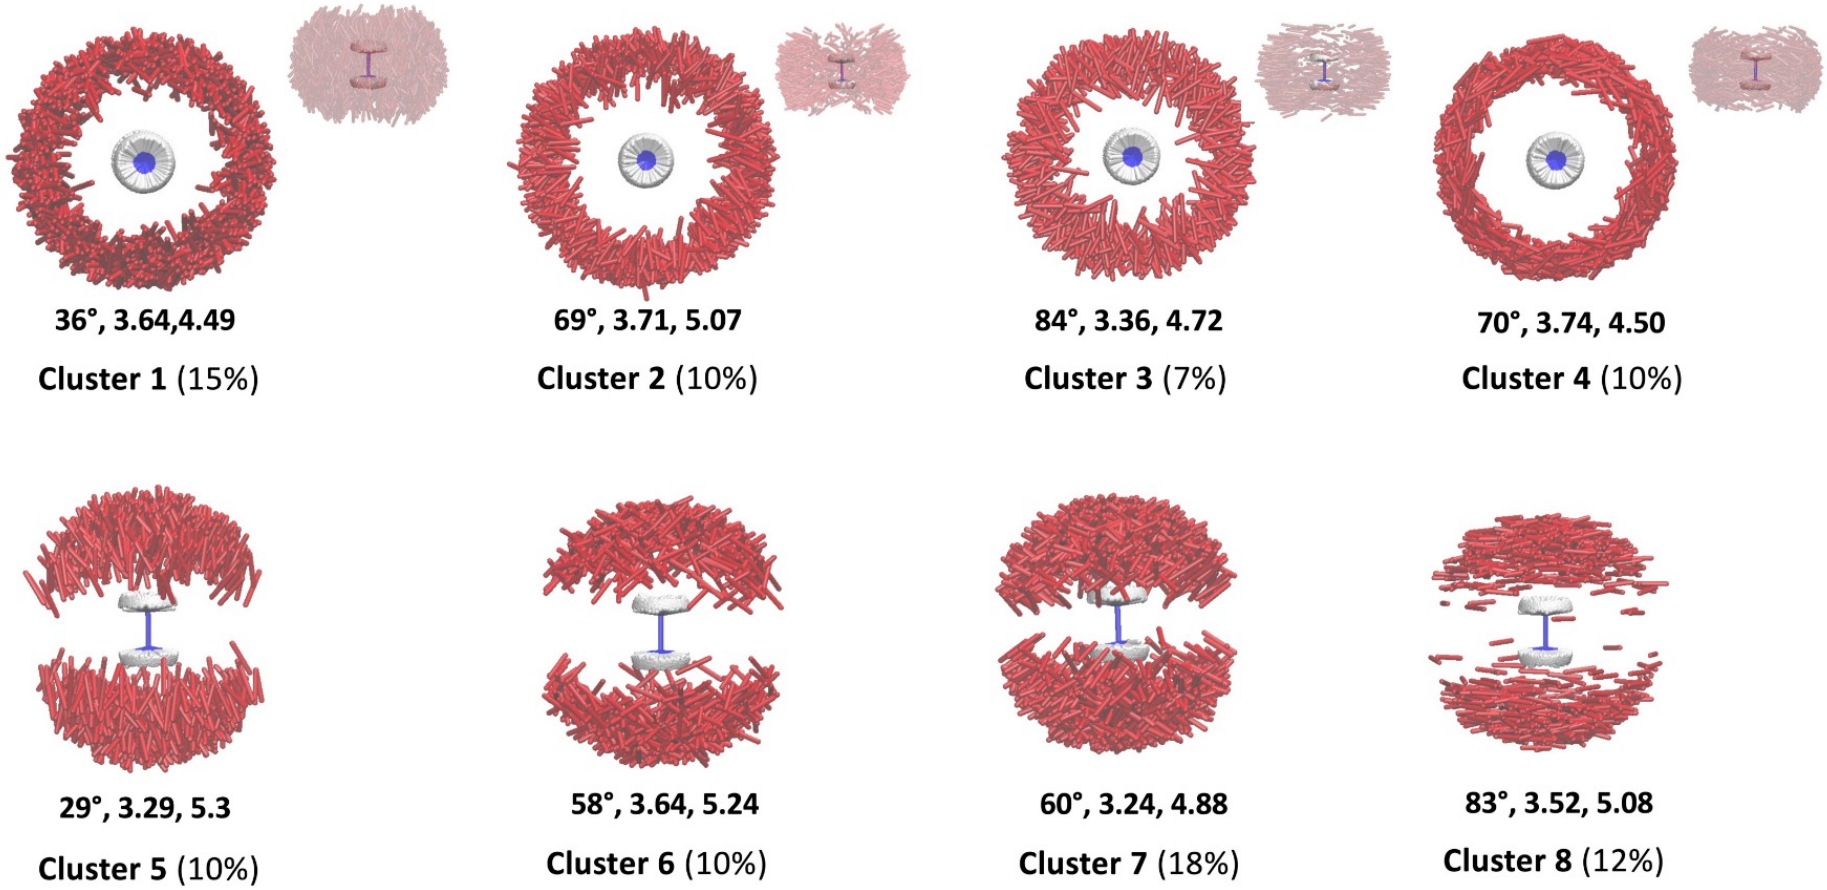
La difficulté ici est l'indiscernabilité des 8 distances R(H---O), une manière de contourner le problème est de définir un vecteur *S* à 9 dimensions, dont les 8 premiers éléments sont les R(H---O) ordonnées par ordre croissant

=> L'identité des hydrogènes H et des oxygènes O n'a pas de signification d'un point de vue chimique, la 'structure' (vecteur) *S* à neuf dimensions prend en compte cet aspect.

Il ne suffit pas d'avoir des données il faut les organiser en considérant des concepts physiques

ISM10 : CLUSTERS IDENTIFIÉS

A l'aide d'un algorithme de type K-mean et de des vecteurs *S*, 8 principaux clusters sont identifiés, les nombres correspondent à l'angle Θ et à la plus petite et la plus grande des distances R(H---O)



36°, 3.64,4.49

Cluster 1 (15%)

69°, 3.71, 5.07

Cluster 2 (10%)

84°, 3.36, 4.72

Cluster 3 (7%)

70°, 3.74, 4.50

Cluster 4 (10%)

29°, 3.29, 5.3

Cluster 5 (10%)

58°, 3.64, 5.24

Cluster 6 (10%)

60°, 3.24, 4.88

Cluster 7 (18%)

83°, 3.52, 5.08

Cluster 8 (12%)

Figure issue de J Phys Chem A, 127 (2023) 10104

ISM10 : Clusters Identifies : Centres des Distributions

Les algorithmes de clustering permettent également d'identifier la conformation (géométrie) la plus représentative des différents clusters, par exemple pour N_2H_4/O_2

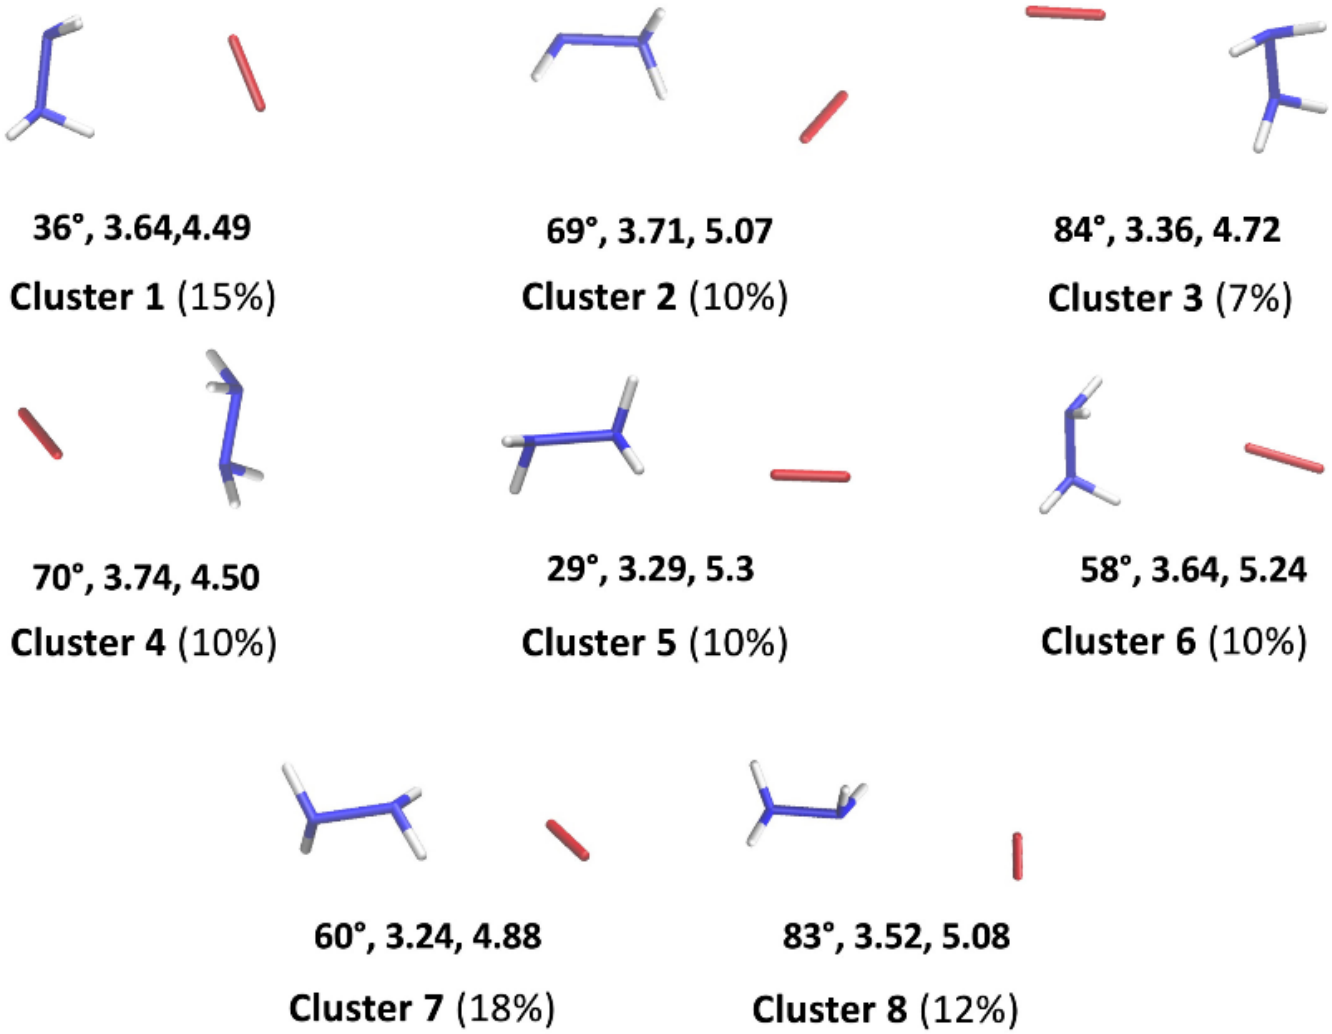


Figure issue de J Phys Chem A, 127 (2023) 10104

ISM10 : CLUSTERING : CONCLUSION

1 - **Les algorithmes de clustering sont particulièrement efficaces pour fouiller, plutôt 'ordonner'** et identifier des sous ensembles 'pertinents' dans de grands volumes de données sans intervention 'humaine'. Ces algorithmes font donc parti des techniques de Machine Learning ;

2 - Mais **l'utilisateur 'humain' joue un rôle prépondérant en amont de l'application** d'un algorithme de clustering : il définit la 'structure' *S* correspondant aux données à trier ;

3 – La structure' *S* contient l'information physique ou chimique dans les algorithmes de clustering, **elle doit donc en refléter les lois fondamentales** ;

4 – En dehors des aspects propres aux algorithmes de clustering, la qualité du clustering dépend de la pertinence de la structure' *S* choisie, **le rôle de l'utilisateur 'humain' n'est donc plus un travail répétitif de comparaison de données entre-elles mais de réflexion en amont visant à la définition de règles permettant de cataloguer aux mieux les données**.

Un champ de force est un potentiel d'interaction **empirique** dont il n'est pas toujours facile de définir des paramètres de bonne qualité.

Historiquement, les paramètres des champs de force étaient définis afin de reproduire un ensemble de données expérimentales. Ceci était réalisé par une approche itérative :

1 – Simulation avec un jeux de paramètres de champ de force
2 – Calcul des propriétés comparables à des données expérimentales
3 – Définition d'un nouveau jeu de paramètres et retour au point 1

Le choix des paramètres était laissé à l'initiative d'un « expert », i.e. un utilisateur 'humain'.

La montée en puissance des ressources de calcul et la prise en compte (enfin…) d'algorithme d'optimisation (comme les algorithmes « génétiques ») permet aujourd'hui de réaliser l'approche itérative précédente de manière automatique.

=> Le rôle de l'expert 'humain' reste pourtant central : il définit les propriétés expérimentales à prendre en compte et vérifie que les simulations (durée, échantillonnage..) donnent bien des résultats statistiquement/numériquement significatifs.

ISM10 : ALGORITHMES D'OPTIMISATION "GÉNÉTIQUES"

Ces algorithmes (proposés dès les années 1950…) se veulent une analogie du processus Darwinien de sélection naturelle. Ils se décomposent en 4 étapes, une fois un jeu de conditions à atteindre défini (par exemple reproduire ***K*** propriétés expérimentales physico-chimiques d'un système microscopique, propriétés notées ***P***). Les 4 étapes :

1 – Choix de ***M*** jeux de paramètres de champ de force $\{\xi_i\}_{i=1,M}$ initiaux permettant de calculer des propriétés expérimentales *P* à l'aide de simulations => ***Parent Solutions***

2 - Calcul d'une fonction de pertinence (***fitness functions***) $\chi(\xi_i)$ des jeux de paramètres

$$\chi(\xi_i) = \sum_{k=1}^{K} \left[\frac{P_{exp} - P(\xi_i)}{\gamma_k} \right]^2$$

3 – Mélange et mutation (***Crossover and mutations***) des ***Parent solutions*** :

$\tilde{\xi}_j = \sum_{j=1}^{M} \alpha_{ji} \times \xi_i$ => mélange des solutions précédentes

$\tilde{\xi}_j^* = \tilde{\xi}_j + \sigma_j \times \mathcal{N}(0,1) \Rightarrow$ mutations des nouvelles solutions

4 – Calcul des ***K*** propriétés sur la base des nouveaux paramètres $\{\tilde{\xi}_j^*\}$ et ***Selection*** d'un jeu 'pertinent' de ces paramètres à considérer comme ***Parent Solutions*** et retour au point 1.

ISM10 : ALGORITHMES D'OPTIMISATION "GÉNÉTIQUES"

De manière théorique rien à redire, une fois l'algorithme lancé plus d'intervention de l'utilisateur 'humain', mais celui-ci doit avoir non seulement défini les ***P*** propriétés expérimentales pertinentes et leur « poids » γ_k mais aussi les « taux de mutation à chaque génération » $\{\sigma_j\}$

$$\tilde{\xi}_j^* = \tilde{\xi}_j + \sigma_j \times \mathcal{N}(0,1)$$

Il n'y a pas aujourd'hui de règle pour définir les paramètres $\{\sigma_j\}$, c'est à l'expert 'humain' en Machine Learning de le faire…. Et il n'y a pas plus de règles pour le processus final de ***Selection***.

Remarque les α_{ji} du processus de ***Crossover*** $\tilde{\xi}_j = \sum_{j=1}^{M} \alpha_{ji} \times \xi_i$ peuvent être définis de manière aléatoire et gardés constants en amont de la boucle d'optimisation ou redéfinis à chaque itération. A priori l'intervention ici de l'expert 'humain' est donc plus limitée.

Le problème essentiel reste aujourd'hui le temps nécessaire pour estimer une propriété expérimentale ***K*** sur la base de simulations microscopiques (en particulier estimation de l'erreur associée à celle-ci => **qualité des données considérées**).

ISM10 : Qualité des Données Considérées

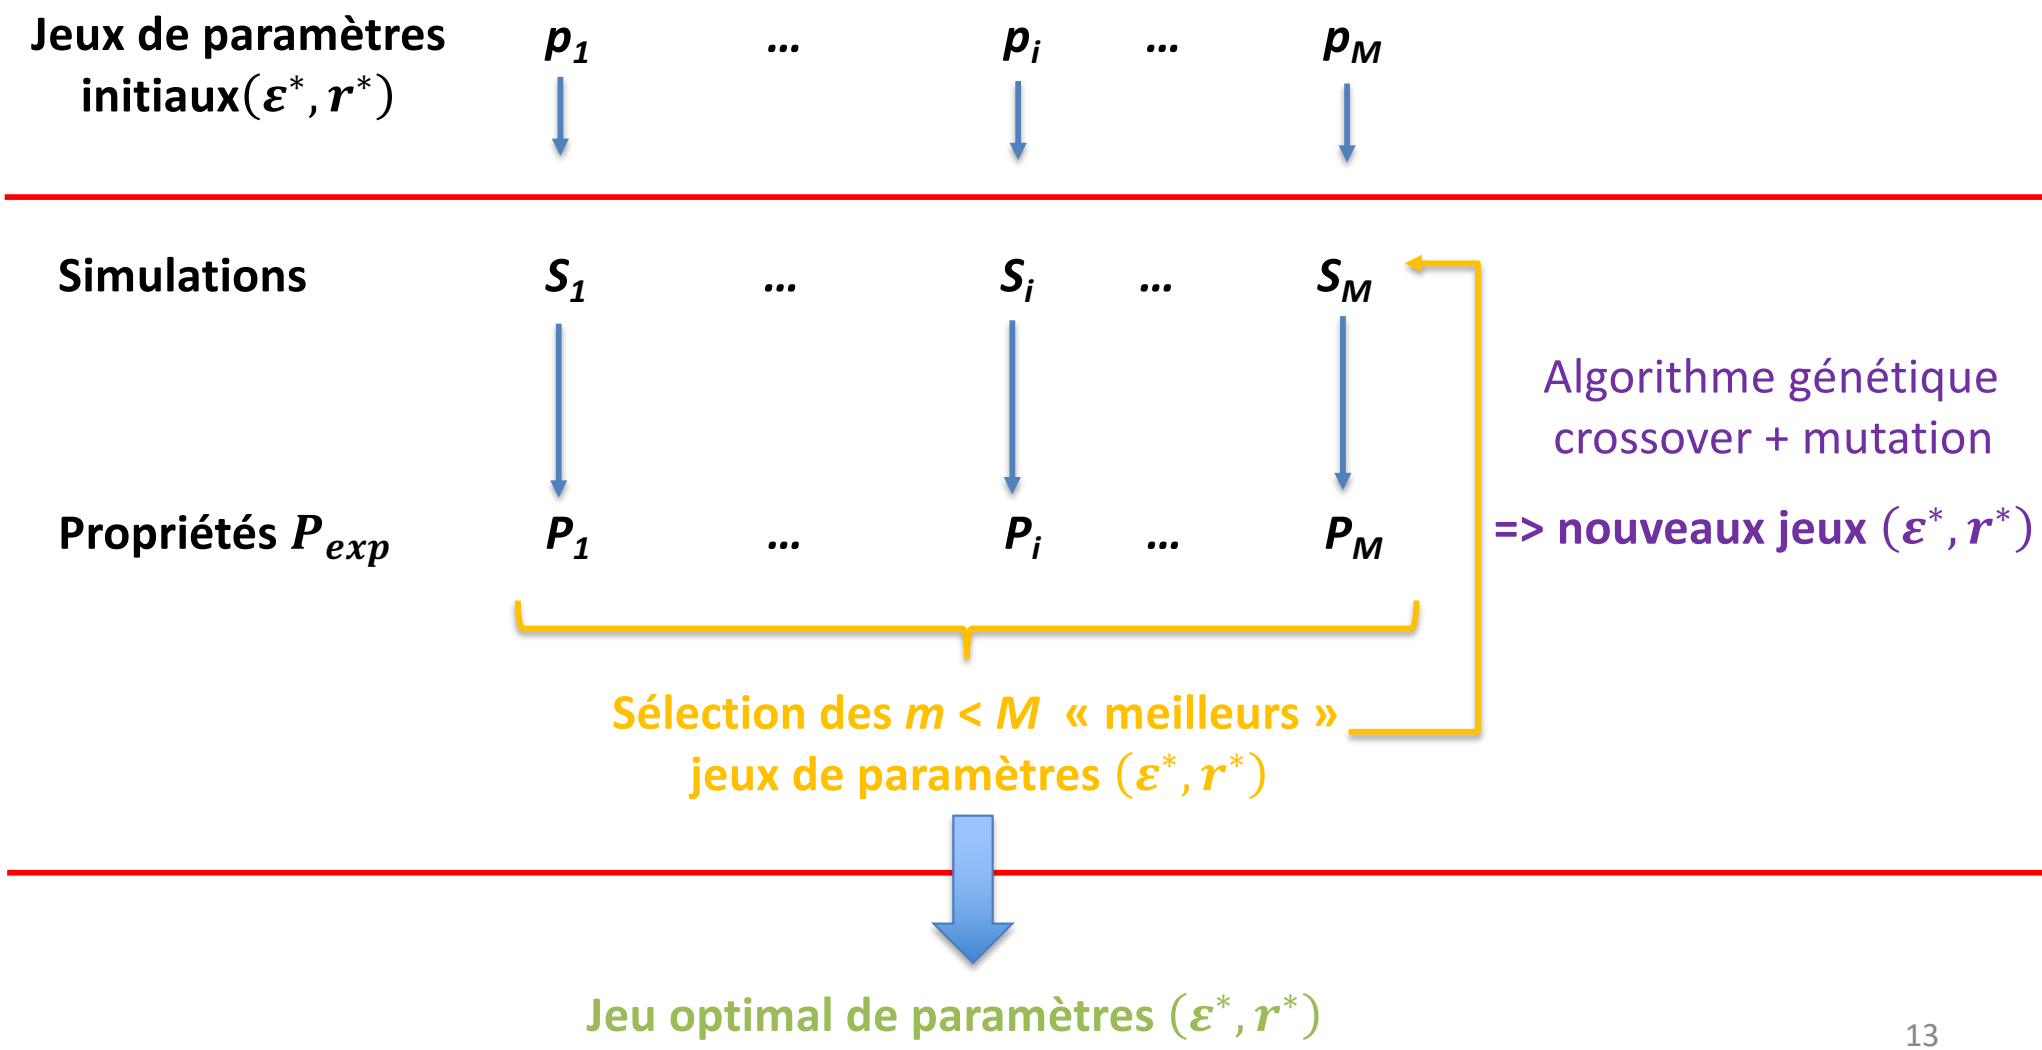
Utiliser un algorithme d'optimisation de paramètres (comme les algorithmes génétiques) permet de définir avec précision et de manière automatique les paramètres d'un champ de force, avec une intervention humaine (un biais) réduite.

Dans le cas d'un potentiel de Lennard-Jones, ces algorithmes permettent a priori de définir de manière automatique les paramètres ε^* et r^*. Par exemple afin que ce type de potentiel puisse reproduire un nombre prédéfini de *K* propriétés P_{exp} du système microscopique considéré, la précision du champ de force obtenu étant quantifiée par

$$\chi(\varepsilon^*, r^*) = \sum_{k=1}^{K} \left[\frac{P_{exp} - P(\varepsilon^*, r^*)}{\gamma_k} \right]^2$$

De manière implicite l'emploi d'un algorithme d'optimisation génétique implique de pouvoir évaluer un très grand nombre de jeux de paramètres (ε^*, r^*). **Or le calcul de propriétés comme la densité d'un fluide à une température et à une pression donnée nécessite de réaliser une simulation microscopique suffisamment longue.**

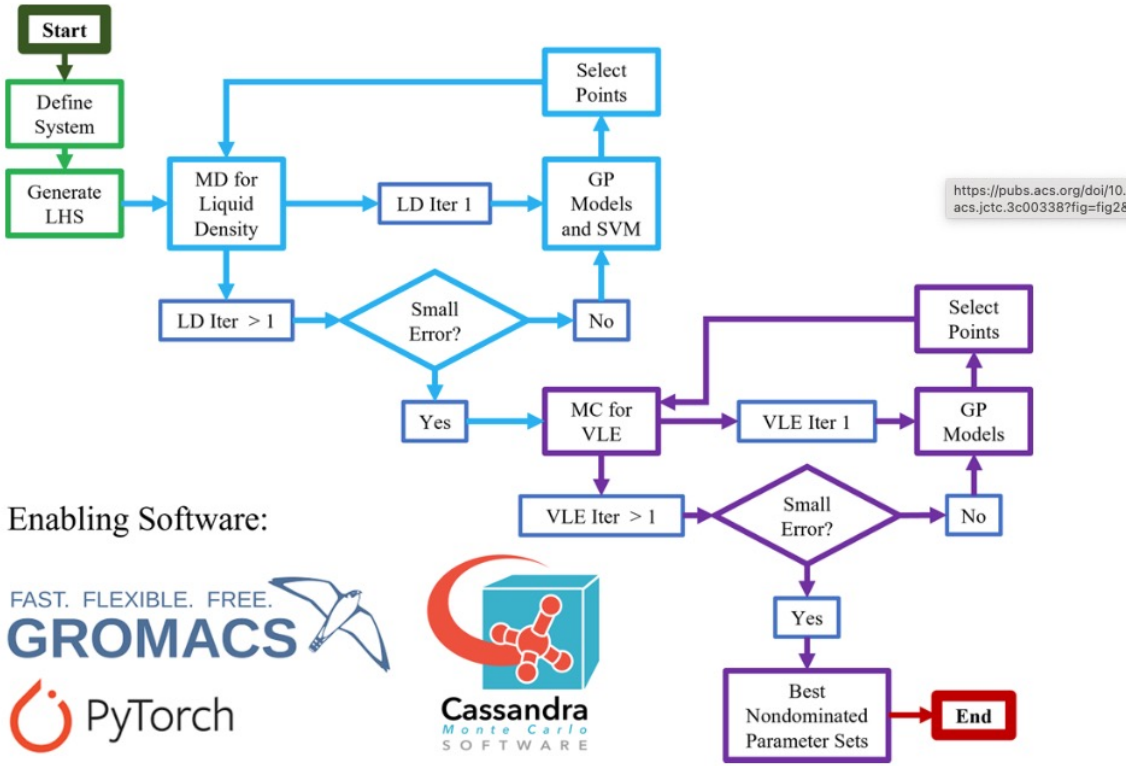
Schéma d'optimisation des paramètres d'un champ de force



ISM10 : Simulation microscopique et Modèles "Gaussian Process"

Les potentiels de Lennard Jones (sans charge électrostatique) ont été proposés historiquement pour pouvoir calculer **analytiquement** les fonctions de partition et donc les fonctions thermodynamiques de systèmes microscopiques (cf. équation de Van der Waals).

Cet aspect « calculable analytiquement » a amené des développements en physique théorique permettant d'estimer efficacement avec une bonne précision une propriété de type $P(\varepsilon^*, r^*)$ sans avoir à réaliser de simulation microscopique (comme les techniques de « Gaussian process surrogate modeling »).



GP = Gaussian Process
LD = fluid density
MC = MonteCarlo simulations
MD = Molecular dynamics simulation
VLE = vapor-liquid equilibrium

J Chem Theor and Comput, 10 (2023) 4546

ISM10 : Optimisation de Champ de Force par Machine Learning

L'approche 'Gaussian Process surrogate modeling' est effectivement suffisamment précise pour accélérer le processus de d'optimisation des paramètres d'un champ de force de type Lennard-Jones pure (sans auter terme d'énergie pris en compte).

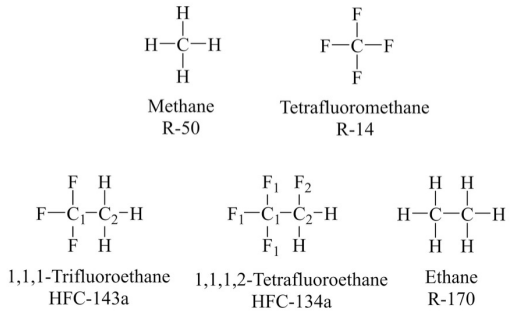
Ecarts pour différentes propriétés P_{exp} entre l'approche Gaussian Process et une simulation microscopique :

Table 3. Overall MAPEs of Liquid Density, Vapor Density, Vapor Pressure, and Enthalpy of Vaporization between GP Predictions and MD or GEMC Results of HFC-143a, HFC-134a, R-50, R-170, and R-14 for all LD or VLE Iterations

Property	Simulation	HFC-143a	HFC-134a	R-50	R-170	R-14
ρ_l	MD	0.89%	0.63%	0.61%	0.84%	0.69%
ρ_l	GEMC	0.3%	0.2%	0.2%	0.2%	0.2%
ρ_v	GEMC	4.6%	9.6%	2.7%	2.9%	4.9%
P_{vap}	GEMC	2.5%	7.6%	1.9%	1.8%	6.5%
ΔH_{vap}	GEMC	0.5%	0.3%	0.2%	0.3%	0.2%

MAPE = « mean absolute percent errors »

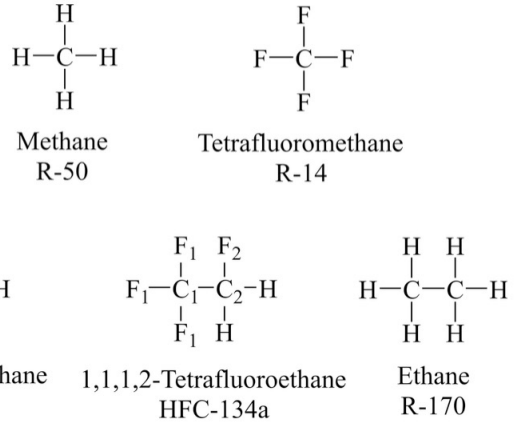
Optimisation de champ de force de type Lennard Jones pour modéliser des molécules réfrigérantes



J Chem Theor and Comput, 10 (2023) 4546

ISM10 : Optimisation de Champ de Force par Machine Learning

Optimisation de champ de force de type Lennard Jones pour modéliser des molécules réfrigérantes



MAPE = « mean absolute percent errors »

Table 5. MAPEs of Liquid Density (ρ_l), Vapor Density (ρ_v), Vapor Pressure (P_{vap}), and Enthalpy of Vaporization (ΔH_{vap}) of Parameter Sets from This Work (Recommended), GAFF,[12] Literature,[19,66] and TraPPE[65] for HFC-134a, HFC-143a, R-170, R-50, and R-14[a]

Refrigerant	Model	MAPE$_{\rho_l}$	MAPE$_{\rho_v}$	MAPE$_{P_{vap}}$	MAPE$_{\Delta H_{vap}}$	
HFC-143a	This work	**1.1%**	**2.6%**	**2.8%**	**2.3%**	
	GAFF[12]	4.3%	33.0%	22.3%	28.4%	→ 2004
HFC-134a	This work	**0.3%**	**1.6%**	**1.9%**	**0.5%**	
	Peguin[19]	0.7%	4.4%	3.1%	2.2%	→ 2009
R-50	This work	3.4%	**1.4%**	2.5%	2.7%	
	GAFF[12]	14.5%	90.8%	59.8%	33.4%	→ 2004
	Potoff[66]	1.4%	3.7%	**0.8%**	8.4%	→ 2009
	TraPPE[65]	**0.8%**	6.5%	8.0%	**1.1%**	→ 2014
R-170	This work	1.8%	**1.6%**	2.1%	**2.0%**	
	GAFF[12]	22.4%	180.3%	83.0%	50.5%	
	Potoff[66]	2.1%	3.2%	**1.9%**	14.4%	→ 2009
	TraPPE[65]	**0.8%**	4.6%	4.0%	8.2%	→ 2014
R-14	This work	0.6%	**1.5%**	1.3%	**0.7%**	
	GAFF[12]	6.7%	72.0%	62.9%	61.5%	
	Potoff[66]	**0.4%**	1.9%	**0.5%**	2.0%	→ 2009

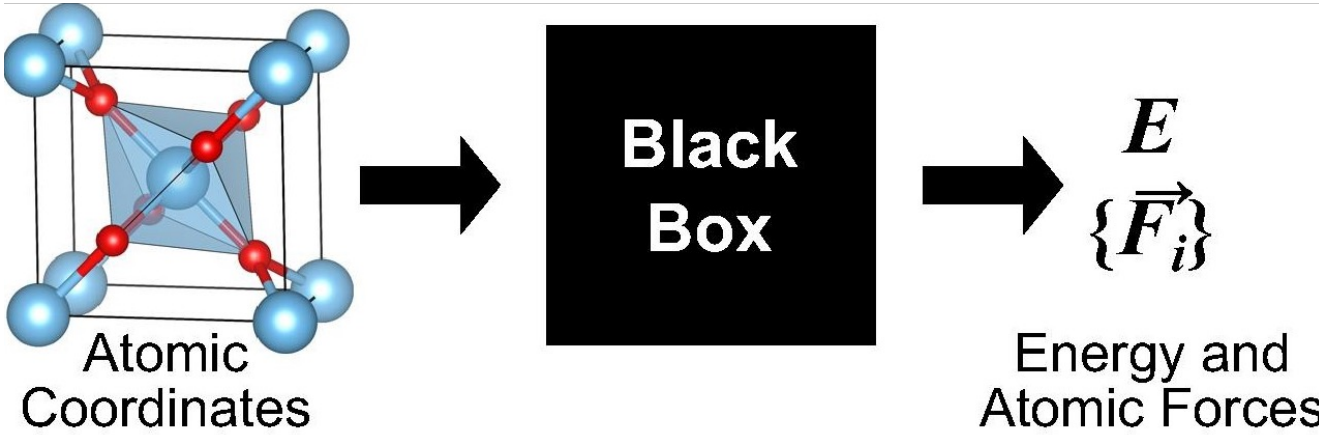
J Chem Theor and Comput, 10 (2023) 4546

ISM10 : CHAMPS DE FORCE IA

Les approches champ de force empirique classique (comme le potentiel de Lennard Jones) sont basées sur des potentiels d'interaction inter atomique dont la forme analytique se veut une traduction fidèle de la nature des interactions au sein d'un système microscopique :

$$U^{LJ} = 4\varepsilon_{AB}\left[\underbrace{\left(\frac{r^{*}_{AB}}{r_{AB}}\right)^{12}}_{répulsion} - \underbrace{\left(\frac{r^{*}_{AB}}{r_{AB}}\right)^{6}}_{dispersion}\right]$$

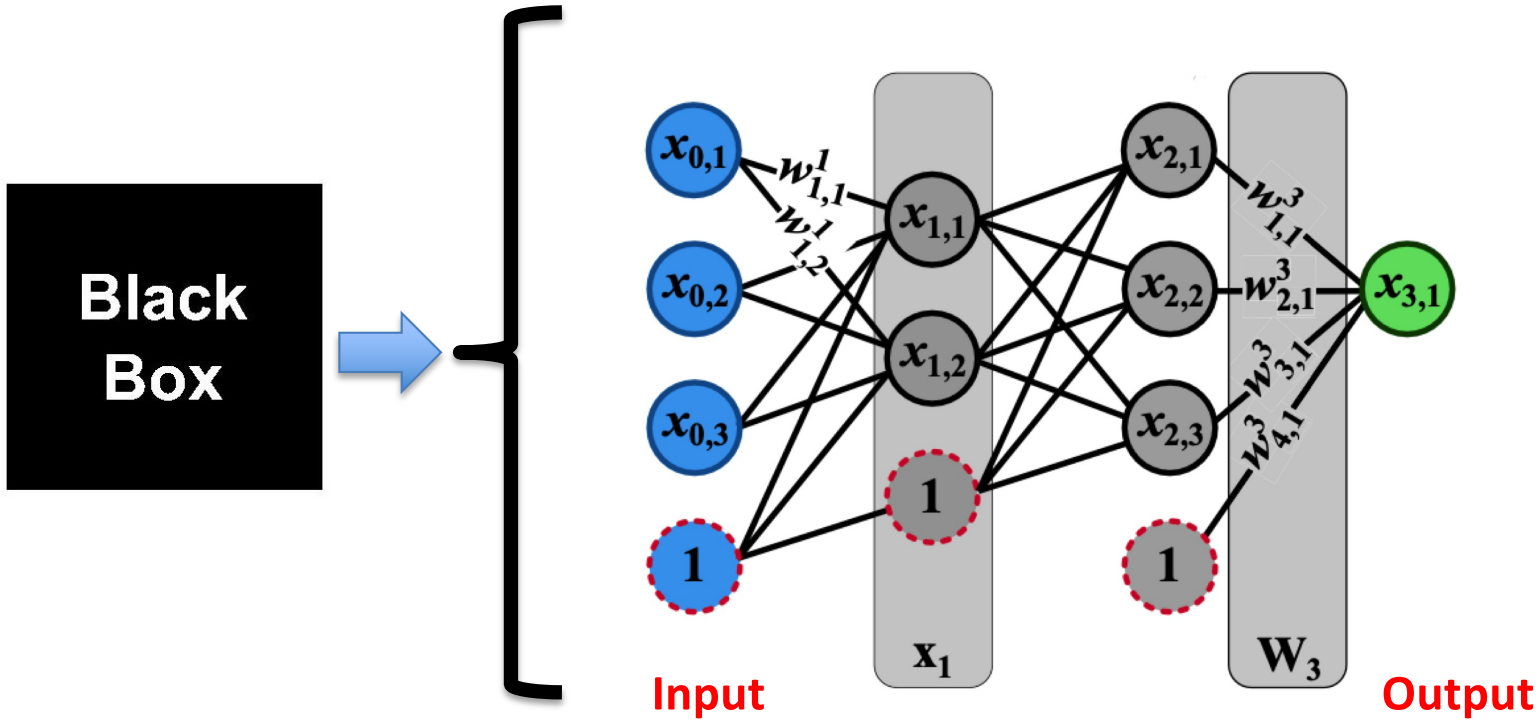
Avec la montée en puissance des approches d'intelligence artificielle, l'aspect « traduction fidèle des interactions » est remplacé par une boite noire (« black box ») dont on comprend mal l'origine de sa capacité prédictive :



Images issues de Comput Mater Sci, 114 (2016) 135

ISM10 : THE IA BLACK BOX

Soit un réseau de neurone de profondeur 3



En entrée du réseau de neurone, un vecteur de données $\mathbf{X}_0$ qui sera « transformé » en un vecteur de $\mathbf{X}_3$ par les opérations successives

$$\mathcal{F}(\mathbf{X}_3) = f_3\{\mathbf{W}_3 f_2(\mathbf{W}_2 f_1(\mathbf{X}_0))\}$$

Images issues de Comput Mater Sci, 114 (2016) 135

ISM10 : THE IA BLACK BOX

Vecteur de données $\mathbf{X}_0$ « transformé » en un vecteur de $\mathbf{X}_{n=3}$ par les opérations successives

$$\mathcal{F}(\mathbf{X}_3) = f_3\{\mathbf{W}_3 f_2(\mathbf{W}_2 f_1(\mathbf{X}_0))\}$$

Les $\mathbf{W}_j$ sont des poids qui modulent le signal reçu par des neurones *j* du fait de chaque élément du vecteur signal $\mathbf{X}_{j-1}$ des neurones *j-1,* et les fonctions d'activation f_j modulent le signal global (somme des signaux de chaque neurone *j-1*) avec différents choix de lois possibles :

$$f_{linear}(x) = x, \qquad f_{tanh}(x) = \tanh(x), \qquad f_{logistic}\ (x) = \frac{1}{1+e^{-x}}$$

Le processus d'entrainement du réseau de neurones (***Training Process***) n'est en fait qu'une tâche d'optimisation de l'ensemble des poids$\{\mathbf{W}_j\}$ du réseau afin de minimiser la fonction :

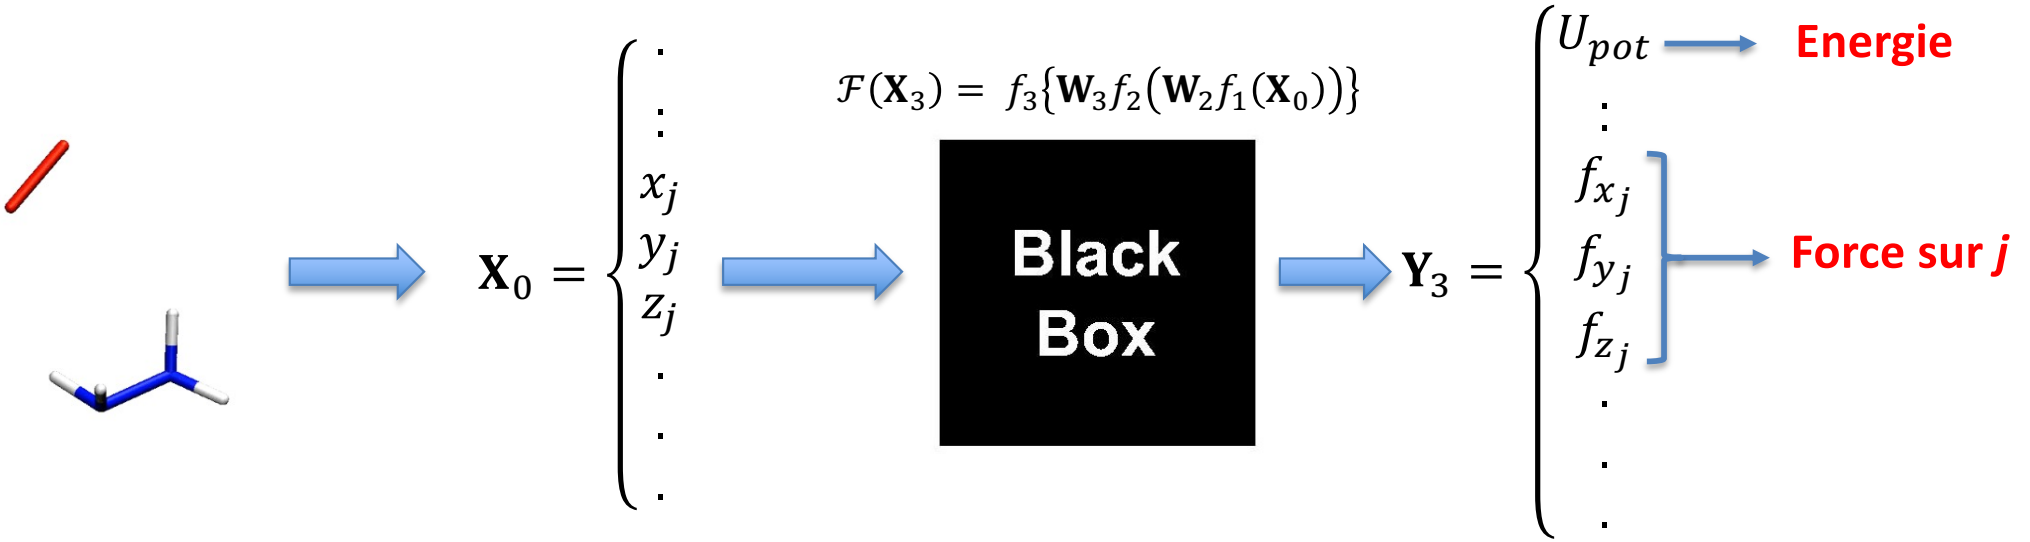
$$\epsilon(n) = \mathcal{F}(\mathbf{X}_n) - \mathbf{Y}_n$$

Le vecteur $\mathbf{Y}_n$ est l'ensemble des données cibles (***target***) qui correspondent à $\mathbf{X}_0$, par exemple l'énergie potentielle et les forces sur chaque atome dans le cas où $\mathbf{X}_0$ est le vecteur de toutes les coordonnées des atomes.

Le processus d'optimisation se fait à l'aide d'opérations matricielles standards (des bibliothèques) qui tirent pleinement profit des unités de calcul vectorielles (GPU…)

ISM10 : Entrainement d'un Champ de Force IA, Quelles Données en entrée ?

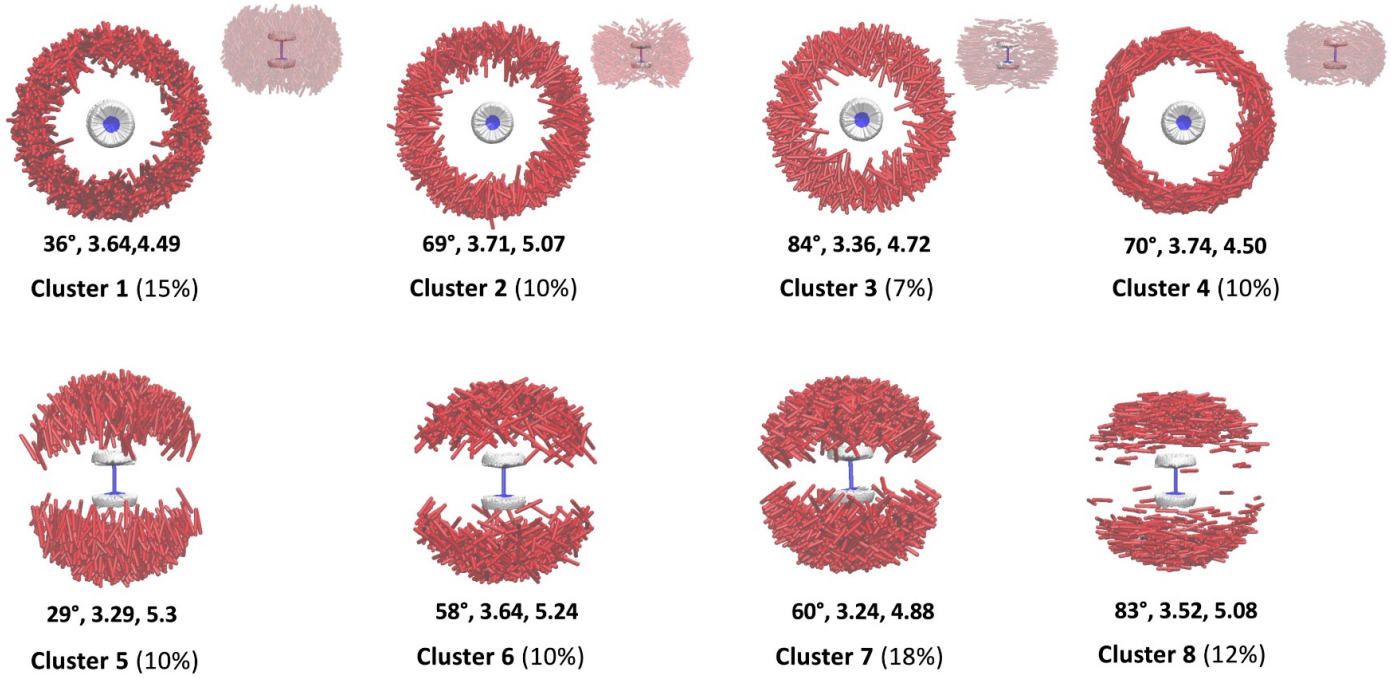
Soit un système microscopique composé de *N* atomes dont les coordonnées cartésiennes $\left(x_j, y_j, z_j\right)_{j=1-N}$ sont stockées dans un vecteur $\mathbf{X}_0$. L'approche naïve serait d'entrainer le réseau sur la base du vecteur $\mathbf{X}_0$



Mais le système de coordonnées cartésiennes $\left(x_j, y_j, z_j\right)_{j=1-N}$ n'est pas absolu, i.e. toute rotation du référentiel choisi ne doit pas modifier U_{pot} et ne doit pas modifier les vecteurs forces élémentaires inter atomiques $\mathbf{F}_{ij}$ projetés sur l'axe connectant les paires d'atomes *i* et *j*.

ISM10 : Approche naïve et cas de N_2H_4/O_2

Cas de N_2H_4/O_2, le résultat du clustering d'une simulation à 300 K par dynamique moléculaire à l'échelle de 50 ns semble être « exhaustif »



NB : figure après superposition des différentes conformations afin de minimiser la fonction RMSD correspondant aux atomes N

$$\mathrm{RMSD(N)} \propto \left|\mathbf{X}_{\mathrm{N}}^{1} - \mathbf{X}_{\mathrm{N}}^{2}\right|^{2}$$

A priori l'approche naïve pourrait être employée dans ce cas, mais le réseau de neurone ne serait pas seulement entrainé pour calculer des forces et des énergies, mais également pour reconnaître (implicitement) des géométries similaires…

ISM10 : Données en Entrée Pertinentes : Fonctions d'Environnement

Sur la base d'une fonction de coupure (***Cutoff***), comme par exemple la fonction *G :*

$$G(r, R_{cut}, \delta R) = \begin{cases} 1 & \text{if} \quad r \leq R_{cut} \\ 0 & \text{if} \quad r \geq R_{cut} + \delta R \\ P_5(r) & \text{if} \quad R_{cut} < r < R_{cut} + \delta R \end{cases} \longrightarrow P_5(x) = 1 - 10\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^3 + 15\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^4 - 6\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}}\right)^5$$

Il est possible de construire un jeu de fonctions $\{F_l\}_i$ permettant de caractériser avec précision l'environnement d'une atome *i*, i.e. quels sont ses atomes voisins et comment ces atomes voisins se disposent dans l'espace autour de l'atome *i*.

Pour bâtir un champ de force AI, il suffit alors de substituer le vecteur en entrée $\mathbf{X}_0$ par $\widetilde{\mathbf{X}}_0$

$$\mathbf{X}_0 = \begin{Bmatrix} \cdot \\ \vdots \\ x_j \\ y_j \\ z_j \\ \cdot \\ \cdot \\ \cdot \end{Bmatrix} \text{ Coordonnées de } j \qquad \Longrightarrow \qquad \widetilde{\mathbf{X}}_0 = \begin{Bmatrix} \cdot \\ \cdot \\ F_j^1 \\ \cdot \\ \cdot \\ F_j^L \\ \cdot \\ \cdot \end{Bmatrix} \text{ Fonctions } \{F_l\}_j \text{ caractérisant l'environnement de } j$$

ISM10 : EXEMPLES DE FONCTIONS D'ENVIRONNEMENT

La fonction 'composition d'environnement', dans le cas d'un système homogène (tous les atomes sont du même type) donne le nombre de voisins à une distance inférieure à R_{cut}

$$\Omega_1^i = \sum_{j \neq i, j=1}^{N} G(R_{ij}, R_{cut}, \delta R)$$

La fonction 'densité locale' à une distance $R_s < R_{cut}$ donnant plus de détails sur la structure radiale

$$\Omega_2^i = \sum_{j \neq i, j=1}^{N} \exp\left(-\frac{\left(R_{ij} - R_s\right)^2}{\gamma}\right) \times G(R_{ij}, R_{cut}, \delta R)$$

La fonction 'de distribution angulaire locale' :

$$\Omega_2^i \propto \sum_{j \neq i, j=1}^{N} \sum_{k \neq (i,j), k=1}^{N} \left[(1 + \lambda \cos(\Theta_{ijk}))\right]^{\zeta} \times \exp\left(-\frac{R_{ij}^2 + R_{ik}^2 + R_{jk}^2}{\gamma}\right) \times G(R_{ij}) \times G(R_{ik}) \times G(R_{jk})$$

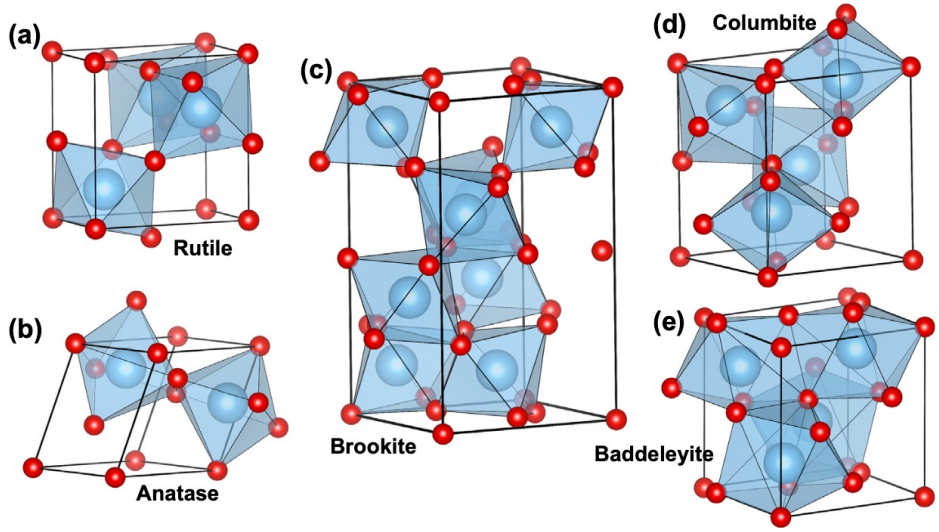
ISM10 : Entrainement d'un Champ de Force IA, Approche Itérative

Les champs de force IA n'ont de sens que si :

1 – il est difficile de proposer une fonction champ de force empirique suffisamment précise (où si l'on ignore quelle forme analytique elle doit avoir);

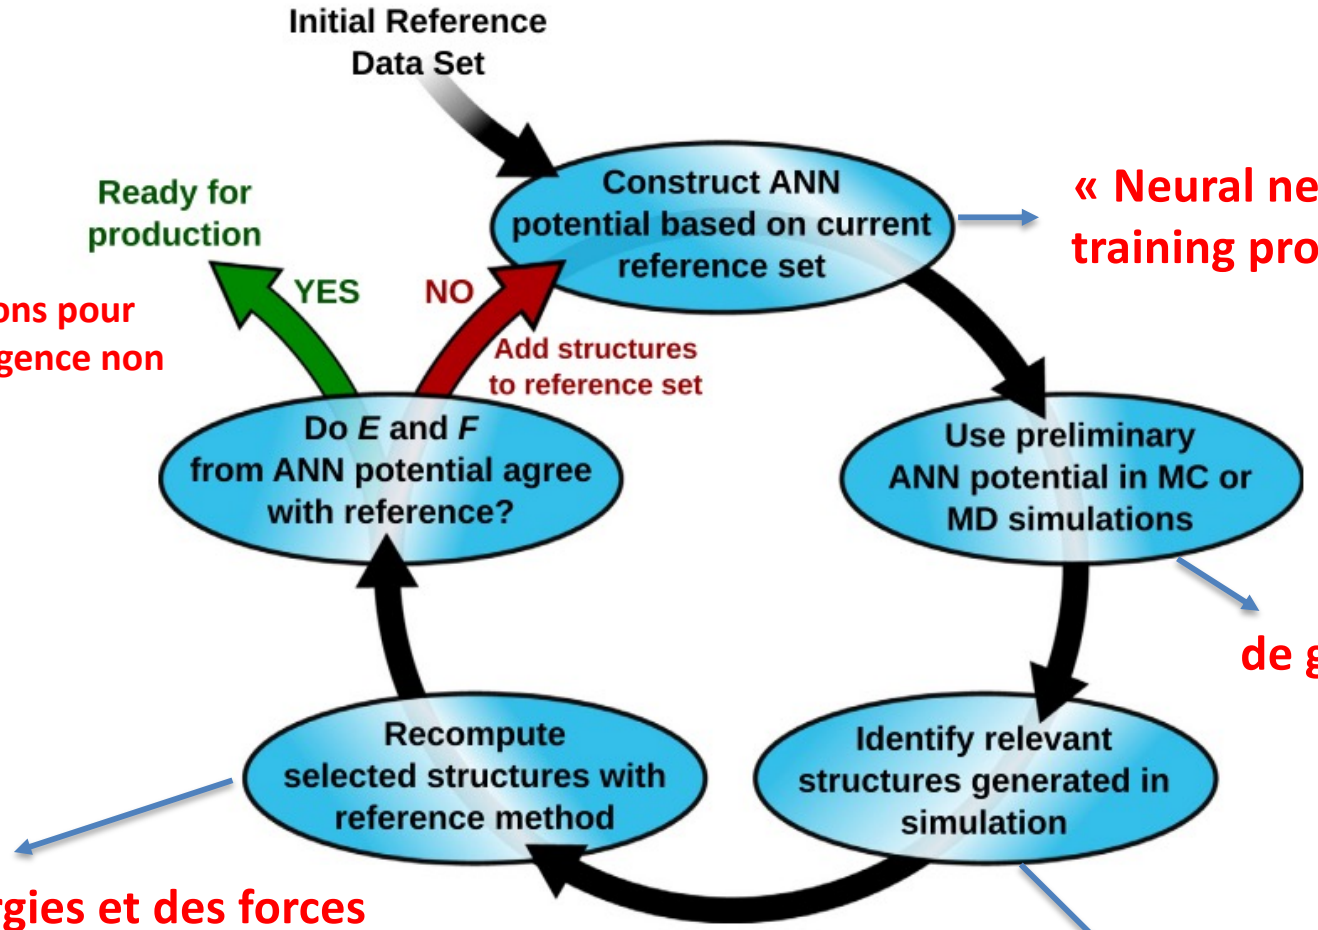
2 – si ils est possible de calculer de manière « efficace » des énergies potentielles et des forces atomiques par des méthodes de chimie quantique, en particulier de type DFT.

=> Ceci explique que ce type d'approche est surtout employée actuellement pour modéliser des systèmes 'métalliques' sur la base de données calculées par des approches de chimie quantique de type DFT.



Exemple d'application : matériaux à base d'oxyde de titane TiO2

ISM10 : Optimisation de Champ de Force IA et Par Approche Itérative



« Neural network training process »

Nombre d'itérations pour atteindre la convergence non précisé…

Simulations de grands systèmes

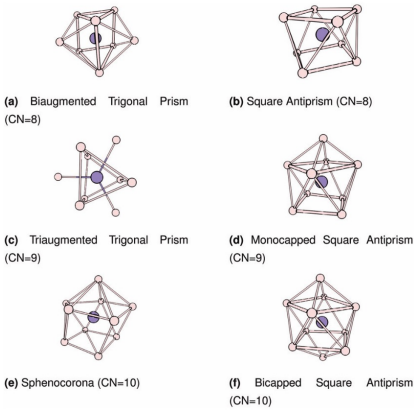
Calculs des énergies et des forces pour de nouvelles conformations avec peu d'atomes avec une Méthode de référence

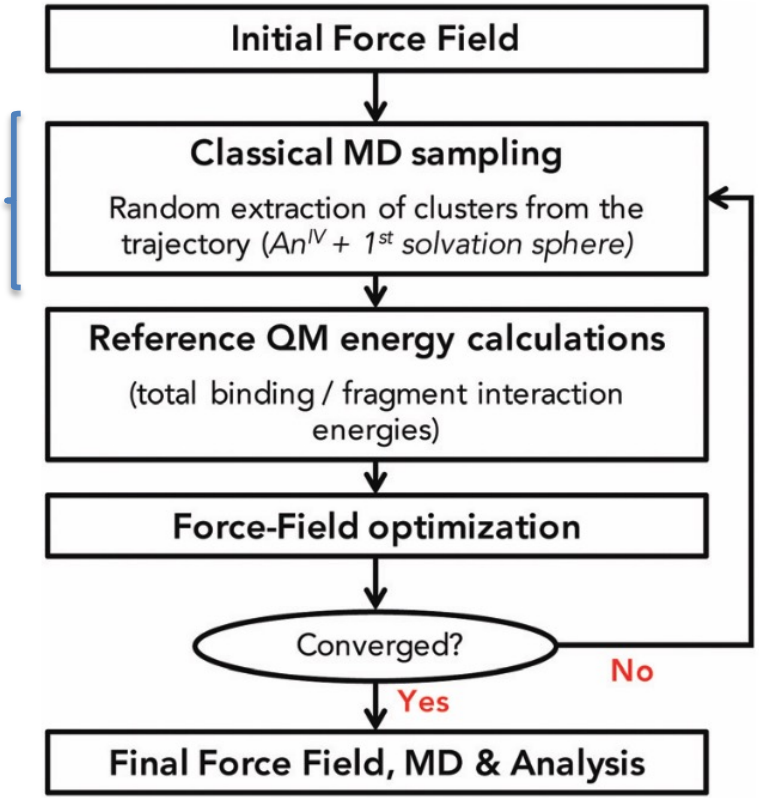
Clustering : Identification de conformations particulières avec peu d'atomes

ISM10 : Optimisation de Champ de Force et Approche Itérative

L'approche itérative de test systématique d'un champ de force par clustering de simulations microscopiques intermédiaires est indépendante de l'approche champ de force choisi (classique ou IA) , par exemple

Properties of the tetravalent actinide series in aqueous phase from a microscopic simulation self-consistent engine





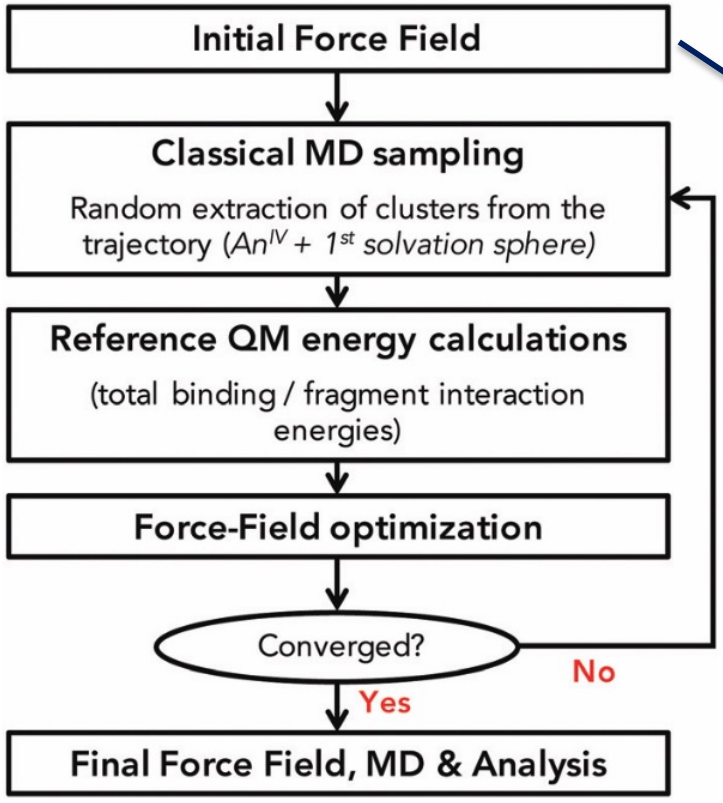
Simulations + Clustering

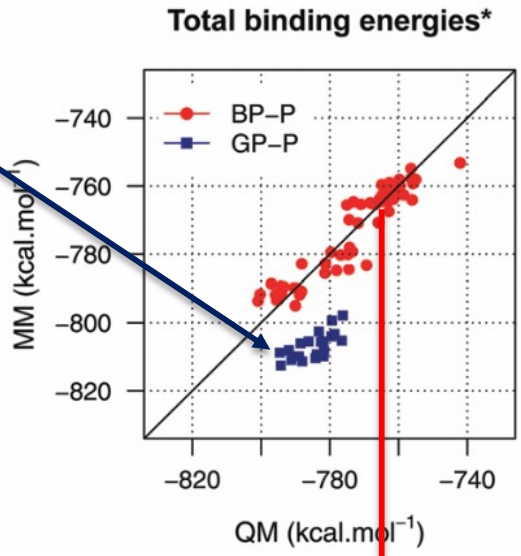
Optimisation par la méthode de moindre carrée classique

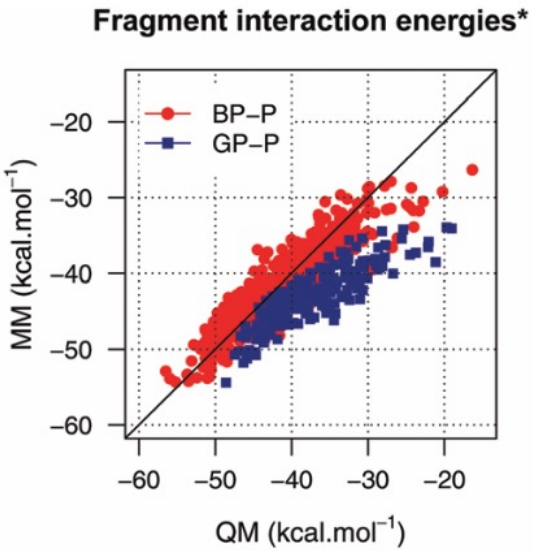
PCCP, 22 (2020) 2343

ISM10 : Optimisation de Champ de Force et Approche Itérative

Properties of the tetravalent actinide series in aqueous phase from a microscopic simulation self-consistent engine





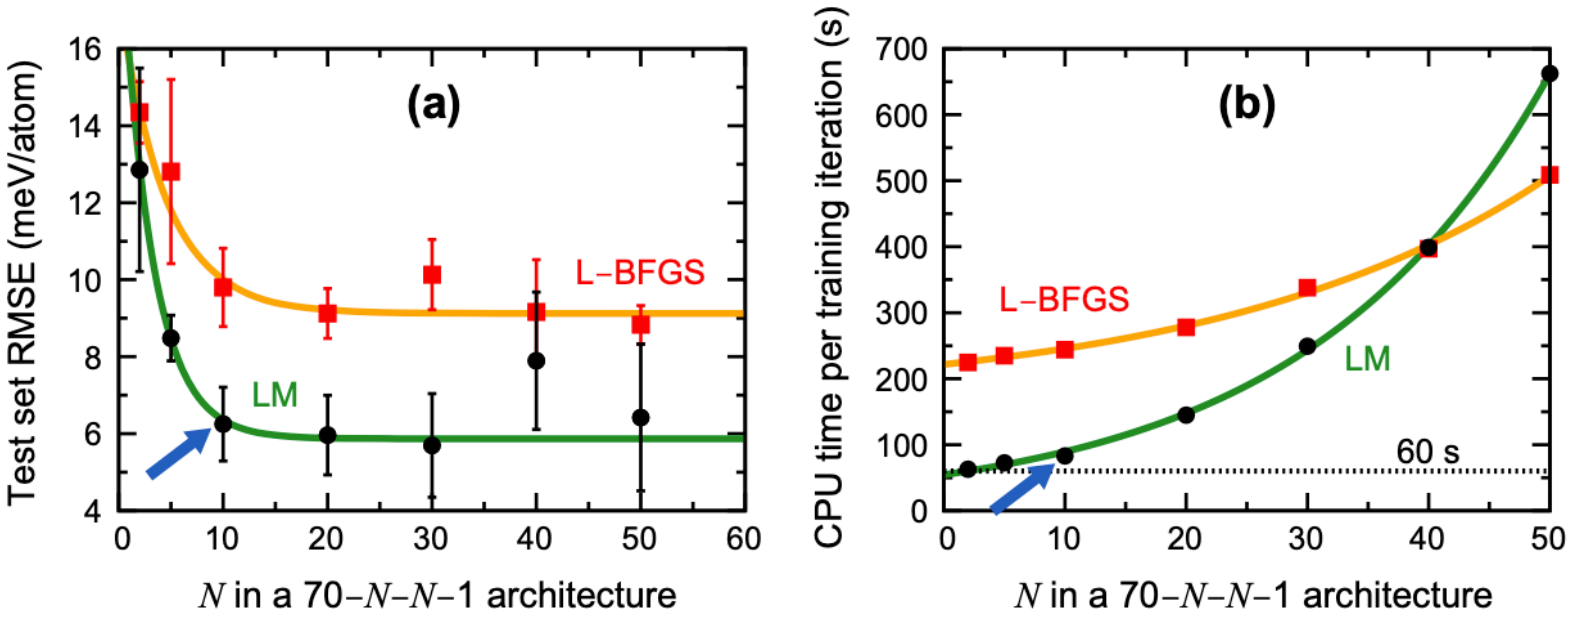


Paramètres du champ de force optimisé en 6 itérations

PCCP, 22 (2020) 2343

ISM10 : Entrainement d'un Champ de Force IA, Approche Itérative

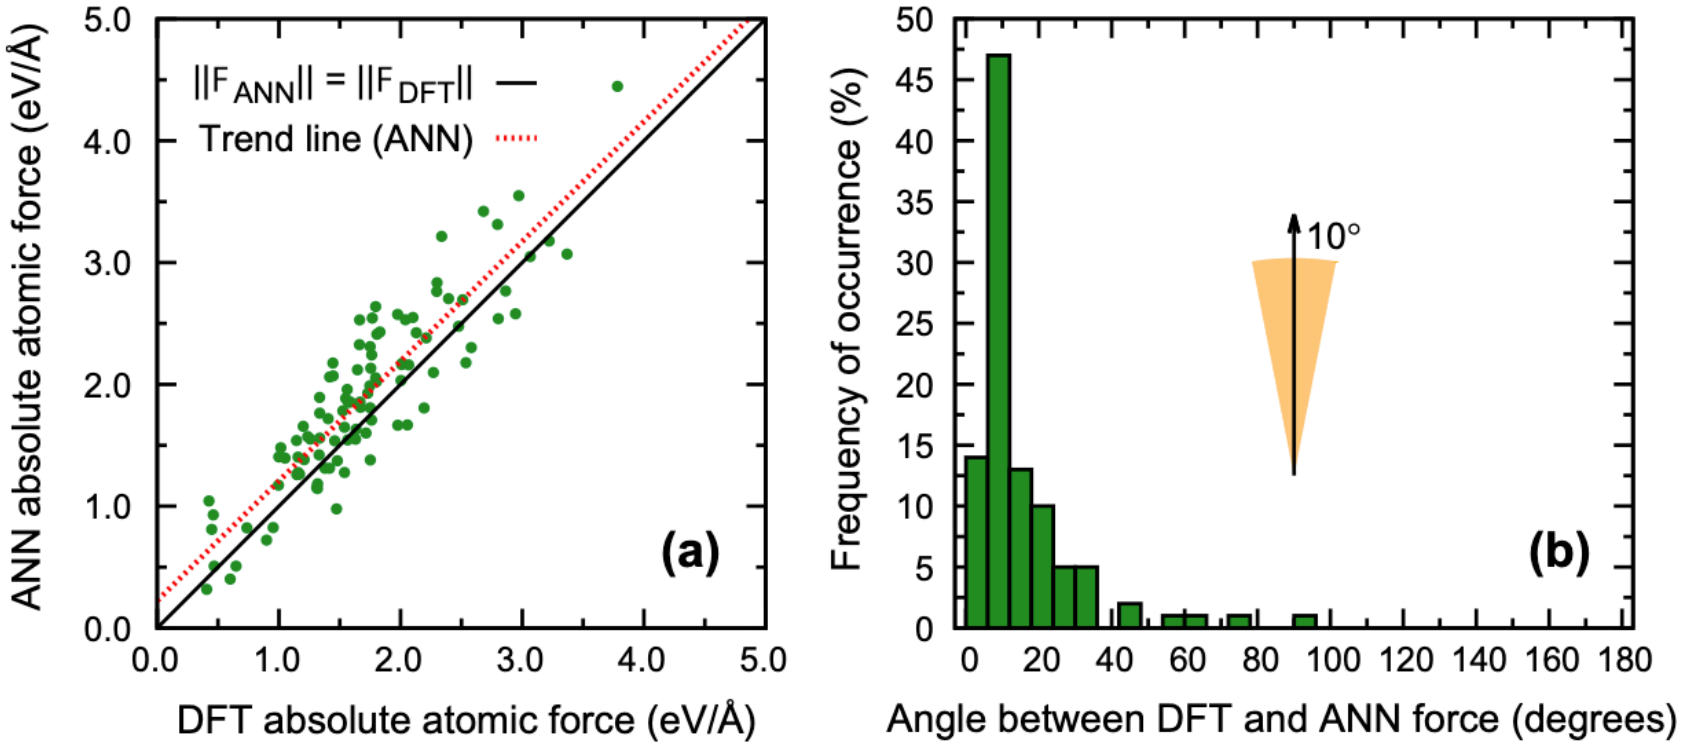
Simulation de matériaux TiO2, **70** paramètres (fonctions) d'environnement en entrée par atome, deux couches de neurone (***hidden layers***) comprenant chacune *N* nœuds (neurones), une seule donnée en sortie, i.e. l'énergie potentielle de la conformation de TiO2 (7 700 structures prises en compte, chacune comprenant de 6 à 95 atomes).



Convergence en fonction du nombre de nœuds et temps d'entrainement

ISM10 : Entrainement d'un Champ de Force IA, Approche Itérative

Erreur pour chacune des structures en entrée :



I.34 Est-il intéressant de développer un champ de force de type IA pour modéliser
Réponses : un système microscopique pour lequel il existe un potentiel empirique efficace et précis, un système microscopique pour lequel on a très peu d'information, un système microscopique composés de différentes entités chimiques, un système homogène ?

I.35 Les approches de type *machine learning* pour améliorer les paramètres d'un champ de force
Réponses : nécessitent peu de ressources informatiques, dépendent de la qualité des données dont on dispose, sont totalement automatisées et peuvent être employées à l'aide de bibliothèques optimisées, sont couramment employées aujourd'hui ?

I.36 Les méthodes de *clustering* des structures microscopiques obtenues le long d'une simulation de type dynamique moléculaire
Réponses : sont pertinentes pour développer un champ de force de type IA, n'ont pas à se préoccuper de l'indiscernabilité des atomes à l'échelle microscopique, permettent de réduire une trajectoire à un jeu pertinent de structures microscopiques ?